Baze podataka

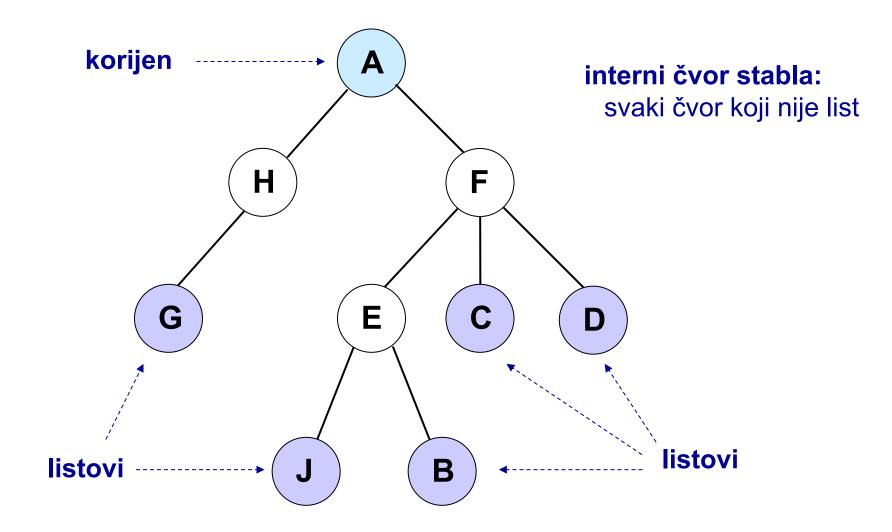
Dopunski materijali (za one koji žele znati više)

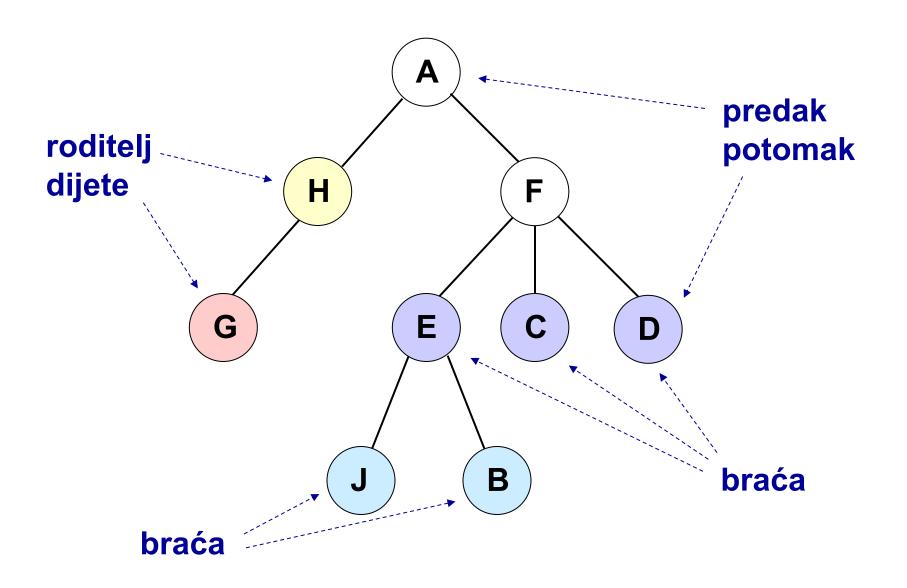
B - stabla

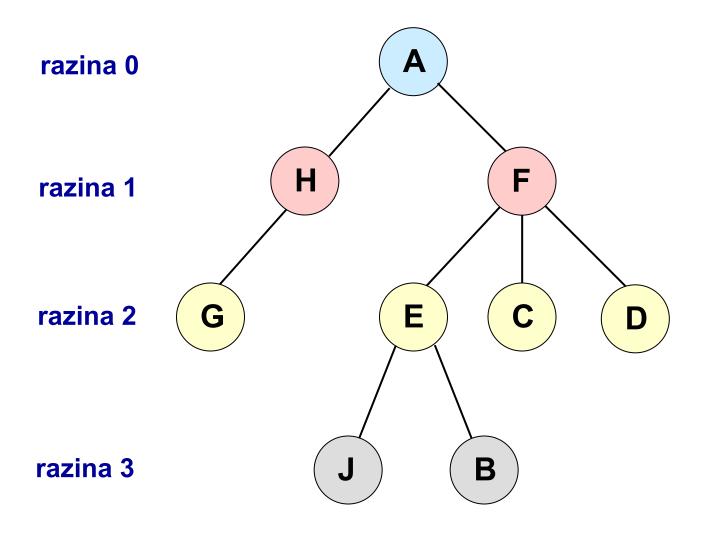
Travanj, 2021.



1. Stablo kao struktura podataka



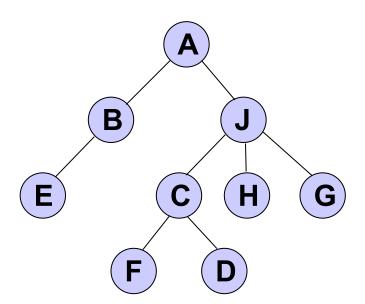




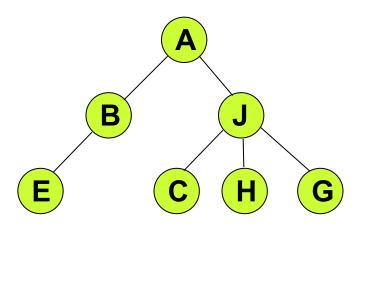
razina čvora (*level*): duljina puta od korijena do čvora dubina stabla (*depth*): najveća duljina puta od korijena do lista red stabla (*order*): najveći broj djece koje čvor može imati

Stablo je **balansirano** (*balanced*) ukoliko je duljina puta od korijena do lista jednaka za svaki list u stablu

stablo nije balansirano



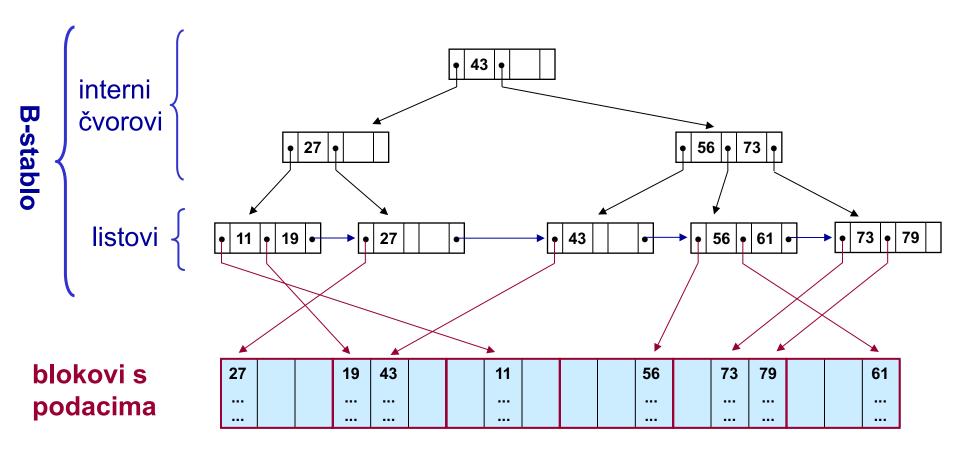
stablo je balansirano



Oznaka B u B-stablo znači "balansirano"!

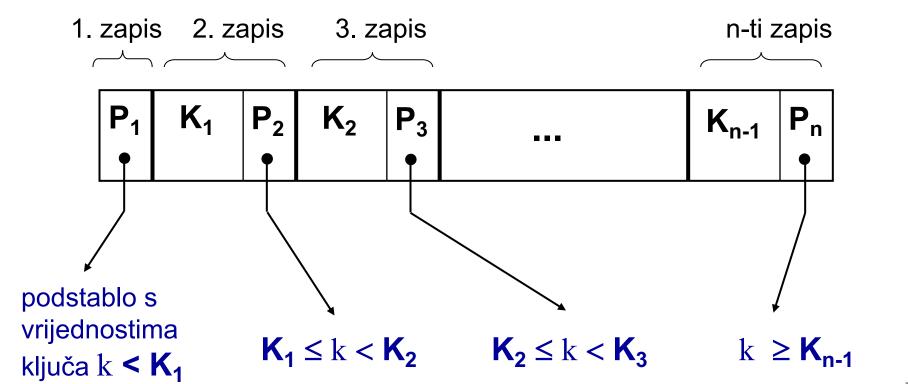
2. Struktura B-stabla

Opisujemo varijantu B-stabla koja se naziva **B⁺-stablo**. Opisi ostalih varijanti B-stabala (B*-stablo, B-stablo, ...) mogu se pronaći u literaturi.



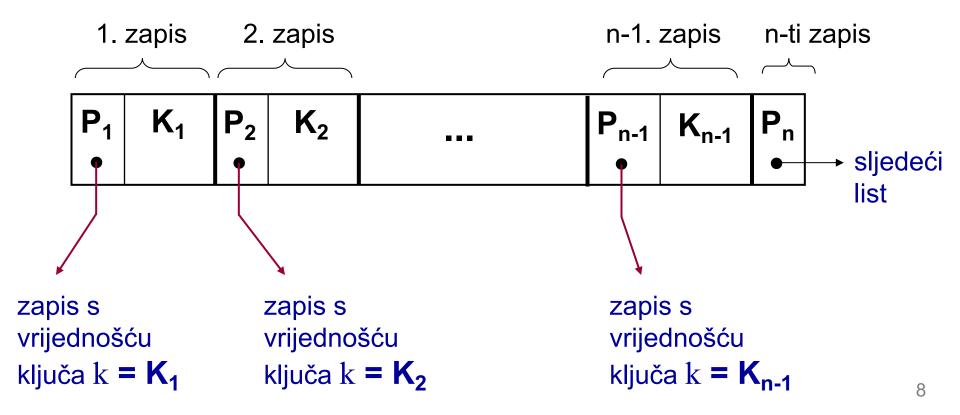
Struktura internog čvora

- U B+-stablu reda n, interni čvor sadrži
 - najviše n kazaljki
 - najmanje [n/2] kazaljki → [a] je najmanji cijeli broj ≥ a
 - ovo ograničenje ne vrijedi za korijen (2 .. n kazaljki)
- uz p kazaljki u čvoru, broj pripadnih vrijednosti K_i u čvoru je p-1

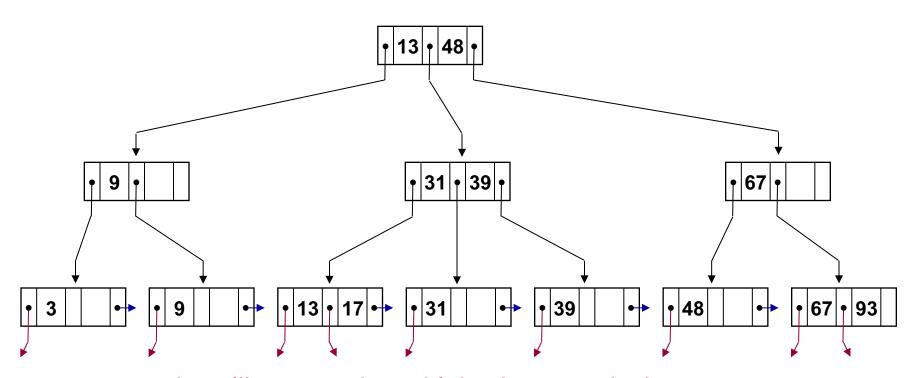


Struktura lista

- U B+-stablu reda n, list sadrži
 - najviše n-1 vrijednosti K_i i pripadnih kazaljki na zapise
 - najmanje [(n-1)/2] vrijednosti K_i i pripadnih kazaljki na zapise
 - svi listovi, osim krajnje desnog, sadrže kazaljku na sljedeći list
 omogućuju se upiti tipa od-do



Primjer B+-stabla reda 3



kazaljke na zapise u blokovima s podacima

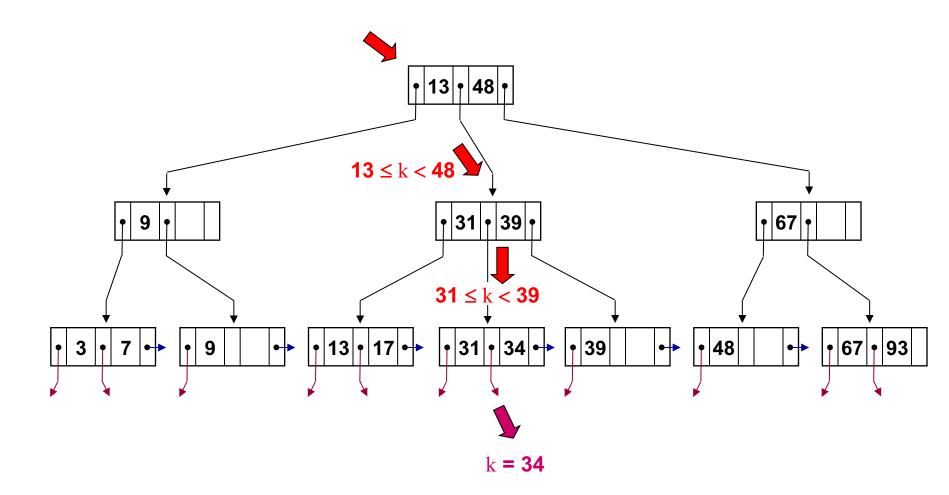
Odabire se red stabla čija primjena rezultira veličinom čvora koja odgovara veličini fizičkog bloka. Ovisno o veličini ključa, red stabla je uglavnom veličine 10 - 200.

3. Algoritmi za B-stablo

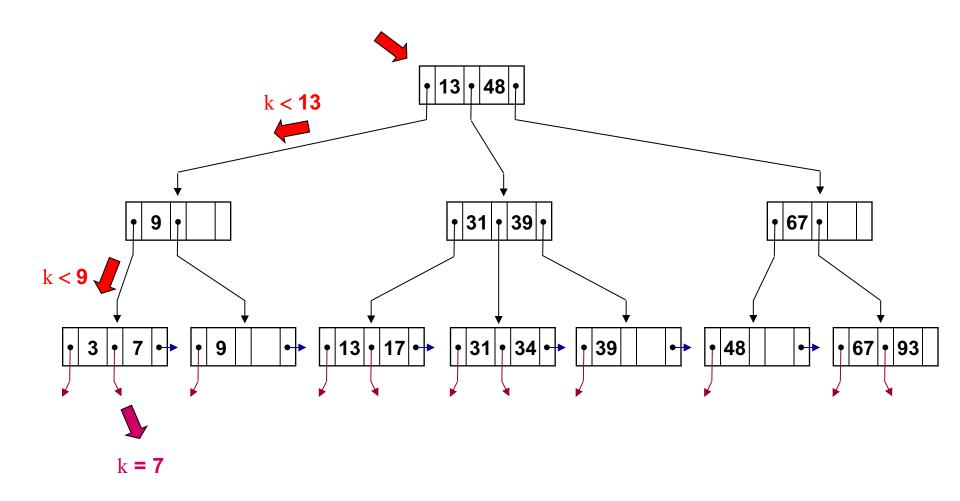
Algoritam za pretragu B*-stabla

- algoritam za traženje zapisa s ključem vrijednosti k je rekurzivan
 - cilj je u svakom koraku rekurzije (pretraga i-te razine) pronaći čvor na nižoj, (i+1)-voj razini, koji će voditi prema listu u kojem se nalazi ključ čija je vrijednost k
- traženje zapisa započinje od korijena (0-te razine)
- u čvoru i-te razine potrebno je pronaći najveću vrijednost ključa koja je manja ili jednaka traženoj vrijednosti k
 - za prvu kazaljku internog čvora nije navedena vrijednost ključa, pa ona "pokriva" sve vrijednosti ključeva manje od prve vrijednosti ključa (K₁) navedene u čvoru
- nakon pronalaženja odgovarajuće vrijednosti ključa, slijedi se pripadna kazaljka i time se obavlja pozicioniranje na (i+1)-vu razinu
- postupak se ponavlja rekurzivno sve dok se ne dođe do lista. U njemu se mora nalaziti, ukoliko postoji, ključ čija je vrijednost k, te pripadna kazaljka prema traženom zapisu u datoteci

traži se zapis s ključem 34

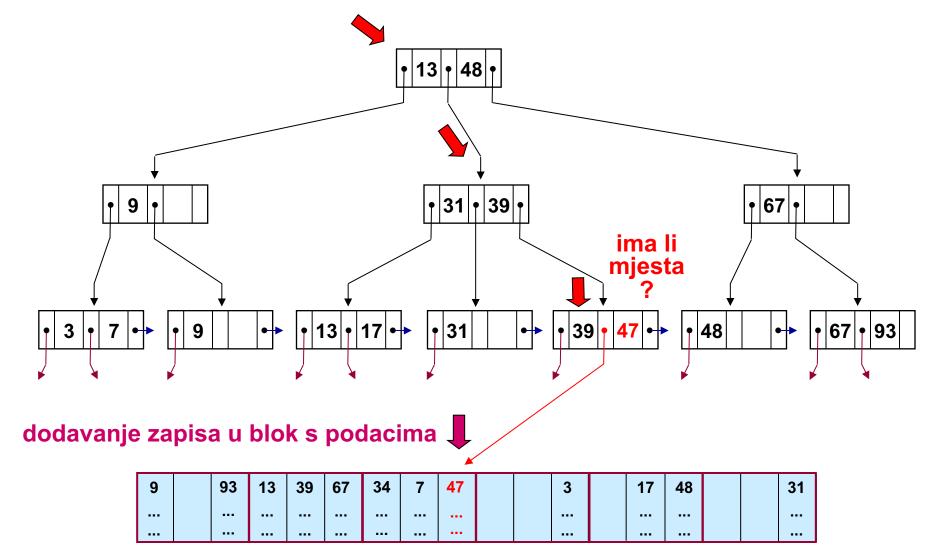


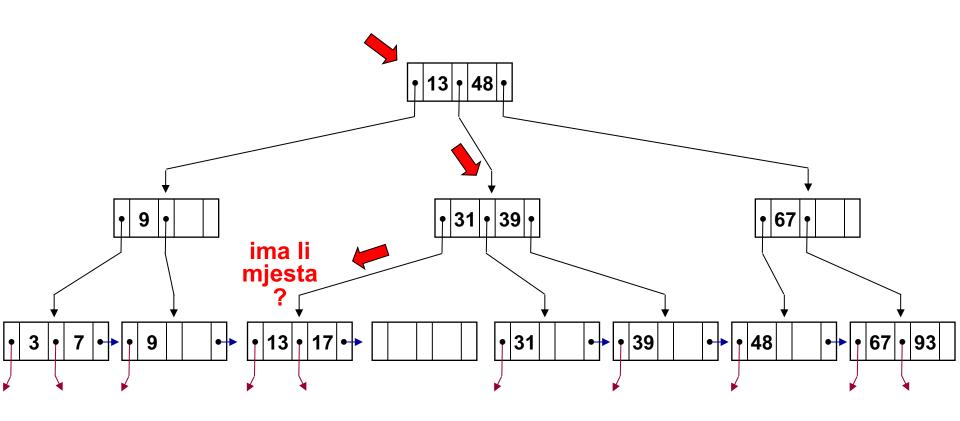
traži se zapis s ključem 7



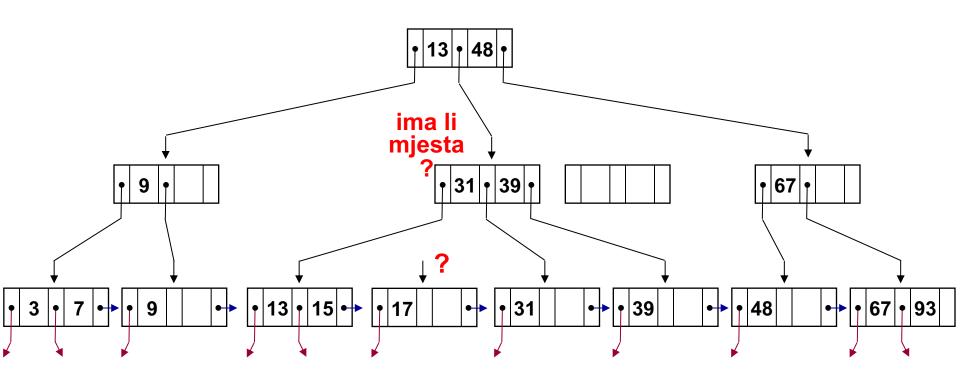
Algoritam za dodavanje zapisa u B+-stablo

- zapis (podaci) se upisuje u jedan od slobodnih blokova s podacima
- obavlja se algoritam za pronalaženje lista L u koji pripada vrijednost ključa k
- ako čvor L nije popunjen, u čvor se dodaje zapis s ključem k i kazaljkom na pripadni zapis u datoteci, uz očuvanje poretka vrijednosti ključeva
 - nova vrijednost nikad nije prva u čvoru, osim u slučaju krajnjeg lijevog čvora
- ako je čvor L popunjen
 - stvara se novi čvor i zapisi među njima se podijele, pri čemu svakom od čvorova pripadne polovica zapisa
 - budući da je dodan novi čvor, u nadređeni čvor potrebno je dodati zapis s kazaljkom i najmanjom vrijednošću ključa u novom čvoru
 - za dodavanje novog zapisa u nadređeni čvor koristi se ista procedura kao za dodavanje zapisa u čvor na nižoj razini
 - postupak je rekurzivan i mora se obaviti za svaku nadređenu razinu (sve dok se ne dođe do korijena ili se na nekoj od razina nađe dovoljno mjesta za upis vrijednosti ključa i kazaljke, bez dodavanja novih čvorova).
 - ako se dođe do korijena, može se desiti da u korijenu nema mjesta za novi zapis. Tada se dodaje novi čvor i formira se novi korijen na višoj razini

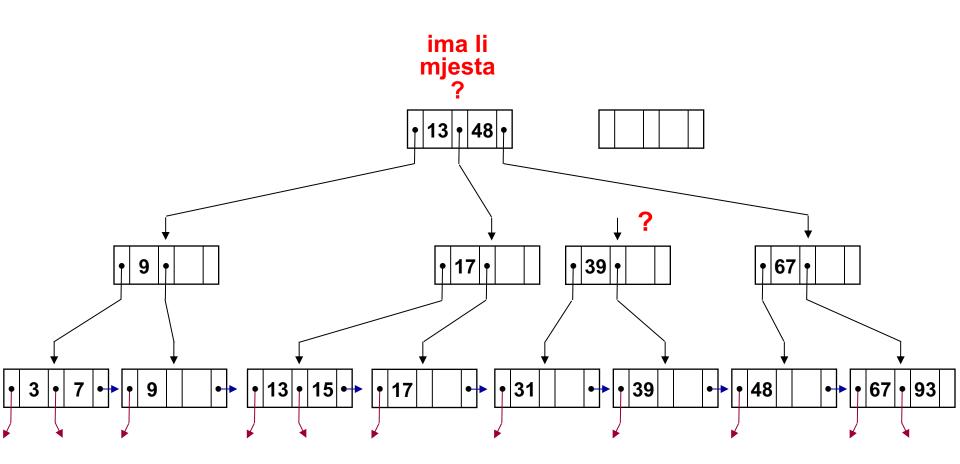




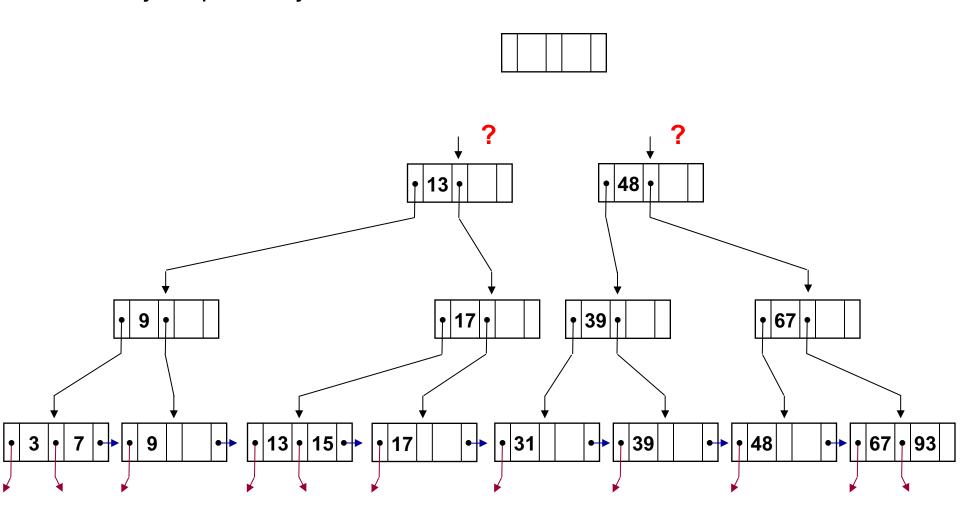
dodati novi čvor i podijeliti zapise 13, 15, 17 među čvorovima



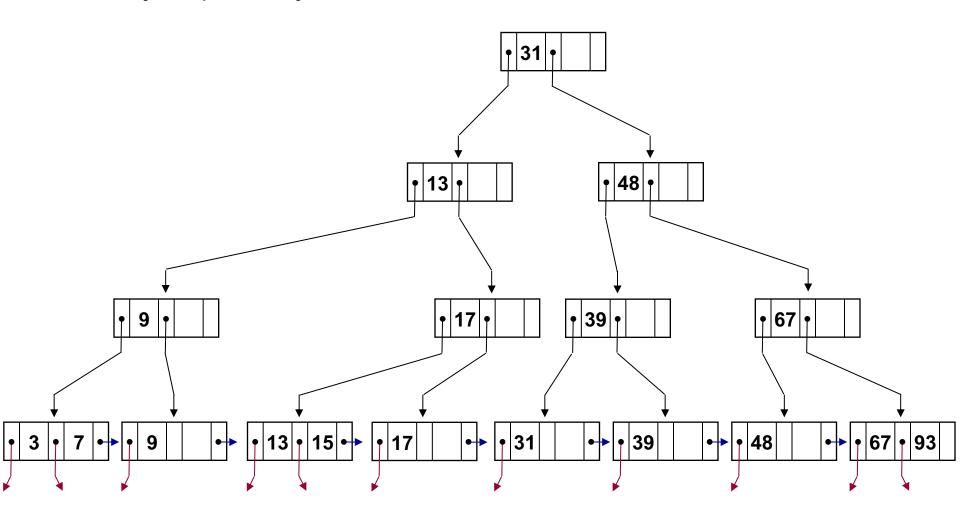
dodati novi čvor i podijeliti zapise 13, 17, 31, 39 među čvorovima



dodati novi čvor i podijeliti zapise 3, 13, 31, 48 među čvorovima



dodati novi korijen i upisati zapise 3, 31

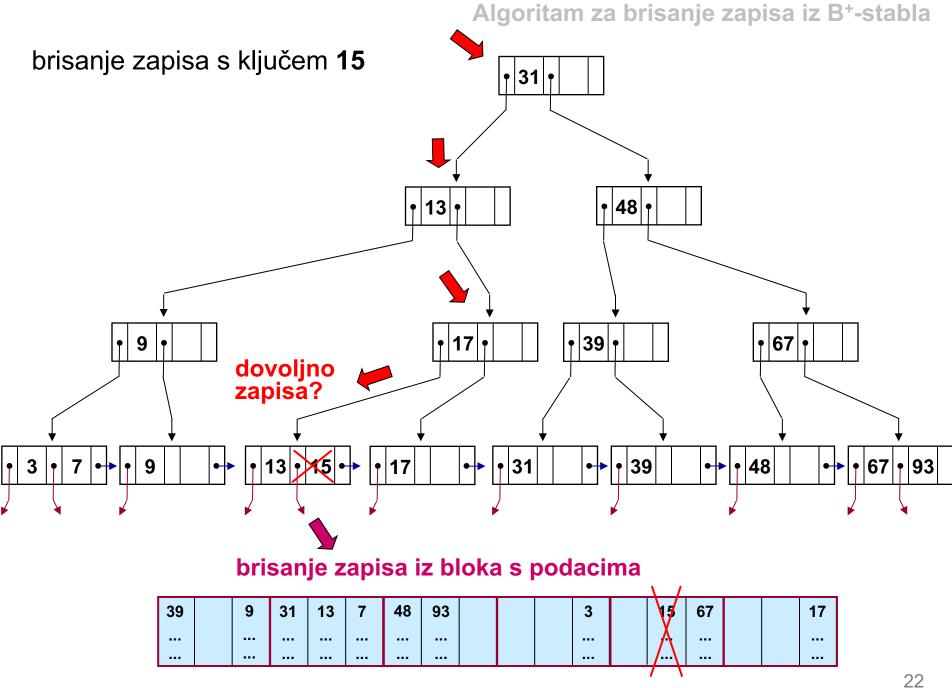


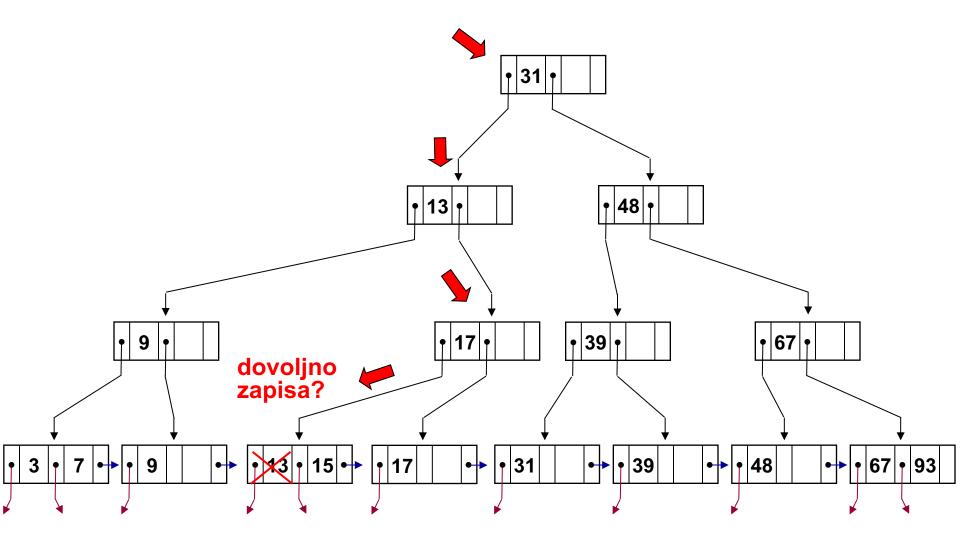
rezultat je balansirano stablo veće dubine

Algoritam za brisanje zapisa iz B+-stabla

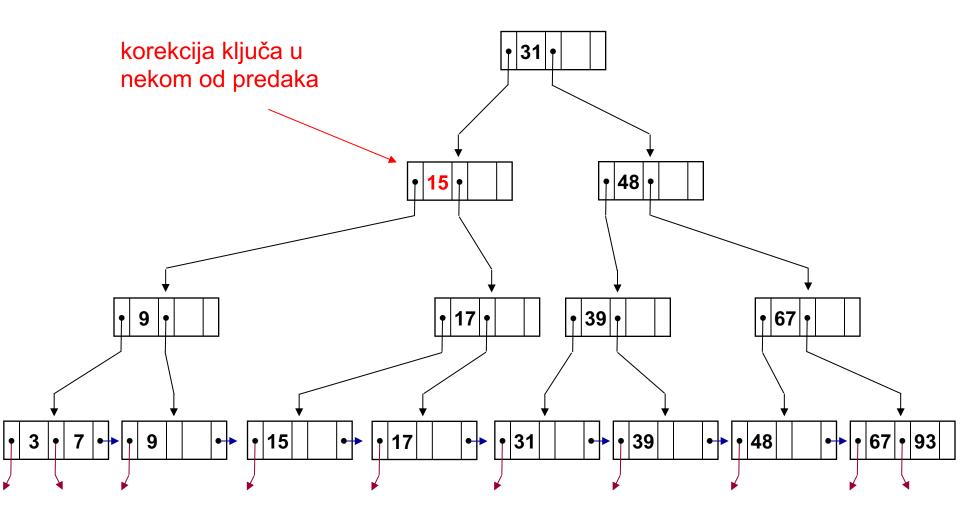
- obavlja se algoritam za pronalaženje lista L u kojem se nalazi ključ k
- zapis se briše iz bloka s podacima, a vrijednost ključa i kazaljka iz čvora L
- ako čvor L sadrži dovoljan broj zapisa
 - ukoliko je potrebno (onda kada se iz lista obriše prvi zapis, osim u krajnje lijevom listu), mijenja se vrijednost ključa u nekom od predaka
- ako čvor L nakon brisanja nema dovoljan broj zapisa, traži se čvor-brat L_X koji se nalazi neposredno s lijeva ili s desna čvoru L i ima više od dovoljnog broja zapisa. Ako se takav ne pronađe, traži se bilo koji čvor-brat L_X koji se nalazi neposredno s lijeva ili s desna čvoru L
 - ako odabrani brat L_X ima više od dovoljnog broja zapisa, tada se zapisi
 podijele između čvorova L i L_X, uz zadržavanje poretka zapisa. U
 pretcima čvorova L i L_X obavljaju se potrebne izmjene vrijednosti ključeva
 - inače (odabrani brat L_X ima upravo dovoljan broj zapisa), čvorovi L i L_X se spajaju u jedan čvor. U nadređenom čvoru briše se zapis za L i eventualno mijenja vrijednost ključa u nekom od predaka. Brisanje zapisa u nadređenom čvoru svodi se na rekurzivno izvođenje procedure za brisanje. Ako se putem prema korijenu dođe u situaciju da treba spojiti jedina dva čvora-djeteta korijena, tada se oni spajaju, postaju novi korijen stabla, a stari se korijen briše

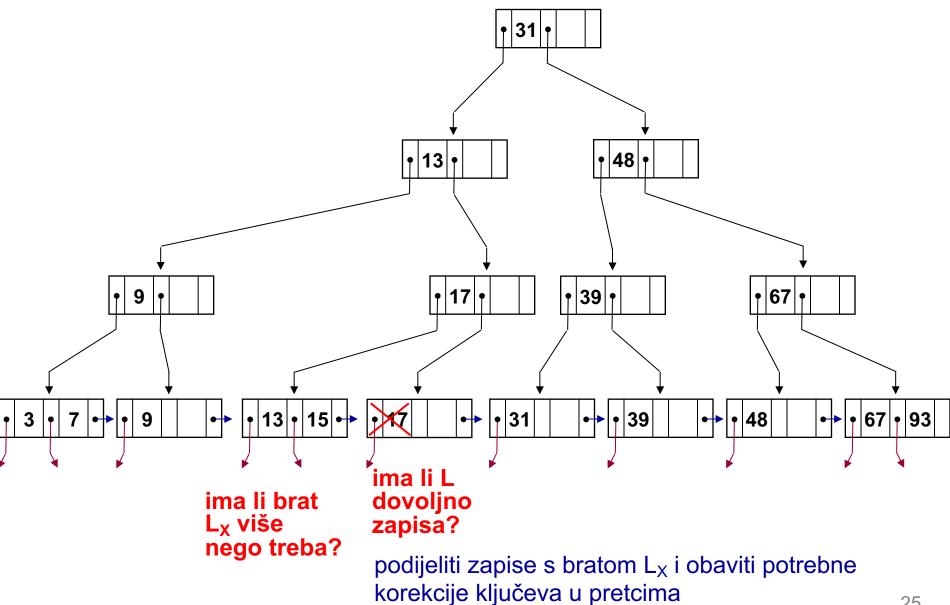
21

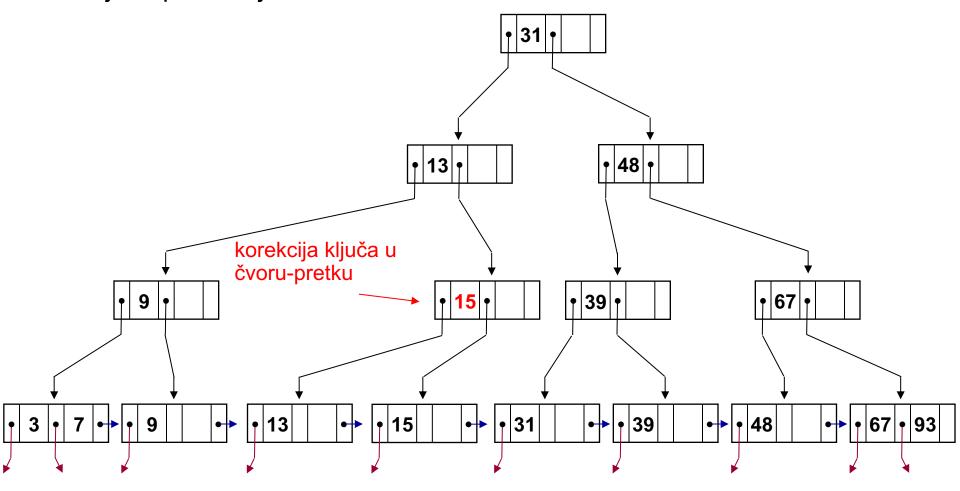


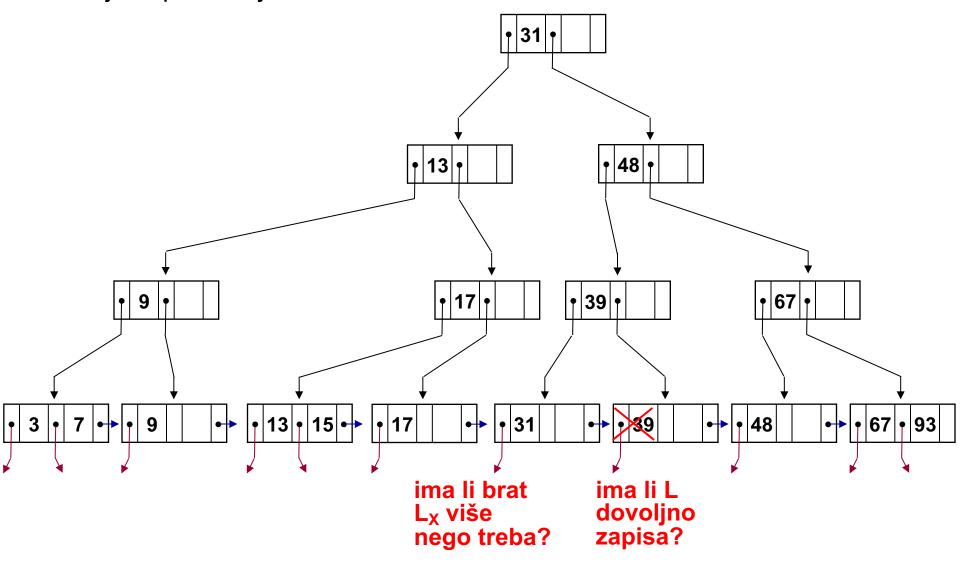


obaviti korekciju ključa u nekom od predaka jer je obrisan prvi zapis lista

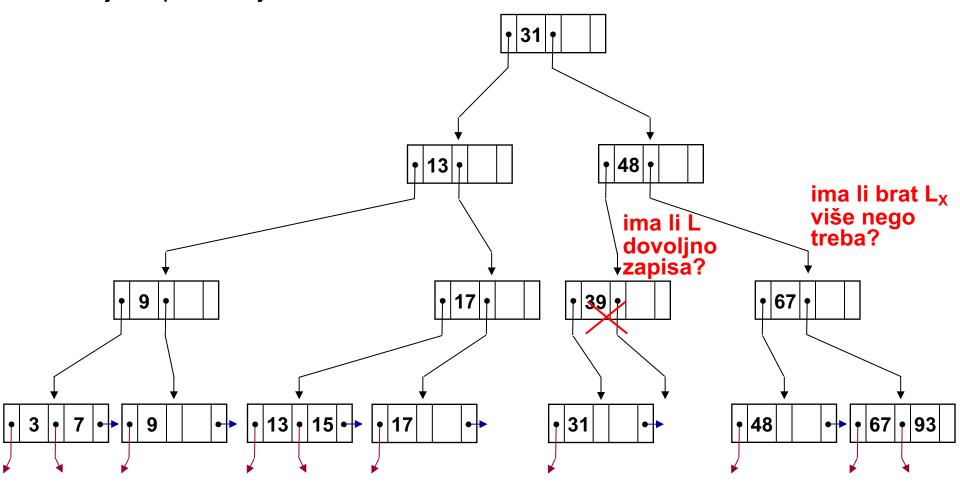




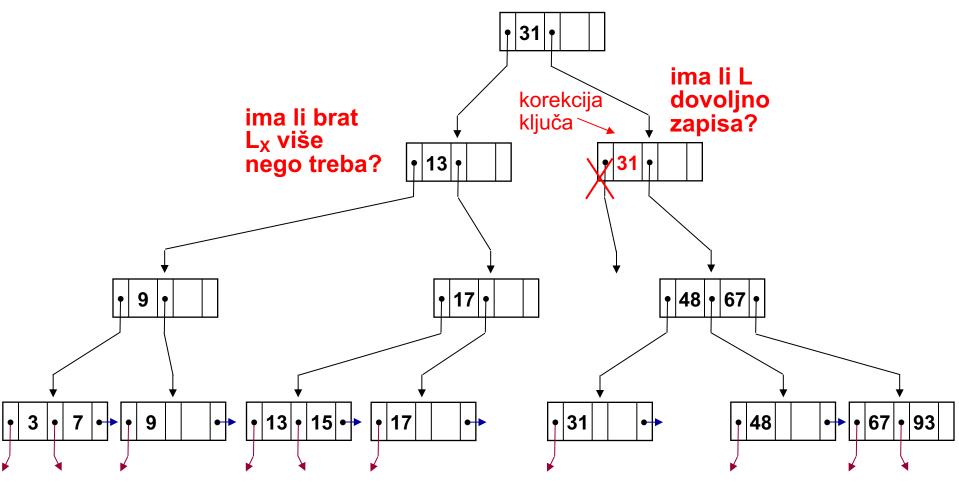




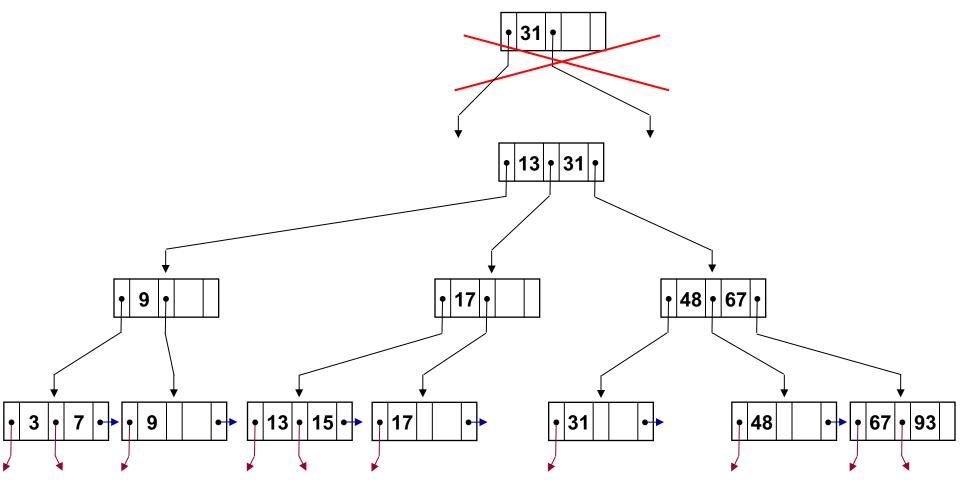
spojiti L i L_X . Obrisati kazaljku na L iz nadređenog čvora i (eventualno) promijeniti vrijednost ključa u nekom od predaka.



spojiti L i L_X . Obrisati kazaljku na L iz nadređenog čvora i (eventualno) promijeniti vrijednost ključa u nekom od predaka.



spojiti L i L_X . Spajanjem L i L_X nastaje novi korijen. Obrisati stari korijen.



rezultat je balansirano stablo manje dubine

4. Učinkovitost operacije pretrage u B-stablu

- broj I/O operacija u stablu pri traženju zapisa ovisi o broju razina u stablu
- pretpostavka: stablo reda n sadrži kazaljke na m zapisa podataka
- stablo će imati najveći broj razina ako su čvorovi najmanje popunjeni
 - najmanja popunjenost korijena je 2
 - najmanja popunjenost internog čvora: [n / 2]
 - najmanja popunjenost lista: 「(n 1) / 2 ≈ [n / 2], za dovoljno veliki n
- u korijenu (1. razina) ima 1 čvor i najmanje 2 kazaljke
- na 2. razini ima najmanje 2 čvora i zato najmanje 2 · [n / 2] kazaljki
- u čvorovima 3. razine ima najmanje 2 [n / 2] [n / 2] kazaljki
- u čvorovima i-te razine ima najmanje **2** \[\bar{n} / **2** \] i-1 kazaljki
- za broj zapisa u podatkovnim blokovima stabla koje ima d razina vrijedi:
 - $m \ge 2 \cdot \lceil n / 2 \rceil^{d-1}$
- iz toga slijedi
 - $d \leq log_{\lceil n/2 \rceil}(m/2) + 1$

$$d \leq \log_{\lceil n/2 \rceil} (m/2) + 1$$

Primjer: za m = 1 000 000, n = 70, ukupni broj razina (uključujući i razinu korijena) u najgorem slučaju je 4.

- 1. točno 1 čvor, najmanje 2 kazaljke
- 2. majmanje 2 čvora, najmanje 70 kazaljki
- 3.

 najmanje 70 čvorova, najmanje 2 450 kazaljki
- 4. 🔲 🗀 🗀 ... 🖂 🖂 🗀 najmanje 2 450 čvorova, najmanje 85 750 kazaljki
- 5.

 najmanje 85 750 čvorova, najmanje 3 001 250 kazaljki

B⁺-stablo koje bi imalo ukupno 5 razina, moralo bi imati **najmanje** 3 001 250 kazaljki na zapise.