

# VJEROJATNOST I STATISTIKA

## Dodatni zadaci za 11. tjedan (22. predavanje)

### 10 Matematička statistika

**Zadatak 1.** Iz intervala  $[\alpha, 1]$ , gdje je  $\alpha$  nepoznat odabrano je na sreću  $n$  brojeva:  $x_1, x_2, \dots, x_n$ . Da bismo procijenili  $1 - \alpha$  duljinu tog intervala odaberimo statistiku

$$Z = 1 - \min(X_1, X_2, \dots, X_n).$$

- (a) Dokažite da statistika  $Z$  nije nepristrana.
- (b) S kojim faktorom treba pomnožiti  $Z$  kako bismo dobili nepristranu statistiku?

**Rješenje.** Označimo

$$Z_m = \min(X_1, X_2, \dots, X_n).$$

Trebamo izračunati očekivanje slučajne varijable

$$Z = 1 - Z_m.$$

U tu svrhu izračunajmo funkciju razdiobe slučajne varijable  $Z_m$ , pomoću koje ćemo dobiti funkciju gustoće a zatim i traženo očekivanje.

$$\begin{aligned} F_{Z_m}(z) &= \mathbf{P}(Z_m < z) = \mathbf{P}(\min(X_1, X_2, \dots, X_n) < z) = 1 - \mathbf{P}(\min(X_1, X_2, \dots, X_n) \geq z) \\ &= 1 - \mathbf{P}(X_1 \geq z, \dots, X_n \geq z). \end{aligned}$$

Budući da brojeve biramo na sreću neovisno jedan o drugome, radi se o nezavisnim slučajnim varijablama te vrijedi

$$F_{Z_m}(z) = 1 - \mathbf{P}(X_1 \geq z) \mathbf{P}(X_2 \geq z) \cdots \mathbf{P}(X_n \geq z) = 1 - \left(1 - \frac{z - \alpha}{1 - \alpha}\right)^n = 1 - \left(\frac{1 - z}{1 - \alpha}\right)^n, \quad z \in [\alpha, 1].$$

Deriviranjem dobivamo funkciju gustoće slučajne varijable  $Z_m$

$$f_{Z_m}(z) = \frac{n(1 - z)^{n-1}}{(1 - \alpha)^n}, \quad z \in [\alpha, 1],$$

a nakon toga i njezino očekivanje

$$\mathbf{E}(Z_m) = \int_{\alpha}^1 z \cdot \frac{n(1 - z)^{n-1}}{(1 - \alpha)^n} dz = 1 - \frac{n}{n+1} (1 - \alpha).$$

Sada lako možemo izračunati očekivanje slučajne varijable  $Z$

$$\mathbf{E}(Z) = 1 - \mathbf{E}(Z_m) = \frac{n}{n+1} (1 - \alpha).$$

Da bi statistika bila nepristrana mora vrijediti  $\mathbf{E}(Z) = 1 - \alpha$ . Stoga zaključujemo kako statistika  $Z$  nije nepristrana, ali također vidimo da vrlo lako možemo učiniti da ona postane nepristrana pomnožimo li je s  $\frac{n+1}{n}$ . Tada vrijedi

$$Z' = \frac{n+1}{n} Z \implies \mathbf{E}(Z') = \frac{n+1}{n} \mathbf{E}(Z) = 1 - \alpha.$$

**Zadatak 2.** Iz intervala  $[\alpha, 1]$ , gdje je  $\alpha < 1$  nepoznat odabrano je na sreću  $n$  brojeva:  $x_1, x_2, \dots, x_n$ . Da bismo procijenili  $\alpha$  odaberimo statistiku

$$Z = \min(X_1, X_2, \dots, X_n) - \frac{1}{n+1}.$$

- (a) Dokažite da statistika  $Z$  nije nepristrana.  
 (b) S kojim faktorom treba pomnožiti  $Z$  kako bismo dobili nepristranu statistiku?

**Rješenje.** Postupamo na identičan način kao u prethodnom zadatku. Označimo

$$Z_m = \min(X_1, X_2, \dots, X_n).$$

Sada trebamo izračunati očekivanje slučajne varijable

$$Z = Z_m - \frac{1}{n+1}.$$

Funkcija razdiobe slučajne varijable  $Z_m$ , njezina funkcija gustoće i očekivanje isti su kao u prethodnom zadatku.

$$\begin{aligned} F_{Z_m}(z) &= 1 - \left( \frac{1-z}{1-\alpha} \right)^n, \quad z \in [\alpha, 1], \\ f_{Z_m}(z) &= \frac{n(1-z)^{n-1}}{(1-\alpha)^n}, \quad z \in [\alpha, 1], \\ \mathbf{E}(Z_m) &= 1 - \frac{n}{n+1}(1-\alpha) = \frac{1}{n+1} + \frac{n}{n+1}\alpha. \end{aligned}$$

Sada lako možemo izračunati očekivanje statistike  $Z$

$$\mathbf{E}(Z) = \mathbf{E}(Z_m) - \frac{1}{n+1} = \frac{n}{n+1}\alpha.$$

Kao u prethodnom zadatku vidimo kako statistika nije nepristrana. Kako bismo je učinili nepristranom trebamo je pomnožiti s  $\frac{n+1}{n}$  jer će tada vrijediti

$$\mathbf{E}(Z') = \mathbf{E}\left(\frac{n+1}{n} \cdot Z\right) = \frac{n+1}{n}\mathbf{E}(Z) = \alpha.$$

**Zadatak 3.** Uzorak  $x_1, x_2, \dots, x_n$  izvučen je iz populacije koja ima gustoću razdiobe

$$f(x) = \lambda x^{\lambda-1}, \quad x \in (0, 1).$$

Koristeći kriterij najveće izglednosti, odredite procjenu za parametar  $\lambda$ .

**Rješenje.** Ovdje se radi o procjeni parametra pomoću kriterija najveće izglednosti pri čemu je nepoznati parametar  $\lambda$ . Funkcija izglednosti je definirana s

$$L(\lambda, x_1, x_2, \dots, x_n) = f(\lambda, x_1) \cdot f(\lambda, x_2) \cdots f(\lambda, x_n) = \prod_{i=1}^n \lambda x_i^{\lambda-1} = \lambda^n \left( \prod_{i=1}^n x_i \right)^{\lambda-1}.$$

Trebamo pronaći vrijednost parametra  $\lambda$  za koji ta funkcija poprima globalni maksimum. Označimo

$$k = \prod_{i=1}^n x_i.$$

Tada je

$$L(\lambda, x_1, x_2, \dots, x_n) = \lambda^n k^{\lambda-1}.$$

U svrhu pronalaska maksimuma deriviramo funkciju izglednosti. Međutim, često se više isplati derivirati funkciju:

$$l = \ln L.$$

To možemo uraditi zato što je funkcija izglednosti uvijek pozitivna pa je funkcija  $l$  dobro definirana. Također je važno primijetiti da funkcija  $l$  poprima maksimum u istim točkama kao i  $L$ . Sada računamo

$$l(\lambda, x_1, x_2, \dots, x_n) = \ln L(\lambda, x_1, x_2, \dots, x_n) = \ln(\lambda^n k^{\lambda-1}) = n \ln \lambda + (\lambda - 1) \ln k,$$

$$\frac{\partial}{\partial \lambda} \ln L = \frac{n}{\lambda} + \ln k.$$

Kako bismo pronašli maksimum tražimo stacionarne točke, tj. izjednačavamo prvu derivaciju s 0:

$$\frac{n}{\lambda} + \ln k = 0 \implies \hat{\lambda} = \frac{-n}{\ln k} = \frac{-n}{\ln(\prod_{i=1}^n x_i)} = \frac{-n}{\sum_{i=1}^n \ln x_i}.$$

Formalno bismo trebali još jednom derivirati  $\frac{\partial}{\partial \lambda} \ln L$  kako bismo odredili predznak i vidjeli da je zaista riječ o maksimumu. To u ovom primjeru možemo lako napraviti

$$\frac{\partial^2}{\partial \lambda^2} \ln L = -\frac{n}{\lambda^2}.$$

Vidimo da je dobivena druga derivacija uvijek negativna, a posebno i za  $\hat{\lambda}$ , te da se zaista radi o maksimumu.

**Zadatak 4.** Uzorak  $x_1, x_2, \dots, x_n$  izvučen je iz populacije koja ima Poissonovu razdiobu. Koristeći kriterij najveće izglednosti, odredite procjenu parametra  $\lambda$  te provjerite je li dobivena procjena nepristrana.

**Rješenje.** Za slučajnu varijablu  $X$  sa Poissonovom razdiobom vrijedi

$$f(\lambda, x) = \mathbf{P}(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}, \quad x = 0, 1, 2, \dots$$

Funkcija izglednosti definana je s

$$\begin{aligned} L(\lambda, x_1, x_2, \dots, x_n) &= f(\lambda, x_1) \cdot f(\lambda, x_2) \cdots f(\lambda, x_n) \\ &= \mathbf{P}(X = x_1) \mathbf{P}(X = x_2) \cdots \mathbf{P}(X = x_n) \\ &= \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i!)} e^{-n\lambda}. \end{aligned}$$

Sada imamo

$$\begin{aligned} \ln L &= \ln \left( \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i!)} e^{-n\lambda} \right) = -n\lambda + \sum_{i=1}^n x_i \ln \lambda - \sum_{i=1}^n \ln(x_i!), \\ \frac{\partial \ln L}{\partial \lambda} &= -n + \frac{\sum_{i=1}^n x_i}{\lambda} = 0 \implies \hat{\lambda} = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}. \end{aligned}$$

Vidimo da je dobivena procjena nepristrana.

**Zadatak 5.** Neka je  $X$  diskretna slučajna varijabla zadana sljedećom razdiobom koja ovisi o parametru  $\vartheta$ :

$$X \sim \begin{pmatrix} 0 & 1 & 2 & 3 \\ \frac{2\vartheta}{3} & \frac{\vartheta}{3} & \frac{2(1-\vartheta)}{3} & \frac{1-\vartheta}{3} \end{pmatrix}.$$

Uzet je uzorak od 10 nezavisnih mjerenja slučajne varijable  $X$  i dobivene su vrijednosti 3, 0, 2, 1, 3, 2, 1, 0, 2, 1. Koristeći kriterij najveće izglednosti, odredite procjenu za parametar  $\vartheta$  na temelju dobivenog uzorka.

**Rješenje.** Ovaj zadatak rješavamo na isti način kao i prethodne zadatke, samo sada radimo s konkretnim brojevima  $x_i$ . Računamo:

$$\begin{aligned} L(\lambda, x_1, x_2, \dots, x_{10}) &= \mathbf{P}(X = x_1) \mathbf{P}(X = x_2) \cdots \mathbf{P}(X = x_{10}) \\ &= \left(\frac{2\vartheta}{3}\right)^2 \left(\frac{\vartheta}{3}\right)^3 \left(\frac{2(1-\vartheta)}{3}\right)^3 \left(\frac{1-\vartheta}{3}\right)^2 \\ &= \frac{2^5}{3^{10}} \vartheta^5 (1-\vartheta)^5, \\ \ln L &= \ln \left(\frac{2^5}{3^{10}}\right) + 5 \ln \vartheta + 5 \ln (1-\vartheta), \\ \frac{\partial \ln L}{\partial \lambda} &= \frac{5}{\vartheta} - \frac{5}{1-\vartheta} = 0 \implies \hat{\vartheta} = \frac{1}{2}. \end{aligned}$$

**Zadatak 6.** Iz intervala  $[a, b]$ , gdje su rubovi  $a$  i  $b$  nepoznati, odabrano je na sreću  $n$  brojeva:  $x_1, x_2, \dots, x_n$ . Kako bismo procijenili sredinu tog intervala, odabiremo statistiku

$$\Theta = \frac{X_m + X_M}{2},$$

gdje je  $X_m = \min\{X_1, X_2, \dots, X_n\}$  i  $X_M = \max\{X_1, X_2, \dots, X_n\}$ .

- (a) Dokažite da je statistika  $\Theta$  nepristrana procjena sredine intervala  $[a, b]$ .
- (b) Dokažite da je ta procjena valjana.
- (c) Dokažite da se pomoću kriterija najveće izglednosti dobiva ista procjena za sredinu intervala.

**Rješenje.** (a) Nezavisne slučajne varijable  $X_1, \dots, X_n$  imaju uniformnu razdiobu s funkcijom razdiobe, odnosno gustoće

$$F(x) = \frac{x-a}{b-a}, \quad x \in [a, b], \quad f(x) = \frac{1}{b-a}, \quad x \in [a, b].$$

Na isti način kao u prvom zadatku određujemo funkciju razdiobe slučajne varijable  $X_m = \min\{X_1, X_2, \dots, X_n\}$ :

$$F_{X_m}(x) = 1 - (1 - F(x))^n, \quad x \in [a, b],$$

a zatim i funkciju gustoće

$$f_{X_m}(x) = \frac{d}{dx} F_{X_m}(x) = n(1 - F(x))^{n-1} f(x) = \frac{n(b-x)^{n-1}}{(b-a)^n}, \quad x \in [a, b].$$

Očekivanje slučajne varijable  $X_m$  je

$$\mathbf{E}(X_m) = \int_{-\infty}^{\infty} x f_{X_m}(x) dx = a + \frac{b-a}{n+1}.$$

Slično radimo i za maksimum  $X_M = \max\{X_1, \dots, X_n\}$ :

$$\begin{aligned} F_{X_M}(x) &= \mathbf{P}(X_M < x) = \mathbf{P}(\max\{X_1, \dots, X_n\} < x) = \mathbf{P}(X_1 < x, \dots, X_n < x) \\ &= \mathbf{P}(X_1 < x) \cdots \mathbf{P}(X_n < x) = F(x)^n, \\ f_{X_M}(x) &= \frac{d}{dx} F_{X_M}(x) = nF(x)^{n-1}f(x) = \frac{n(x-a)^{n-1}}{(b-a)^n}, \quad x \in [a, b]. \end{aligned}$$

Očekivanje slučajne varijable  $X_M$  je

$$\mathbf{E}(X_M) = \int_{-\infty}^{\infty} x f_{X_M}(x) dx = b - \frac{b-a}{n+1}.$$

Sada možemo izračunati i očekivanje statistike  $\Theta$

$$\mathbf{E}(\Theta) = \frac{\mathbf{E}(X_m) + \mathbf{E}(X_M)}{2} = \frac{a+b}{2},$$

te zaključujemo da je  $\Theta$  nepristrana procjena sredine  $\frac{a+b}{2}$  intervala  $[a, b]$ .

- (b) Da bi statistika bila valjana dovoljno je da njena disperzija teži u nulu. Disperziju  $\mathbf{D}(\Theta)$  računamo na način:

$$\mathbf{D}(\Theta) = \mathbf{D}\left(\frac{X_m + X_M}{2}\right) = \frac{1}{4}\mathbf{D}(X_m + X_M) = \frac{1}{4}\left(\mathbf{E}\left((X_m + X_M)^2\right) - (\mathbf{E}(X_m) + \mathbf{E}(X_M))^2\right).$$

Odredimo razdiobu slučajnog vektora  $(X_m, X_M)$ :

$$\begin{aligned} F_{X_m, X_M}(x, y) &= \mathbf{P}(X_m < x, X_M < y) \\ &= \mathbf{P}(X_M < y) - \mathbf{P}(X_m \geq x, X_M < y) \\ &= F_{X_M}(y) - \mathbf{P}(x \leq X_1 < y, \dots, x \leq X_n < y) \\ &= F(y)^n - (F(y) - F(x))^n, \quad x, y \in [a, b], \quad x \leq y. \end{aligned}$$

Deriviranjem dolazimo do funkcije gustoće

$$\begin{aligned} f_{X_m, X_M}(x, y) &= \frac{\partial^2}{\partial x \partial y} F_{X_m, X_M}(x, y) \\ &= n(n-1)f(x)f(y)(F(y) - F(x))^{n-2} \\ &= \frac{n(n-1)}{(b-a)^n}(y-x)^{n-2}, \quad x, y \in [a, b], \quad x \leq y. \end{aligned}$$

Računamo očekivanje kvadrata zbroja minimuma i maksimuma:

$$\begin{aligned}
\mathbf{E}\left((X_m + X_M)^2\right) &= \int \int (x + y)^2 f_{X_m, X_M}(x, y) \, dx \, dy \\
&= \frac{1}{(b-a)^n} \int_a^b \left( \int_x^b n(n-1)(x+y)^2(y-x)^{n-2} \, dy \right) dx \\
&= \frac{1}{(b-a)^n} \int_a^b \left( \int_x^b n(n-1) \left( (y-x)^n + 4x(y-x)^{n-1} + 4x^2(y-x)^{n-2} \right) dy \right) dx \\
&= \frac{1}{(b-a)^n} \int_a^b \left( \frac{n(n-1)}{n+1} (y-x)^{n+1} + 4x(n-1)(y-x)^n + 4x^2n(y-x)^{n-1} \right) \Big|_{y=x}^b dx \\
&= \frac{1}{(b-a)^n} \int_a^b \left( \frac{n(n-1)}{n+1} (b-x)^{n+1} + 4x(n-1)(b-x)^n + 4x^2n(b-x)^{n-1} \right) dx \\
&= \frac{1}{(b-a)^n} \int_a^b \left( \left( \frac{n(n-1)}{n+1} + 4 \right) (b-x)^{n+1} - 4b(n+1)(b-x)^n + 4b^2n(b-x)^{n-1} \right) dx \\
&= \frac{1}{(b-a)^n} \left( -\frac{n^2+3n+4}{(n+1)(n+2)} (b-x)^{n+2} + 4b(b-x)^{n+1} - 4b^2(b-x)^n \right) \Big|_{x=a}^b \\
&= \frac{1}{(b-a)^n} \left( \frac{n^2+3n+4}{(n+1)(n+2)} (b-a)^{n+2} - 4b(b-a)^{n+1} + 4b^2(b-a)^n \right) \\
&= \frac{n^2+3n+4}{(n+1)(n+2)} (b-a)^2 - 4b(b-a) + 4b^2 \\
&= \frac{n^2+3n+4}{(n+1)(n+2)} (b-a)^2 + 4ab.
\end{aligned}$$

Sada je

$$\begin{aligned}
\mathbf{D}(\Theta) &= \frac{1}{4} \left( \frac{n^2+3n+4}{(n+1)(n+2)} (b-a)^2 + 4ab - (a+b)^2 \right) \\
&= \frac{1}{4} \left( \frac{n^2+3n+4}{(n+1)(n+2)} (b-a)^2 - (b-a)^2 \right) \\
&= \frac{(b-a)^2}{2(n+1)(n+2)} \xrightarrow{n \rightarrow \infty} 0,
\end{aligned}$$

odakle slijedi da je statistika  $\Theta$  valjana.

(c) Primijetimo da funkcija izglednosti ovisi i o dva nepoznata parametra  $a$  i  $b$ :

$$L(a, b, x_1, \dots, x_n) = f(a, b, x_1) \cdots f(a, b, x_n) = \frac{1}{(b-a)^n}.$$

Vidimo da funkcija  $L$  poprima maksimum kada izraz  $b-a$  poprima minimum. Budući da je

$$a \leq x_i \leq b, \quad \forall i \in \{1, \dots, n\},$$

odnosno

$$a \leq \min(x_1, \dots, x_n) \leq \max(x_1, \dots, x_n) \leq b,$$

razlika  $b-a$  je najmanja moguća za

$$a = \min(x_1, \dots, x_n) \text{ i } b = \max(x_1, \dots, x_n).$$

Dakle, za procjenu sredine intervala  $[a, b]$  uzimamo vrijednost

$$c = \frac{a + b}{2} = \frac{\min(x_1, \dots, x_n) + \max(x_1, \dots, x_n)}{2}$$

što je ista procjena koju smo imali ranije.