2. Intervalne procjene za parametre normalne razdiobe 3. Intervalne procjene za razdiobe različite od normalne

Sadržaj poglavlja

Intervali povjerenja

11.1.1. Kvantili

Intervali povjerenja

nepotrebnu složenost, pretpostavit ćemo da postoji interval $\langle a, b \rangle$ takav da je f(x) pozitivan broj u svakoj točki x tog intervala, a jednak nuli za x < a i za x > b. Ovakav se interval naziva **nosač** funkcije gustoće. Vrijednosti $a = -\infty$

točke vezane uz funkciju razdiobe i funkciju gustoće slučajne varijable X.

Zbog primjena koje će uslijediti, upoznajmo detaljnije neke karakteristične

Neka je F funkcija razdiobe, a f gustoća te varijable. Da bismo izbjegli

ili $b = +\infty$ su dopuštene. Tamo gdje je gustoća pozitivna, funkcija razdiobe je rastuća. Dakle, za nju vrijedi F(a) = 0, F(b) = 1 i F je rastuća na intervalu $\langle a, b \rangle$. Izaberimo realan broj p, 0 . Onda jednadžba <math>F(x) = p ima jedincato rješenje.

Kvantil Relan broj x_p za koji vrijedi

 $F(x_p) = p$

 $\int_{-\infty}^{x_p} f(t) \, \mathrm{d}t = p$


to jest

naziva se **kvantil** reda p.

f(x)

р

F(x)



11.1.2. Intervali povjerenja slučajne varijable | Razdioba slučajne varijable u problemima matematičke statistike najčešće nije potpuno poznata, jer ovisi o jednom ili više nepoznatih parametara. U pret-


hodnom smo poglavlju naučili kako na temelju realizacija dobivenih iz uzorka možemo odrediti točkastu procjenu nepoznatog parametra. Ta je procjena više ili manje pouzdana. Poznavanje razdiobe traženog parametra omogućava nam da utvrdimo interval povjerenja oko dobivene procjene. Veličina tog intervala

Radi jednostavnosti, najprije ćemo promotriti problematiku intervala povjerenja za slučajnu varijablu X kojoj je razdioba poznata. Interval povjerenja slučajne varijable Neka je $0 . Interval <math>[c_1, c_2]$ za koji vrijedi

 $P(c_1 < X < c_2) = p$

Ako je p zadan, određivanje intervala povjerenja nije uvijek jednostavan

naziva se interval povjerenja reda p za slučajnu varijablu X.



govori o pouzdanosti dobivene procjene.

Time se zadatak svodi na problem minimizacije: $\int_{c_1}^{c_2} f(t) \, \mathrm{d}t = p.$

vrlo često ispunjeno: f posjeduje samo jednu točku lokalnog maksimuma. Takvu funkciju gustoće nazivamo **unimodalna**. Lako je onda pokazati da zadaća minimizacije ima jednoznačno rješenje, te da za rub intervala povjerenja vrijedi

 $f(c_1) = f(c_2).$

Čak niti s tim dodatnim uvjetom problem određivanja rubnih točaka nije olakšan. Zato se najčešće zadovoljavamo bilo kojim intervalom povjerenja reda p, ili pak njegove rubove određujemo pomoću odabranih kvantila. Na primjer rubne

 $c_1 = x_{\frac{1}{2}(1-p)}, \qquad c_2 = x_{\frac{1}{2}(1+p)}$

 $P(c_1 \le X \le c_2) = \frac{1}{2}(1+p) - \frac{1}{2}(1-p) = p.$

U većini literature koristi se sljedeća standardna oznaka:

U statistici najčešće želimo odrediti interval povjerenja najmanje duljine.

Za zadani broj p, 0 koji određuje interval povjerenja, veličina $\alpha = 1 - p$ naziva se nivo značajnosti (signifikantnosti). Pri tom za jednostrane kvantile vrijedi: a za dvostrane:

Ukoliko funkcija gustoće posjeduje svojstvo simetrije (s obzirom na pravac

Ova se zadaća ne može uvijek riješiti eksplicitnim formulama. Pretpostavimo da funkcija f ima dodatno svojstvo, koje je u primjenama

točke možemo odabrati ovako:

Zaista, u tom slučaju vrijedi

Nivo značajnosti

x = m):

za sve $x \in \mathbf{R}$,

(2)

(3)

tada će za odabir (2) biti ispunjen uvjet (1).

f(m-x) = f(m+x),

Sl. 11.4. Interval povjerenja za simetričnu funkciju gustoće. 11.1.3. Interval povjerenja za nepoznati parametar | Neka je sad razdioba varijable X ovisna o nepoznatom parametru ϑ . Taj ćemo parametar procjeniti pomoću neke točkovne procjene. Pokažimo sad kako se određuje kvaliteta te procjene. Ona će biti iskazana duljinom intervala

Interval povjerenja za nepoznati parametar Pretpostavimo da postoje funkcije $\overline{\Theta}(X_1,\ldots,X_n)$ i $\underline{\Theta}(X_1,\ldots,X_n)$ takve da za sve realizacije x_1,\ldots,x_n uzorka vrijedi

povjerenja za nepoznati parametar.

 $P\left\{\underline{\Theta}(x_1,\ldots,x_n)<\vartheta<\overline{\Theta}(x_1,\ldots,x_n)\right\}=p.$

Ovdje valja napomenuti da je interval $\langle \underline{\Theta}, \overline{\Theta} \rangle$ slučajan, jer njegovi rubovi ovise o realizaciji uzorka. Međutim, vjerojatnost da parametar ϑ padne unutar tog intervala jednaka je p i ne ovisi o tim realizacijama.

Interval $\langle \underline{\Theta}, \overline{\Theta} \rangle$ se zove interval povjerenja za parametar ϑ reda p.

parametara, a moguće i oba, nepoznati.

lacksquare 11.2.1. Intervalna procjena očekivanja uz poznatu disperziju σ^2 lacksquare

Pretpostavimo da X ima normalnu razdiobu $\mathcal{N}(a, \sigma^2)$ kod koje su neki od

Intervalne procjene za parametre normalne razdiobe

Statistika za očekivanje je $\overline{X} = \frac{X_1 + \ldots + X_n}{n}.$

Ova statistika nam daje točkastu procjenu očekivanja. Slučajna varijabla \overline{X} je zbroj nezavisnih normalnih varijabli, pa zato i sama

Slučajna varijabla
$$\overline{X}$$
 je zbroj nezavisnih normima normalu razdiobu. Njezini su parametri

 $E(\overline{X}) = \frac{1}{n}[E(X_1) + \ldots + E(X_n)] = E(X) = a,$

 $D(\overline{X}) = \frac{1}{n^2}[D(X_1) + \ldots + D(X_n)] = \frac{D(X)}{n} = \frac{\sigma^2}{n}.$

Dakle,
$$\overline{X} \sim \mathcal{N}(a, \frac{\sigma^2}{n})$$
.
 Istaknimo i zapamtimo ovaj važni rezultat.


Teorem 11.1. Razdioba sredine uzorka

Ako populacija X ima normalnu razdiobu $\mathcal{N}(a, \sigma^2)$, onda za sredinu

Ako populacija
$$X$$
 ima normalnu razdiobu $\mathcal{N}(a,$ uzorka vrijedi
$$\overline{X} = \frac{X_1 + \ldots + X_n}{n} \sim \mathcal{N}(a, \frac{\sigma^2}{n}).$$

(4)

Ovdje je važno uočiti efekt povećanja volumena uzorka. Što je n veći, to će



za varijablu $\it U$. Odaberimo za $\it c$ kvantil normalne razdiobe. $\it Uobičajeno je taj$ kvantil označavati slovom u: $c = u_{1-\alpha/2}$. Onda je $P(|U| < u_{1-\alpha/2}) = 1 - \alpha = p.$

pripadnu jediničnu normalnu razdiobu. Neka je sad zadan p, 0 .

P(|U| < c) = p.Broj c, dobiven kao rješenje ove jednadžbe, dat će interval povjerenja [-c,c]

Označimo $\alpha = 1 - p$ i promotrimo uvjet

 $\Phi(x)$

p


Sl. 11.6. Kvantili jedinične normalne razdiobe Sad dobivamo

3. Izračuna se sredina \overline{x} uzorka x_1, \ldots, x_n **4.** Izračuna se $u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$.

Iz populacije $\mathcal{N}(a,4)$ izvučen je uzoral

Odredi procjenu i 90%-tni interval za očekivanje a.

Interval povjerenja je



 $P\left(\left|\frac{\overline{X}-a}{\sigma/\sqrt{n}}\right| < u_{1-\alpha/2}\right) = 1-\alpha,$

 $P\left(\overline{x} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leqslant a \leqslant \overline{x} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = p.$ (5)

▶ Imamo $\overline{X} \sim \mathcal{N}(a, \frac{4}{25})$. Iz uzorka računamo procjenu sredine: $\overline{x} = \frac{0 \cdot 1 + 1 \cdot 4 + 2 \cdot 6 + 3 \cdot 12 + 4 \cdot 2}{25} = 2.40.$

 $u_{1-\alpha/2} = u_{0.95} = 1.645.$

 $u_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} = 1.645 \cdot \frac{2}{5} = 0.658.$

Sad je $\alpha=1-p=0.1$. Iz tablica pročitamo vrijednost kvantila

Dalje je

Primjer 11.1.

t.j.

liku:

varijable ima **gama razdiobu** s parametrima $(\frac{1}{2}, \frac{1}{2})$.

Očekivanje i disperzija su

toće dani su u poglavlju §8.2.

t.j.

imamo

pa je

stupnjeva slobode. Označavamo je s χ_n^2 . Njezina je gustoća

 $E(\chi_n^2) = n$

Vratimo se na početni problem. Promatramo statistiku

Dakle, P(1.742 < a < 3.058) = 0.9.

11.2.2. Intervalna procjena za disperziju, uz poznato očekivanje
$$a$$
 Statistika za nepoznatu disperziju, uz poznatu vrijednost očekivanja a je
$$D^2 = \frac{1}{n} \sum_{k=1}^{n} (X_k - a)^2 = \frac{\sigma^2}{n} \sum_{k=1}^{n} \left(\frac{X_k - a}{\sigma}\right)^2.$$

Varijabla $\frac{X_k - a}{\sigma}$ ima jediničnu normalnu razdiobu. Kvadrat te slučajne

Zbroj kvadrata n nezavisnih jediničnih normalnih razdioba ima gama razdiobu s parametrima $(\frac{1}{2}n, \frac{1}{2})$. Tu razdiobu nazivamo **hi kvadrat razdioba** s n

Eksplicitna formula za nekoliko početnih vrijednosti indeksa n i graf te gus-

 $D(\chi_n^2) = 2n$.

 $f_{\chi_n^2}(x) = \frac{1}{2^{n/2}\Gamma(\frac{1}{2}n)} x^{\frac{1}{2}n-1} e^{-\frac{1}{2}x}.$

Prema dokazanom, slučajna varijabla $\frac{nD^2}{\sigma^2}$ ima hi hvadrat razdiobu s n stupnjeva slobode. Odavde možemo odrediti interval povjerenja za disperziju.

Disperzija je veličina koja je uvijek pozitivna. Zato interval povjerenja možemo tražiti bilo kao jednostrani (u kojem je lijeva granica fiksna, jednaka nuli, a desna nepoznata), bilo kao dvostrani, u kojima tražimo i lijevu i desnu granicu.

 $D^2 = \frac{\sigma^2}{n} \sum_{k=1}^{n} \left(\frac{X_k - a}{\sigma} \right)^2.$

Varijabla $\frac{nD^2}{\sigma^2}$ ima χ_n^2 razdiobu. Zato vrijedi $P\left(\frac{nD^2}{\sigma^2} \geqslant \chi_{n,1-p}^2\right) = p,$ $P\left(\sigma^2 \leqslant \frac{nD^2}{\gamma^2}\right) = p.$

Jednostrani interval povjerenja za disperziju, uz poznato očekivanje $\,a\,$

3. Izračuna se procjena disperzija \hat{d}^2 iz uzorka x_1, \ldots, x_n .

2. Iz tablica kvantila hi kvadrat razdiobe s n stupnjeva slobode, odredi

Dvostrani interval povjerenja. Odredimo sad dvostrani interval povjerenja za disperziju σ^2 , dakle, interval $[eta_1,eta_2]$ sa svojstvom $P(eta_1<\sigma^2<eta_2)=p$. Postupit ćemo na sljedeći način.

1. Zadaje se nivo pouzdanosti p.

se odgovarajući kvantil $\chi_{n,1-p}^2$.

Jednostrani interval povjerenja je

4. Izračuna se $\frac{nd^2}{\chi_{n,1-p}^2}$.

za zadanu vrrijednost p (obično blisku jedinici). Krenimo od uvjeta $P(\chi_n^2 < x_{1-p}) = 1 - p$ i potražimo kvantil x_{1-p} za koji je ovaj uvjet ispunjen. Taj kvantil se za interesantne vrijednosti od p čita iz tablica hi kvadrat razdiobe. U tim tablicama on je najčešće označen sa $\chi^2_{n,1-p}$. Dakle, vrijedi $P(\chi_n^2 \geqslant \chi_{n,1-n}^2) = p$

 $P(\sigma^2 \leqslant t) = p$

Jednostrani interval povjerenja. To je interval [0, t] takav da vrijedi

$$P\left(0\leqslant\sigma^2\leqslant\frac{n\widehat{d}^2}{\chi_{n,1-p}^2}\right)=p.$$

(6)

(7)

 $P(c_1 \le \chi_n^2 \le c_2) = 1 - \alpha/2 - \alpha/2 = 1 - \alpha = p.$ Dakle, površina ispod funkcije gustoće, a između ovih kvantila, jednaka je $\,p\,.\,$

Sl. 11.8. Kvantili hi kvadrat razdiobe za dvostrani interval povjerenja.

 $P(\chi_n^2 < c_1) = \alpha/2, \qquad P(\chi_n^2 < c_2) = 1 - \alpha/2,$

Označimo lpha=1-p i odredimo kvantile $c_1=\chi^2_{n,lpha/2}$ i $c_2=\chi^2_{n,1-lpha/2}$. Sad

Slučajna varijabla $\frac{nD^2}{\sigma^2}$ ima χ_n^2 razdiobu. Tako dobivamo

 $P\left(\frac{nD^2}{c_2} < \sigma^2 < \frac{nD^2}{c_1}\right) = p.$

3. Izračuna se disperzija \hat{d}^2 uzorka x_1, \ldots, x_n . **4.** Izračunaju se $\beta_1 = \frac{n\widehat{d}^2}{c_2}$, $\beta_2 = \frac{n\widehat{d}^2}{c_1}$.

 $P(c_1 \leqslant \frac{nD^2}{\sigma^2} \leqslant c_2) = p$ odnosno

se kvantili $c_1 = \chi^2_{n,\alpha/2}$, i $c_2 = \chi^2_{n,1-\alpha/2}$.

Dvostrani interval povjerenja je

 $P(\beta_1 \leqslant \sigma^2 \leqslant \beta_2) = p.$

■ 11.2.3. Svojstva hi kvadrat razdioba Sad ćemo promotriti najčešći slučaj. Za populaciju nam je poznato samo da

se ravna po normalnoj razdiobi, ali nam nisu poznati niti očekivanje niti disperzija te razdiobe. Te veličine računamo iz uzorka pomoću njihovih nepristranih statistika:

 $\overline{X} = \frac{X_1 + \ldots + X_n}{n}, \qquad S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \overline{X})^2.$

$$n$$
 $n-1$ $\frac{1}{k-1}$ Međutim, sada nije jednostavno objasniti koju razdiobu ima slučajna varijabla S^2 . Slučajne varijable $X_k - \overline{X}$ su normalno distribuirane, zato što i X_k i \overline{X} imaju

normalnu razdiobu, međutim, one nisu nezavisne za različite vrijednosti od k!Vrijedi naime $(X_1 - \overline{X}) + \ldots + (X_n - \overline{X}) = X_1 + \ldots + X_n - n\overline{X} = 0,$ te među njima postoji linearna zavisnost. Pokazat ćemo da $(n-1)S^2/\sigma^2$ ima χ^2 -razdiobu, međutim, zbog te linearne zavisnosti među njezinim pribrojnicima,

va slobode će se smanjiti za jedan; bit će riječ o
$$\chi^2_{n-1}$$

broj stupnjeva slobode će se smanjiti za jedan; bit će riječ o χ^2_{n-1} razdiobi! **Teorem 11.2.** Neka su X_1,\ldots,X_n nezavisne s $\mathcal{N}(a,\sigma^2)$ razdiobom. Tada su \overline{X} i S^2 nezavisne slučajne varijable! Pri tom $(n-1)S^2/\sigma^2$ ima χ^2_{n-1} razdiobu.

Dokaz. Definirajmo

 $Y_1 = \frac{1}{\sqrt{n}} X_1 + \ldots + \frac{1}{\sqrt{n}} X_n,$

 $Y_2 = c_{21}X_1 + \ldots + c_{2n}X_n,$

:
$$Y_n = c_{n1}X_1 + \ldots + c_{nn}X_n.$$
 Vektore $\vec{c_k} = (c_{k1}, \ldots, c_{kn})^{\top}$ možemo izabrati tako da budu jedinični te da $\vec{c_1}, \ldots, \vec{c_n}$ čine ortonormiranu bazu. Tada je matrica
$$A = \begin{pmatrix} \frac{1}{\sqrt{n}} & \ldots & \frac{1}{\sqrt{n}} \\ c_{21} & \ldots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & \ldots & c_{nn} \end{pmatrix}$$

ortogonalna.

Retke ove matrice čine vektori
$$\vec{c}_1, \dots, \vec{c}_n$$
. Među njezinim svojstvima izdvoo sljedeća

1. $A^{-1} = A^{\top}$. Zaista,
$$A \cdot A^{\top} = \begin{bmatrix} \vec{c}_1^{\top} \\ \vdots \\ \vec{c}^{\top} \end{bmatrix} [\vec{c}_1, \dots, \vec{c}_n] = [\vec{c}_i^{\top} \vec{c}_j] = [\delta_{ij}] = I.$$

1. $A^{-1} = A^{\top}$. Zaista,

jimo sljedeća

2. Po prvom svojstvu, $1 = \det(A^{\top}A) = \det(A^{\top})\det(A) = \det(A)^{2}$ te je $det(A) = \pm 1$, odnosno |det(A)| = 13. Ortogonalno preslikavanje čuva normu: ako je $\vec{y} = A\vec{x}$, tada imamo

 $\|\vec{y}\|^2 = \vec{y}^\top \vec{y} = \vec{x}^\top A^\top A \vec{x} = \vec{x}^\top \vec{x} = \|\vec{x}\|^2.$

 $g(y_1,\ldots,y_n)=f(x_1,\ldots,x_n)\cdot\frac{1}{|\det(A)|}$ $= f(x_1, ..., x_n) = f_{X_1}(x_1) \cdot \cdot \cdot f_{X_n}(x_n)$

$$=\frac{1}{(2\pi\sigma^2)^{n/2}}\exp\left\{-\frac{1}{2\sigma^2}\sum_{k=1}^n(x_k-a)^2\right\}.$$
 Transformirajmo zbroj u eksponentu, koristeći svojstvo 3 i definiciju za y_1 ::
$$\sum_{k=1}^n(x_k-a)^2=\sum_{k=1}^nx_k^2-2a\sum_{k=1}^nx_k+na^2=\sum_{k=1}^ny_k^2-2a\sqrt{n}y_1+na^2$$

 $= (y_1 - \sqrt{n} a)^2 + \sum_{k=1}^{n} y_k^2$

 $g(y_1,\ldots,y_n) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(y_1-\sqrt{n}a)^2}{2\sigma^2}\right\} \cdot \prod_{k=2}^n \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{y_k^2}{2\sigma^2}\right\}.$

kcija gustoće
$$g$$
 se faktorizira, pa su Y_1, \ldots, Y_n nezavisne. Pri t $\mathcal{N}(a\sqrt{n}, \sigma^2)$, te $Y_k \sim \mathcal{N}(0, \sigma^2)$, $k = 2, \ldots, n$. Nadalje, vrijedi
$$(n-1)S^2 = \sum_{k=1}^n (X_k - \overline{X})^2 = \sum_{k=1}^n X_k^2 - n(\overline{X})^2$$


$$1)S^2 = \sum_{k=2}^{n} Y_k^2 \text{ i } \overline{X} = \frac{1}{\sqrt{n}} Y_1 \text{ su nezavisne. Pri tom vrijedi i}$$

budući su varijable Y_k/σ , $k=2,\ldots,n$ nezavisne s jediničnom normalnom razdiobom.

Neka su
$$X, X_1, \dots, X_n$$
 nezavisne jedinične normalne varijable. Tada kažemo da slučajna varijabla
$$t := \frac{X}{\sqrt{(X_1^2 + \dots + X_n^2)/n}} = \frac{X}{\sqrt{\chi_n^2/n}}$$

 $f(x) = C_n \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}.$

gdje je C_n neka konstanta normiranja.



 $P(|t_{n-1}| \leqslant t_{1-\alpha/2}) = p.$ (S lijeve strane nejednakosti nalazi se slučajna varijabla t_{n-1} , a s desne strane kvantil $t_{1-\alpha/2}$.) Sada vrijedi

 $P\left(\left|\frac{\overline{X}-a}{S}\sqrt{n}\right| \leqslant t_{1-\alpha/2}\right) = p$

Sl. 11.10. Kvantili t_n razdiobe

Intervali povjerenja za očekivanje normalne razdiobe, uz nepoznati σ^2

2. Iz tablica kvantila Studentove razdiobe s n-1 stupnjeva slobode,

1. Zadaje se nivo pouzdanosti $p = 1 - \alpha$.

3. Izračuna se procjena sredine \overline{x} iz uzorka x_1, \ldots, x_n . **4.** Izračuna se procjena disperzije \hat{s}^2 iz uzorka x_1, \ldots, x_n .

odredi se odgovarajući kvantil $t_{1-\alpha/2}$.

5. Izračuna se $t_{1-\alpha/2} \frac{\widehat{s}}{\sqrt{n}}$

1 - p = 0.1 i $1 - \alpha/2 = 0.95$.

bode):

Odavde

Interval povjerenja je

 $P\left(\overline{x} - t_{1-\alpha/2} \frac{\widehat{s}}{\sqrt{n}} \leqslant a \leqslant \overline{x} + t_{1-\alpha/2} \frac{\widehat{s}}{\sqrt{n}}\right) = p.$ Primjer 11.2. Slučajna varijabla X ima normalnu razdiobu s nepoznatim parametrima. Odredi točkaste procjene za očekivanje i disperziju, te 90%-tni interval povjerenja za očekivanje, na osnovu vrijednosti iz uzorka

$$u_{0.95}=1.645$$
 i granica intervala povjerenja bila bi određena brojem $u_{0.95} \frac{\sigma}{\sqrt{n}}=2.63$.


Jednostrani interval povjerenja je

📕 11.2.6. Intervalne procjene za disperziju uz nepoznato očekivanje 📗 Intervale povjerenja za disperziju određujemo iz statistike $S^{2} = \frac{1}{n-1} \sum_{k=1}^{n} (X_{k} - \overline{X})^{2}.$

4a. Izračuna se $\beta = \frac{(n-1)\hat{s}^2}{c}$ **4b.** Izračunaju se $\beta_1=rac{(n-1)\widehat{s}^2}{c_2}$, $\beta_2=rac{(n-1)\widehat{s}^2}{c_1}$.

Funkcija gustoće
$$g$$
 se faktorizira, pa su Y_1,\ldots,Y_n nezavisne. Pri tom je $Y_1 \sim \mathcal{N}(a\sqrt{n},\sigma^2)$, te $Y_k \sim \mathcal{N}(0,\sigma^2)$, $k=2,\ldots,n$. Nadalje, vrijedi
$$(n-1)S^2 = \sum_{k=1}^n (X_k - \overline{X})^2 = \sum_{k=1}^n X_k^2 - n(\overline{X})^2$$

$$= \sum_{k=1}^n Y_k^2 - Y_1^2 = \sum_{k=2}^n Y_k^2.$$
 Dakle, $(n-1)S^2 = \sum_{k=2}^n Y_k^2$ i $\overline{X} = \frac{1}{\sqrt{n}}Y_1$ su nezavisne. Pri tom vrijedi i
$$\frac{(n-1)S^2}{\sigma^2} = \sum_{k=2}^n \left(\frac{Y_k}{\sigma}\right)^2 \sim \chi_{n-1}^2$$



$$P\left(\overline{X} - t_{1-\alpha/2} \frac{S}{\sqrt{n}} \leqslant a \leqslant \overline{X} + t_{1-\alpha/2} \frac{S}{\sqrt{n}}\right) = p.$$

i odavde

povjerenja za očekivanje, na osnovu vrijednosti iz uzorka
$$\frac{x_j \mid 110 \quad 115 \quad 120 \quad 125 \quad 130 \quad 135}{n_j \mid 2 \quad 3 \quad 6 \quad 5 \quad 2 \quad 2}$$

$$\blacktriangleright \text{ Izračunajmo sredinu:}$$

$$\overline{x} = 120 + \frac{-20 - 15 + 25 + 20 + 30}{20} = 122.$$
Također,
$$\widehat{s}^2 = \frac{1}{19}(2 \cdot 12^2 + 3 \cdot 7^2 + 6 \cdot 2^2 + 5 \cdot 3^2 + 2 \cdot 8^2 + 2 \cdot 13^2) = \frac{970}{19} = 51.05.$$

Odredimo interval povjerenja za matematičko očekivanje. Vrijedi $\alpha =$

Odgovarajući kvantil je (tablice Studentove razdiobe s 19 stupnjeva slo-

 $t_{1-\alpha/2} = t_{0.95} = 1.729$.

 $t_{1-\alpha/2} \frac{\hat{s}}{\sqrt{n}} = 2.76$.

Pretpostavimo za trenutak da je disperzija populacije bila poznata te da se podudara s ovom izračunatom iz uzorka: $\sigma^2 = 51.05$. U tom bismo slučaju

Prema tome, 90% -tni interval povjerenja za očekivanje je 122 ± 2.76 .

U ovom bi slučaju interval povjerenja bio 122 ± 2.63 .

kvantil $x_{1-\alpha/2}$ dobili iz tablica normalne razdiobe:

lobode, odrede se kvantili a procjena disperzije
$$\hat{s}^2$$
 uzo $(n-1)\hat{s}^2$

 $P(0 \leqslant \sigma^2 \leqslant \beta) = p.$ Dvostrani interval povjerenja je $P(\beta_1 \leqslant \sigma^2 \leqslant \beta_2) = p.$

U Teoremu 11.2 je dokazano da slučajna varijabla
$$\frac{(n-1)S^2}{\sigma^2}$$
 ima hi kvadrat razdiobu s $n-1$ stupnjeva slobode.

Intervali povjerenja za disperziju normalne razdiobe, uz nepoznato očekivan

1. Zadaje se nivo pouzdanosti p i odredi $\alpha=1-p$.

2a. Za jednostrani interval, iz tablica kvantila hi kvadrat razdiobe s $n-1$ stupnjeva slobode, odredi se odgovarajući kvantil $c=\chi_{n-1,\alpha}^2$.

2b. Za dvostrani interval, iz tablica kvantila hi kvadrat razdiobe s $n-1$ stupnjeva slobode, odrede se kvantili $c_1=\chi_{n-1,\alpha/2}^2$, i $c_2=\chi_{n-1,1-\alpha/2}^2$.

3. Izračuna nepristrana procjena disperzije \hat{s}^2 uzorka x_1,\ldots,x_n .

ima **Studentovu razdiobu** $^{\perp}$ (ili t-razdiobu) s n stupnjeva slobode. Kad je to važno, navodimo stupanj slobode u indeksu razdiobe: t_n . Gustoća t_n -razdiobe iznosi

utvrditi točnu distribuciju za statistike \overline{X} i S^2 . Ipak, tehnike opisane u ovom poglavlju mogu se primjeniti, ukoliko uzorak ima dovoljnu dimenziju. Tu činjenicu treba zahvaliti centralnom graničnom teoremu. Prisjetimo se iskaza tog teorema, danog u §9.7:

Ukoliko razdioba populacije X nije normalna, tada je praktički nemoguće

Neka je (X_n) niz identički distribuiranih nezavisnih slučajnih varijabla s

očekivanjem a i disperzijom σ^2 . Označimo $Z_n = X_1 + \ldots + X_n$. Onda

 $\frac{Z_n - na}{\sigma\sqrt{n}} \stackrel{\mathscr{D}}{\longrightarrow} \mathscr{N}(0,1).$

To znači da se upute iz ovog poglavlja mogu primjenjivati i u ovom slučaju, s tim da je točnost računa to bolja što je ova aproksimacija točnija.

Iskustvo pokazuje da je prikladna minimalna veličina uzorka
$$n=20$$
 za

interval povjerenja za očekivanje, te n = 50 za interval povjerenja za varijancu.

Primjer 11.3. Neka je veličina izmjerena 25 puta mjernim instrumentom koji nema sis-

tematske pogreške, a slučajna pogreška je normalna varijabla s odstupanjem Odredi interval u kojem se s vjerojatnošću 0.99 nalazi ta veličina.

 $\sigma=10~\mu\mathrm{m}$. Srednja vrijednost uzorka mjerene veličine je $\overline{x}=100~\mu\mathrm{m}$. Prirodno je pretpostaviti da pogreška mjerenja ima normalnu razdiobu,

ali je volumen uzorka dovoljno velik da račun neće ovisiti o tome. Ovdje je $\alpha = 1 - p = 1 - 0.99 = 0.01$ pa je dovoljno odrediti kvantil

 $u_{1-\alpha/2} = u_{0.995} = 2.58$. Sada računamo $u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} = 2.58 \cdot \frac{10}{5} = 5.16$.

99%-tni interval povjerenja je [94.84, 105.16].

11.3.1. Interval povjerenja za vjerojatnost događaja |

U Primjeru 10.7 odredili smo točkastu procjenu za vjerojatnost
$$p$$
 nekog događaja A . Ovaj pokus prati indikatorska slučajna varijabla
$$X \sim \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$$

nepristrana procjena za vjerojatnost p. Ovdje je m broj realizacija događaja Au *n* ponavljanja pokusa. Odredimo sad interval povjerenja za vjerojatnost p. Slučajna varijabla X ima binomnu razdiobu $\mathcal{B}(1,p)$ pa zbroj n nezavisnih

$$X_1 + X_2 + \ldots + X_n \sim \mathscr{B}(n,p)$$

Ovu razdiobu možemo aproksimirati normalnom razdiobom, s parametrima $a = np$, $\sigma^2 = npa$. Zato je

a = np, $\sigma^2 = npq$. Zato je

 $u_{1-\alpha/2}$. Dakle:

eficijentom:

nejednakosti razriješiti po p:

$$\widehat{p}=rac{1}{n}(X_1+\ldots+X_n)pprox \mathscr{N}\Big(p,rac{pq}{n}\Big).$$
 Definirajmo sad statistiku

 $\Theta = \frac{\widehat{p} - p}{\sqrt{\frac{pq}{pq}}} = \sqrt{\frac{n}{pq}}(\widehat{p} - p).$ Ona ima približno jediničnu normalnu razdiobu. Sad možemo odrediti interval povjerenja reda $1-\alpha$ za tu razdiobu:

 $P(-u_{1-\alpha/2} < \Theta < u_{1-\alpha/2}) = 1 - \alpha.$ Radi jednostavnosti zapisivanja u nastavku, označit ćemo ovaj kvantil s c=

$$P\left(-c < \sqrt{\frac{n}{p(1-p)}}(\widehat{p}-p) < c\right) = 1 - \alpha.$$

Da bismo odavde dobili interval povjerenja za vjerojatnost p, moramo ove

 $\sqrt{\frac{n}{p(1-p)}} |\widehat{p} - p| < c.$ Nejednakost ekvivalentna ovoj je $n(\hat{p}-p)^2 < c^2 p(1-p).$

Sl. 11.11. Interval povjerenja za vjerojatnost p, u ovisnosti o sredini \overline{x} .

Nakon sređivanja, dobivamo kvadratnu jednadžbu s pozitivnim vodećim ko-


Ako su $p_1 < p_2$ rješenja odgovarajuće jednadžbe, onda je $[p_1, p_2]$ interval

(8)

(9)

 $(n+c^2)p^2 - (2n\hat{p}+c^2)p + n\hat{p}^2 < 0.$

 p_1



Anketa rađena na uzorku od 300 osoba utvrdila je da 210 među njima

 $\mathbf{P}(p_1 \leqslant p \leqslant p_2) = 1 - \alpha$

 $p_{1,2} = \widehat{p} \mp u_{1-\alpha/2} \sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}}.$

Interval povjerenja za vjerojatnost reda $1 - \alpha$ jest

Veća se točnost postiže korištenjem formule (8).

pri čemu se rubovi računaju formulom

Pokazali smo da je veličina $\widehat{p} = \frac{x_1 + \ldots + x_n}{n} = \frac{m}{n}$

kopija te varijable ima također binomnu razdiobu:

$$n(p-p)^{-} < c^{-}p(1-p)$$
.
Sve točke u ravnini koje zadovoljavaju ovu nejednakost leže unutar elipse nacrtane na sljedećoj slici. Primjetite da ta elipsa prolazi točkama $(0,0)$ i $(1,1)$.

povjerenja za veličinu p. Rješavajući kvadratnu jednadžbu dobivamo

$$p_{1,2} = \widehat{p} \mp c \sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}}.$$
 ervalna procjena za vjerojatnost p događaja Procjena vjerojatnosti p događaja A računa se pomoću relativne frekvencije pojavljivanja tog događaja:
$$\widehat{p} = \frac{m}{n}.$$

pouzdanošću od 95% rješilo taj test?

lu (9). Procjena postotka:

pa je traženi interval [0.313, 0.832].

Računajući prema (9) dobili bismo interval [0.296, 0.904]. Vidimo da su intervalne procjene vrlo neprecizne za malene volumene uzorka. 11.3.2. Intervalna prociena parametra eksponencijalne razdiobe

 $f(x) = \lambda e^{-\lambda x}, \qquad x > 0.$

 $E(X) = \frac{1}{2}, \qquad D(X) = \frac{1}{2^2}.$

 $\widehat{\lambda} = \frac{1}{\overline{\lambda}}$.

Odredimo sad interval povjerenja za tu procjenu.

Pretpostavimo da je parametar λ nepoznat. Pokazali smo da je njegova

U ovom slučaju možemo odrediti točnu razdiobu za statistiku \overline{X} . Naime, slučajne varijable X_1,\ldots,X_n su nezavisne, s eksponencijalnom razdiobom $\mathscr{E}(\lambda)$, zato zbroj $X_1+\ldots+X_n$ ima gama razdiobu s parametrima n i λ . (Vidi §8.2.) Tu razdiobu nazivamo Erlangova razdioba, a njezina je gustoća

 $\widehat{p} = \frac{m}{n} = \frac{6}{10} = 0.6.$

Za kvantil vrijedi $\alpha=1-0.95=0.05$ pa je $1-\alpha/2=0.975$ i $u_{0.975}=1.96$. Sad dobivamo, prema formuli (8)

 $p_{1,2} = 0.57225 \mp 0.25958$

Uzorak je premalog volumena da bismo koristili jednostavniju formu-

Slučajna varijabla X ima eksponencijalnu razdiobu, $X \sim \mathscr{E}(\lambda)$. Njezina

 $g(x) = \frac{n^n \lambda^n x^{n-1}}{(n-1)!} e^{-\lambda nx}, \qquad x > 0.$ Teorijski, odavde bismo mogli izračunati interval povjerenja, na temelju poz-

Ovakav bi račun imao smisla za maleni volumen uzorka. Međutim, ako je

n dovoljno velik, mnogo je jednostavnije aproksimirati zbroj $X_1 + \ldots + X_n$ normalnom razdiobom s parametrima $\frac{n}{\lambda}$ i $\frac{n}{\lambda^2}$. Tako sredina ima približno

 $h(x) = \frac{\lambda^n x^{n-1}}{(n-1)!} e^{-\lambda x}, \qquad x > 0.$

11.3.2. Interval povjerenja za parametar Poissonove razdiobe Neka slučajna varijabla X ima Poissonovu razdiobu s nepoznatim paramet-

 $\frac{1 - 1.96/10}{260} < \lambda < \frac{1 + 1.96/10}{260}$

Zato za očekivanje vrijedi 217.4 < E(X) < 323.4, s vjerojatnošću 0.954.

 $P\left(\frac{1-u_{1-\alpha/2}/\sqrt{n}}{\overline{x}}<\lambda<\frac{1+u_{1-\alpha/2}/\sqrt{n}}{\overline{x}}\right)=p.$

Primjer 11.6. Trajanje žarne niti je slučajna varijabla s eksponencijalnom razdiobom. Uzorak od 100 žarnih niti je promatran, i on je dao srednju vrijednost 260 sati. Koliki je 95%-tni interval povjerenja za očekivano vrijeme života žarne ► Ovdje je $\alpha = 1 - p = 0.05$, $u_{1-\alpha/2} = u_{0.975} = 1.96$. To nam daje

sljedeći interval povjerenja reda 0.95:

Sl. 11.12. Interval povjerenja za parametar Poissonove razdiobe. Za sadanu vrijednost \bar{x} , rubovi intervala λ_1 i λ_2 odrede se rješavanjem kvadratne nejednadžbe (10).

(10)

Primjer 11.7.

rom λ :

▶ Volumen uzorka je dovoljno velik i aproksimacija normalnom razdiobom će biti odlična. Računamo

Broj poziva na centrali je Poissonova slučajna varijabla. Bilježeni su

 $P(X=k) = \frac{\lambda^k}{k!}e^{-\lambda}, \qquad k=0,1,\ldots$ Znamo da vrijedi $E(X) = \lambda$, $D(X) = \lambda$. Zato je razdioba sredine \overline{X} za veliki broj n približno normalna, $\overline{X} \sim \mathcal{N}\left(\lambda, \frac{\lambda}{n}\right)$. Odatle slijedi $P\left(|\overline{X} - \lambda| < u_{1-\alpha/2}\sqrt{\frac{\lambda}{n}}\right) = p.$ Za zadanu vrijednost \bar{x} sredine, iz ove nejednakosti moramo odrediti interval za Skup svih točaka u ravnini koje zadovoljavaju nejednakost $(\lambda - \overline{x})^2 < \frac{u_{1-\alpha/2}^2}{n} \lambda$ leže unutar parabole skicirane na sljedećoj slici: λ_1

pozivi u svakoj minuti jednog sata i dobivena je srednja vrijednost $\bar{x} = 5.8$. Odredimo 95%-tni interval povjerenja za parametar λ .

Primjer 11.4. podržava trenutnu vladinu mirovinsku politiku. Odredite 90%-tni interval povjerenja za postotak populacije koja ne podržava tu politiku. Vjerojatnost izračunata iz uzorka je $\widehat{p} = \frac{210}{300} = 0.7$ što daje točkovnu procjenu od 70%. Interval povjerenja računat ćemo formulom (9). Odgovarajući kvantil je $u_{1-\alpha/2}=u_{0.95}=1.64$ pa dobivamo $p_{1,2} = 0.7 \mp 1.64 \cdot \sqrt{\frac{0.7 \cdot 0.3}{300}} = 0.7 \mp 0.04339$. Dakle, 90 %-tni interval povjerenja je [0.657, 0.743]. Da smo računali prema formulama (8) dobili bismo interval [0.655, 0.741]. Primjer 11.5. Deset na sreću odabranih studenata prve godine rješavalo je probni test i šestorica su ga položila. Koliki je postotak svih studenata te godine koji bi s

Znamo da vrijedi

točkasta procjena

Zato sredina \overline{X} ima gustoći

nate realizacije $x = \overline{x}$.

razdiobu

 $\overline{X} \approx \mathcal{N}\left(\frac{1}{\lambda}, \frac{1}{n\lambda^2}\right).$ Neka je p zadani nivo pouzdanosti, $\alpha = 1-p$ i $u_{1-\alpha/2}$ kvantil normalne $P\left(\frac{1}{\lambda} - u_{1-\alpha/2} \frac{1}{\lambda \sqrt{n}} < \overline{x} < \frac{1}{\lambda} + u_{1-\alpha/2} \frac{1}{\lambda \sqrt{n}}\right) = p.$

 $\frac{u_{1-\alpha/2}^2}{n} = 0.064$ pa trebamo riješiti kvadratnu nejednadžbu $(\lambda - 5.8)^2 < 0.064 \lambda$. Njezina su rješenja $\lambda_{1,2}=5.832\mp0.61$. Tako dobivamo interval povjerenja $5.22<\lambda<6.44$. \blacktriangleleft