Geometrijsko pretraživanje

Upit raspona i najbliži susjed u niskim i visokim dimenzijama

dr.sc.tech. Kristijan Poje, 2026.

Dva upita i referentno rješenje

Zadan je fiksan skup P od n točaka u $\mathbb{R}^d$.

- **Upit raspona:** za pravokutnik R vrati sve $p \in P \cap R$.
- **Upit najbližeg susjeda:** za točku q vrati $\operatorname{argmin}_{\{p \in P\}} \|p - q\|$.
- **Linearni pregled:** izračunaj sve udaljenosti — $O(nd)$ po upitu, bez pripreme. To je **definicija točnog odgovora**; svaka metoda danas uspoređuje se s njim.
- Dogovor: uspoređujemo **kvadrate udaljenosti** $d^2(p, q) = \Sigma_i (p_i - q_i)^2$ — isti poredak, bez korijena, cijeli brojevi ostaju cijeli.
- Cilj: jednom pripremiti podatke tako da jedno mjerenje (ili jedna usporedba) isključi **cijelo područje** točaka.



Odjeljak 1 — Stablo raspona (1D)

Stablo raspona: definicija

Zadan je skup S od n brojeva. Upit $[lo, hi]$: vrati sve $x \in S$ s $lo \le x \le hi$.

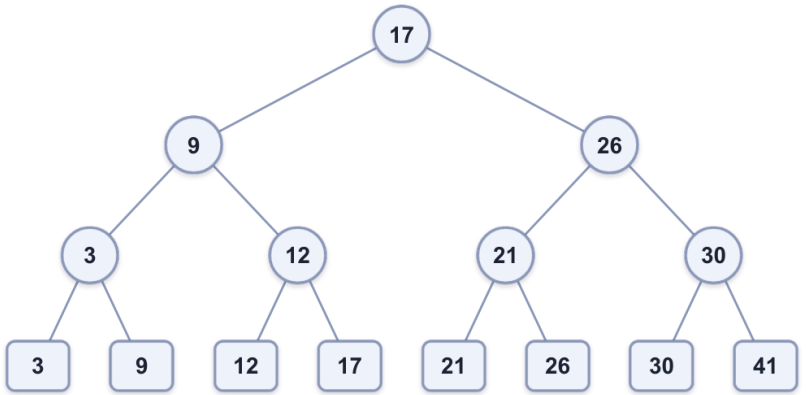
- Uravnoteženo binarno stablo; **listovi** sadrže ključeve sortirane slijeva nadesno.
- Unutarnji čvor v čuva **split(v) = najveći ključ u lijevom podstablu**.
- Lijevo podstablo dobiva $\lceil n/2 \rceil$ ključeva.
- **Invarijanta:** ključevi lijevo $\le$ split(v) $<$ ključevi desno.
- Dubina $\lceil \log_2 n \rceil$, ukupno $2n - 1$ čvorova.

Gradnja korak po korak

S = {3, 9, 12, 17, 21, 26, 30, 41} (već sortirano).

1. Korijen: {3, 9, 12, 17} | {21, 26, 30, 41} → split = **17**
2. Lijevo {3, 9, 12, 17}: {3, 9} | {12, 17} → **9** · desno {21, 26, 30, 41}: {21, 26} | {30, 41} → **26**
3. {3, 9} → **3** · {12, 17} → **12** · {21, 26} → **21** · {30, 41} → **30**
4. Svaki jednočlani skup je list.

```
              17
       9                26
   3       12       21       30
  3  9   12  17   21  26   30  41
```



Squares: the keys, sorted, in the leaves.
Circles: each holds the largest key on its left.

Upit: čvor razdvajanja i dvije šetnje

1. **Čvor razdvajanja:** od korijena se spuštaj dok je cijeli raspon s jedne strane: ako $hi <$ split(v) → lijevo; ako split(v) $< lo$ → desno. Prvi čvor gdje ne vrijedi ni jedno ni drugo je čvor razdvajanja v.
2. **Lijeva šetnja** od lijevog djeteta od v: ako $lo \leq$ split(w) → **prijavi desno podstablo cijelo**, idi lijevo; inače idi desno. Na listu provjeri ključ.
3. **Desna šetnja** od desnog djeteta od v (zrcalno): ako split(w) $\leq hi$ → **prijavi lijevo podstablo cijelo**, idi desno; inače idi lijevo. Na listu provjeri ključ.

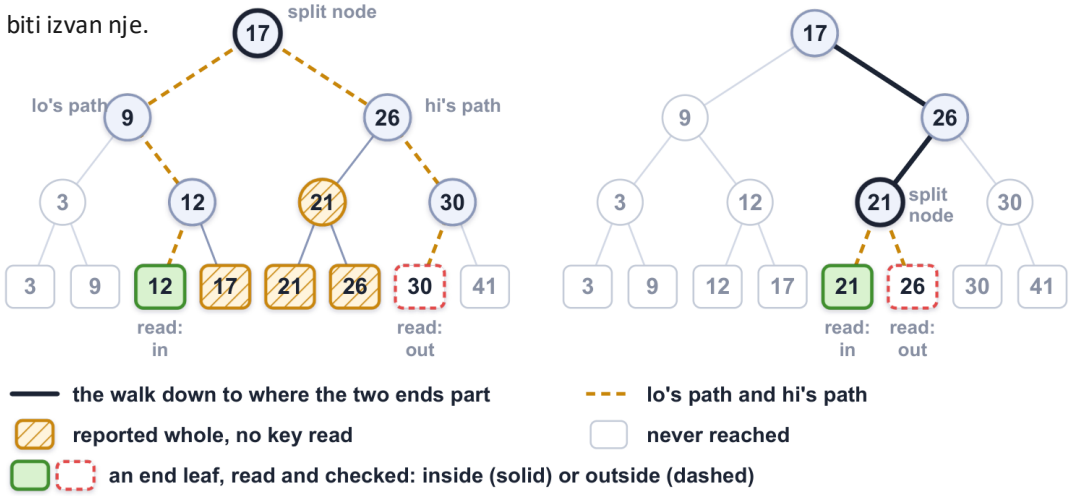
"Prijavi cijelo" = ispiši sve listove podstabla **bez ijedne usporedbe** → *kanonska podstabla*.

Upit [10, 28] korak po korak, složenost i 2D

korak	čvor	test	akcija
1	17	10 ≤ 17 ≤ 28	korijen je čvor razdvajanja
2	9	9 < 10	idi desno
3	12	10 ≤ 12	prijavi {17} cijelo, idi lijevo
4	list 12	10 ≤ 12 ≤ 28	prijavi 12
5	26	26 ≤ 28	prijavi {21, 26} cijelo, idi desno
6	30	28 < 30	idi lijevo
7	list 30	30 > 28	odbaci

Odgovor: 12, 17, 21, 26. Uspoređena 2 lista; 3 ključa prijavljena bez usporedbe; 3, 9, 41 nikad posjećeni.

- Složenost upita: **O(log *n* + *k*)**, memorija O(*n*).
- 2D (pravokutnik): na svakom čvoru stablo po *y* za točke podstabla → upit O(log² *n* + *k*), memorija O(*n* log *n*).
- Ograničenje: upit raspona **ne odgovara** na "najbliže" — kutija oko *q* može biti prazna, a najbliža točka može biti izvan nje.



Odjeljak 2 — k-d stablo

k-d stablo: definicija

- Binarno stablo koje dijeli ravninu na pravokutnike.
- **Unutarnji čvor** čuva rez: os $a \in \{x, y\}$ i vrijednost s ("$x \leq 5$", "$y \leq 4$").
- **List** čuva jednu točku.
- Svaki čvor pokriva pravokutnik — **ćeliju**.
- **Invarijanta 1:** točke lijevo imaju a-koordinatu $\leq s$, točke desno $\geq s$.
- **Invarijanta 2:** svaki rez dijeli točke napola → dubina $\lceil \log_2 n \rceil$.

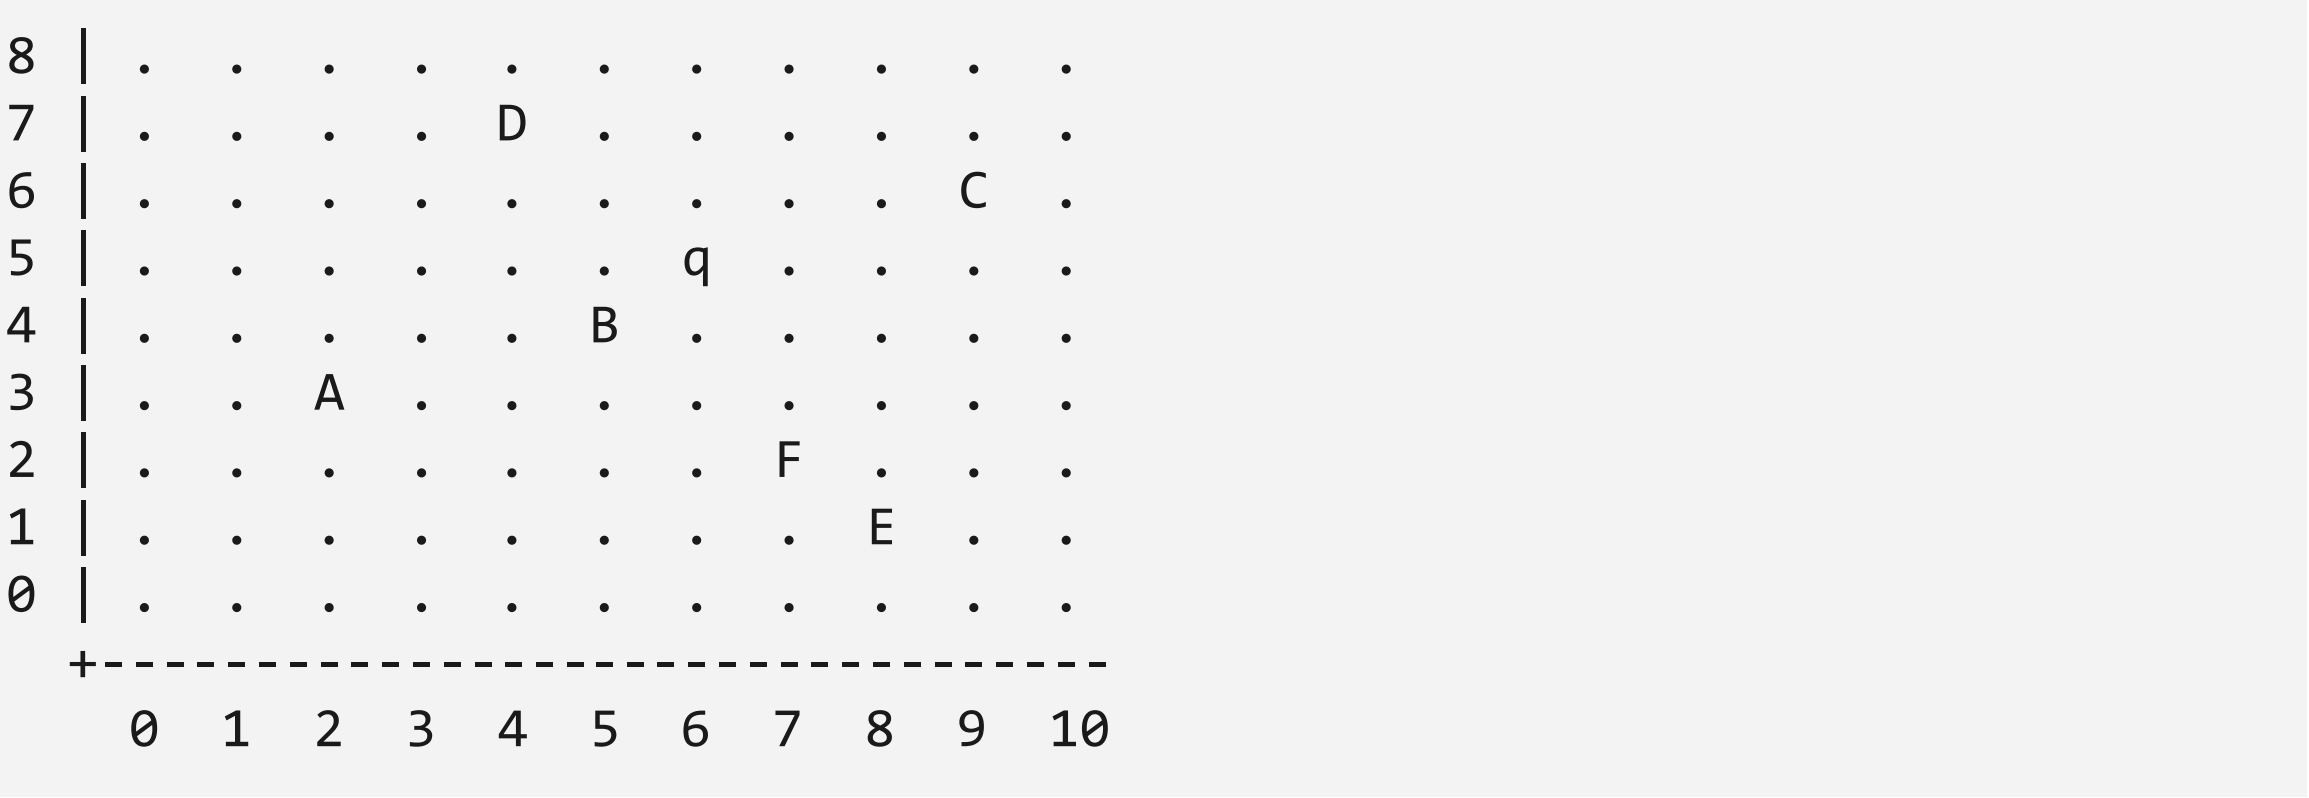
Pravilo gradnje

U čvoru sa skupom S na dubini t:

1. **Os:** x ako je t paran, y ako je neparan.
2. **Sortiraj** S po toj koordinati.
3. **Lijevo** dijete dobiva prvih $\lceil |S|/2 \rceil$ točaka, **desno** ostatak.
4. **Rez** prolazi kroz zadnju točku lijevog dijela: "os ≤ njezina koordinata".
5. Ako je $|S| = 1 \rightarrow$ **list**.

Primjer: šest točaka

A(2, 3), *B*(5, 4), *C*(9, 6), *D*(4, 7), *E*(8, 1), *F*(7, 2). Upit (kasnije): *q* = (6, 5).



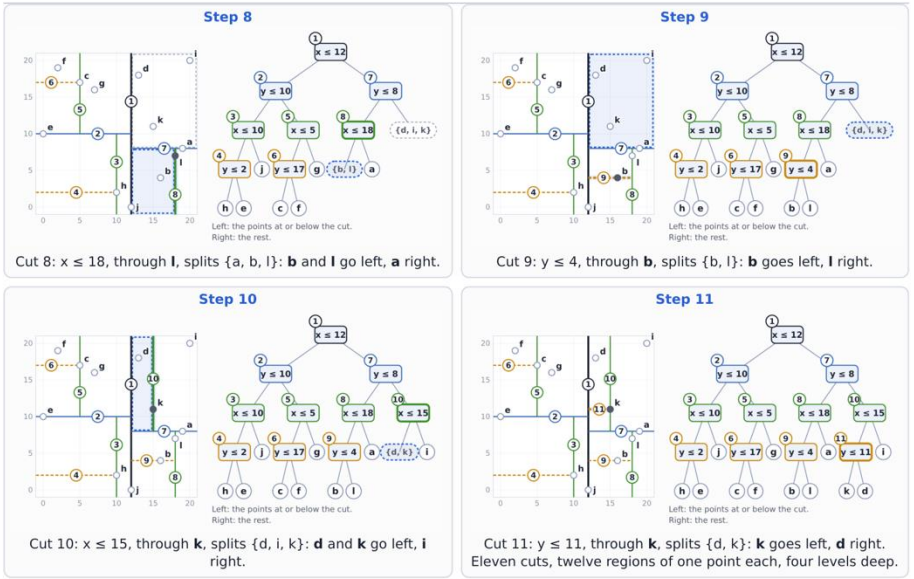
Gradnja, koraci 1–3 (lijeva polovica)

Korak 1 — korijen, 6 točaka, dubina 0, os *x*. Sortirano po *x*: *A*(2), *D*(4), ***B*(5)** | *F*(7), *E*(8), *C*(9). Lijevo ⌈6/2⌉ = 3. Rez **x ≤ 5**. Lijevo {*A*, *D*, *B*}, desno {*F*, *E*, *C*}.

Korak 2 — {*A*, *D*, *B*}, dubina 1, os *y*. Sortirano po *y*: *A*(3), ***B*(4)** | *D*(7). Lijevo ⌈3/2⌉ = 2. Rez **y ≤ 4**. Lijevo {*A*, *B*}, desno *D* (list).

Korak 3 — {*A*, *B*}, dubina 2, os *x*. Sortirano po *x*: ***A*(2)** | *B*(5). Rez **x ≤ 2**. Listovi *A* i *B*.

```
            x≤5
       y≤4          {F,E,C}
    x≤2    D
  A    B
```

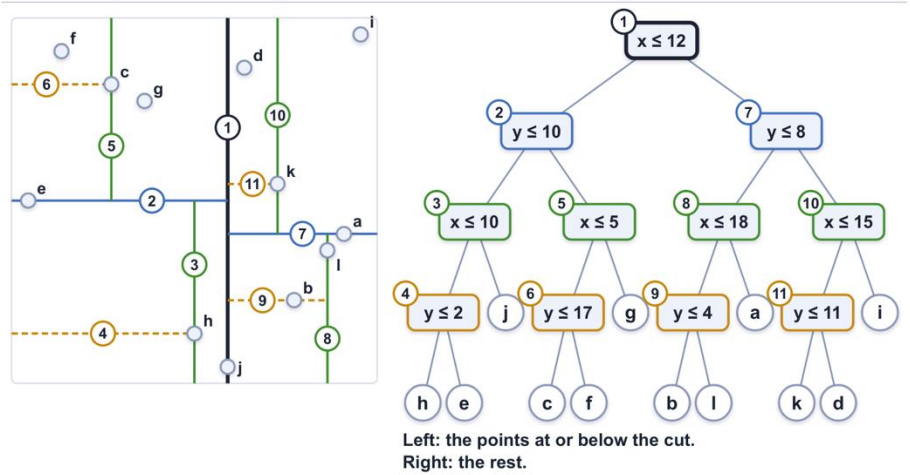


Gradnja, koraci 4–5 (desna polovica) i gotovo stablo

Korak 4 — {*F*, *E*, *C*}, dubina 1, os *y*. Sortirano po *y*: *E*(1), ***F*(2)** | *C*(6). Rez **y ≤ 2**. Lijevo {*E*, *F*}, desno *C* (list).

Korak 5 — {*E*, *F*}, dubina 2, os *x*. Sortirano po *x*: ***F*(7)** | *E*(8). Rez **x ≤ 7**. Listovi *F* i *E*.

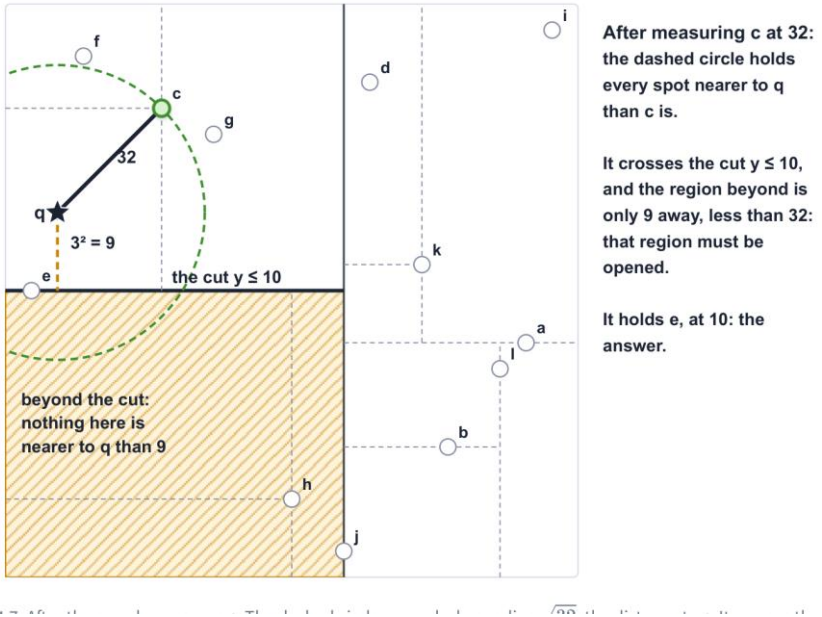
```
                x≤5
        y≤4                 y≤2
    x≤2     D           x≤7     C
  A    B                F    E
```



5 rezova, 6 listova, 3 razine. Gradnja: O(*n* log *n*) (svaka os se sortira jednom; podjela sortiranih lista čuva poredak).

Ključna ideja pretraživanja: donja granica ćelije

- Za ćeliju *C* i točku *q* drži **pomak po svakoj osi**: koliko je *q* udaljen od *C* po toj osi (0 ako je *q* unutar raspona ćelije po toj osi).
- **bound(*C*) = pomak$_x^2$ + pomak$_y^2$**
- **Lema:** bound(*C*) ≤ $d^2(p, q)$ za svaku točku $p \in C$.
- Pri dijeljenju čvora s rezom na osi *a* u vrijednosti *s*:
  - **bliže** dijete (strana na kojoj je *q*) zadržava roditeljeve pomake;
  - **dalje** dijete: pomak na osi *a* postaje $s - q_a$, ostali ostaju isti.



Algoritam: pretraživanje "najbolji prvi"

```
Q ← {(0, korijen)};  best ← ∞
dok Q nije prazan:
    (β, v) ← izvadi-min(Q)
    ako β > best: STOP
    ako je v list: best ← min(best, d²(p_v, q))
    inače:
        bliže ← dijete na strani od q   (q_a ≤ s → lijevo)
        dalje ← drugo dijete
        umetni (β, bliže)
        umetni (bound s pomakom_a = s − q_a, dalje)
```

- *Q* je **prioritetni red** (gomila) poredan po granici.
- Uvijek se otvara ćelija s **najmanjom** granicom.
- Zaustavljanje je strogo (>): ćelija s granicom jednakom *best* ipak se otvara (izjednačenja).

Pretraživanje $q = (6, 5)$, koraci 1–3

Za provjeru — prave kvadratne udaljenosti: *A* 20, ***B* 2**, *C* 10, *D* 8, *E* 20, *F* 10.

Korak 1. Otvori korijen (rez $x \le 5$). $q_x = 6 > 5 \rightarrow$ *q* je desno. Bliže {*F*, *E*, *C*}: pomaci (0, 0), granica **0**. Dalje {*A*, *D*, *B*}: $\text{pomak}_x = 5 - 6 = -1$, granica **1**. *Q*: {*F*,*E*,*C*} 0 · {*A*,*D*,*B*} 1 · *best* = ∞

Korak 2. Otvori {*F*, *E*, *C*} (0), rez $y \le 2$. $q_y = 5 > 2 \rightarrow$ desno. Bliže {*C*}: granica **0**. Dalje {*E*, *F*}: $\text{pomak}_y = 2 - 5 = -3$, granica **9**. *Q*: {*C*} 0 · {*A*,*D*,*B*} 1 · {*E*,*F*} 9

Korak 3. Otvori {*C*} (0) — list, izmjeri: $(9 - 6)^2 + (6 - 5)^2 =$ **10**. *best* = 10. *Q*: {*A*,*D*,*B*} 1 · {*E*,*F*} 9 — najmanja granica 1 < 10 → nastavi.

Pretraživanje, koraci 4–8

Korak 4. Otvori {*A*, *D*, *B*} (1, pomaci (−1, 0)), rez $y \le 4$. $q_y = 5 > 4$ → desno. Bliže {*D*}: pomaci (−1, 0), granica **1**. Dalje {*A*, *B*}: pomaci (−1, 4 − 5) = (−1, −1), granica **2**. *Q*: {*D*} 1 · {*A*,*B*} 2 · {*E*,*F*} 9

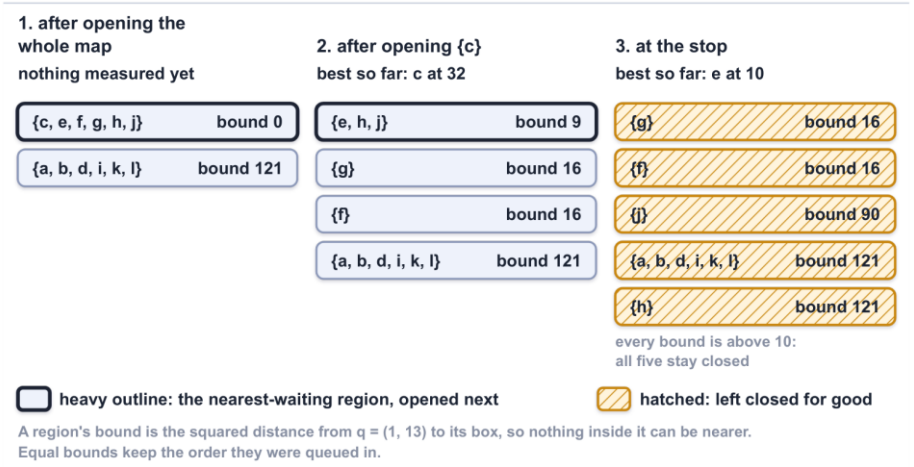
Korak 5. Otvori {*D*} (1) — list: $(4 - 6)^2 + (7 - 5)^2 = \mathbf{8}$. *best* = 8. Najmanja granica 2 < 8 → nastavi.

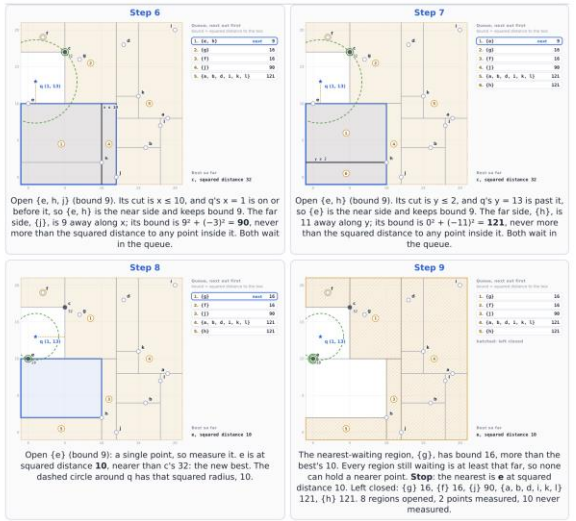
Korak 6. Otvori {*A*, *B*} (2, pomaci (−1, −1)), rez $x \le 2$. $q_x = 6 > 2$ → desno. Bliže {*B*}: granica **2**. Dalje {*A*}: pomaci (2 − 6, −1) = (−4, −1), granica 16 + 1 = **17**. *Q*: {*B*} 2 · {*E*,*F*} 9 · {*A*} 17

Korak 7. Otvori {*B*} (2) — list: $(5 - 6)^2 + (4 - 5)^2 = \mathbf{2}$. *best* = 2.

Korak 8. Najmanja granica u *Q* je 9 > 2 → **STOP**.

Odgovor: *B*. Izmjerene 3 točke (*C*, *D*, *B*); *A*, *E*, *F* nikad izmjerene.





Ispravnost: zašto je sigurno ne otvoriti ćeliju

Lema: bound(C) ≤ $d^2(p, q)$ za svaki $p \in C$. Dokaz indukcijom po dubini:

- **Korijen:** svi pomaci 0 → granica 0 ≤ svaka udaljenost.
- **Bliže dijete:** nasljeđuje pomake, sadrži podskup točaka. ✓
- **Dalje dijete:** rez u s, $q_a \le s$. Po invarijanti 1 svaka točka desno ima $p_a \ge s$, pa $(s - q_a)^2 \le (p_a - q_a)^2$. Ostale osi nepromijenjene. ✓ (Zrcalno za $q_a > s$.)

Teorem: pretraživanje vraća isti odgovor kao linearni pregled. Kad je najmanja granica u Q veća od *best*, svaka neotvorena ćelija ima samo točke udaljenije od *best*.

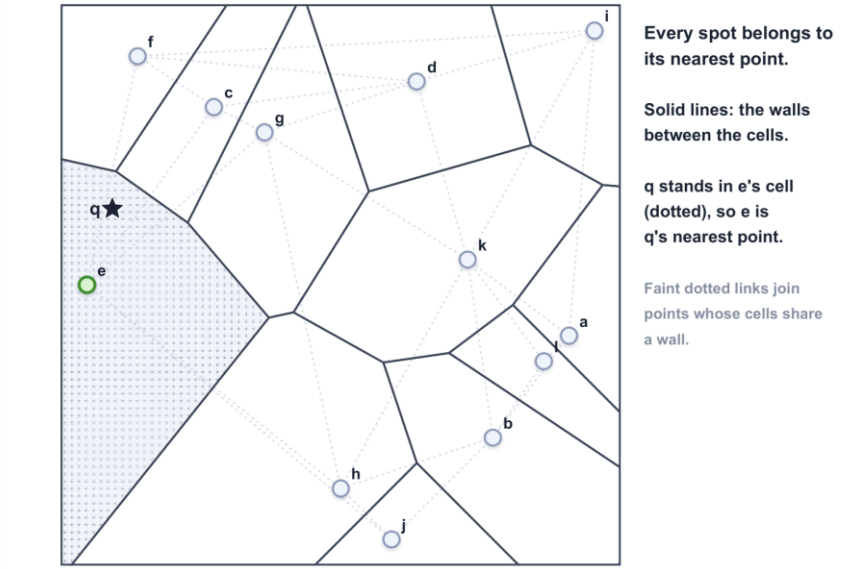
Složenost i mjerenja

	cijena
gradnja	O(n log n)
memorija	O(n), 2n − 1 čvorova
najbliži susjed, najgori slučaj	O(n) — otvore se sve ćelije
najbliži susjed, očekivano (slučajne točke, mali d)	O(log n)
upit pravokutnikom u 2D	O(√n + k)

- Izmjereno (knjiga): 1 000 000 jednoliko raspoređenih točaka → prosječno **3,93 izmjerene točke** po upitu, ~30 otvorenih ćelija, ~830 000 upita/s.
- k najbližih: drži k najboljih u max-gomili; stani kad je najmanja granica > k-ti najbolji.
- Do 8 točaka po listu: +23 % brže (manje stablo, bolja lokalnost u memoriji), iako se mjeri ~14 točaka.

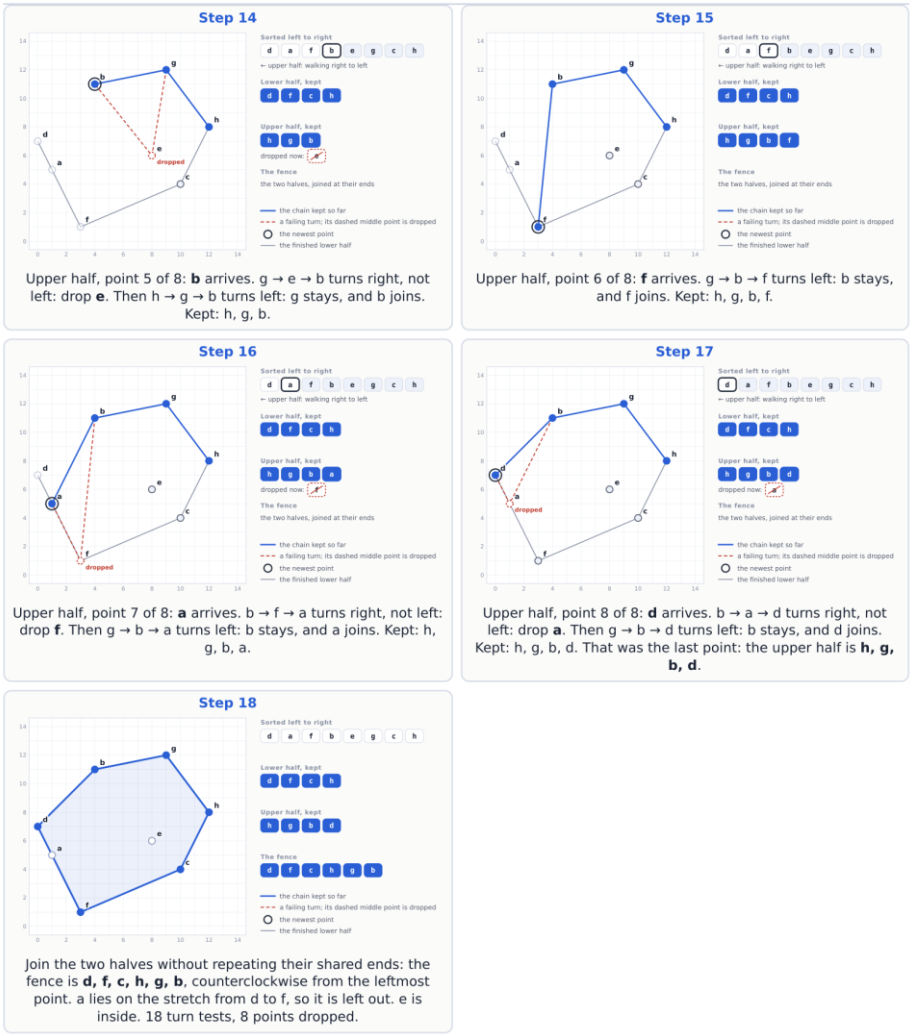
Crtica: Voronojev dijagram

- Svaku točku ravnine dodijeli najbližoj točki iz P → ćelije koje popločavaju ravninu.
- Upit najbližeg susjeda = "u kojoj je ćeliji q?" (problem pošte).
- Ćelija dijeli granicu s malo susjeda, raspoređenih u različitim smjerovima — ta ideja temelj je grafovskog indeksa (HNSW, za doma).



Crtica: konveksna ljuska

- Najmanji konveksni mnogokut koji sadrži sve točke.
- Test orijentacije: orient(p, q, r) = $(q_x - p_x)(r_y - p_y) - (q_y - p_y)(r_x - p_x)$; > 0 lijevo skretanje, < 0 desno, = 0 kolinearno.
- Andrewov monotoni lanac: sortiraj po x; gradi donji, zatim gornji lanac; izbaci zadnju točku dok zadnje tri ne skreću strogo lijevo.
- O(n log n) (sortiranje) + O(n) (amortizirano: svaka točka jednom ulazi i najviše jednom izlazi).



Bilanca i pretpostavka koja će pasti

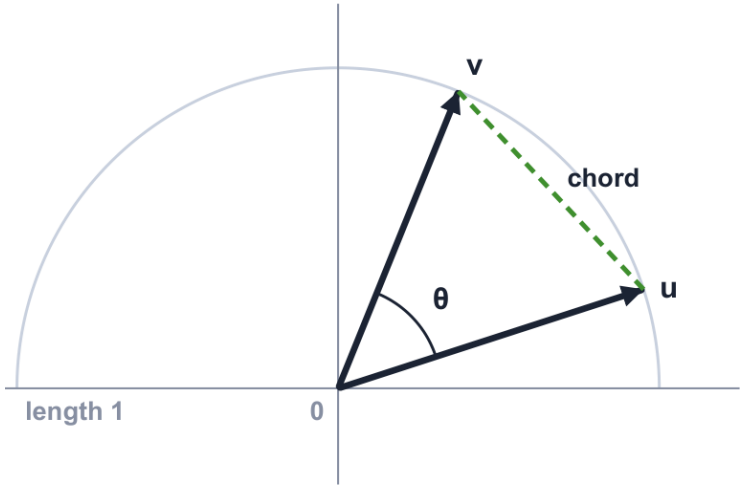
struktura	**priprema**	**upit**	**odgovara na**
linearni pregled	ništa	$O(nd)$	sve
stablo raspona	$O(n \log n)$	$O(\log n + k)$	raspon (2D: $O(\log^2 n + k)$)
k-d stablo	$O(n \log n)$	~4 točke od 10^6 (2D)	najbliži, *k* najbližih, pravokutnik

- Pretpostavka k-d stabla: **intrinzična dimenzija podataka je niska**.
- Pitanje za pauzu: što se dogodi s granicama ako svaka točka ima 500 koordinata?

Odjeljak 4 — Prokletstvo dimenzionalnosti

Točke s mnogo koordinata: definicije

- **Vektorska reprezentacija (*embedding*):** objekt (riječ, slika, dokument, mjesto) → vektor u $\mathbb{R}^d$, d ~ 100–1000; slični objekti → slični vektori.
- **Kosinusna sličnost:** $\cos\theta = (u \cdot v) / (\|u\| \, \|v\|)$.
- Ako su svi vektori normirani ($\|u\| = 1$): $\mathbf{d^2(u, v) = 2 - 2\cos\theta}$ → najbliži po udaljenosti = najsličniji po kosinusu.
- **Odziv@k** (*recall@k*): udio pravih k najbližih koje je metoda vratila, prosjek po upitima.
- Svaku približnu metodu mjerimo s **dva broja**: odziv i broj upita u sekundi.



Two descriptions scaled to length 1.

The squared length of the chord between their tips is

$\text{chord}^2 = 2 - 2\cos\theta$

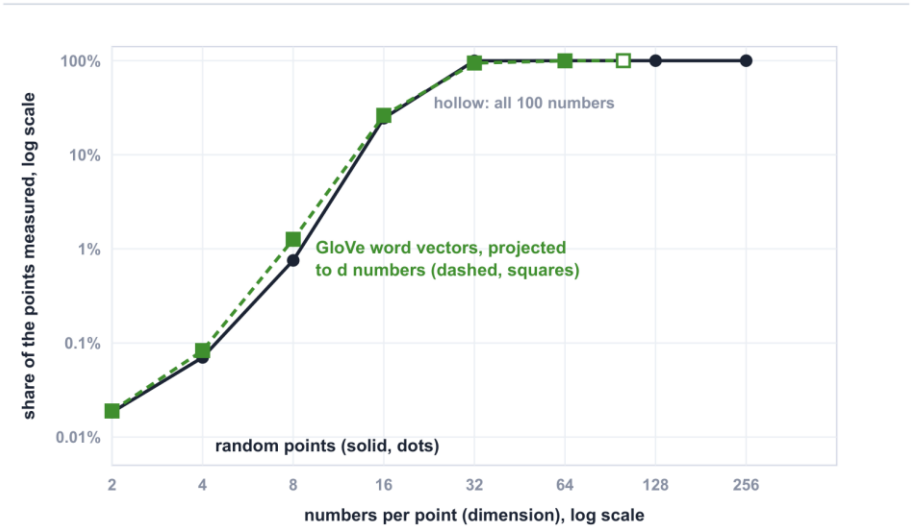
The smaller the angle, the shorter the chord: ranking by squared distance ranks by cosine.

k-d stablo u visokim dimenzijama: mjerenje

Udio točaka koje k-d stablo izmjeri (100 000 slučajnih točaka, 10 najbližih, prosjek 200 upita):

d	**2**	**4**	**8**	**16**	**32**	**≥ 64**
izmjereno	0,02 %	0,07 %	0,75 %	24,46 %	99,86 %	100 %

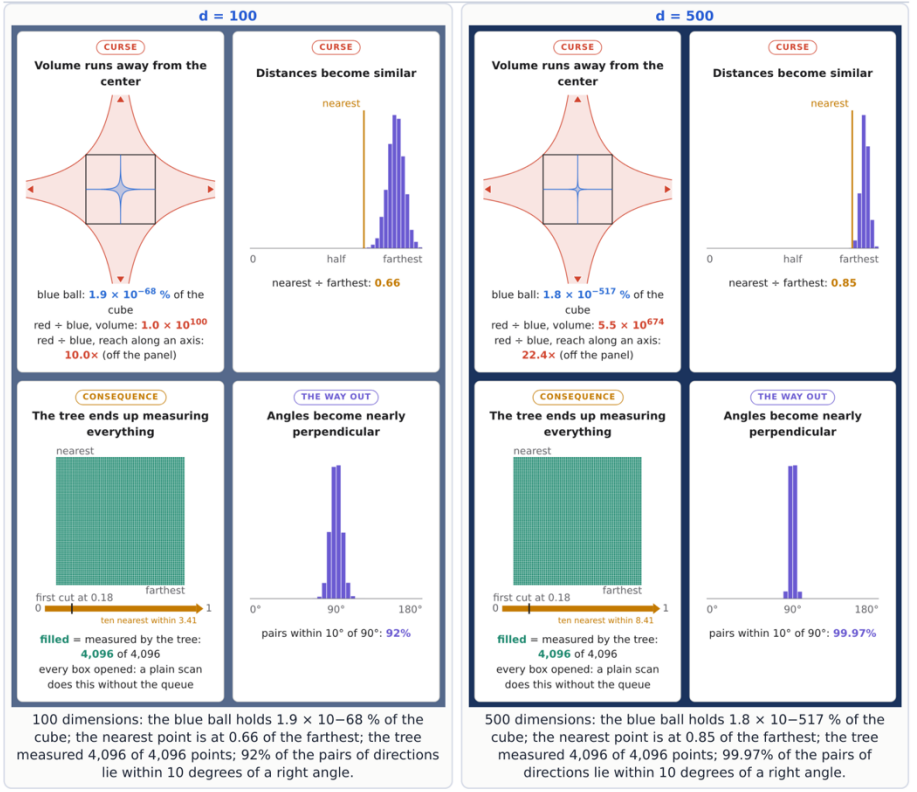
- GloVe (*d* = 100): izmjerene sve točke.
- Fashion-MNIST (*d* = 784): više od **10× sporije** od linearnog pregleda.
- Odgovor je i dalje točan — ali stablo je beskorisno.



Četiri pojave u visokim dimenzijama

	$d = 2$	$d = 10$	$d = 100$	$d = 500$
upisana kugla / volumen kocke	79 %	0,25 %	$1{,}9 \times 10^{-68}$ %	$1{,}8 \times 10^{-517}$ %
najbliža / najdalja udaljenost	0,01	0,19	0,66	0,85
k-d stablo izmjeri (od 4 096)	16	1 055	4 096	4 096
parovi slučajnih smjerova unutar 10° od 90°	11 %	39 %	92 %	99,97 %

1. **Volumen bježi iz središta** (gotovo sav volumen kugle je u tankoj vanjskoj ljusci).
2. **Udaljenosti se izjednačuju** (najbliža ≈ najdalja).
3. **Prostorna particija prestaje rezati** (kugla oko q presijeca gotovo sve ćelije).
4. **Slučajni smjerovi su gotovo okomiti** — jedina korisna pojava.



100 dimensions: the blue ball holds 1.9 × 10−68 % of the cube; the nearest point is at 0.66 of the farthest; the tree measured 4,096 of 4,096 points; 92% of the pairs of directions lie within 10 degrees of a right angle.

500 dimensions: the blue ball holds 1.8 × 10−517 % of the cube; the nearest point is at 0.85 of the farthest; the tree measured 4,096 of 4,096 points; 99.97% of the pairs of directions lie within 10 degrees of a right angle.

Slučajne projekcije i Johnson–Lindenstraussova lema

- Projekcija vektora x na slučajni jedinični smjer r: $x \cdot r$. Za $x \in \mathbb{R}^d$, $E[(x \cdot r)^2] = \|x\|^2/d$.
- Procjena $\|x\|^2 \approx (d/m) \Sigma_j (x \cdot r_j)^2$ iz m projekcija. Za $\|x\| = 1$, $d = 100$:

m	pet pokušaja	tipično odstupanje
1	0,13 · 0,07 · 1,45 · 0,20 · 1,76	1,42
20	0,67 · 0,51 · 0,73 · 0,65 · 0,82	0,30
80	0,98 · 1,05 · 1,06 · 0,92 · 0,85	0,16

- **JL lema:** $m = O(\log n / \varepsilon^2)$ slučajnih smjerova čuva sve udaljenosti među n točaka unutar faktora $1 \pm \varepsilon$, s velikom vjerojatnošću. m **ne ovisi** o d.
- Slučajni (a ne odabrani) smjerovi: nijedan skup podataka ne može se unaprijed namjestiti protiv njih.

Zaključak: prelazimo na približno pretraživanje

- Problem nije *d*, nego **intrinzična dimenzija** (u koliko se smjerova podaci stvarno šire). Grupirani podaci: stablo još može raditi.
- Za visoke *d* nije poznata metoda koja nalazi **točnog** najbližeg susjeda u bitno manje od O(*n*) mjerenja po upitu; takva metoda oborila bi jaku hipotezu eksponencijalnog vremena (SETH).
- **Približni najbliži susjed (ANN):** vrati kandidate, izmjeri ih točno, prihvati da ponekad promašiš; točnost se **mjeri** (odziv).

Odjeljak 5 — Lokalno osjetljivo raspršivanje (LSH)

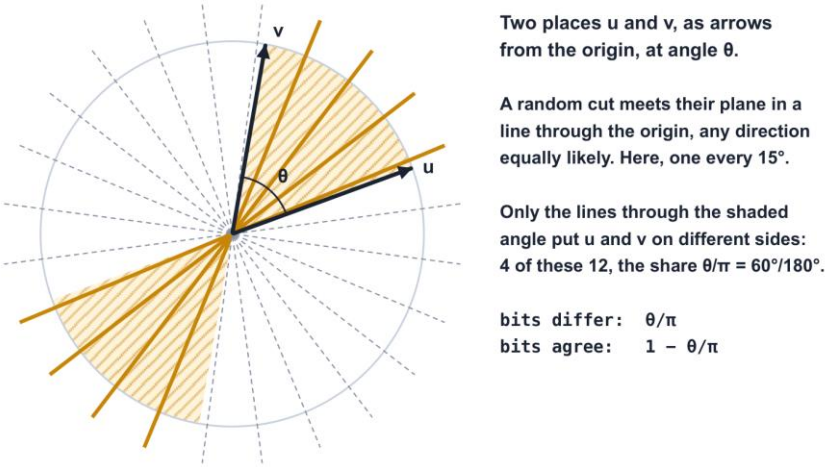
Ideja: namjerne kolizije

- Obična funkcija raspršivanja **rasipa** ključeve: bliski ključevi završe u nepovezanim pretincima.
- **LSH:** familija funkcija h takvih da je $\Pr[h(u) = h(v)]$ **velika** kad su u, v bliski, a **mala** kad su daleki.
- Shema:

  1. **Gradnja:** spremi svaku točku u pretinac $h(p)$.
  2. **Upit:** pogledaj samo pretinac $h(q)$ → **kandidati**.
  3. **Provjera:** svakom kandidatu izračunaj točnu udaljenost; vrati najbliži.

SimHash: jedan slučajni rez, jedan bit

- Izvuci slučajni vektor $r \in \mathbb{R}^d$, svaka koordinata iz N(0, 1).
- **Bit:** $h_r(p) = 1$ ako je $r \cdot p \geq 0$, inače 0.
- Geometrijski: hiperravnina kroz ishodište okomita na *r*; bit kaže s koje je strane *p* (test orijentacije iz konveksne ljuske!).
- **Lema:** za vektore *u*, *v* pod kutom θ: **$\Pr[h_r(u) = h_r(v)] = 1 - \theta/\pi$**.



Ključ od *K* bitova i *L* tablica

- **Ključ** u jednoj tablici: $g(p) = (h_1(p), \ldots, h_k(p))$ — *K* neovisnih rezova.
  - Pr[isti ključ] = $\mathbf{(1 - \theta/\pi)^K}$ → dulji ključ izbacuje daleke točke, ali i mnoge bliske.
- ***L* tablica**, svaka sa svojih *K* rezova; kandidat = točka koja dijeli ključ s *q* u **barem jednoj** tablici.
  - Pr[točka pod kutom θ postane kandidat] = $\mathbf{1 - (1 - (1 - \theta/\pi)^K)^L}$.
- Brojke za *K* = 8, *L* = 64:
  - θ = 45°: jedna tablica $0{,}75^8 \approx 0{,}10$; ukupno ≈ **0,999**.
  - θ = 90°: jedna tablica $0{,}5^8 = 1/256$; ukupno ≈ **0,22**.

Primjer: podaci i rezovi

Upit $q = (-7, 1)$. Osam točaka (sve na istoj kružnici, pa je najbliži po udaljenosti ujedno najbliži po kutu):

a (−5, 5), *b* (5, 5), *c* (−1, 7), *d* (5, −5), *e* (1, 7), *f* (−5, −5), *g* (1, −7), *h* (−7, −1)

$K = 3$ bita, $L = 2$ tablice. Rezovi (smjerovi *r*):

- Tablica 1: $r_1 = (0, 2)$, $r_2 = (3, -1)$, $r_3 = (-1, 2)$
- Tablica 2: $r_1 = (-3, -1)$, $r_2 = (-1, 3)$, $r_3 = (-3, -2)$

Za provjeru — prave kvadratne udaljenosti od *q*: *a* 20, *b* 160, *c* 72, *d* 180, *e* 100, *f* 40, *g* 128, ***h* 4**.

Gradnja tablice 1 korak po korak

Bit = 1 ako je $r \cdot p \geq 0$.

točka	$r_1 \cdot p$	$r_2 \cdot p$	$r_3 \cdot p$	ključ
q (−7, 1)	2	−22	9	**101**
a (−5, 5)	10	−20	15	101
b (5, 5)	10	10	5	111
c (−1, 7)	14	−10	15	101
d (5, −5)	−10	20	−15	010
e (1, 7)	14	−4	13	101
f (−5, −5)	−10	−10	−5	000
g (1, −7)	−14	10	−15	010
h (−7, −1)	−2	−20	5	001

Pretinci: 101 {*a*, *c*, *e*} · 111 {*b*} · 010 {*d*, *g*} · 000 {*f*} · 001 {*h*}

Gradnja tablice 2 korak po korak

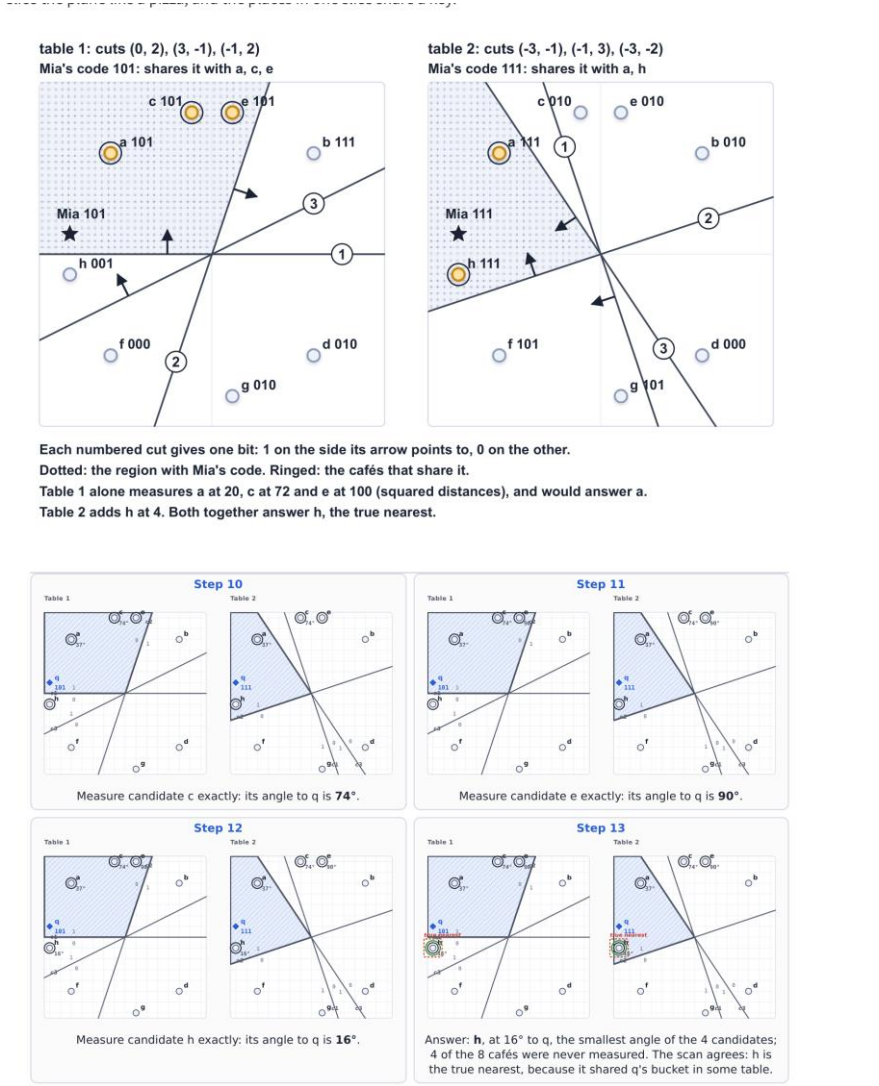
točka	$r_1 \cdot p$	$r_2 \cdot p$	$r_3 \cdot p$	ključ
q (−7, 1)	20	10	19	**111**
a (−5, 5)	10	20	5	111
b (5, 5)	−20	10	−25	010
c (−1, 7)	−4	22	−11	010
d (5, −5)	−10	−20	−5	000
e (1, 7)	−10	20	−17	010
f (−5, −5)	20	−10	25	101
g (1, −7)	4	−22	11	101
h (−7, −1)	22	4	23	111

Pretinci: 111 {*a*, *h*} · 010 {*b*, *c*, *e*} · 101 {*f*, *g*} · 000 {*d*}

Upit korak po korak

1. Tablica 1: ključ(q) = 101 → kandidati {a, c, e}.
2. Tablica 2: ključ(q) = 111 → kandidati {a, h}.
3. Unija kandidata: {a, c, e, h}.
4. Točna provjera: a 20, c 72, e 100, h **4**.
5. Odgovor: ***h*** — pravi najbliži susjed.

- Samo s tablicom 1 odgovor bi bio a (pogrešan, i to bez ikakvog upozorenja).
- b, d, f, g nikad izmjereni (4 od 8).



Jamstvo: vjerojatnost promašaja

$K = 8$, najbliži susjed pod kutom 45°. Promašaj u jednoj tablici: $1 - 0{,}75^8 \approx 0{,}90$; u L tablica: $0{,}90^L$.

L	**Pr[promašaj]**
1	0,90
8	0,43
16	0,18
32	0,034
64	0,0012
128	0,0000014

- Udvostručenje L **kvadrira** vjerojatnost promašaja.
- Jamstvo vrijedi za **svaki** skup podataka: jedina slučajnost su rezovi, izvučeni nakon što su podaci zadani.
- Zadaš kut θ i rizik δ → riješiš $(1 - (1 - \theta/\pi)^K)^L \leq \delta$ po L.

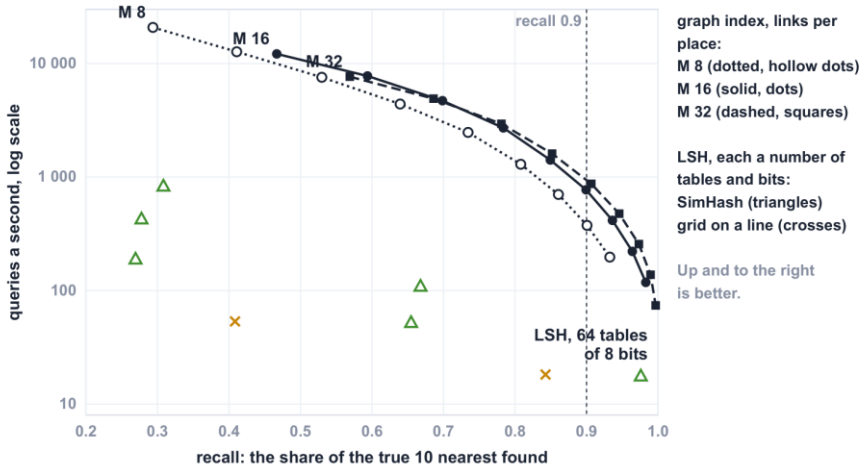
Složenost i mjerenja

	cijena
gradnja	$\Theta(nLKd)$
memorija	$\Theta(nL)$ unosa + točke
upit	$\Theta(LKd)$ za ključeve + d po kandidatu

- **Dobro:** gotovo-duplikati (pravi susjedi mnogo bliži od ostalih). Google: SimHash, 64-bitni otisak, 8 milijardi stranica; razlika ≤ 3 bita → gotovo-duplikat.
- **Loše:** GloVe (susjedi nisu bitno bliži od ostalih). $K = 8$, $L = 64$: odziv 0,976, ali izmjereno **39 %** podataka i **sporije od polovice** brzine linearnog pregleda.
- $K = 16$: ~50× brže, odziv 0,308. $L = 16$: 3× brže, odziv 0,655.
- Gotovo sve vrijeme odlazi na mjerenje kandidata (ključevi: 0,03 % vremena).
- *Multi-probe* LSH: pregledaj i susjedne pretince → isti odziv s manje tablica.

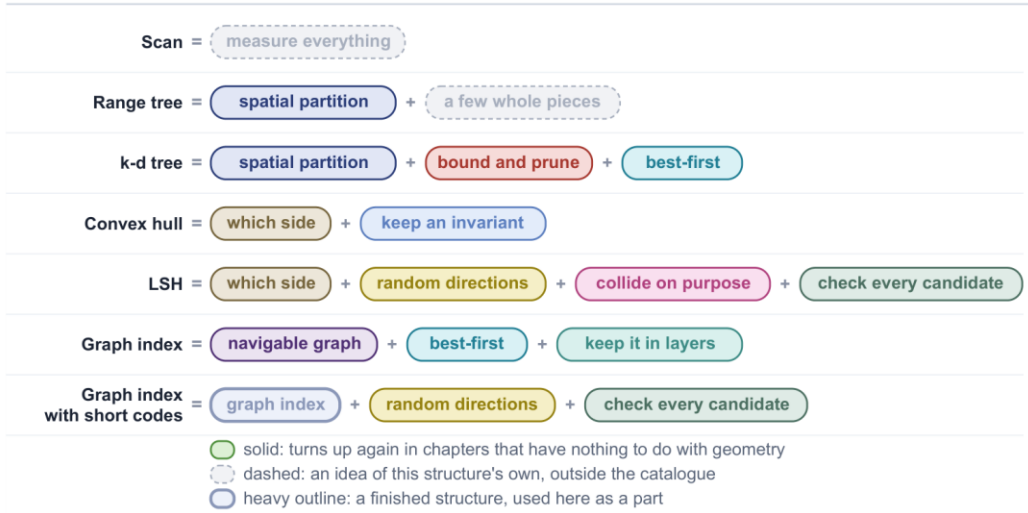
Reading between two widths

Over all 10,000 questions LSH reaches recall 0.9763. The two measured beam widths around it answer 221.7 questions a second at recall 0.9640 and 117.9 questions a second at recall 0.9828. Recall 0.9763 lies 65% of the way from 0.9640 to 0.9828, so on a log scale of speed the graph reads as $221.7 \times (117.9/221.7)^{0.654} \approx 147$ questions a second. LSH answers 17 questions a second.



Usporedba k-d stabla i LSH-a

	k-d stablo	LSH
rezovi	prema podacima (medijan)	slučajni, neovisni o podacima
odgovor	točan (dokazano)	točno izmjeren kandidat; može promašiti
dobar kad	niska intrinzična dimenzija	gotovo-duplikati, zadani rizik
kvar	točan, ali sporo (mjeri sve)	tiho vrati daljnju točku
sastavnice	particija + donja granica + "najbolji prvi"	test strane + slučajni smjerovi + namjerne kolizije + provjera



Odjeljak 6 — Zaključak i priprema za labos

Zaključak

- Niske dimenzije: prostorna particija + donja granica → **točan** odgovor, O(log *n*) očekivano.
- Visoke dimenzije: granice ne isključuju ništa → **približan** odgovor, točnost se mjeri odzivom.
- Iste ideje drugdje: granica i podrezivanje → alfa-beta u šahu, *branch and bound*; "najbolji prvi" → Dijkstra, A*; slučajne projekcije → skice podatkovnih tokova; "jeftini filtar + točna provjera" → Rabin–Karp, Bloomov filtar (obrnuti izbor).

Za doma: grafovski indeks (HNSW) — priprema za labos

Pročitati §4.8 (str. 43–58). Ideja: svaka točka povezana je s nekoliko bliskih točaka u **različitim smjerovima**; pretraživanje je šetnja po grafu prema *q*.

1. **Odabir susjeda** (§4.8.1): kandidati od najbližeg; preskoči kandidata koji je bliži već odabranom susjedu nego samoj točki. [Slika 4.19]
2. **Pohlepna šetnja i snop** (§4.8.2): pohlepna šetnja zapne u lokalnom minimumu; snop širine *ef* drži *ef* najboljih (isti prioritetni red kao kod k-d stabla). [Slika 4.18], [Slika 4.20], [Slika 4.21]
3. **Gradnja umetanjem** (§4.8.3): snop nađe kandidate, pravilo odabire *M* susjeda, veze u oba smjera; preopterećeni čvor ponovno bira. [Slika 4.22], [Slika 4.23]
4. **Slojevi** (§4.8.4): slučajne razine, spuštanje od vrha (kao preskočna lista). [Slika 4.24]
5. **Cijena** (§4.8.5–4.8.6): odziv naspram brzine kad raste *ef*; nema dokazanog jamstva. [Tablica 4.6], [Slika 4.25]

Pitanja za samoprovjeru: Gdje zapne pohlepna šetnja od *a* prema *q* = (12, 0) na slici 4.18 i koja bi je jedna veza "odglavila"? Zašto čvor *d* pri umetanju točke *i* izbacuje *g*, *a* i *e*? Što na GloVeu donosi povećanje *ef* sa 160 na 640?

