Transformacije slika

Prof. dr. sc. Sven Lončarić
http://www.fer.unizg.hr/ipg

Pregled tema

- Uvod
- 2-D linearne transformacije
- 2-D ortogonalne transformacije
- Matrični zapis 2-D ortogonalnih transformacija
- Pregled odabranih transformacija

Uvod

- Transformacije slike dio su šireg problema reprezentacije (predstavljanja) slike
- Jedan logičan pristup predstavljanja složene cjeline (npr. slike) je pomoću rastava u jednostavne komponente
- Najjednostavniji pristup reprezentaciji slika je pomoću linearnih transformacija
- Osim linearnih postoje i nelinearne transformacije, ali one su matematički složenije za primjenu

Uvod

- Kod linearnih transformacija uvijek imamo par transformacija: izravnu i inverznu transformaciju
- Izravna ili direktna transformacija nam kao rezultat daje niz koeficijenata
- Inverzna transformacija koristi te koeficijente kao težine s kojom se množe jednostavne komponente i sve zajedno zbrojeno onda daje originalnu sliku
- Slika je linearna kombinacija osnovnih komponenti
- To je jedan način reprezentacije slike

Uvod

- Transformacije slika su važne za mnoga područja digitalne obrade slike
- Transformacije slike koriste se za poboljšanje, obnavljanje, kodiranje i opis slika
- Transformacije i dalje predstavljaju jedno od područja intenzivnog znanstvenog istraživanja
- Linearne transformacije su pogodnije za korištenje od nelinearnih

2-D linearne transformacije

- 2-D transformacija slike (diskretnog niza) $u(m,n)$ dimenzija $N \times N$ je opisana parom jednadžbi:

$$v(k,l) = \sum_{m=0}^{N-1} \sum_{n=0}^{N-1} a_{k,l}(m,n)\, u(m,n), \quad 0 \le k,l \le N-1$$

$$u(m,n) = \sum_{k=0}^{N-1} \sum_{l=0}^{N-1} b_{m,n}(k,l)\, v(k,l), \quad 0 \le m,n \le N-1$$

gdje su $a_{k,l}(m,n)$ i $b_{m,n}(k,l)$ jezgra transformacije i jezgra inverzne transformacije

Separabilne 2-D transformacije

- Jezgra transformacije je separabilna ako vrijedi:

$$a_{k,l}(m,n) = c_k(m)\, d_l(n)$$

- Jezgra transformacije je simetrična ako vrijedi:

$$c_k(m) = d_k(m), \quad \forall k, m$$

Primjer separabilne 2-D transformacije

- jezgra 2-D Fourierove transformacije:

$$a_{k,l}(m,n)=\frac{1}{N}\exp\left[-\frac{j2\pi(mk+nl)}{N}\right]=c_k(m)\,d_l(n)$$

gdje je:

$$c_k(m)=\frac{1}{\sqrt{N}}\exp\left(-\frac{j2\pi\,mk}{N}\right)$$

$$d_l(n)=\frac{1}{\sqrt{N}}\exp\left(-\frac{j2\pi\,nl}{N}\right)$$

- jezgra 2-D F.T. je također simetrična

2-D ortogonalne transformacije

- 2-D ortogonalna transformacija slike $u(m,n)$ dimenzija $N \times N$ se može prikazati parom jednadžbi:

$$v(k,l) = \sum_{m=0}^{N-1} \sum_{n=0}^{N-1} a_{k,l}(m,n)\, u(m,n), \quad 0 \le k,l \le N-1$$

$$u(m,n) = \sum_{k=0}^{N-1} \sum_{l=0}^{N-1} a^{*}_{k,l}(m,n)\, v(k,l), \quad 0 \le m,n \le M-1$$

gdje je $a_{k,l}(m,n)$ jezgra transformacije, koja je skup ortonormalnih 2-D funkcija (baza)

Separabilnost i simetričnost ortogonalnih 2-D transformacija

- 2-D transformacija je separabilna ako vrijedi:

$$a_{k,l}(m,n)=a_k(m)b_l(n)=a(k,m)b(l,n)$$

gdje su

$$\{a_k(m),k=0,\ldots,N-1\},\{b_l(n),l=0,\ldots,N-1\}$$

1-D ortonormalni skupovi vektora, tj. matrice **A**={*a*(*k,m*)}, **B**={*b*(*l,n*)} su unitarne matrice

- 2-D transformacija je simetrična ako je **A**=**B**

Jednadžbe separabilne i simetrične 2-D transformacije

- Za separabilnu i simetričnu 2-D transformaciju jednadžbe su dane sa:

$$v(k,l)=\sum_{m=0}^{N-1}\sum_{n=0}^{N-1} a(k,m)u(m,n)a(l,n), \qquad 0\le k,l\le N-1$$

$$u(m,n)=\sum_{k=0}^{N-1}\sum_{l=0}^{N-1} a^{*}(k,m)v(k,l)a^{*}(l,n), \quad 0\le m,n\le M-1$$

Matrična formulacija separabilne i simetrične 2-D transformacije

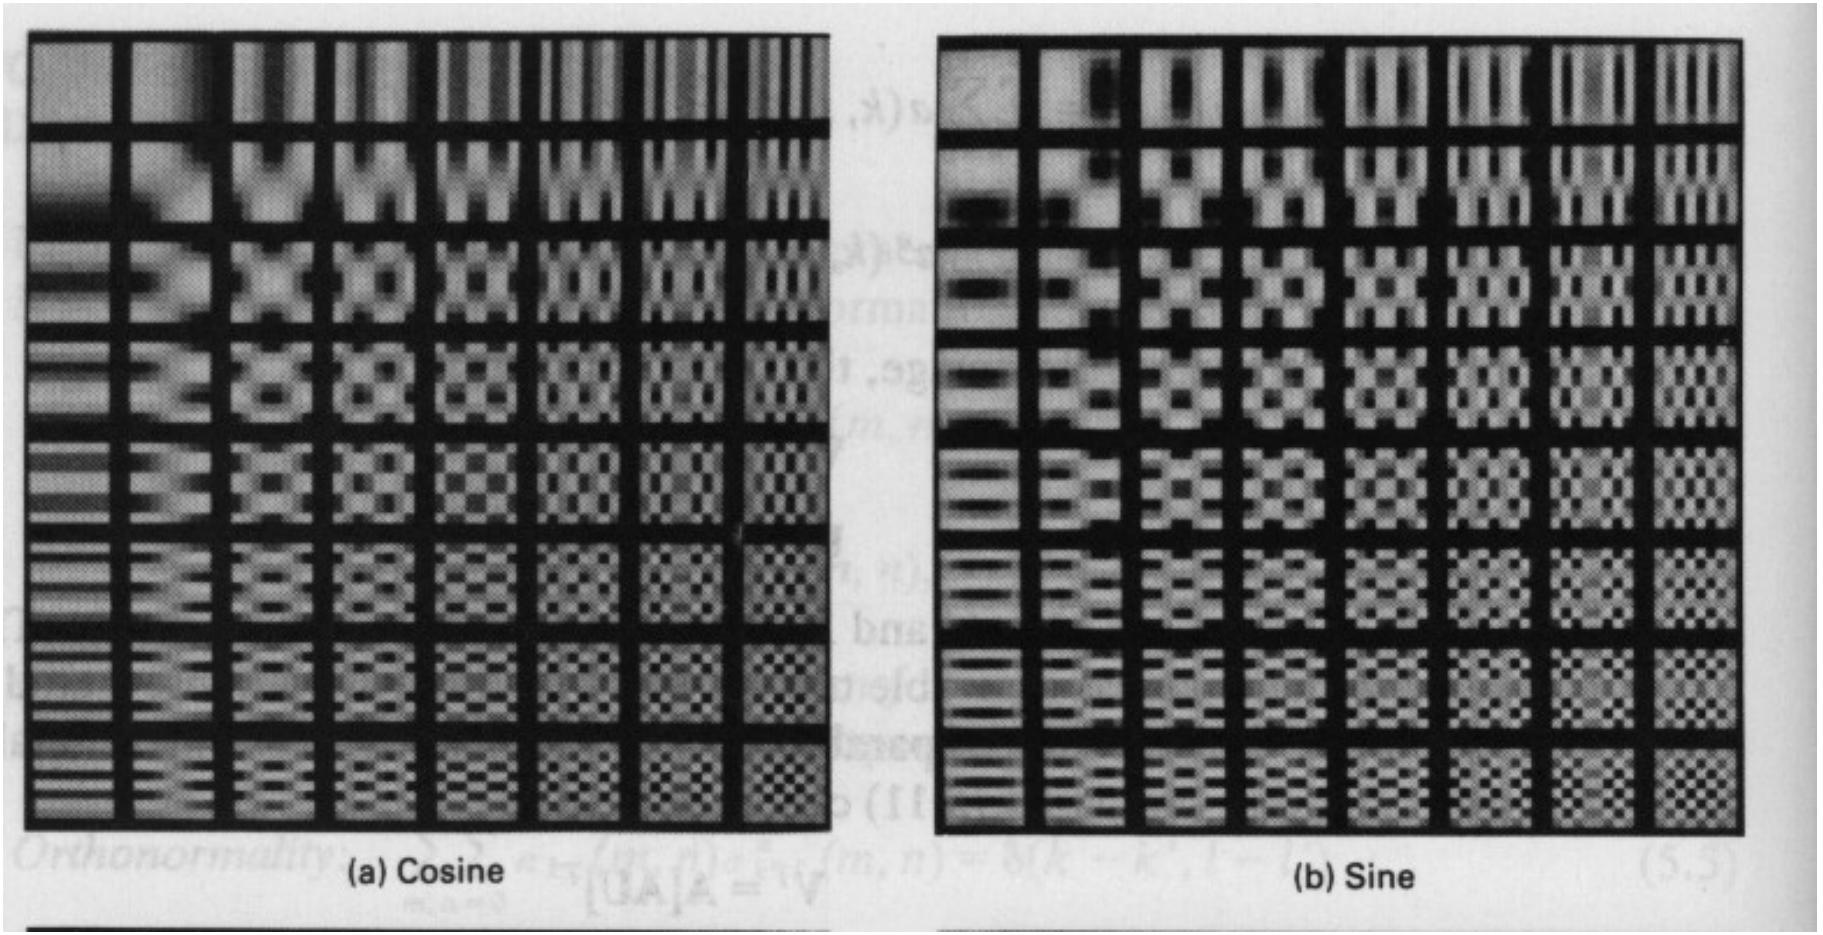
- Matrična formulacija separabilne i simetrične 2-D transformacije dana je sa:

$$V = \mathbf{A}\mathbf{U}\mathbf{A}^{T}$$
$$U = \mathbf{A}^{T*}\mathbf{V}\mathbf{A}^{*}$$

gdje je **U** $N \times N$ matrica slike, **V** je $N \times N$ transformacija slike, a **A** je unitarna matrica transformacije dimenzija $N \times N$ definirana ranije kao: $\mathbf{A}=\{a(k,m)\}$

Primjeri baza ortogonalnih transformacija

- Baze kosinusne i sinusne transformacije 8×8



Svojstva ortogonalnih transformacija

- Očuvanje energije
- Raspodjela energije
- Nekoreliranost koeficijenata transformacije

Očuvanje energije

- Tvrdnja: neka je **v=Au** gdje je **A** unitarna matrica, tada vrijedi:

$$\|v\| = \|u\|$$

- Dokaz:

$$\|v\|^2 = v^H v = u^H A^H \mathbf{A}\mathbf{u} = u^H u = \|u\|^2$$

- Interpretacija: 1-D unitarna transformacija samo rotira vektor **u** u *N*-dimenzionalnom vektorskom prostoru (ne mijenja duljinu vektora)
- Očuvanje energije vrijedi i za 2-D unitarne transformacije

Raspodjela energije

- Raspodjela ili pakiranje energije: većina ortogonalnih transformacija pakira veliki dio srednje energije u svega nekoliko koeficijenata tj. ostali koeficijenti sadrže mali dio energije
- Raspodjela energije je važna npr. kod kompresije slika gdje je poželjno koristiti takvu transformaciju koja za određenu klasu slika pakira maksimalnu količinu energiju u što manji broj koeficijenata

Nekoreliranost

- Nekoreliranost ili dekorelacija je tendencija koeficijenata transformacije (elemenata vektora **v**) da su obično nekorelirani ako su elementi ulaznog vektora **u** korelirani
- Kod većine realnih slika postoji jaka koreliranost u vrijednostima susjednih piksela
- Elementi izvan dijagonale kovarijancijske matrice izlaznog slučajnog vektora su mali u usporedbi s dijagonalnim elementima
- U ekstremnom slučaju potpune nekoreliranosti kovarijancijska matrica vektora **v** postaje dijagonalna

Pregled odabranih diskretnih transformacija

- Fourier-ova transformacija
- Kosinusna transformacija
- Karhunen-Loeve transformacija

Unitarna 2-D DFT

- Unitarna 2-D DFT je definirana sa:

$$v(k,l)=\frac{1}{N}\sum_{m=0}^{N-1}\sum_{n=0}^{N-1}u(m,n)W_N^{km}W_N^{\ln},\qquad 0\le k,l\le N-1$$

$$u(m,n)=\frac{1}{N}\sum_{k=0}^{N-1}\sum_{l=0}^{N-1}v(k,l)W_N^{-km}W_N^{-\ln},\quad 0\le m,n\le N-1$$

gdje je: $W_N=\mathrm{e}^{-\frac{j2\pi}{N}}$

Matrični zapis unitarne 2-D DFT

- Matrica **F** za Fourierovu transformaciju definirana je:

$$\mathbf{F} = \{f_{kn}\} = \left\{ \frac{1}{\sqrt{N}} W_N^{kn} \right\}, \quad 0 \le k, n \le N-1$$

- 2-D DFT (direktna i inverzna transformacija) može se izraziti matrično kao:

$$\mathbf{V} = \mathbf{FUF}$$
$$\mathbf{U} = \mathbf{F^*VF^*}$$

gdje je matrica **U** ulazna slika, a **V** matrica koeficijenata, a * označava operaciju kompleksne konjugacije

Primjer 2-D DFT

- 2-D unitarna DFT slike dimenzija 256×256
- Prikazane su:
  - originalna slika,
  - fazna karakteristika,
  - amplitudna karakteristika i
  - centrirana amplitudna karakteristika

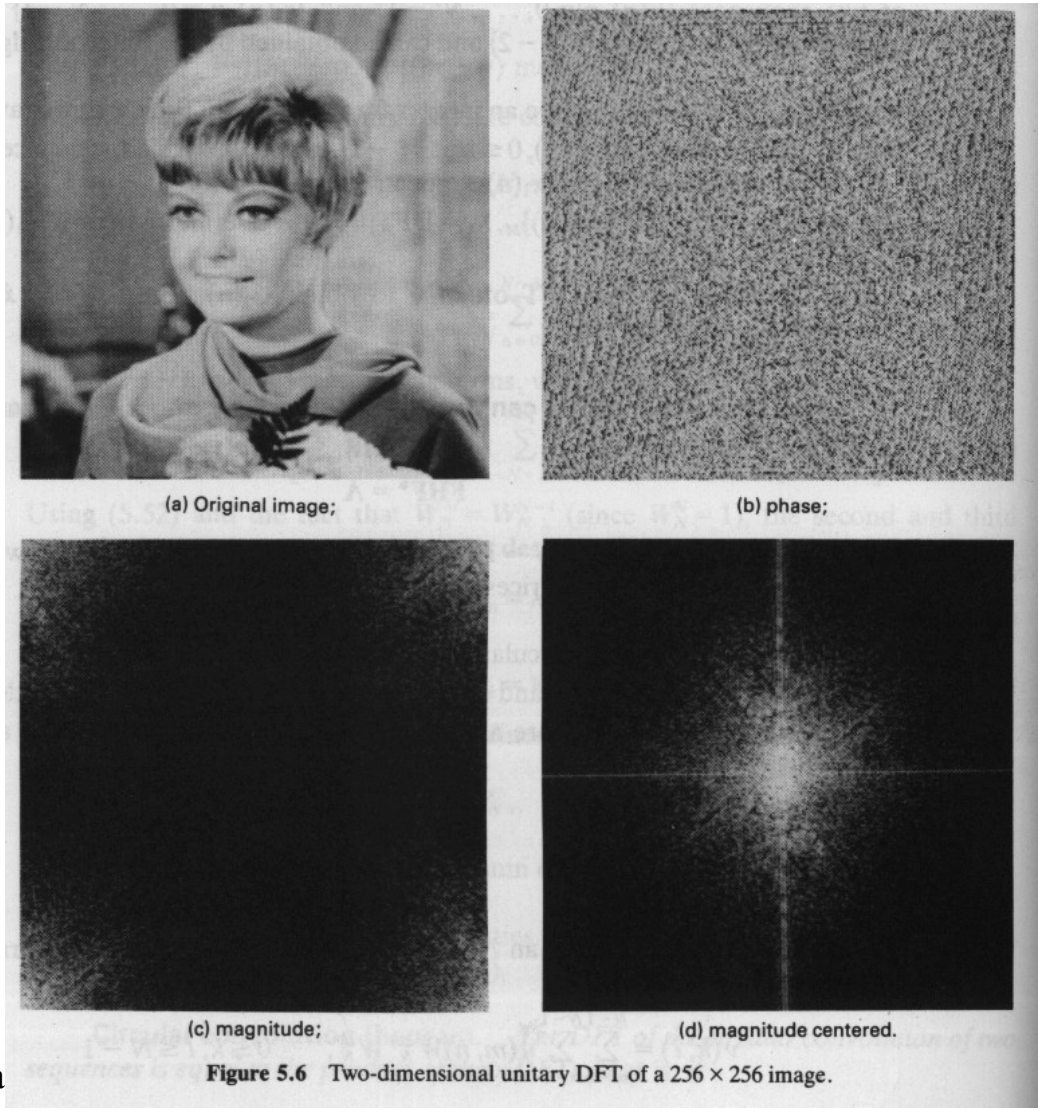


Figure 5.6 Two-dimensional unitary DFT of a 256 × 256 image.

Svojstva 2-D FT

- Separabilnost
- Translacija
- Periodičnost i konjugirana simetrija
- Rotacija
- Skaliranje
- Laplaceov operator
- Cirkularna konvolucija
- Korelacija

Separabilnost 2-D DFT

- Slijedi iz definicije:

$$\mathbf{V} = \mathbf{F}\mathbf{U}\mathbf{F}$$

$$\Rightarrow \quad \mathbf{V}^T = \mathbf{F}^T \mathbf{U}^T \mathbf{F}^T = \mathbf{F}\left(\mathbf{F}\mathbf{U}\right)^T$$

- 2-D DFT se svodi na dvije 1-D DFT: 1-D DFT po stupcima, zatim 1-D DFT po redovima (engl. row-column metoda)
- 1-D FFT ima broj operacija reda: $O(N \log_2 N)$
- 2-D DFT ima broj operacija reda: $O(N^2 \log_2 N)$

Translacija 2-D DFT

- Pretpostavimo da je:

$$v(k,l) = \mathrm{F}\{u(m,n)\}$$

gdje je F diskretna 2-D F.T.

- Translacija u prostornoj i frekvencijskoj domeni:

$$u(m-a,n-b) \Leftrightarrow v(k,l)\,\mathrm{e}^{-\frac{j2\pi(ka+lb)}{N}}$$

$$u(m,n)\,\mathrm{e}^{\frac{j2\pi(\alpha m+\beta n)}{N}} \Leftrightarrow v(k-\alpha,l-\beta)$$

Periodičnost 2-D DFT

- 2-D DFT i inverzna 2-D DFT su periodični nizovi s periodom (*N,N*):

$$v(k,l)=v(k+N,l)=v(k,l+N)=v(k+N,l+N), \quad \forall k,l$$

- Kod periodičnih 2-D nizova period se izražava parom brojeva (M,N) jer period može biti različit u svakoj od dvije dimenzije

Konjugirana simetrija 2-D DFT

- Pretpostavimo da je:

$$v(k,l) = \mathrm{F}\{u(m,n)\}$$

gdje je F diskretna F.T. I da je $u(m,n)$ realni 2-D niz

- Tada vrijedi:

$$v(k,l) = v*(-k,-l)$$
$$|v(k,l)| = |v(-k,-l)|$$

Rotacija 2-D FT i DFT

- Pretpostavimo da su korištene polarne koordinate u prostornoj i u frekvencijskoj domeni:

$$x = r\cos\theta \quad y = r\sin\theta \quad u = \omega\cos\varphi \quad v = \omega\sin\varphi$$

  i neka je: $F(u,v) = \mathrm{F}\{f(x,y)\}$ gdje je F{.} kontinuirana F.T.

- Tada vrijedi:

$$f(x,y) \rightarrow f(r,\theta), \quad F(u,v) \rightarrow F(\omega,\varphi)$$

- Može se pokazati da rotacija slike izaziva jednaku rotaciju u frekvencijskoj domeni:

$$f(r,\theta+\theta_0) \Leftrightarrow F(\omega,\varphi+\theta_0)$$

Svojstvo skaliranja 2-D FT

- Pretpostavimo da je:

$$F(u,v) = \mathrm{F}\{f(x,y)\}$$

gdje je F{., .} kontinuirana 2-D F.T.

- Tada vrijedi:

$$f(ax, by) \Leftrightarrow \frac{1}{|ab|} F\left(\frac{u}{a}, \frac{v}{b}\right)$$

gdje su *a* i *b* realni brojevi različiti od nule

Laplace-ov operator

- Laplace-ov operator je definiran kao:

$$\nabla^2 f(x,y) = \frac{\partial^2 f(x,y)}{\partial x^2} + \frac{\partial^2 f(x,y)}{\partial y^2}$$

- Pretpostavimo da je $F(u,v) = \mathrm{F}\{f(x,y)\}$ gdje je F{.} kontinuirana F.T.
- Tada vrijedi:

$$\nabla^2 f(x,y) \Leftrightarrow -4\pi^2 (u^2+v^2) F(u,v)$$

- Primjena: isticanje rubova, izoštravanje slike

Linearna konvolucija I

- Linearna konvolucija dvaju kontinuiranih 2-D signala definirana je kao:

$$(f*g)(x,y)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha,\beta)g(x-\alpha,y-\beta)\,d\alpha d\beta$$

- Pretpostavimo da su

$$f \Leftrightarrow F, \quad g \Leftrightarrow G$$

originalne i transformirane slike

- Tada vrijedi:

$$f(x,y)*g(x,y) \Leftrightarrow F(u,v)G(u,v)$$
$$f(x,y)g(x,y) \Leftrightarrow F(u,v)*G(u,v)$$

Linearna konvolucija II

- Linearna konvolucija dvaju diskretnih 2-D signala definirana je kao:

$$(h*u)(m,n)=\sum_{i=0}^{\infty}\sum_{j=0}^{\infty}h(m-i,n-j)u(i,j)$$

- Pretpostavimo da su

$$h \Leftrightarrow H, \quad u \Leftrightarrow U$$

  originalne i transformirane slike
- Tada vrijedi:

$$h(m,n)*u(m,n) \Leftrightarrow H(u,v)U(u,v)$$

Cirkularna konvolucija

- Definicija 2-D cirkularne konvolucije duljine (*N*,*N*):

$$(h \otimes u)(m,n) = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} h((m-i) \bmod N, (n-j) \bmod N) u(i,j)$$

- Kod direktnog računanja gornjom formulom 2-D cirkularna konvolucija ima složenost O(N^4)

Cirkularna konvolucija

- Pretpostavimo da je:

$$h \Leftrightarrow H, \quad u \Leftrightarrow U$$

  gdje je F 2-D DFT duljine (*N,N)*
- Tada vrijedi:

$$(h \otimes u)(m,n) \Leftrightarrow H(k,l)U(k,l)$$

- Računanje cirkularne konvolucije pomoću 2-D DFT ima složenost O($N^2 \log_2 N$), što je puno manje od O(N^4)
- Puno je efikasnije računati cirkularnu konvoluciju pomoću 2-D DFT transformacije

Korelacija I

- Korelacija dvaju realnih kontinuiranih 2-D funkcija *f* i *g* definirana je sa:

$$f(x,y)\circ g(x,y)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha,\beta)\,g(x+\alpha,y+\beta)\,d\alpha d\beta$$

- Pretpostavimo da su $f \Leftrightarrow F, \quad g \Leftrightarrow G$ originalne i transformirane slike
- Tada vrijedi:

$$f(m,n)\circ g(m,n)\Leftrightarrow F^{*}(u,v)\,G(u,v)$$

Korelacija II

- Korelacija dvaju realnih aperiodičnih 2-D nizova *f* i *g* definirana je sa:

$$f(m,n) \circ g(m,n) = \sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} f(i,j) g(m+i, n+j)$$

- Tada vrijedi:

$$f(m,n) \circ g(m,n) \Leftrightarrow F^{*}(u,v) G(u,v)$$

Diskretna kosinusna transformacija (DCT)

- Matrica **C** = {*c*(*k*,*n*)} diskretne kosinusne transformacije (DCT) dimenzija *N*×*N* definirana je kao:

$$c(k,n)=\begin{cases}\dfrac{1}{\sqrt{N}}, & k=0, \quad 0\le n\le N-1\\ \sqrt{\dfrac{2}{N}}\cos\dfrac{\pi(2n+1)k}{2N}, & 1\le k\le N-1, \quad 0\le n\le N-1\end{cases}$$

2-D DCT

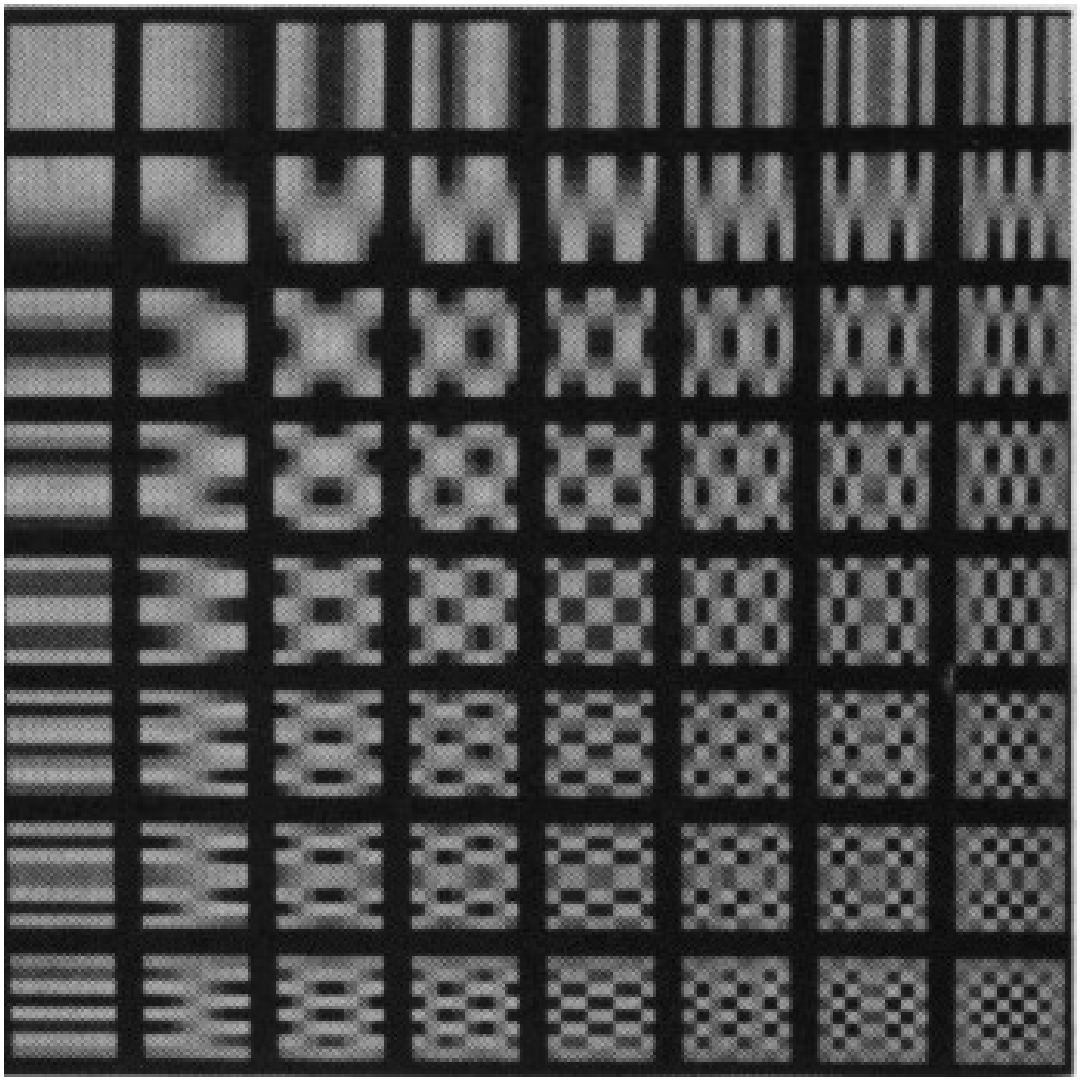
- 2-D verzija DCT se dobiva u matričnoj formi kao:

$$\mathbf{V} = \mathbf{C}\mathbf{U}\mathbf{C}^{T}$$
$$\mathbf{U} = \mathbf{C}^{T}\mathbf{V}\mathbf{C}$$

gdje je $\mathbf{U}=[u(m,n)]$ ulazna 2-D sekvencija (slika),
a $\mathbf{V}=[v(k,l)]$ transformacija ulazne slike $\mathbf{U}$

Primjer baze 2-D DCT

- Baza 2-D DCT transformacije dimenzija 8×8



Svojstva DCT I

- DCT realna transformacija (koeficijenti transformacije tj. elementi matrice **C** su realni brojevi)
- DCT je ortogonalna transformacija:

$$C = C^{*} \quad \Rightarrow C^{-1} = C^{T}$$

- DCT nije realni dio DFT (to se može vidjeti uspoređivanjem matrica **F** i **C**)
- DCT niza duljine *N* moguće je izračunati pomoću DFT simetrično proširenog niza duljine *2N*

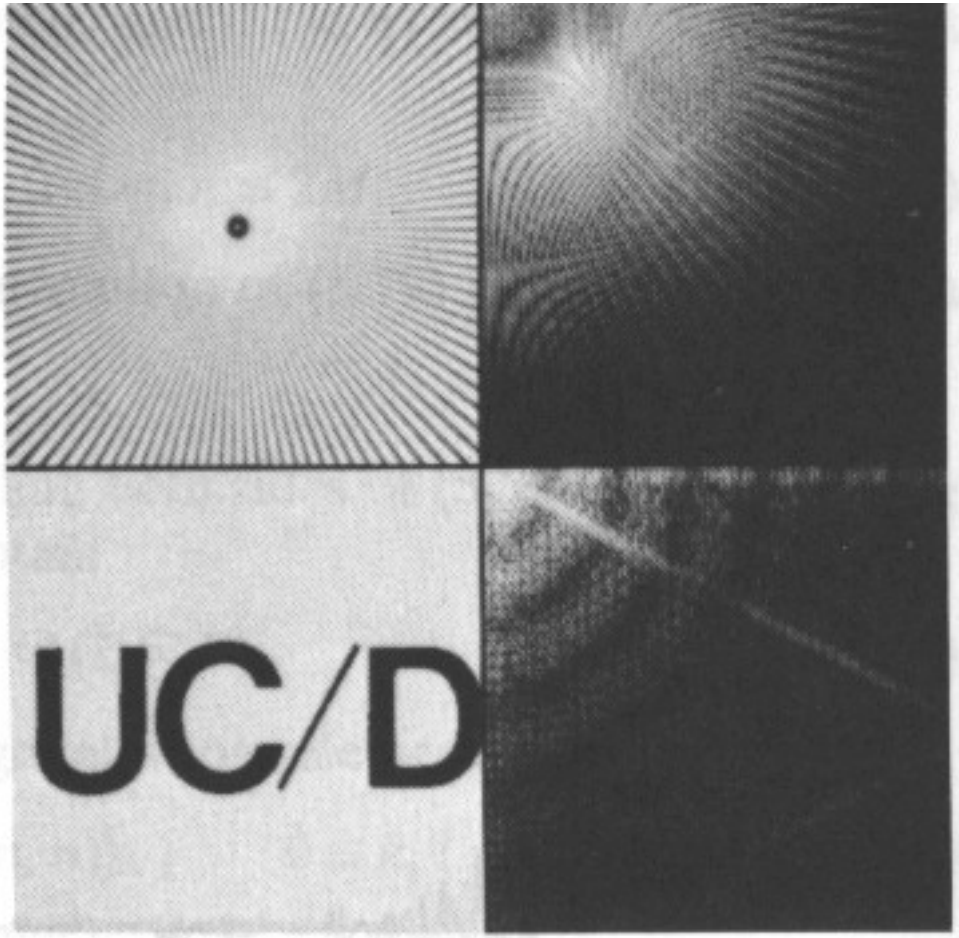
Svojstva DCT II

- Odlično pakiranje energije za jako korelirane slike
- Veći dio prosječne energije se nalazi u nižim koeficijentima DCT (razlog: DCT je bliska KL transformaciji stacionarnog Markovljevog niza prvog reda za jako korelirane slike)
- To je dobro za kompresiju jer eliminacija viših DCT koeficijenata predstavlja relativno malen gubitak informacije
- Zato se DCT često koristi u kompresiji slika

Primjer DCT



(a) Cosine transform examples of monochrome images;



(b) Cosine transform examples of binary images.

Karhunen-Loeve transformacija

- Neka je **u** realni slučajni vektor duljine *N*
- Autokorelacijska matrica vektora **u** je: **R** = E[**uu**^{T}]
- Neka je **A** *N*×*N* matrica čiji su stupci ortonormalizirani vlastiti vektori matrice **R**:

$$\mathbf{R}\mathbf{a}_k = \lambda_k a_k, \quad 0 \le k \le N-1, \quad \lambda_0 \ge \lambda_1 \ge \cdots \ge \lambda_{N-1}$$

- Matrica **A** je *N*×*N* unitarna matrica koja reducira **R** na dijagonalnu formu **Q** = **A**^{H}**RA**

Karhunen-Loeve transformacija

- 1-D KL transformacija vektora **u** je definirana izrazom:

  $\mathbf{v} = \mathbf{A}^H\mathbf{u}$

  gdje je **A** matrica koja dijagonalizira **R**, autokorelacijsku matricu vektora **u**
- Inverzna 1-D KL transformacija je definirana izrazom:

$$u = \mathbf{A}\mathbf{v} = \sum_{k=0}^{N-1} v(k)\, a_k$$

Svojstva KL transformacije

- Zbog pojednostavljenja u slijedećem tekstu pretpostavlja se da je E[**u**] = 0
- Svojstva KL transformacije:
  - Dekoreliranost koeficijenata
  - Restrikcija baze

Dekoreliranost koeficijenata

- Tvrdnja: Koeficijenti KL transformacije $v(k)$ imaju očekivanje jednako nuli i nekorelirani su:

$$E\left[v(k)\right]=0$$
$$E\left[v(k)v*(l)\right]=\lambda_k\delta(k-l)$$

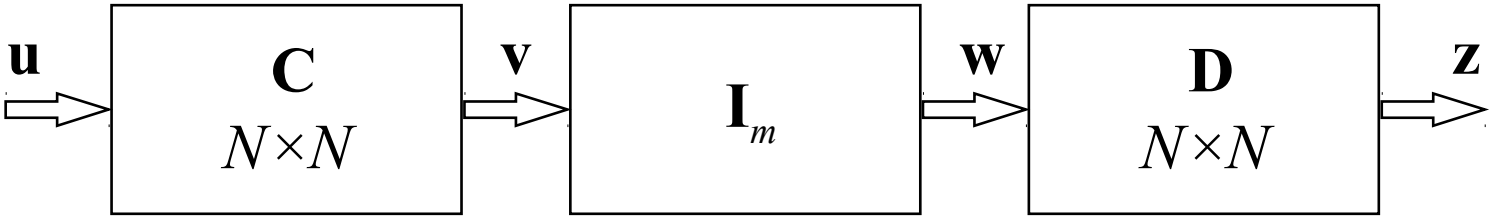
- Dokaz:

$$E\left[\mathbf{v}\right]=\mathbf{A}^{\boldsymbol{H}}E\left[\mathbf{u}\right]=0$$
$$E\left[\mathbf{v}\mathbf{v}^{\boldsymbol{H}}\right]=\mathbf{A}^{\boldsymbol{H}}E\left[\mathbf{u}\mathbf{u}^{\boldsymbol{H}}\right]\mathbf{A}=\mathbf{A}^{\boldsymbol{H}}\mathbf{R}\mathbf{A}=\mathbf{Q}$$
$$\Rightarrow E\left[v(k)v*(l)\right]=\lambda_k\delta(k-l)$$

- Kovarijancijska matrica **Q** vektora **v** ima dijagonalnu formu tj. $v(k)$ su nekorelirani

Restrikcija baze I

- Osjetljivost transformacije na smanjenje broja vektora u bazi:



- Vektor **w** ima prvih *m* elemenata iz **v** a ostalo nule
- C i D su *N*×*N* matrice a $\mathbf{I}_m$ je matrica s *m* jedinica uzduž glavne dijagonale a ostalo su nule
- **u** i **v** su vektori iz *N*-dimenzionalnog prostora
- **w** je vektor iz *m*<=*N* dimenzionalnog prostora

Restrikcija baze II

- MS pogreška između nizova $u(n)$ i $z(n)$ je:

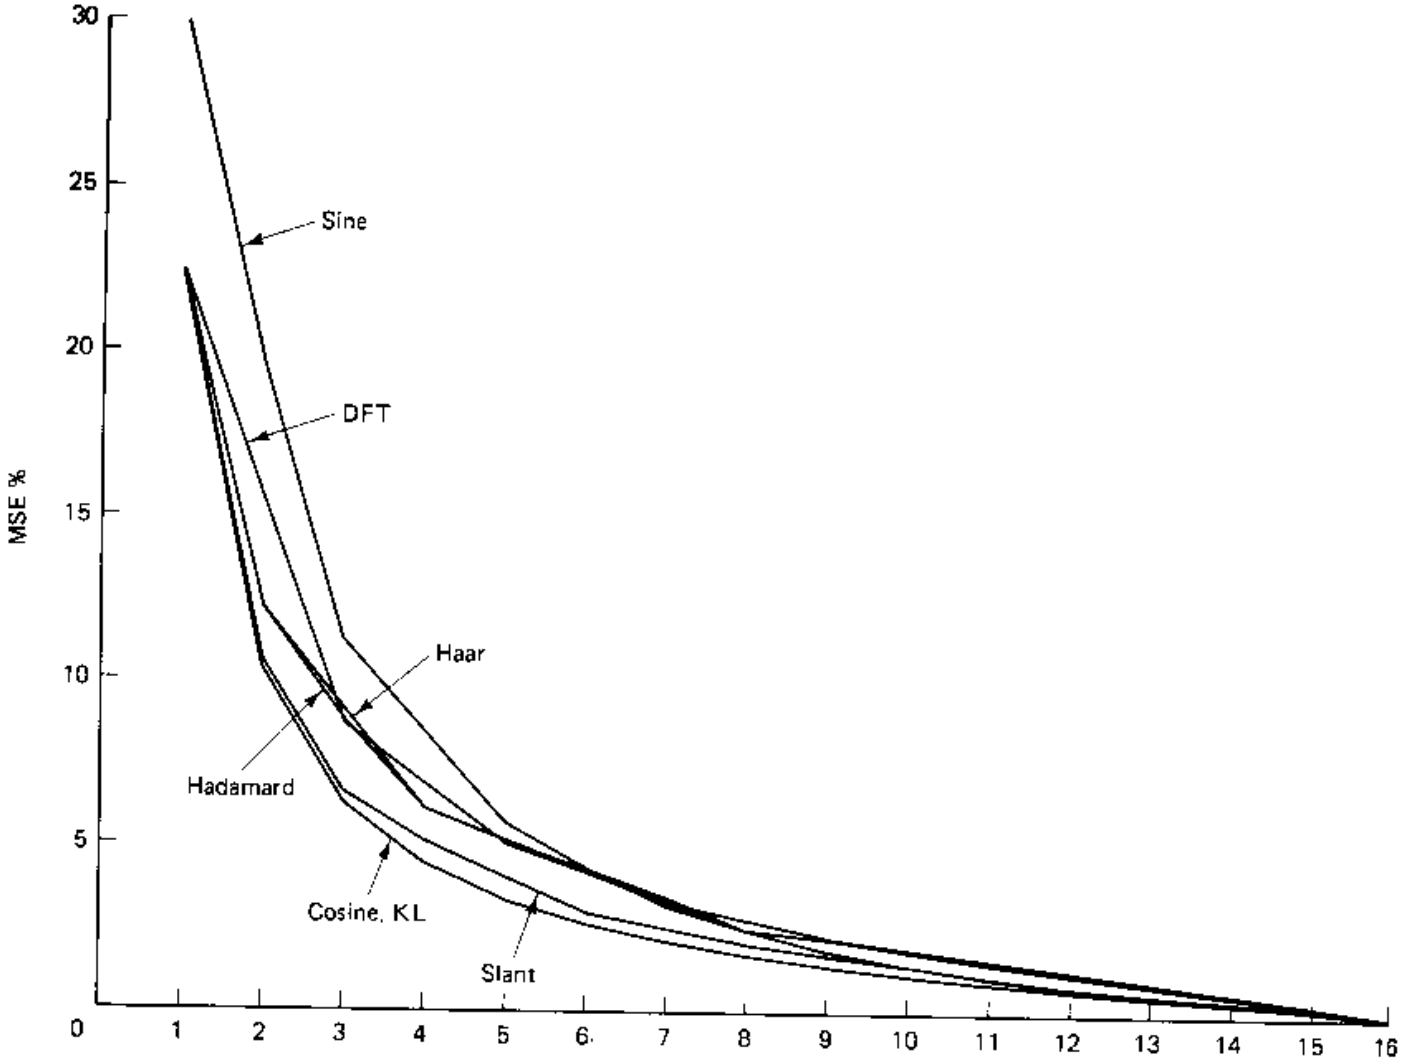
$$J_m = \frac{1}{N} E\left[\sum_{n=0}^{N-1} |u(n) - z(n)|^2\right]$$

- Tvrdnja: MS pogreška J_m je minimalna kada je:

  $\mathbf{C} = \mathbf{A}^H$, $\mathbf{D} = \mathbf{A}$, $\mathbf{CD} = \mathbf{I}$

- Interpretacija: za dani broj koeficijenata m KL transformacija predstavlja niz u s najmanjom pogreškom (manjom od bilo koje druge unitarne transformacije)

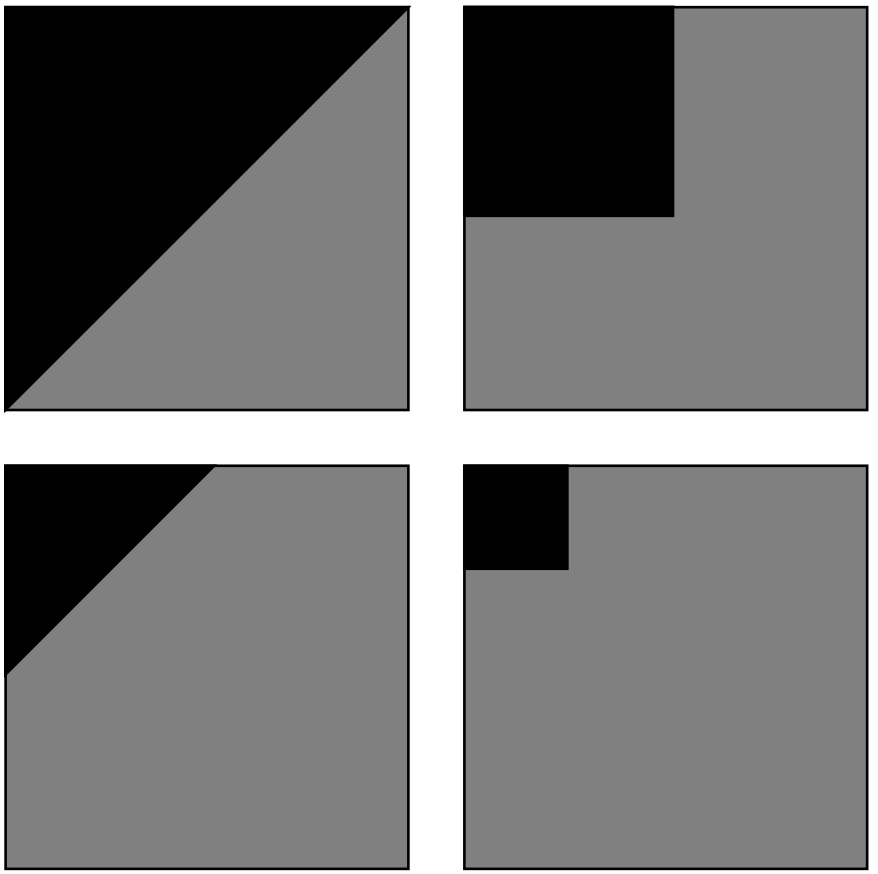
Restrikcija baze III



- Pogreška uslijed restrikcije baze unitarnih transformacija za N=16 i stacionarni Markovljev niz

Restrikcija baze IV

- NP filtri (maske) za redukciju broja uzoraka u “frekvencijskoj” domeni za faktore: 2, 4, 8 i 16
- crno: područje propuštanja
- sivo: područje gušenja



Restrikcija baze V

- Restrikcija baze NP filtriranjem u domeni DCT
- Faktori redukcije broja uzoraka: 1 (original), 4, 8 i 16



Restrikcija baze VI

- Utjecaj restrikcije baze za faktor 4 za DCT, DST, DFT i Hadamardovu transformaciju



Restrikcija baze VII

- Utjecaj restrikcije baze za faktor 4 za Haarovu i Slant transformaciju



(e) Haar; (f) Slant.

Zaključak

- Reprezentacija slike je vrlo važan problem o čijem rješenju ovisi efikasnost mnogih naknadnih postupaka obrade i analize slike
- Predstavljeni su primjeri ortogonalne transformacije: DFT, DCT, KL
- KL transformacija: optimalna za familiju slika s danim statističkim svojstvima (korelacijskom matricom)