Obnavljanje slike

Uvod

- engl. image restoration
- Obnavljanje slike ima za svrhu restauraciju originalne iz degradirane slike pretpostavljajući neki model degradacije
- Za razliku od obnavljanja poboljšanje slike je koncentrirano na isticanje nekih karakteristika slike
- Problemi obnavljanja su precizno postavljeni dok se kriteriji poboljšanja slike teško formaliziraju matematički

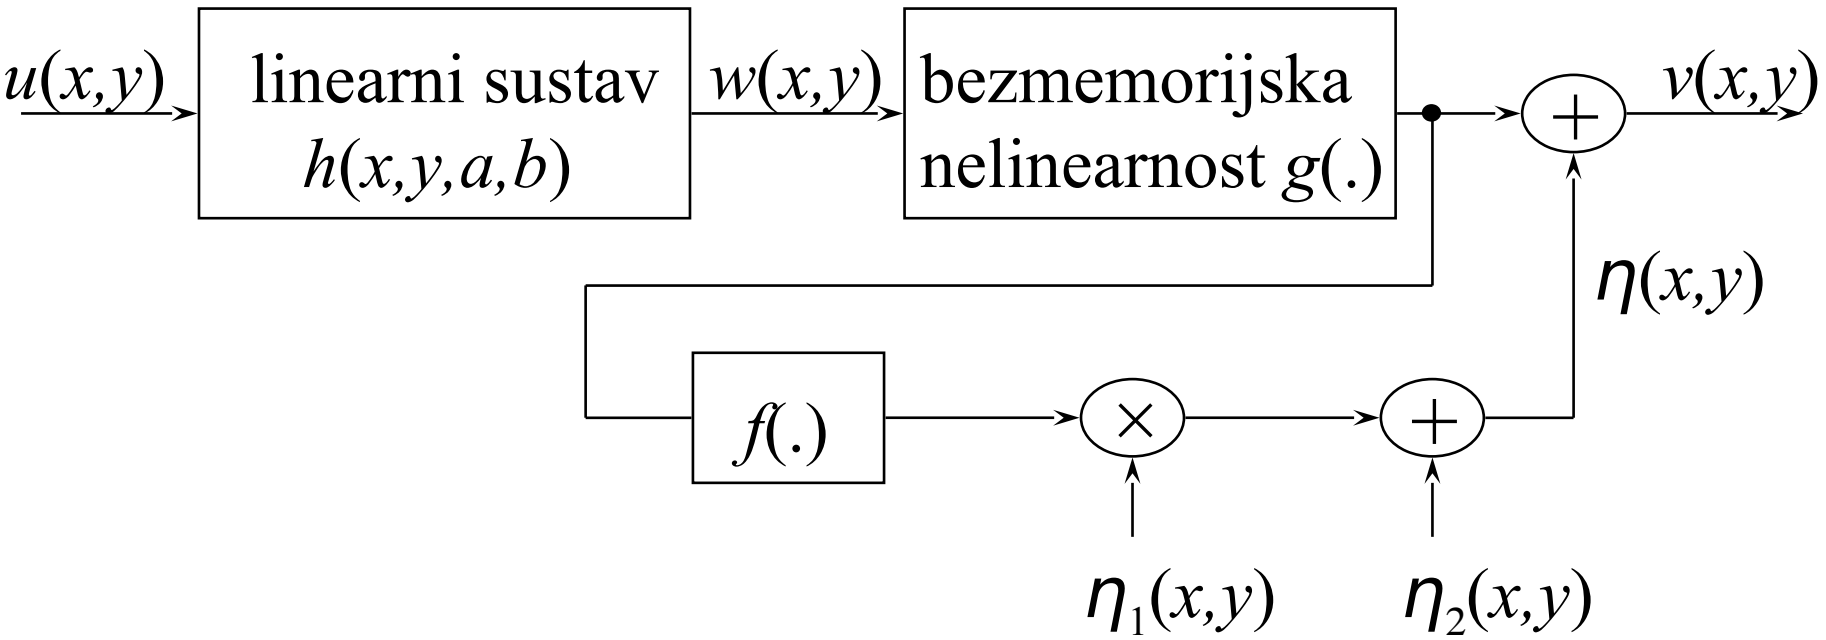
Pregled tema

- Modeli degradacije slike
- Inverzni i Wiener filtar
- Pseudoinverzna matrica
- Geometrijske modifikacije slike

Sustav za akviziciju slike

- Tipični sustav za akviziciju slike se sastoji od:
  - sustava za formiranje slike (objektiv)
  - detektora slike
  - sustava za registraciju (pamćenje) slike
- Primjer: foto aparat, TV kamera
- Svaka od gornje tri komponente unosi degradaciju koja se može modelirati
- Šum također unosi degradaciju

Primjer modela degradacije I



Primjer modela degradacije II

- $u(x,y)$ predstavlja objekt (originalnu sliku)
- $v(x,y)$ predstavlja opaženu sliku (rezultat akvizicije)
- $\eta(x,y)$ je aditivni šum koji se sastoji od dijela ovisnog o slici $\eta_1(x,y)$ i dijela $\eta_2(x,y)$ neovisnog o slici:

$$v(x,y)=g\left[w(x,y)\right]+\eta(x,y)$$

$$w(x,y)=\iint h(x,y,a,b)u(a,b)dadb$$

$$\eta(x,y)=f\left[g(w(x,y))\right]\eta_1(x,y)+\eta_2(x,y)$$

Primjeri degradacije slike I

- Optički sustav ograničen difrakcijom:

$$h(x,y) = ab\,\mathrm{sinc}(ax)\,\mathrm{sinc}(by)$$
$$H(\xi_1,\xi_2) = \mathrm{rect}(\xi_1/a, \xi_2/b)$$

- Horizontalno gibanje:

$$h(x,y) = \mathrm{rect}(x/a - 0.5)/a$$
$$H(\xi_1,\xi_2) = e^{-j\pi\xi_1 a}\,\mathrm{sinc}(\xi_1 a)$$

Primjeri degradacije slike II

- Atmosferske turbulencije:

$$h(x,y)=\exp(-\pi\alpha^2(x^2+y^2))$$

$$H(\xi_1,\xi_2)=\frac{1}{\alpha^2}\exp\left(\frac{-\pi(\xi_1^2+\xi_2^2)}{\alpha^2}\right)$$

Modeli detektora i registratora

- Film, uređaji za prikaz imaju nelinearnu karakteristiku:

  $g = aw^b$

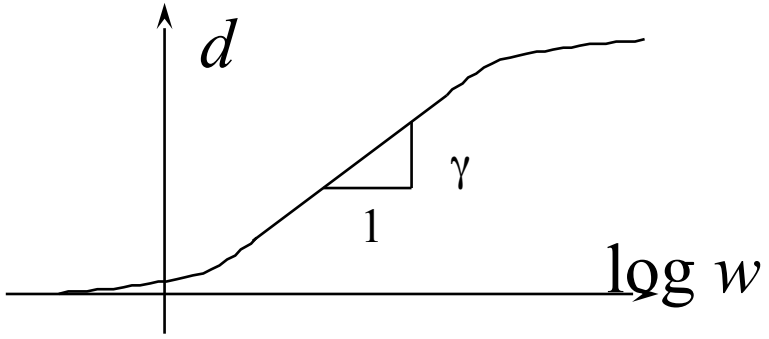
  gdje su *a* i *b* konstante koje ovise o tipu detektora a *w* je ulazna varijabla

Primjer fotografskog filma

- Za fotografski film gornja nelinearna karakteristika (nakon logaritmiranja) se često piše u obliku:

$$d = \gamma \log w - d_0$$

gdje je w intenzitet svjetla a d je optička gustoća

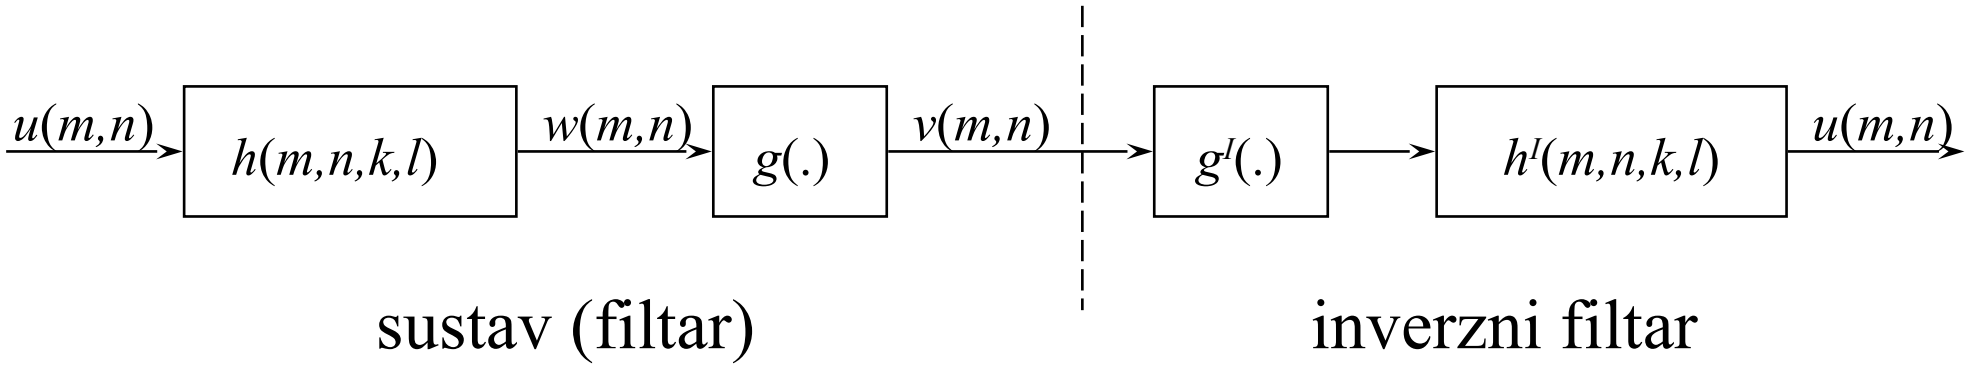


Metode za obnavljanje slike

- Inverzni filtar
- Pseudo inverzni filtar
- Wienerov filtar

Inverzni filtar

- Inverzni filtar je metoda obnavljanja slike gdje se za obnavljanje slike koristi filtar koji poništava djelovanje sustava degradacije



Matematička formulacija I

- Poništavanje bezmemorijskih nelinearnosti traži:

  $g^I(x) = g^{-1}(x)$

- Za poništavanje memorijskog dijela treba vrijediti:

$$\sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} h^I(m,n,i,j)h(i,j,k,l) = \delta(m-k,n-l)$$

- Inverzni filtri su korisni i za pre-korekciju grešaka koje se očekuju (npr. nelinearnost ekrana za prikaz)

Matematička formulacija II

- Za sustave invarijantne na pomak gornji izraz postaje kovolucijska sumacija:

$$\sum_{i=-\infty}^{\infty}\sum_{j=-\infty}^{\infty} h^I(m-i,n-j)h(i,j)=\delta(m,n)$$

- Nakon Fourierove transformacije dobiva se:

$$H^I(\omega_1,\omega_2)H(\omega_1,\omega_2)=1$$

$$\Rightarrow H^I(\omega_1,\omega_2)=\frac{1}{H(\omega_1,\omega_2)}$$

Praktični problemi u realizaciji

- Dizajn realizabilnih filtara je težak zbog moguće nestabilnosti
- Nule originalnog sustava postaju polovi inverznog sustava
- Ako originalni sustav ima nule na jediničnoj kružnici inverzni sustav će imati polove na jediničnoj kružnici. Odziv za te frekvencije bit će beskonačan (nestabilan sustav)

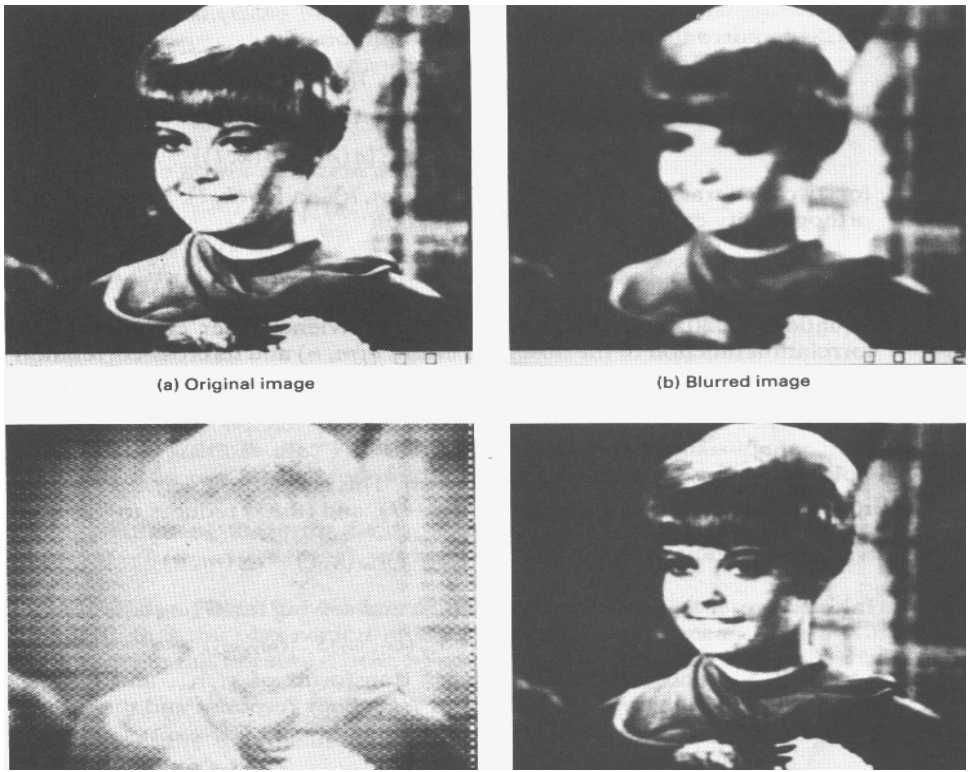
Pseudoinverzni filtar

- Pseudoinverzni filtar je stabilizirana verzija inverznog filtra
- Za linearni sustav invarijantan na pomak s frekvencijskom karakteristikom $H(\omega_1, \omega_2)$ pseudoinverzni filtar je definiran kao:

$$H^{-}(\omega_1,\omega_2)=\begin{cases}\dfrac{1}{H(\omega_1,\omega_2)}, & H(\omega_1,\omega_2)\neq 0\\ 0, & H(\omega_1,\omega_2)=0\end{cases}$$

Primjer inverznog i pseudoinverznog filtriranja

- GL: originalna slika
- GD: zamućena slika
- DL: inverzna filtracija
- DD: pseudo-inverzna filtracija



Wienerov filtar

- Glavna mana inverznog filtriranja je velika osjetljivost na šum
- Osjetljivost je velika zbog prirode inverznog filtriranja koje se sastoji u računanju kvocjenta dvaju malih veličina:
  - na visokim frekvencijama vrijednosti u spektru slike su male,
  - sustav degradacije ima malo pojačanje na visokom frekvencijama
- Wienerov filtar je metoda obnavljanja slike koja uzima u obzir prisustvo šuma

Formulacija problema

- Neka su *u*(*m,n*) i *v*(*m,n*) slučajni nizovi s srednjom vrijednosti jednakom nuli
- Problem: Treba odrediti procjenu (estimaciju)

$$\hat{u}(m,n)$$

niza *u*(*m,n*) na temelju *v*(*m,n*) takvu da se minimizira srednja kvadratna pogreška:

$$s_e^2 = E\left\{\left[u(m,n) - \hat{u}(m,n)\right]^2\right\}$$

Rješenje problema I

- Najbolja procjena je uvjetna srednja vrijednost niza *u*(*m,n*) uz dane $\{v(k,l), \quad \forall k,l\}$

$$\hat{u}(m,n) = E\left[u(m,n) \middle| \{v(k,l), \quad \forall k,l\}\right]$$

- Gornju jednadžbu je teško analitički riješiti zato se najčešće koristi najbolja linearna ocjena oblika:

$$\hat{u}(m,n) = \sum_{k=-\infty}^{\infty} \sum_{l=-\infty}^{\infty} g(m,n,k,l)\, v(k,l)$$

gdje se impulsni odziv filtra *g*(*m,n,k,l*) odabere tako da se minimizira srednja kvadratna pogreška

Rješenje problema II

- Uvjet minimizacije srednje kvadratne pogreške je uvjet ortogonalnosti:

$$E\left[\left\{u(m,n)-\hat{u}(m,n)\right\}v(m',n')\right]=0, \quad \forall\, m,n,m',n'$$

- Koristeći definiciju kros-korelacije:

$$r_{ab}(m,n,k,l)=E\left[a(m,n)b(k,l)\right]$$

i gornju jednadžbu za linearnu ocjenu dobiva se:

$$\sum_{k=-\infty}^{\infty}\sum_{l=-\infty}^{\infty} g(m,n,k,l)\,r_{vv}(k,l,m',n')=r_{uv}(m,n,m',n')$$

Rješenje problema III

- Ako su *u*(*m,n*) i *v*(*m,n*) stacionarni procesi onda je:

$$r_{ab}(m,n,m',n') = r_{ab}(m-m',n-n')$$

gdje je *ab* jednako *uu*, *uv*, *vv*

- Tada je i filtar *g*(*m-k,n-l*) invarijantan na pomak te dobivamo:

$$\sum_{k=-\infty}^{\infty} \sum_{l=-\infty}^{\infty} g(m-k,n-l) r_{vv}(k,l) = r_{uv}(m,n)$$

Rješenje problema IV

- Transformacijom jednadžbe u Fourierovu domenu dobivamo rješenje :

$$G(\omega_1,\omega_2)=S_{uv}(\omega_1,\omega_2)S_{vv}^{-1}(\omega_1,\omega_2)$$

gdje su G, S_{uv}, S_{vv} Fourierove transformacije od g, r_{uv}, r_{vv} respektivno

- Konačno se može pisati:

$$\hat{u}(m,n)=\sum_{k=-\infty}^{\infty}\sum_{l=-\infty}^{\infty} g(m-k,n-l)v(k,l)$$

$$\hat{U}(\omega_1,\omega_2)=G(\omega_1,\omega_2)V(\omega_1,\omega_2)$$

Rješenje problema V

- Pretpostavimo sada sljedeći model degradacije:

$$v(m,n)=\sum_{k=-\infty}^{\infty}\sum_{l=-\infty}^{\infty} h(m-k,n-l)u(k,l)+\eta(m,n)$$

gdje je $\eta(m,n)$ stacionarni šum nekoreliran s $u(m,n)$ i koji ima spektralnu gustoću $S_{\eta\eta}$

Rješenje problema VI

- Tada je:

$$S_{vv}(\omega_1,\omega_2)=|H(\omega_1,\omega_2)|^2 S_{uu}(\omega_1,\omega_2)+S_{\eta\eta}(\omega_1,\omega_2)$$

$$S_{uv}(\omega_1,\omega_2)=H^*(\omega_1,\omega_2)S_{uu}(\omega_1,\omega_2)$$

što konačno daje izraz za Wienerov filtar:

$$G(\omega_1,\omega_2)=\frac{H^*(\omega_1,\omega_2)S_{uu}(\omega_1,\omega_2)}{|H(\omega_1,\omega_2)|^2 S_{uu}(\omega_1,\omega_2)+S_{\eta\eta}(\omega_1,\omega_2)}$$

Diskusija rješenja

- Rješenje se može pisati i kao:

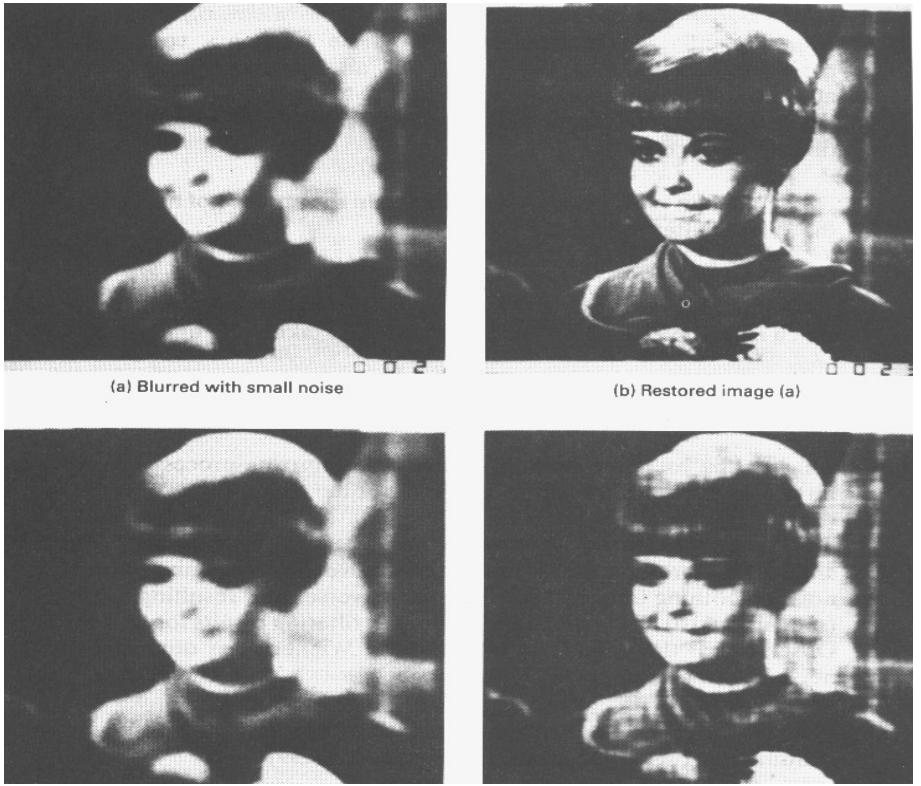
$$G(\omega_1,\omega_2)=\frac{H^*(\omega_1,\omega_2)}{|H(\omega_1,\omega_2)|^2+\dfrac{S_{\eta\eta}(\omega_1,\omega_2)}{S_{uu}(\omega_1,\omega_2)}}$$

- Kada je $S_{\eta\eta} << |H|^2 S_{uu}$ dobivamo inverzni filtar:

$$G(\omega_1,\omega_2)\simeq\frac{H*(\omega_1,\omega_2)}{|H(\omega_1,\omega_2)|^2}=\frac{1}{H(\omega_1,\omega_2)}$$

Primjer Wiener filtra

- GL: malo zamućena slika
- GD: obnovljena slika
- DL: jako zamućena slika
- DD: obnovljena slika



Pseudoinverzna matrica I

- U nastavku opisujemo pristup obnavljanju slike koji je temeljen na linearnoj algebri
- Promatrajmo sljedeći model degradacije:

$$\mathbf{v} = \mathbf{H}\mathbf{u}$$

gdje su **u** i **v** vektori, a **H** je matrica dimenzija *M*×*N*

- Neka je $\hat{\mathbf{u}}$ procjena vektora **u** koja minimizira kvadratnu pogrešku:

$$J = \left\| \mathbf{v} - \mathbf{H}\,\hat{\mathbf{u}} \right\|^2$$

Pseudoinverzna matrica II

- Pogreška *J* se može napisati u obliku:

$$J = \left(\mathbf{v} - \mathbf{H}\hat{\mathbf{u}}\right)^T \left(\mathbf{v} - \mathbf{H}\hat{\mathbf{u}}\right)$$
$$= \mathbf{v}^T\mathbf{v} - \mathbf{v}^T\mathbf{H}\hat{\mathbf{u}} - \hat{\mathbf{u}}^T\mathbf{H}^T\mathbf{v} + \hat{\mathbf{u}}^T\mathbf{H}^T\mathbf{H}\hat{\mathbf{u}}$$

- Vektor $\hat{\mathbf{u}}$ koji minimizira *J* mora zadovoljiti:

$$\frac{\partial J}{\partial \hat{\mathbf{u}}} = 0 \Leftrightarrow \mathbf{H}^T\mathbf{v} = \mathbf{H}^T\mathbf{H}\hat{\mathbf{u}}$$

- Ako $\mathbf{H}^T\mathbf{H}$ nije singularna onda je $\hat{\mathbf{u}}$ dan izrazom:

$$\hat{\mathbf{u}} = \mathbf{H}^-\mathbf{v}, \quad \mathbf{H}^- = \left(\mathbf{H}^T\mathbf{H}\right)^{-1}\mathbf{H}^T$$

Pseudoinverzna matrica III

- $\mathbf{H}^{-}$ je psudoinverzna matrica matrice $\mathbf{H}$
- Pseudoinverzna matrica ima svojstvo da vrijedi:

$$\mathbf{H}^{-}\mathbf{H}=\mathbf{I}$$

- Ako je $\mathbf{H}$ dimenzija $M \times N$ onda je $\mathbf{H}^{-}$ dimenzija $N \times M$
- Treba primjetiti da je:

$$\mathbf{H}\mathbf{H}^{-} \neq I$$

Pseudoinverzna matrica IV

- Nužan uvjet da $\mathbf{H}^T\mathbf{H}$ nije singularna je da $M \geq N$
  i da je rang matrice $\mathbf{H}$ jednak *N*
- Ako je $M < N$ i rang matrice **H** je jednak *M* onda je pseudoinverzna matrica definirana kao matrica koja zadovoljava:

$$\mathbf{H}\mathbf{H}^{-} = \mathbf{I}$$

- $\mathbf{H}^{-}$ tada nije jednoznačno određena i jedno je rješenje dano izrazom:

$$\mathbf{H}^{-} = \mathbf{H}^T\left(\mathbf{H}^T\mathbf{H}\right)^{-1}$$

Geometrijske transformacije slike

- translacija
- skaliranje
- rotacija
- nelinearno iskrivljenje (engl. warping)

Notacija

- Neka je $g(x,y)$ prostorno kontinuirana izlazna slika koja je nastala geometrijskom transformacijom prostorno kontinuirane ulazne slike $f(u,v)$
- u, v, x, y su realne koordinate

Translacija

- Translacija je definirana izrazima:

$$x = u + t_x$$
$$y = v + t_y$$

gdje su t_x, t_y iznosi translacije u x i y smjeru

- Dva načina računanja koordinata:
  - direktni: $(u, v) \rightarrow (x, y)$
  - inverzni: $(x, y) \rightarrow (u, v)$
- U praksi se pojavljuje potreba za interpolacijom ako dobivene koordinate nisu cijeli brojevi

Skaliranje

- Prostorno skaliranje je definirano izrazima:

$$x = s_x u$$

$$y = s_y v$$

gdje su s_x, s_y realne pozitivne konstante skaliranja

- Povećanje slike: $1 < s_x, s_y$
- Smanjivanje slike: $0 < s_x, s_y < 1$
- Interpolacija je potrebna da bi se dobile cjelobrojne koordinate

Rotacija

- Rotacija slike je definirana izrazima:

$$x = u\cos\theta - v\sin\theta$$
$$y = u\sin\theta + v\cos\theta$$

gdje je Θ kut rotacije u smjeru obrnutom od kazaljke na satu

- Interpolacija je potrebna da bi se dobile cjelobrojne koordinate

Matrični oblik transformacija I

- Geometrijske transformacije se mogu prikazati i u matričnom obliku
- Ulazne realne koordinate dane su vektorom:

$$\begin{bmatrix} u \\ v \end{bmatrix}$$

- Transformirane koordinate dane su vektorom:

$$\begin{bmatrix} x \\ y \end{bmatrix}$$

Matrični oblik transformacija II

- Translacija:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} u \\ v \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix}$$

- Skaliranje:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} s_x & 0 \\ 0 & s_y \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix}$$

- Rotacija:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix}$$

Složene transformacije I

- Transformacija koja se npr. sastoji od translacije, zatim skaliranja i konačno rotacije može se opisati kao:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} s_x & 0 \\ 0 & s_y \end{bmatrix} \left(\begin{bmatrix} u \\ v \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix} \right)$$

Složene transformacije II

- Nakon sređivanja gornja složena transformacija može se napisati u obliku:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} c_1 & c_2 \\ d_1 & d_2 \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} + \begin{bmatrix} c_0 \\ d_0 \end{bmatrix}$$

što je ekvivalentno izrazu:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} c_1 & c_2 & c_0 \\ d_1 & d_2 & d_0 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}$$

Složene transformacije III

- Za inverzno računanje koordinata potrebno je gornju matricu dimenzija 2×3 invertirati
- Budući da to nije kvadratna matrica ne postoji inverzna matrica
- Zato se koristi trodimenzionalna reprezentacija dvodimenzionalnih vektora što se naziva prikaz pomoću homogenih koordinata

Homogene koordinate

- Pravokutna matrica transformacije se proširuje na slijedeći način:

$$\begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} c_1 & c_2 & c_0 \\ d_1 & d_2 & d_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}$$

što omogućuje inverziju matrice transformacije za potrebe inverznog računanja adresa

Translacija

- Prikaz translacije pomoću homogenih koordinata dan je matričnim izrazom:

$$\begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}$$

Skaliranje

- Prikaz skaliranja pomoću homogenih koordinata dan je matričnim izrazom:

$$\begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}$$

Rotacija

- Prikaz rotacije pomoću homogenih koordinata dan je matričnim izrazom:

$$\begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}$$

Složene geometrijske transformacije

- Složene geometrijske transformacije koje se sastoje od translacije, rotacije i skaliranja mogu se prikazati produktom odgovarajućih matrica dimenzija 3×3
- Rezultantna matrica ima dimenziju 3×3

Nelinearne geometrijske transformacije I

- Translacija, skaliranje i rotacija su primjeri linearne transformacije koordinata između ulazne i izlazne slike
- Osim linearnih transformacija koordinata mogu se koristiti i nelinearne transformacije
- Termini: iskrivljenje (engl. warping), rastezanje (engl. rubber sheet stretching)

Nelinearne geometrijske transformacije II

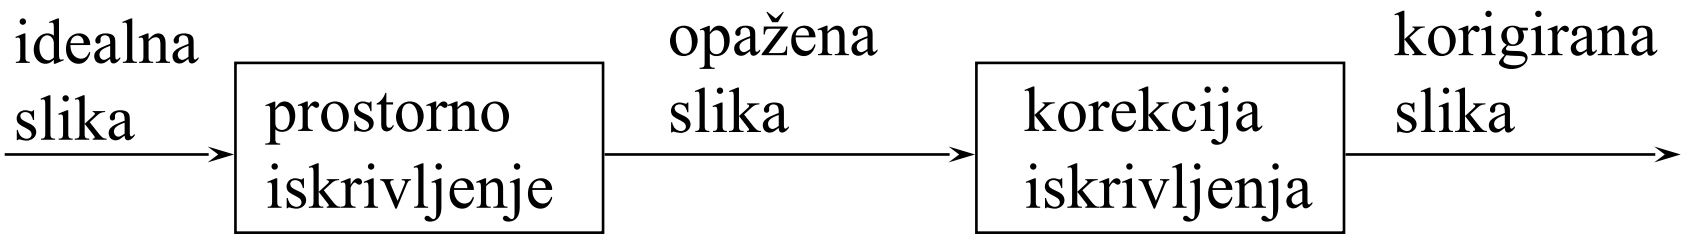
- Opći oblik direktne i inverzne nelinearne transformacije koordinata definiran je izrazima:

$$\begin{aligned} x &= X(u,v) \\ y &= Y(u,v) \end{aligned}, \qquad \begin{aligned} u &= U(x,y) \\ v &= V(x,y) \end{aligned}$$

gdje su *X*(.,.), *Y*(.,.), *U*(.,.) i *V*(.,.) nelinearne funkcije dvije varijable (npr. polinom *N*-tog stupnja od dvije varijable)

Primjene nelinearnih geometrijskih transformacija

- U praksi se iskrivljenje može koristiti za kompenzaciju (korekciju) geometrijskih izobličenja optičkih sustava ili uređaja za prikaz (display)



Polinomsko iskrivljenje

- Iskrivljenje slike polinomom *N*-tog stupnja od dvije varijable definirano je izrazima:

$$x = \sum_{i=0}^{N} \sum_{j=0}^{N} a_{ij} u^i v^j$$

$$y = \sum_{i=0}^{N} \sum_{j=0}^{N} b_{ij} u^i v^j$$

gdje su a_{ij}, b_{ij} koeficijenti polinoma *N*-tog stupnja

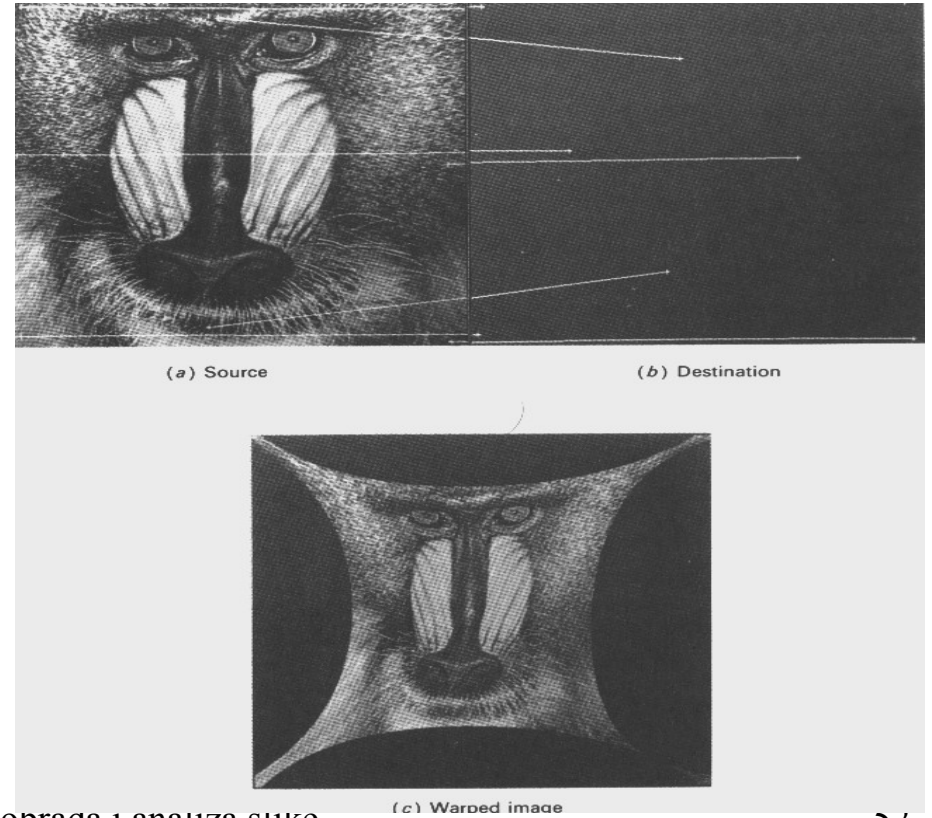
- Ukupno ima $2(N+1)^2$ koeficijenata

Određivanje koeficijenata

- Za određivanje koeficijenata polinoma potrebno je specificirati $(N+1)^2$ korespondentnih parova točaka u originalnoj i transformiranoj slici
- Svaki par korespondentnih točaka daje dvije jednadžbe (za x i y koordinate)
- Ukupno se dobiva $2(N+1)^2$ linearnih jednadžbi s jednakim brojem nepoznanica a_{ij}, b_{ij}
- Rješenjem sustava linearnih jednadžbi dobivaju se koeficijenti geometrijske transformacije

Primjer iskrivljenja

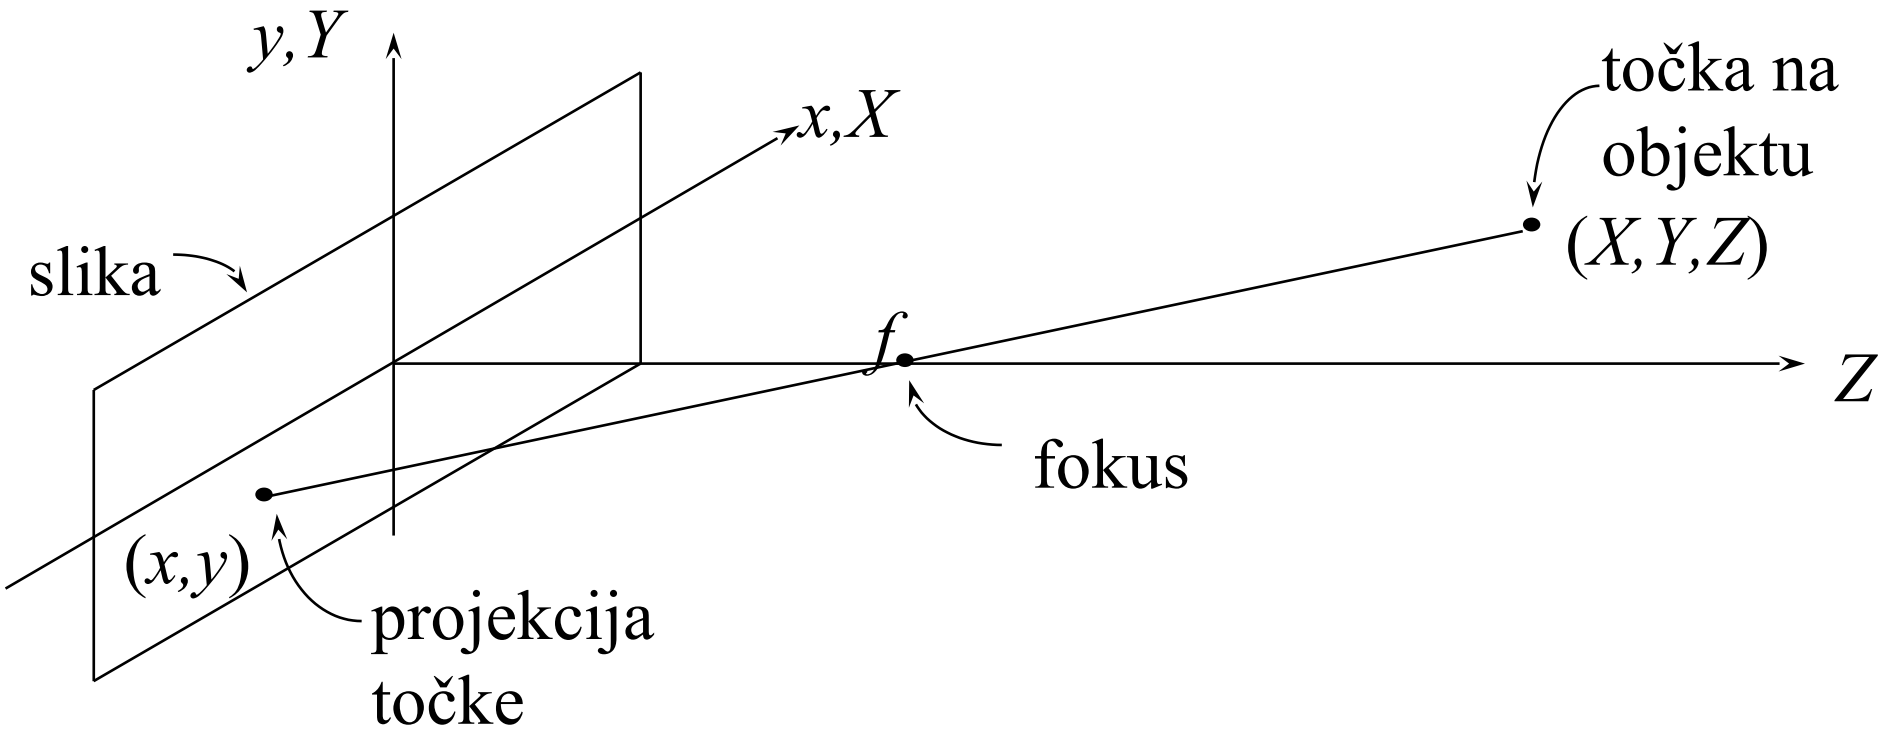
- gore lijevo: originalna slika
- gore lijevo i desno: prikaz korespondentnih točaka
- dolje: iskrivljena slika



Perspektivna transformacija

- Mnoge dvodimenzionalne slike sadrže prikaze trodimenzionalnih scena
- Nekad se želi simulirati pogled na scenu iz druge točke pogleda (iz druge perspektive)
- Perspektivna transformacija preslikava svaku točku (X,Y,Z) iz trodimenzionalnog prostora u dvodimenzionalnu projekciju (x,y) te točke u ravninu slike

Model sustava za snimanje



Perspektivna transformacija I

- Upotrebom sličnih trokuta dobivaju se izrazi:

$$x = \frac{fX}{f - Z}, \quad y = \frac{fY}{f - Z}$$

- Koordinate projekcije su vezane s koordinatama točke objekta nelinearnom relacijom

Perspektivna transformacija II

- Neka je $v = \begin{bmatrix} X & Y & Z \end{bmatrix}^T$ točka objekta
- Neka je $\tilde{v} = \begin{bmatrix} sX & sY & sZ & s \end{bmatrix}^T$ prikaz točke objekta pomoću homogenih koordinata gdje je *s* konstanta skaliranja
- Vektor **v** se može dobiti iz homogenog vektora $\tilde{v}$ dijeljenjem prvih triju komponenti s četvrtom

Perspektivna transformacija III

- Matrica perspektivne transformacije definirana je na slijedeći način:

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & -1/f & 1 \end{bmatrix}$$

Perspektivna transformacija IV

- Produkt $\tilde{w} = \mathbf{P}\,\tilde{v}$ daje homogene koordinate transformirane točke:

$$\tilde{w} = \begin{bmatrix} sX & sY & sZ & s - sZ/f \end{bmatrix}^T$$

- Dijeljenjem prvih triju komponenti vektora s četvrtom dobiva se:

$$w = \begin{bmatrix} \frac{fX}{f-Z} & \frac{fY}{f-Z} & \frac{fZ}{f-Z} \end{bmatrix}^T$$

- Prve dvije komponente vektora **w** predstavljaju perspektivnu projekciju točke u ravninu slike

Zaključak

- Dan je pregled osnovnih metoda za obnavljanje slike:
  - Modeli degradacije slike
  - Inverzni i Wiener filtar
  - Pseudoinverzna matrica
  - Geometrijske modifikacije slike