Ekstrakcija značajki slike

Prof. dr. sc. Sven Lončarić
http://www.fer.unizg.hr/ipg

Uvod

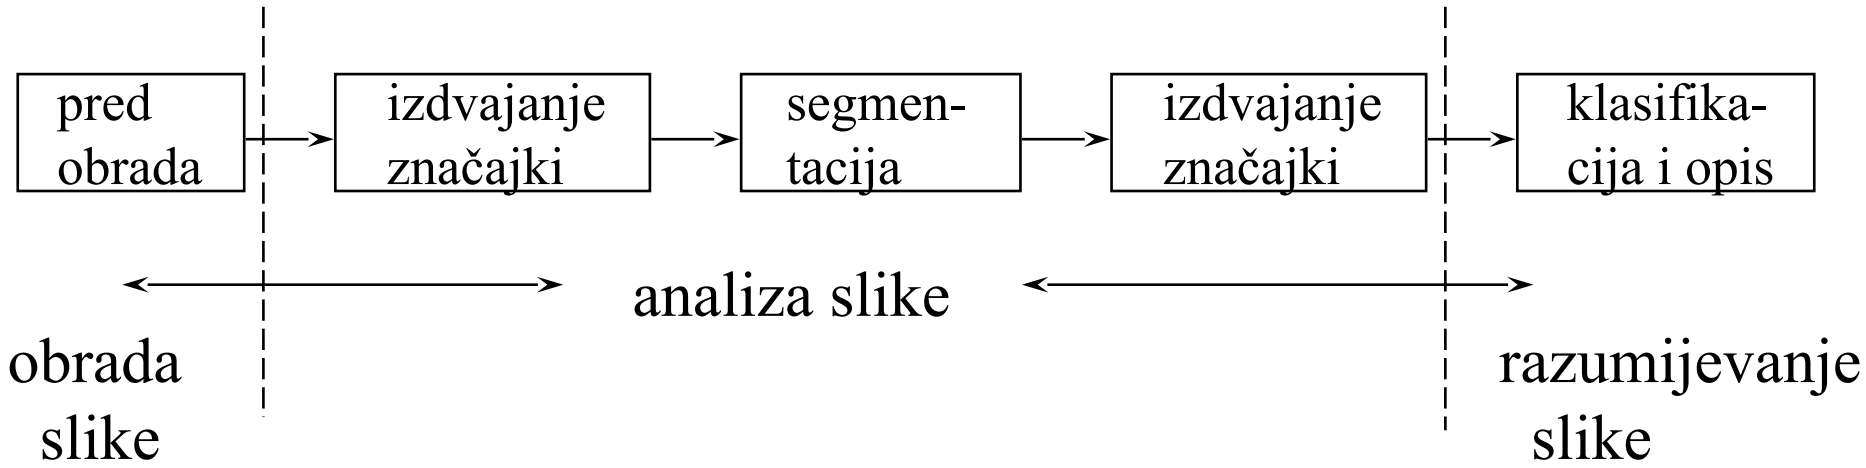
- engl. image feature extraction
- U velikom broju aplikacija potrebno je izdvojiti značajke slike na osnovu kojih se računalom može opisati, interpretirati ili razumjeti sadržaj slike
- Izdvajanje značajki predstavlja početnu kariku u lancu analize slike
- Izdvajanje značajki igra važnu ulogu u metodama za segmentaciju i klasifikaciju sadržaja slike

Pregled tema

- Prostorne značajke
- Značajke u domeni transformirane slike
- Detekcija rubova
- Detekcija granica

Sustav za računalni vid

- engl. computer vision system



Prostorne značajke

- Ova vrsta značajki se direktno izvodi iz vrijednosti elemenata slike
- Postoje dve grupe prostornih značajki:
  - amplitudne značajke
  - značajke histograma

Amplitudne značajke

- Srednja vrijednost u nekoj točki izračunata u okolini dimenzija *W*×*W*:

$$M(j,k)=\frac{1}{W^2}\sum_{m=-w}^{w}\sum_{n=-w}^{w}x(j+m,k+n)$$

gdje je $W = 2w+1$, a $x(m,n)$ ulazna slika

- Standardna devijacija u okolini *W*×*W*:

$$S(j,k)=\frac{1}{W^2}\sum_{m=-w}^{w}\sum_{n=-w}^{w}\left[x(j+m,k+n)-M(j+m,k+n)\right]^2$$

Histogram prvog reda

- Neka je u slučajna varijabla koja predstavlja vrijednosti točaka slike
- Definirajmo funkciju gustoće vjerojatnosti:

$$p_u(x) = P[u = x] \simeq \frac{N_x}{N}, \quad 0 \leq x \leq L-1$$

gdje je N_x broj točaka u slici s vrijednošću x, a N je ukupan broj točaka u slici

- Kvocjent N_x / N predstavlja procjenu funkcije $p_u(x)$ i naziva se histogram prvog reda

Značajke histograma I

- Momenti:

$$m_i = E\left[u^i\right] = \sum_{x=0}^{L-1} x^i \, p_u(x), \quad i = 1,2,\ldots$$

- Centralni momenti:

$$\mu_i = E\left[(u - E(u))^i\right] = \sum_{x=0}^{L-1} \left(x - m_1\right)^i \, p_u(x)$$

- Entropija

$$H = E\left[-\log_2 p_u\right] = -\sum_{x=0}^{L-1} p_u(x) \log_2 p_u(x)$$

Značajke histograma II

- Često se koriste slijedeće značajke:
  - srednja vrijednost: m_1
  - varijanca: μ_2
  - prosječna energija: m_2
  - engl. skewness: μ_3
  - engl. kurtosis: $\mu_4 - 3$
- Histogram se može računati globalno ili lokalno (npr. unutar pomičnog prozora nekih dimenzija)

Histogram drugog reda I

- Neka su u_1 i u_2 slučajne varijable koje predstavljaju vrijednosti dvaju piksela u slici
- Odnos tj. međusobna pozicija dvaju piksela je definiran nekom relacijom
- Primjer: Druga točka može biti na nekoj fiksnoj udaljenosti r i kutem Θ u odnosu na prvu točku

Histogram drugog reda II

- Gustoća vjerojatnosti definirana je izrazom:

$$p_{u_1,u_2}(x_1,x_2)=P\left[u_1=x_1,u_2=x_2\right]\simeq\frac{N(x_1,x_2)}{N}$$

gdje je $0 \le x_1, x_2 \le L\text{-}1$, $N(x_1, x_2)$ je broj parova točaka u slici s vrijednostima x_1, x_2, a N je ukupan broj parova točaka u slici

- Kvocijent $P(x_1, x_2) = N(x_1, x_2) / N$ predstavlja procjenu funkcije gustoće vjerojatnosti drugog reda i zove se histogram drugog reda

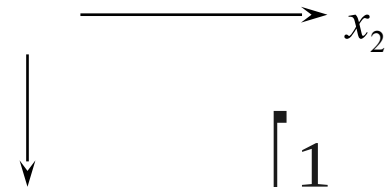
Histogram drugog reda III

- Ako su parovi točaka unutar slike jako korelirani onda će maksimum histograma biti lociran oko glavne dijagonale polja $P(i,j)$
- Histogram drugog reda se koristi u analizi tekstura
- Postoje različite mjere koncentracije energije oko glavne dijagonale polja $P(i,j)$ od kojih su neke spomenute u daljnjem tekstu

Primjer histograma drugog reda

- Neka je U slika dimenzija 4×4 prikazana preciznošću od 2 bita (vrijednosti 0-3)
- Neka je međusobna pozicija dvaju točaka definirana s $u_1 = u(m,n)$, $u_2 = u(m+1,n+1)$,

$$U = \begin{bmatrix} 0 & 1 & 0 & 2 \\ 3 & 2 & 1 & 1 \\ 2 & 1 & 0 & 1 \\ 3 & 1 & 2 & 0 \end{bmatrix}$$



$$H = \frac{1}{9}\begin{bmatrix} 1 & 1 & 1 & 0 \\ 0 & 2 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

Značajke histograma drugog reda

- Autokorelacija:

$$S_A = \sum_{x_1=0}^{L-1} \sum_{x_2=0}^{L-1} x_1 x_2 P(x_1, x_2)$$

- Kovarijanca:

$$S_C = \sum_{x_1=0}^{L-1} \sum_{x_2=0}^{L-1} (x_1 - \bar{x}_1)(x_2 - \bar{x}_2) P(x_1, x_2)$$

- Inercija:

$$S_I = \sum_{x_1=0}^{L-1} \sum_{x_2=0}^{L-1} (x_1 - x_2)^2 P(x_1, x_2)$$

Značajke histograma drugog reda

- Apsolutna vrijednost razlike:

$$S_V = \sum_{x_1=0}^{L-1} \sum_{x_2=0}^{L-1} |x_1 - x_2| P(x_1, x_2)$$

- Energija:

$$S_G = \sum_{x_1=0}^{L-1} \sum_{x_2=0}^{L-1} \left[P(x_1, x_2) \right]^2$$

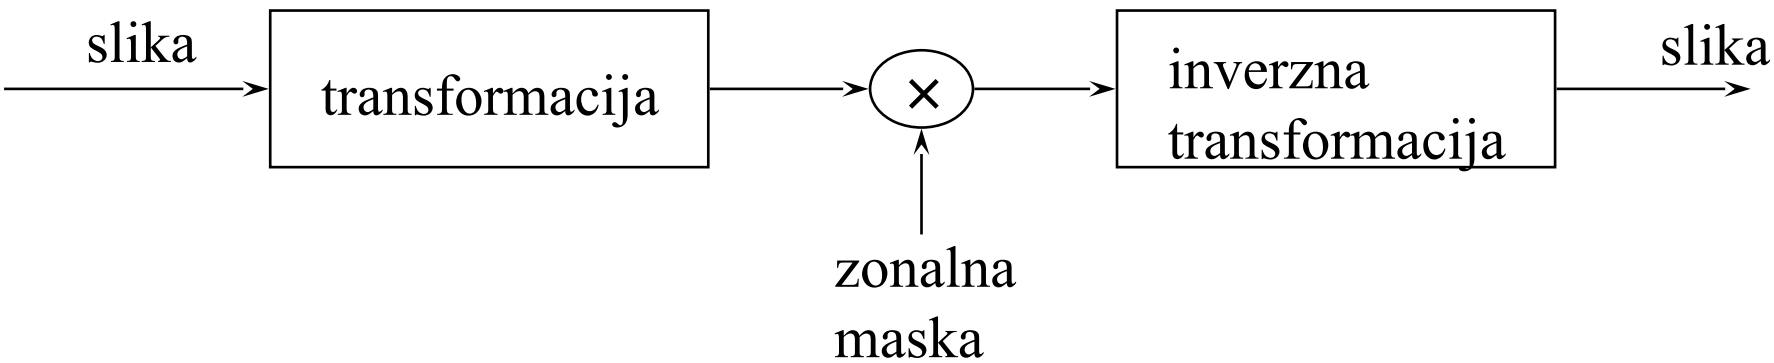
- Entropija:

$$S_T = -\sum_{x_1=0}^{L-1} \sum_{x_2=0}^{L-1} P(x_1, x_2) \log_2 P(x_1, x_2)$$

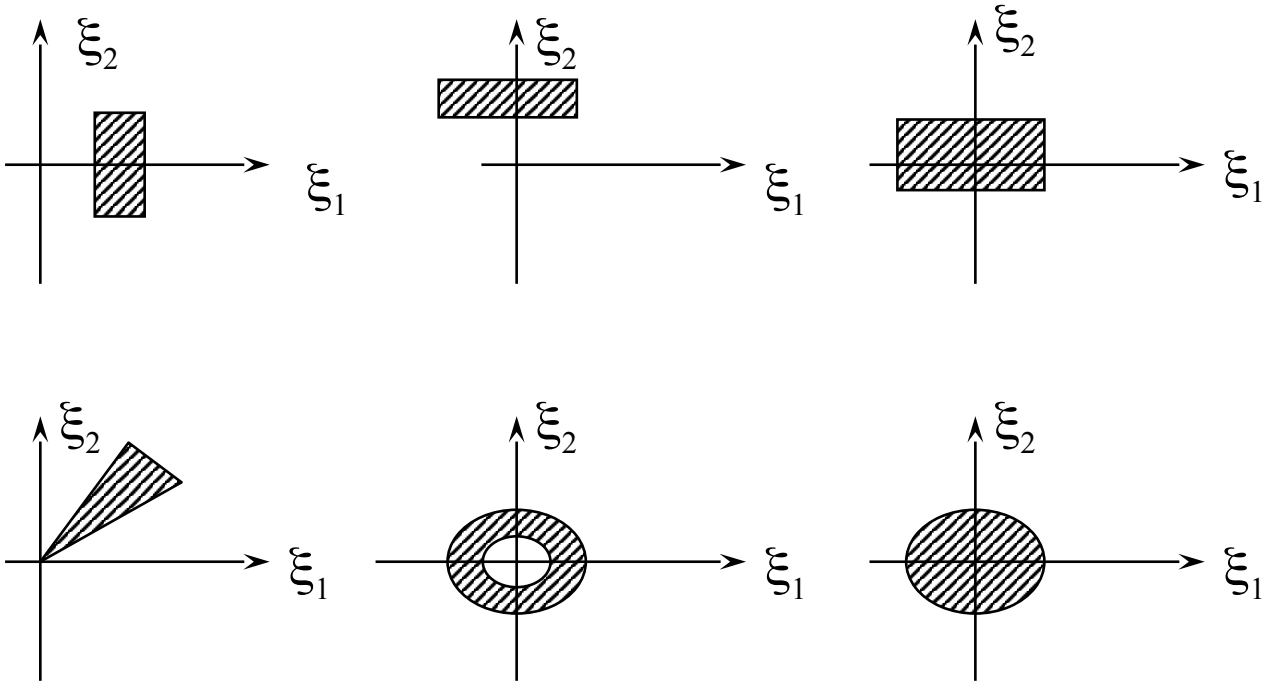
Značajke transformirane slike I

- Značajke mogu biti izdvojene iz transformirane slike (koeficijenata transformacije) upotrebom zonalnih maski
- Zonalne maske izdvajaju koeficijente koji odgovaraju nekoj značajki
- VF značajke odgovaraju rubovim, bridovima, itd.
- Kutne maske služe za detekciju orijentacije

Značajke transformirane slike II



Primjeri zonalnih maski



Detekcija rubova I

- Detekcija rubova je važna u analizi slika zato što rubovi određuju granice objekata i zato su korisni za segmentaciju registraciju i identifikaciju objekata na slici
- Rubovi su mjesta naglih promjena u vrijednosti točaka slike
- Zato je moguće koristiti gradijent funkcije za detekciju ruba

Detekcija rubova II

- Gradijent funkcije dviju varijabli je vektor koji pokazuje smjer najbrže promjene funkcije *f*

$$\operatorname{grad} f(x,y) = \left[\frac{\partial f(x,y)}{\partial x} \quad \frac{\partial f(x,y)}{\partial y} \right]^T = \left[f_x \quad f_y \right]^T$$

- Neka je **u** jedinični vektor orijentiran u smjeru θ :

$$u = \left[\cos\theta \quad \sin\theta \right]^T$$

Detekcija rubova III

- Duljina komponente vektora gradijenta u smjeru vektora u dana je skalarnim produktom:

$$\langle u, \operatorname{grad} f \rangle = f_x \cos\theta + f_y \sin\theta$$

- Odabirom kuta Θ moguće je mjeriti brzinu promjene funkcije u željenom smjeru (detektirati rubove raznih orijentacija)

Detekcija rubova IV

- S obzirom na detekciju smjera ruba postoji podjela na gradijentne (u dva ortogonalna smjera) i kompas (u više smjerova) operatore
- Za diskretne slike operatori se često nazivaju i maske
- Rezultat konvolucije slike s maskama predstavlja ocjenu ortogonalnih gradijenata f_x, f_y

Gradijentni operatori I

- Gradijentni operator je definiran s dvije maske koje mjere gradijent slike $u(m,n)$ u dva ortogonalna smjera
- Neka su maske $h_1(m,n)$, $h_2(m,n)$
- Tada je rezultat konvolucije slike s maskama:

$$g_1(m,n) = \sum_i \sum_j h_1(i,j)\, u(m-i, n-j)$$

$$g_2(m,n) = \sum_i \sum_j h_2(i,j)\, u(m-i, n-j)$$

Gradijentni operatori II

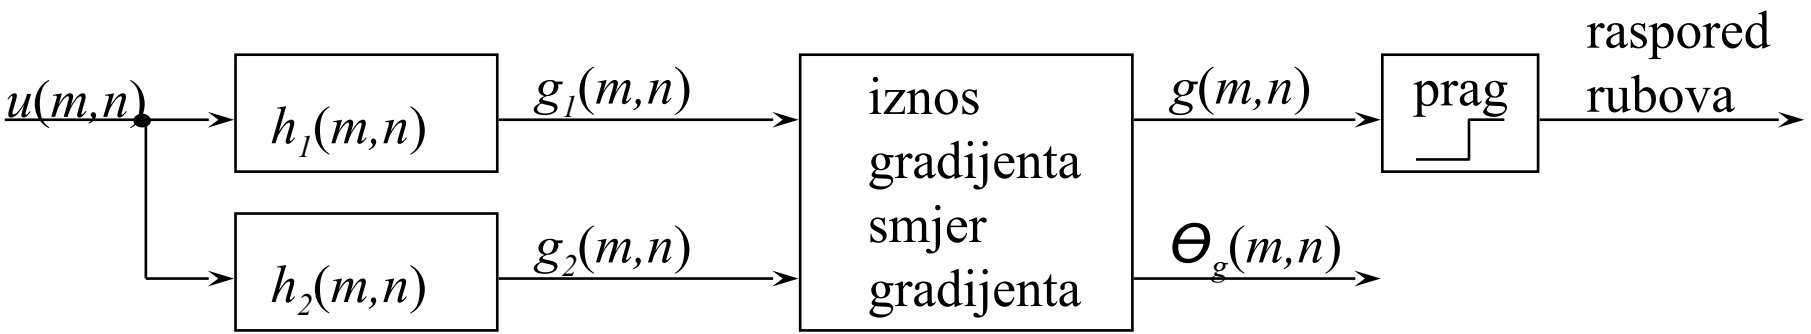
- Iznos i smjer gradijentnog vektora mogu se izračunati na slijedeći način:

$$g(m,n)=\sqrt{g_1^2(m,n)+g_2^2(m,n)}$$

$$\theta_g(m,n)=\tan^{-1}\frac{g_2(m,n)}{g_1(m,n)}$$

Gradijentni operatori III

- Detekcija ruba gradijentnim operatorom prikazana je na slici



Primjeri gradijentnih operatora I

	$h_1(m,n)$	$h_2(m,n)$
Roberts	$\begin{matrix} 0 & 1 \\ -1 & 0 \end{matrix}$	$\begin{matrix} 1 & 0 \\ 0 & -1 \end{matrix}$
Prewitt	$\begin{matrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{matrix}$	$\begin{matrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{matrix}$

Primjeri gradijentnih operatora II

	$h_1(m,n)$	$h_2(m,n)$
Sobel	$\begin{matrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{matrix}$	$\begin{matrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{matrix}$
Frei-Chen	$\begin{matrix} -1 & 0 & 1 \\ -\sqrt{2} & 0 & \sqrt{2} \\ -1 & 0 & 1 \end{matrix}$	$\begin{matrix} -1 & -\sqrt{2} & -1 \\ 0 & 0 & 0 \\ 1 & \sqrt{2} & 1 \end{matrix}$

Ograničenja gradijentnih operatora

- Problem: Nemogućnost točne detekcije ruba u prisutnosti smetnji (šuma)
- Rješenje: Povećanje dimenzija maski da bi se postigao efekt usrednjavanja radi smanjenja utjecaja šuma
- Prednosti: Velika maska jače usrednjava šum
- Mane: Velika maska jače zamućuje sliku, te onemogućava točnu lokalizaciju ruba

Prewitt horizontalna maska 7x7

$$H = \frac{1}{21}\begin{bmatrix} 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \end{bmatrix}$$

Abdou piramidalna maska 7x7

$$H = \frac{1}{34}\begin{bmatrix} 1 & 1 & 1 & 0 & -1 & -1 & -1 \\ 1 & 2 & 2 & 0 & -2 & -2 & -1 \\ 1 & 2 & 3 & 0 & -3 & -2 & -1 \\ 1 & 2 & 3 & 0 & -3 & -2 & -1 \\ 1 & 2 & 3 & 0 & -3 & -2 & -1 \\ 1 & 2 & 2 & 0 & -2 & -2 & -1 \\ 1 & 1 & 1 & 0 & -1 & -1 & -1 \end{bmatrix}$$

Maske Gaussovog oblika I

- Neka je

$$g(x,s)=\frac{1}{s\sqrt{2\pi}}\exp\left\{-\frac{1}{2}\left(\frac{x}{s}\right)^2\right\}$$

kontinuirana Gaussova funkcija s standardnom devijacijom *s*

- Tada se horizontalna maska dobiva (Argyle) otipkavanjem funkcija

$$H(x,y)=-2g(x,s)g(y,t), \quad x\geq 0$$
$$H(x,y)=2g(x,s)g(y,t), \quad x<0$$

gdje *s* i *t* određuju širinu maske

Maske Gaussovog oblika II

- Macleod je predložio metodu gdje se horizontalna gradijentna maska određuje kao

$$H(x,y)=\left[g(x+s,s)-g(x-s,s)\right]g(y,t)$$

- Argyle i Macleod Gaussove maske daju manju važnost pikselima koji su daleko od centra maske

Struktura detektora ruba

- Radi boljih svojstava u prisutnosti šuma filtri za detekciju rubova se često projektiraju kao kombinacija dvaju nezavisnih impulsnih odziva:
  - NP sustav za uklanjanje šuma $H_{NP}(j,k)$
  - VP sustav za detekciju rubova $H_G(j,k)$
- Ukupni odziv (maska) jednaka je konvoluciji:

$$H(j,k) = H_G(j,k) \otimes H_{NP}(j,k)$$

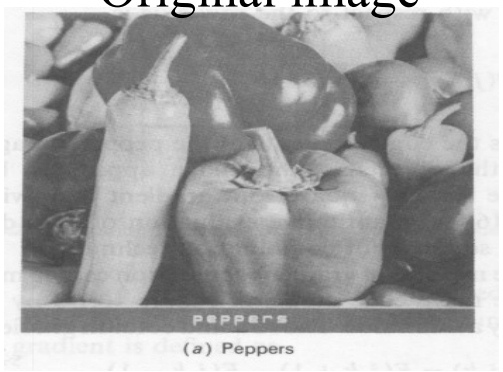
Derivacija Gaussove funkcije

- Primjer prethodnog koncepta je DroG (derivative of Gaussian) maska koja se sastoji od izglađivanja (usrednjavanja) Gaussovom funkcijom nakon čega slijedi diferencijacija

$$H(x,y) = -\frac{d}{dx}\left[g(x,s)g(y,t)\right]$$
$$= -\frac{xg(x,s)g(y,t)}{s^2}$$

Primjer gradijenata

Original image



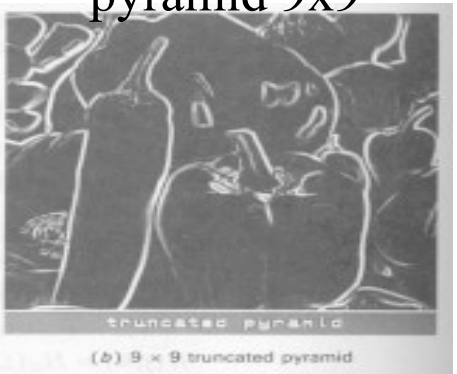
(a) Peppers

Prewitt 7x7



(a) 7 × 7 boxcar

pyramid 9x9



(b) 9 × 9 truncated pyramid



(e) 11 × 11 derivative of Gaussian, $s = 2.0$

DroG 11x11



(c) 11 × 11 Argyle, $s = 2.0$

Argyle 11x11



(d) 11 × 11 Macleod, $s = 2.0$

Macleod 11x11

Canny maska I

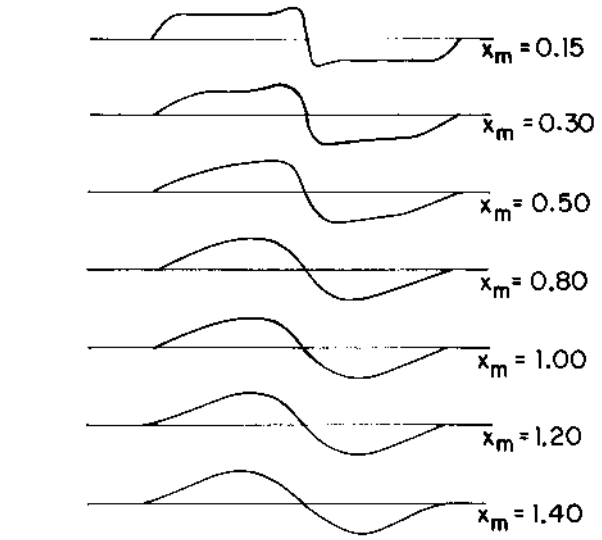
- Sve prethodne maske su heuristički izvedene
- Canny je koristio analitički pristup na osnovi 1-D kontinuiranog modela skokovitog ruba iznosa h_E te aditivnog Gaussovog šuma varijance σ_n
- Detekcija se obavlja konvolucijom 1-D impulsnog odziva $h(x)$ i zašumljenog signala $f(x)$
- Rub se detektira na mjestu maksimalnog odziva u konvoluciji signala $h(x)$ i $f(x)$

Canny maska II

- Maska $h(x)$ je odabrana tako da zadovoljava tri kriterija:
  - 1. Dobra detekcija (maksimizacija odnosa signal/šum kod odziva)
  - 2. Dobra lokalizacija (izbjegavanje pogrešnog označavanja mjesta ruba)
  - 3. Jedan odziv (potrebno je da postoji samo jedan detektirani rub)

Canny maska III

- Numeričkim metodama Canny je našao rješenje problema za neke slučajeve
- Krajnji slučajevi odgovaraju Prewitt i DroG maskama



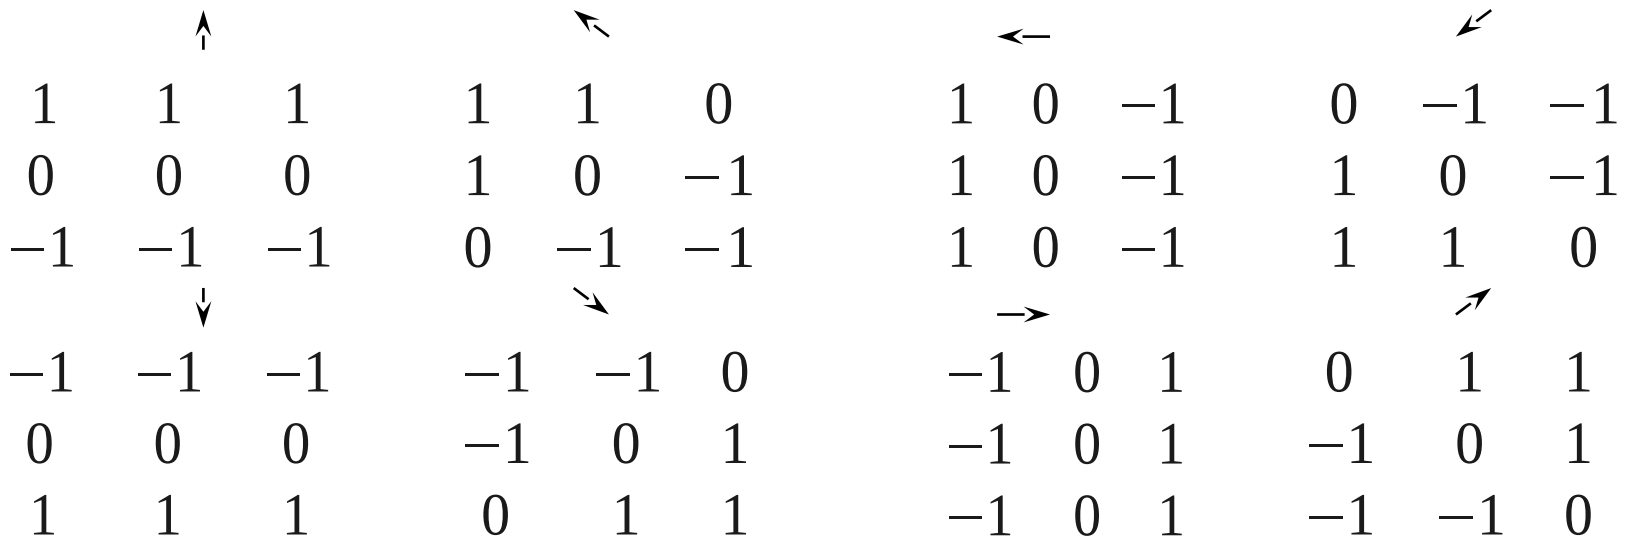
Kompas operatori I

- Kompas operatori mjere gradijent u nekoliko odabranih smjerova
- Tablica prikazuje maske za detekciju ruba sjeverne orijentacije za nekoliko različitih kompas operatora:

$$\begin{matrix} 1 & 1 & 1 \\ 1 & -2 & 1 \\ -1 & -1 & -1 \end{matrix} \qquad \begin{matrix} 5 & 5 & 5 \\ -3 & 0 & -3 \\ -3 & -3 & -3 \end{matrix} \qquad \begin{matrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{matrix} \qquad \begin{matrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{matrix}$$

Kompas operatori II

- Osam maski trećeg kompas operatora iz gornje tablice dobivenih rotacijom za 45 stupnjeva prikazane su u slijedećoj tablici:



Kompas operatori III

- Gradijent u točki (*m,n*) je definiran izrazom:

$$g(m,n)=\max_k \left\{|g_k(m,n)|\right\}$$

- Dobiveni gradijent se može ograničiti na dva nivoa upotrebom praga da bi se dobio raspored rubova
- Kompas operatori s većom kutnom rezolucijom od 45 stupnjeva se mogu kreirati upotrebom veće dimenzije maske

Laplace-ov operator I

- Gradijentne maske daju najbolje rezultate za oštre rubove (nagla promjena vrijednosti točaka)
- Kada rubovi postaju blaži (širi prijelaz) bolje rezultate daju druge derivacije
- Često se koristi Laplace-ov operator:

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

Laplace-ov operator II

- Kontinuirani Laplace-ov operator u diskretnom slučaju nadomješta se maskom
- Konvolucija maske s slikom daje ocjenu (engl. estimate) Laplace-ovog operatora
- Tablica prikazuje tri diskretna operatora za ocjenu vrijednosti Laplaceovog operatora:

$$\begin{matrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{matrix} \qquad \begin{matrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{matrix} \qquad \begin{matrix} 1 & -2 & 1 \\ -2 & 4 & -2 \\ 1 & -2 & 1 \end{matrix}$$

Laplace-ov operator III

- Upotrebom Lapace operatora moguće je izračunati položaj rubova na dva načina:

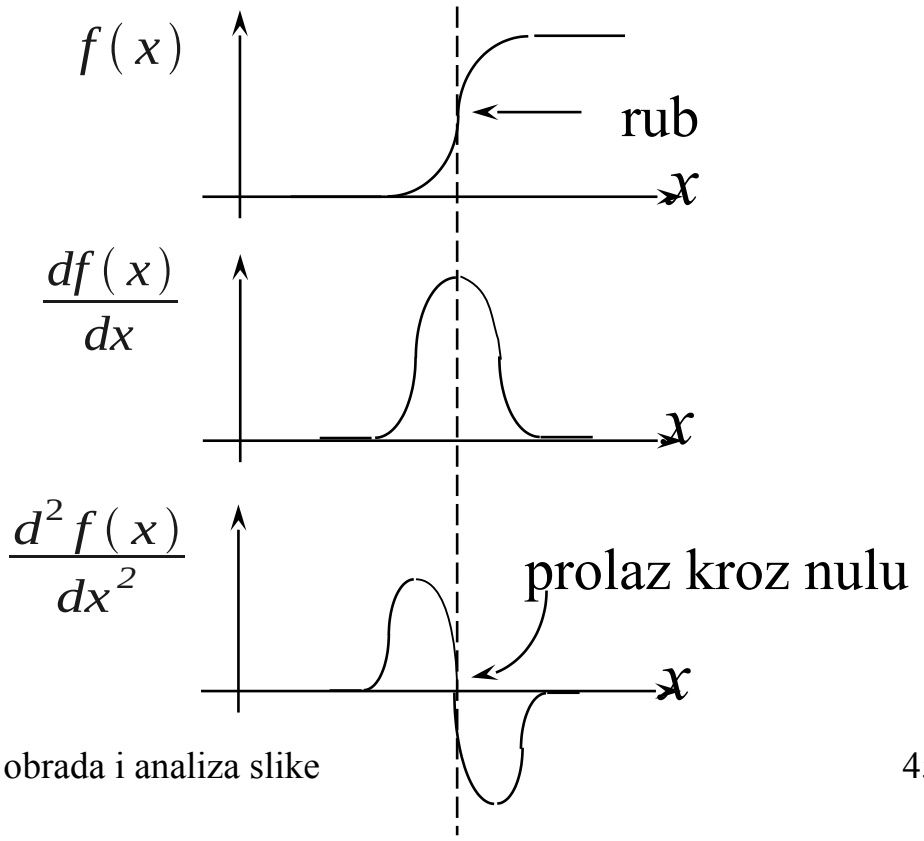
  1. odziv bloka prag na funkciju $\nabla^2 f$

  2. nule funkcije $\nabla^2 f$

- Prvi način ne daje dobre rezultate zato jer proizvodi dvostruke rubove
- Drugi način je bolji ali postoji velika osjetljivost na šum (zbog druge derivacije)

Detekcija prolazom kroz nulu

- Slika desno ilustrira detekciju rubova prolazom druge derivacije kroz nulu (jednodimenzionalni slučaj)
- engl. zero-crossing edge detection



Detekcija ruba Laplace operatorom

- Zbog osjetljivosti na šum $\nabla^2 f$ operatoru Marr je dodao NP filter Gaussovog oblika tako da je frekvencijska karakteristika kobinacije jednaka:

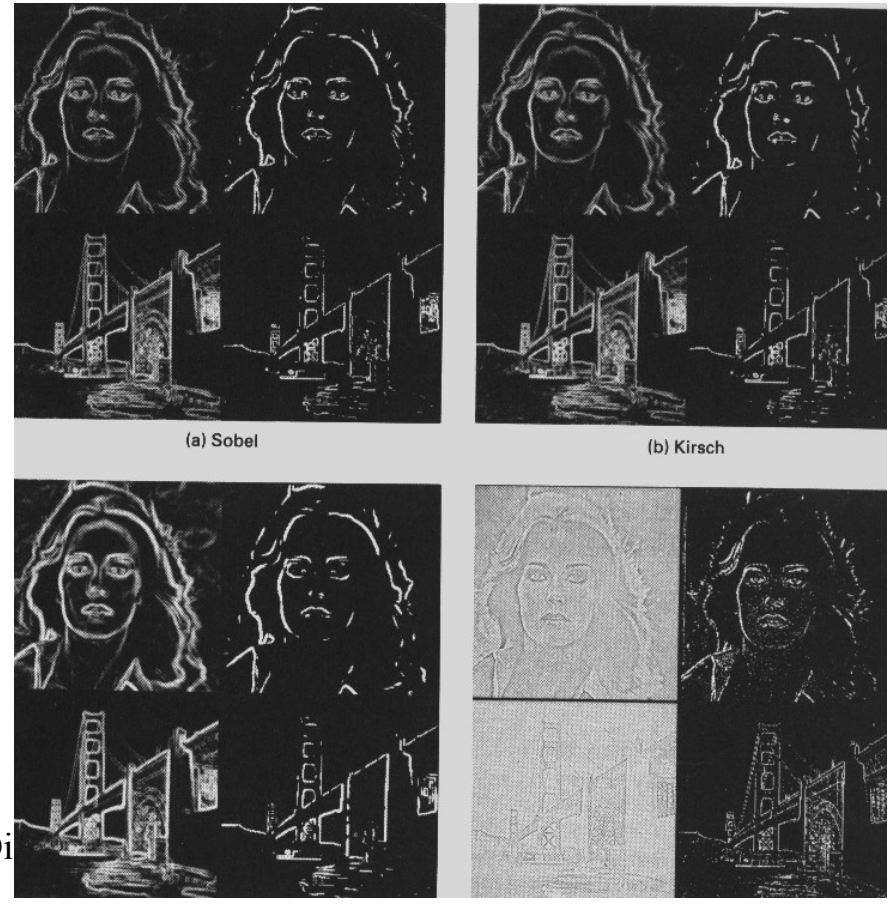
$$H(\xi_1,\xi_2)=(\xi_1^2+\xi_2^2)\exp\left[-2\sigma^2(\xi_1^2+\xi_2^2)\right]$$

$$h(m,n)=c\left(1-\frac{m^2+n^2}{\sigma^2}\right)\exp\left(-\frac{m^2+n^2}{2\sigma^2}\right)$$

- Položaj rubova je određen nulama odziva na gornji filter (engl. zero-crossings)

Primjeri detekcije rubova

- GL: Sobel
- GD: Kirsch
- DL: stohastički
- DD: Laplace

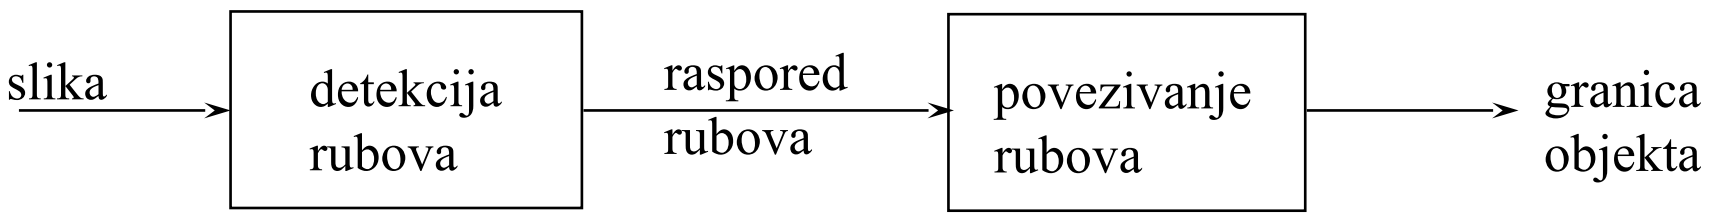


Primjer detekcije rubova prolazom kroz nulu



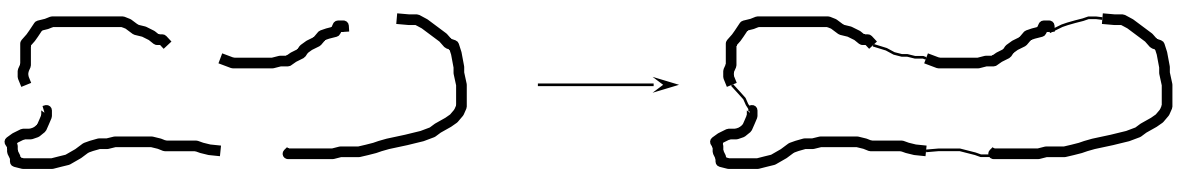
Detekcija granica

- Granica objekta je skup povezanih rubova koji predstavljaju oblik objekta
- Granica je korisna za opis i određivanje geometrijskih značajki (površina ili orijentacija)
- Granica se može odrediti postupkom povezivanja rubova (engl. edge linking)



Povezivanje rubova I

- Problem: Detektori rubova tipično ne mogu detektirati kompletan rub objekta (npr. uslijed lošeg kontrasta na dijelu granice objekta)
- Zbog toga su rubovi razlomljeni ili prekinuti
- Povezivanje rubova je konverzija binarne slike koja prikazuje raspored rubova (nepovezan) u sliku koja sadrži cijelu (povezanu) granicu objekta

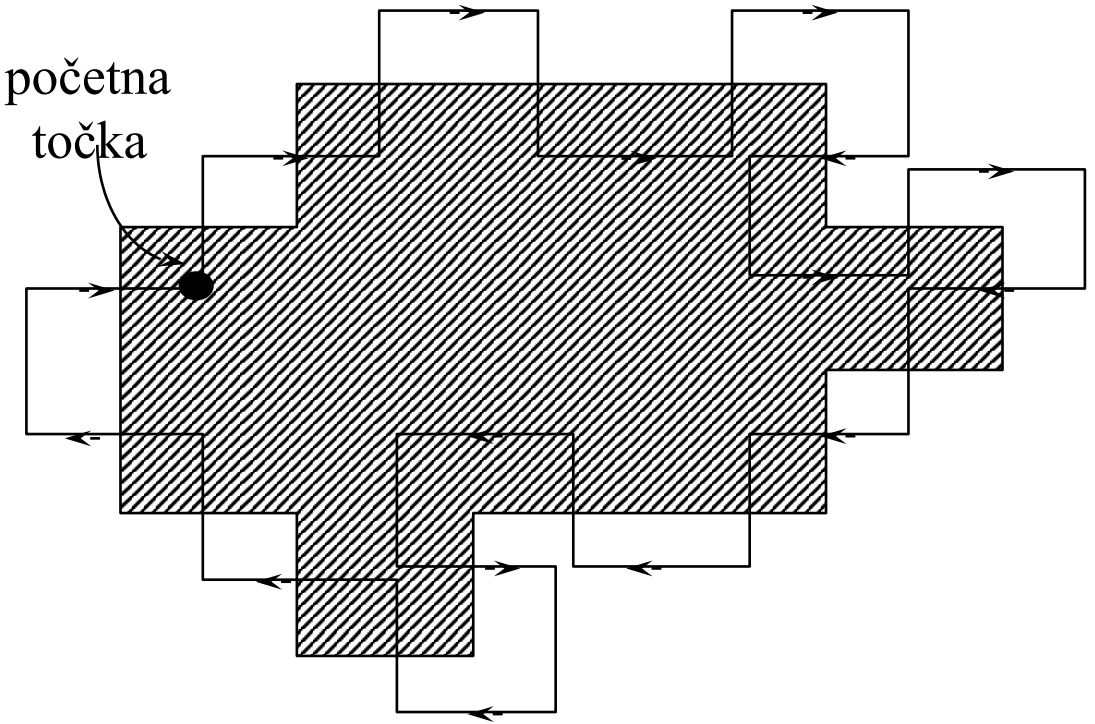


Povezivanje rubova II

- Povezivanje rubova objekta radi dobivanja granice objekta je problem prepoznavanja linija i krivulja u binarnoj slici odnosno problem segmentacije
- Metode za povezivanje rubova uključuju:
  - Iterativno povezivanje točaka linijskim segmentima
  - Heurističke metode za povezivanje rubova
  - Hough-ova transformacija

Praćenje konture I

- Kod binarnih slika granica objekta može se naći postupkom praćenja konture (engl. contour following, bug following)



Praćenje konture II

Algoritam: Praćenje konture

1. Odaberi početnu točku unutar objekta uz granicu
2. Napravi početni korak preko granice objekta
3. Dok se ne stigne u početnu točku ponavljaj
4. Ako je trenutna pozicija unutar objekta
   - onda napravi korak u lijevo
   - inače napravi korak u desno

Zaključak

- Značajke slike važne su za više nivoe u hijerarhiji analize slike: segmentaciju, prepoznavanje, ...
- Predstavljene su osnovne metode za ekstrakciju značajki slike:
  - Prostorne značajke
  - Značajke u domeni transformirane slike
  - Detekcija rubova
  - Detekcija granica