Segmentacija slike

Uvod

- Segmentacija slike se bavi dekompozicijom scene u njezine sastavne dijelove (regije)
- Segmentirane regije slike imaju sljedeće željene karakteristike:
  - Regije su uniformne s obzirom na neko svojstvo (kao npr. vrijednost točke ili tekstura)
  - Granice regija moraju biti jednostavne
  - Regije ne smiju imati male otvore
  - Susjedne regije se moraju značajno razlikovati

Pregled tema

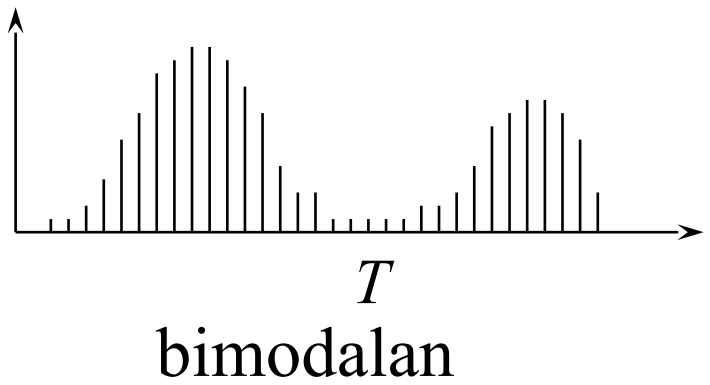
- Amplitudna segmentacija (amplitude thresholding)
- Obilježavanje komponenti (component labeling)
- Metode koje koriste granicu objekta
- Metode koje koriste unutrašnjost objekta
- Metode grupiranja
- Segmentacija ekspertnim sustavima
- Segmentacija neuronskim mrežama

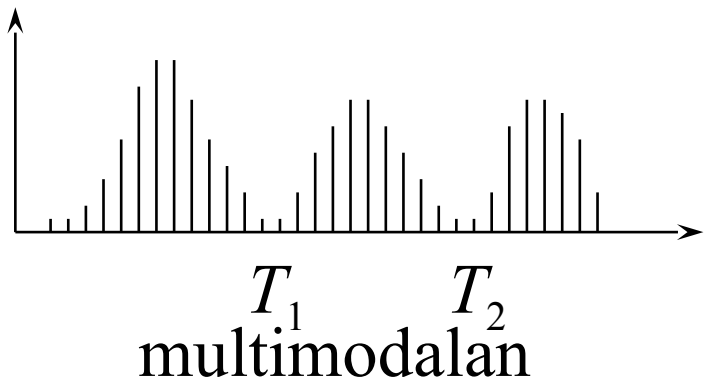
Amplitudna segmentacija

- Amplitudna segmentacija je korisna kad amplitudne značajke dovoljno precizno definiraju regije scene
- engl. amplitude thresholding
- Najčešće se za amplitudnu segmentaciju koristi histogram prvog reda

Histogram prvog reda

- Histogram prvog reda predstavlja relativnu frekvenciju svjetlina točaka u slici
- Histogram može biti bimodalan ili multimodalan
- Histogram se može izračunati globalno ili lokalno





Pristupi amplitudnoj segmentaciji

- Odrediti pragove pomoću minimuma u histogramu
- Odrediti iznos praga tako da određeni dio točaka ima svjetlinu nižu od praga
- Odrediti prag na osnovu histograma izračunatog samo za točke u slici koje zadovoljavaju neki kriterij (npr. imaju veliki gradijent)
- Koristiti a priori statističko znanje o regijama da bi minimzirali neku veličinu (npr. pogrešku)

Bimodalna segmentacija

- Kod mnogih slika vrijednost točaka pada u jednu od dvije grupe (tamne ili svjetle točke)
- Primjeri: pisani tekst, mikroskopski uzorci, avioni na pisti, kosti na rendgenskom filmu, ...
- U takvim slučajevim se objekt može izdvojiti od pozadine na osnovi vrijednosti amplitude
- Praktični problemi kod izbora vrijednosti praga: šum i smetnje, objekt i pozadina imaju širok raspon vrijednosti, neuniformna pozadina

Odabir praga

- Ako je histogram bimodalan (ima dva istaknuta maksimuma između kojih se nalazi minimum) onda za prag treba odabrati amplitudnu vrijednost koja odgovara srednjem minimumu
- Problem: Određivanje minimuma je teško zbog izlomljenosti krivulje histograma
- Rješenje: Izgladiti histogram ili izvršiti interpolaciju glatkom funkcijom

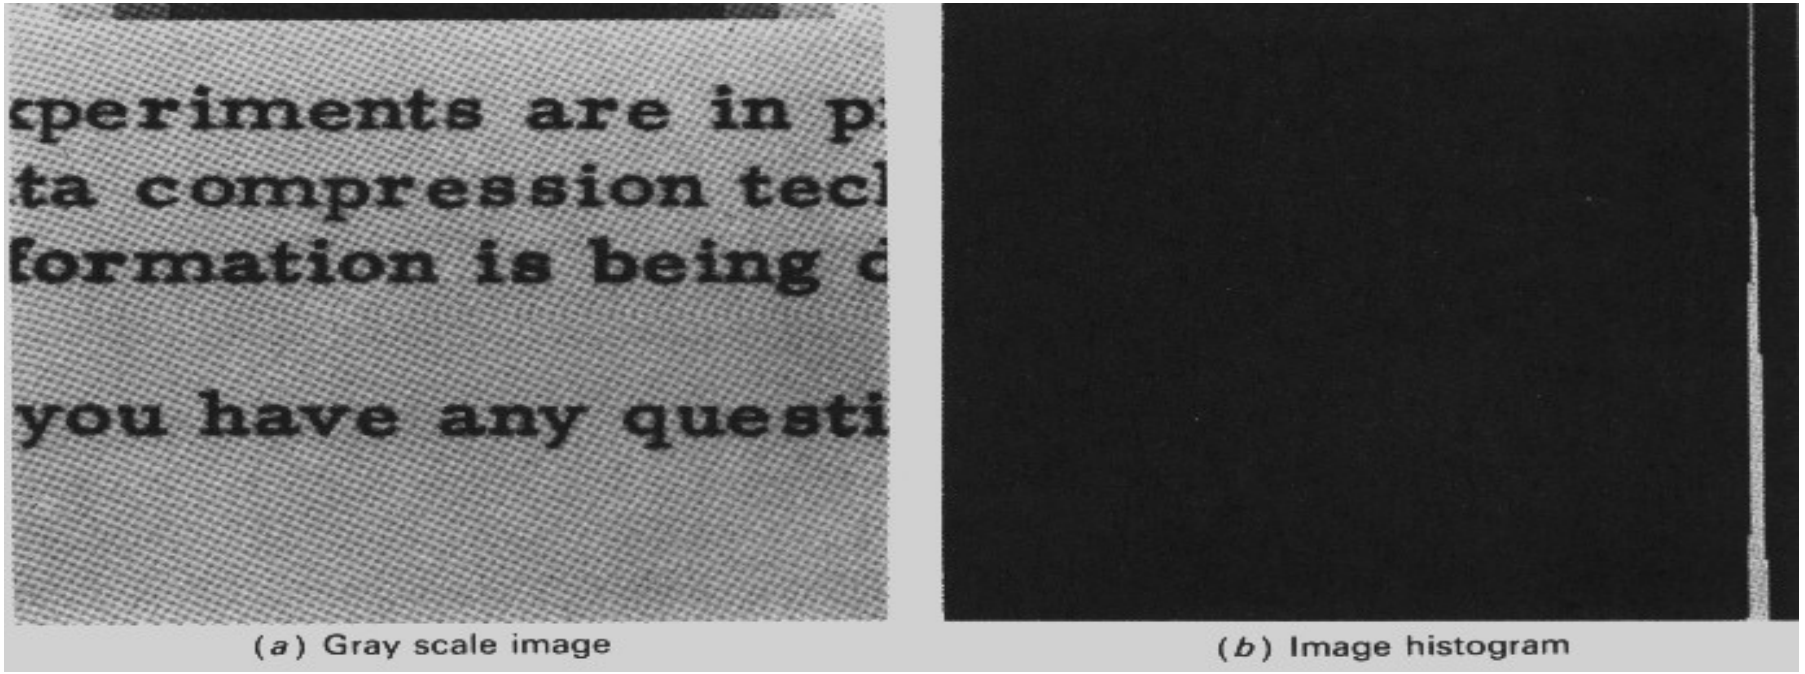
Primjer a priori znanja

- Ako je poznato da objekt prekriva određeni dio površine slike može se prag odrediti tako da segmentirana regija ima površinu jednaku željenom dijelu ukupne površine slike
- Primjer: Ako crna slova pokrivaju 25% površine stranice onda se prag odabere tako da četvrtina točaka bude crna nakon segmentacije

Adaptivna segmentacija

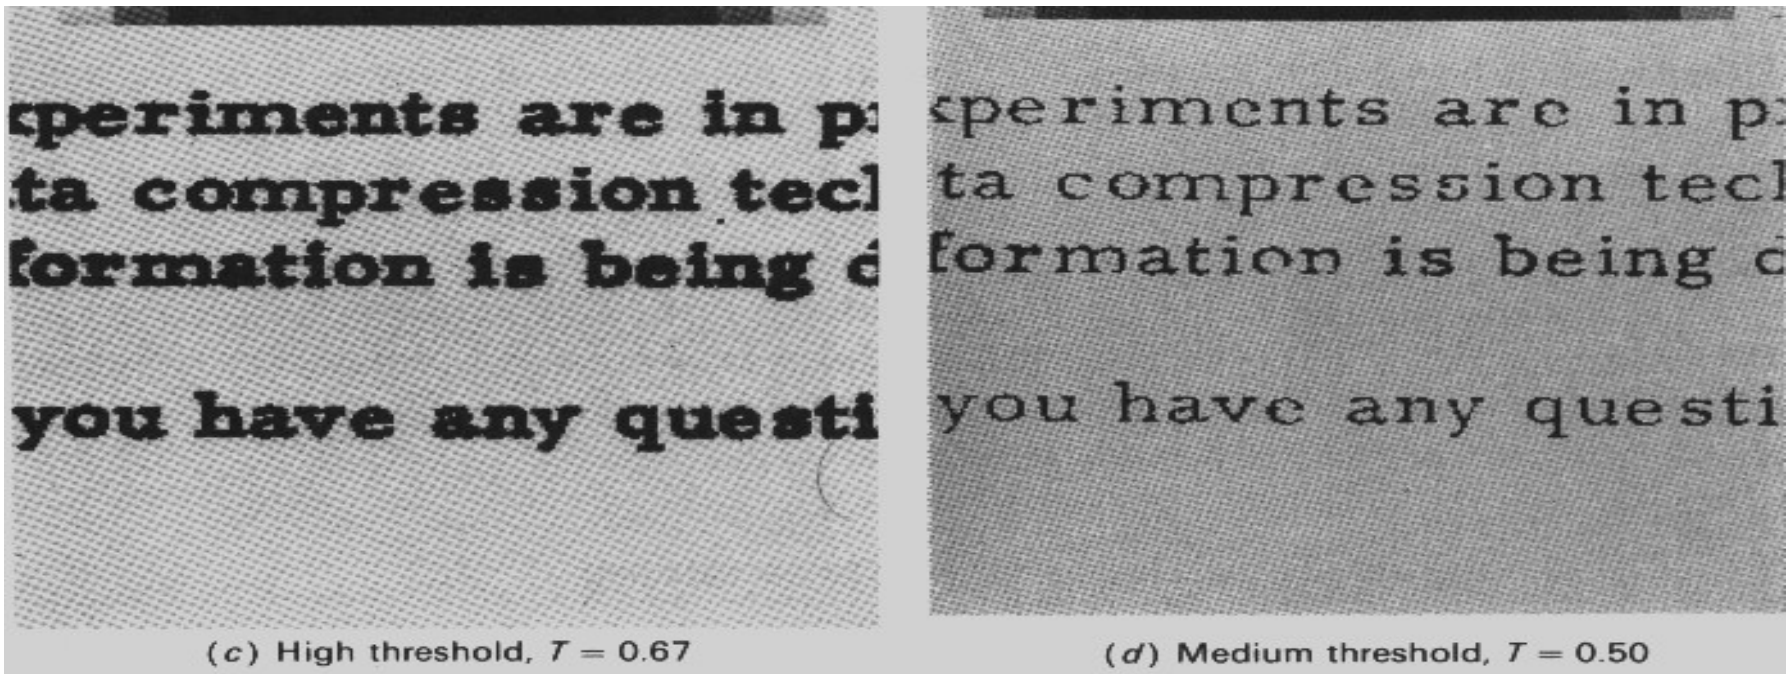
- engl. adaptive thresholding
- Kod adaptivne tehnike prag za neku točku određuje se na osnovi histograma izračunatog u nekoj okolini te točke, a ne cijele slike
- Okolina točke može biti npr. kvadratnog oblika, dimenzija $N \times N$

Primjer bimodalne segmentacije I



(*a*) Gray scale image (*b*) Image histogram

Primjer bimodalne segmentacije II



(*c*) High threshold, $T = 0.67$ (*d*) Medium threshold, $T = 0.50$

Višemodalna segmentacija

- Višemodalni histogram je histogram koji ima više od dva globalna maksimuma
- Slika tada sadrži nekoliko dominantnih nivoa amplituda (nekoliko vrsta objekata)
- Ako je razdioba dominantnih amplituda unaprijed poznata onda je lako odrediti pragove
- Ako je razdioba amplituda slike nepoznata sliku je moguće segmentirati raznim iterativnim metodama

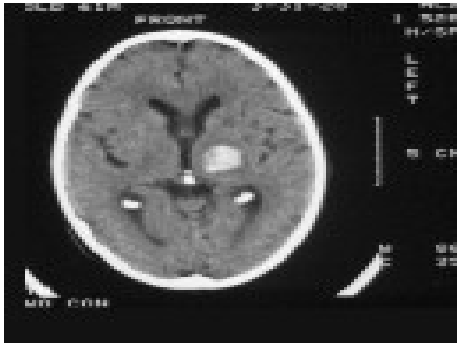
Tomita metoda

- Tomita je razvio rekurzivnu metodu gdje se u prvom koraku slika pragom dijeli u dvije regije
- U drugom koraku se računa histogram za svaku od regija i ako je histogram bimodalan regija se ponovo dijeli u dva dijela
- Ako je histogram unimodalan regija se ne dijeli
- Procedura se rekurzivno ponavlja sve dok se svi bimodalni histogrami ne eliminiraju i ostanu samo unimodalni histogrami (prema nekom kriteriju)

Višemodalna segmentacija II

- U nekim slučajevima slike imaju promjenjive karakteristike (varijabilnu svjetlinu)
- Iterativni algoritam grupiranja dijelova histograma upotrebom algoritma s *K* srednjih vrijednosti (engl. *K*-means clustering) može detektirati modove
- Srednje vrijednosti su centri pojedinih dijelova histograma
- Prikaz algoritma s *K* srednjih vrijednosti dan je kasnije u poglavlju

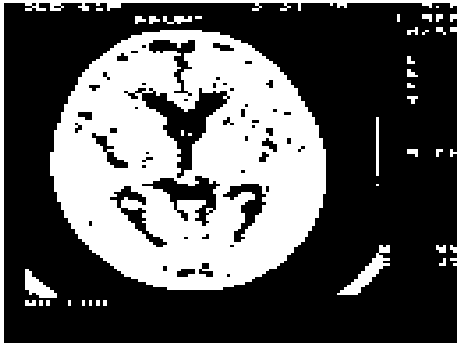
Primjer višemodalne segmentacije



CT slika glave



histogram



thr=100



thr=128



thr=150

Amplitudne projekcije

- U nekim slučajevima slika se može segmentirati upotrebom projekcija u smjeru redaka i stupaca:

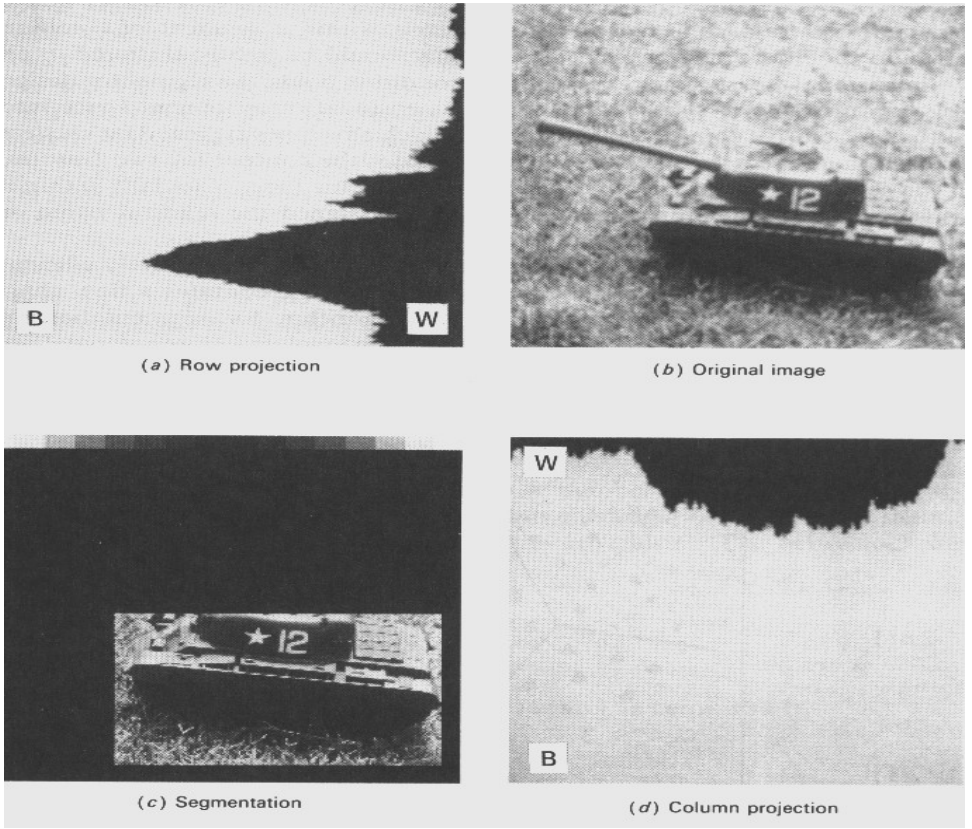
$$H(k) = \frac{1}{N} \sum_{j=1}^{N} F(j,k)$$

$$V(j) = \frac{1}{N} \sum_{k=1}^{N} F(j,k)$$

- Pravokutni segment se definira primjenom praga na projekcijama slike (amplitude thresholding)

Primjer amplitudnih projekcija

- GL: projekcija uzduž redaka
- GD: originalna slika
- DL: segmentirana slika
- DD: projekcija uzduž stupaca



Obilježavanje komponenti slike

- engl. component labeling
- Ako se slika segmentira u dvije regije (npr. pozadina i objekt) onda je se rezultat segmentacije može prikazati kao binarna slika
- Dobiveni objekt može se sastojati od više nepovezanih regija (komponenti)
- U tom slučaju je potrebno obilježiti (labelirati) dobivene komponente tako da svaka komponenta ima svoju oznaku

Obilježavanje komponenti I

- Binarnom slikom se prolazi liniju po liniju (slijeva na desno i odozgo prema dolje)
- Trenutna točka X može biti objekt (vrijednost 1) ili pozadina (vrijednost 0)
- Ako je X=1 (objekt) točka se obilježi ispitivanjem susjeda A,B,C,D kako slijedi:

C	A	D
B	X	

Obilježavanje komponenti II

- Ako je neki od susjeda A,B,C,D već obilježen da pripada nekom objektu onda i X dobiva istu oznaku (labelu)
- Ako neki od susjeda imaju razne oznake onda se pripadni objekti stapaju (ekvivalentni objekti)
- Nova oznaka se stvara kod svakog prijelaza iz vrijednosti 0 na izoliranu točku 1 (novi objekt)
- Rezultat pretraživanja je segmentacija slike u regije (skupina objekata slike)

Metode koje koriste granicu objekta

- engl. boundary methods
- Ova grupa metoda vrši segmentaciju objekata u slici na osnovi granica objekata
- Granice objekata se mogu izdvojiti metodama:
  - Praćenje granice
  - Interpolacije krivulja
  - Hough-ova transformacija

Praćenje granice

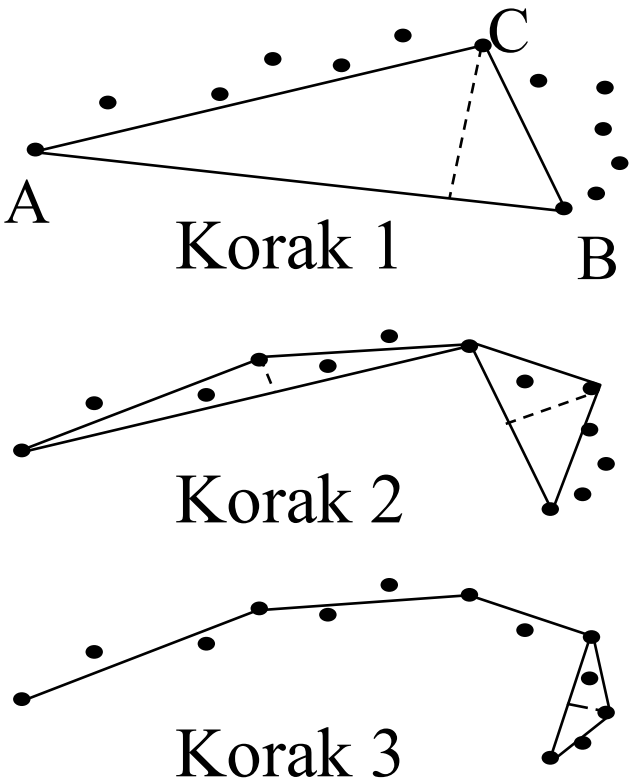
- Algoritam praćenja granice je opisan u poglavlju o ekstrakciji značajki slike
- Rezultat algoritma je niz koordinata točaka koje su na granici objekta
- Dobiveni niz određuje regiju slike koja pripada objektu

Interpolacija krivulja

- Nekad je moguće točke rasporeda rubova (edge map) povezati metodama interpolacije da bi se dobila zatvorena kontura koja definira regiju
- Potrebno je razbiti konturu u dijelove koji se interpoliraju
- Za interpolaciju moguće je koristiti polinomske ili spline metode
- Jednostavni iterativni algoritam za interpolaciju krivulje linearnim segmentima je opisan u nastavku

Interpolacija linearnim segmentima

- Početna i završna točka su A i B
- U svakom koraku mjeri se maksimalna pogreška i ako ona prelazi granicu onda se segment razbija u dva segmenta
- Postupak se ponavlja dok se ne postigne željena točnost



Hough-ova transformacija I

- HT se koristi za detekciju linija u slici
- Pravac se može opisati slijedećom jednadžbom:

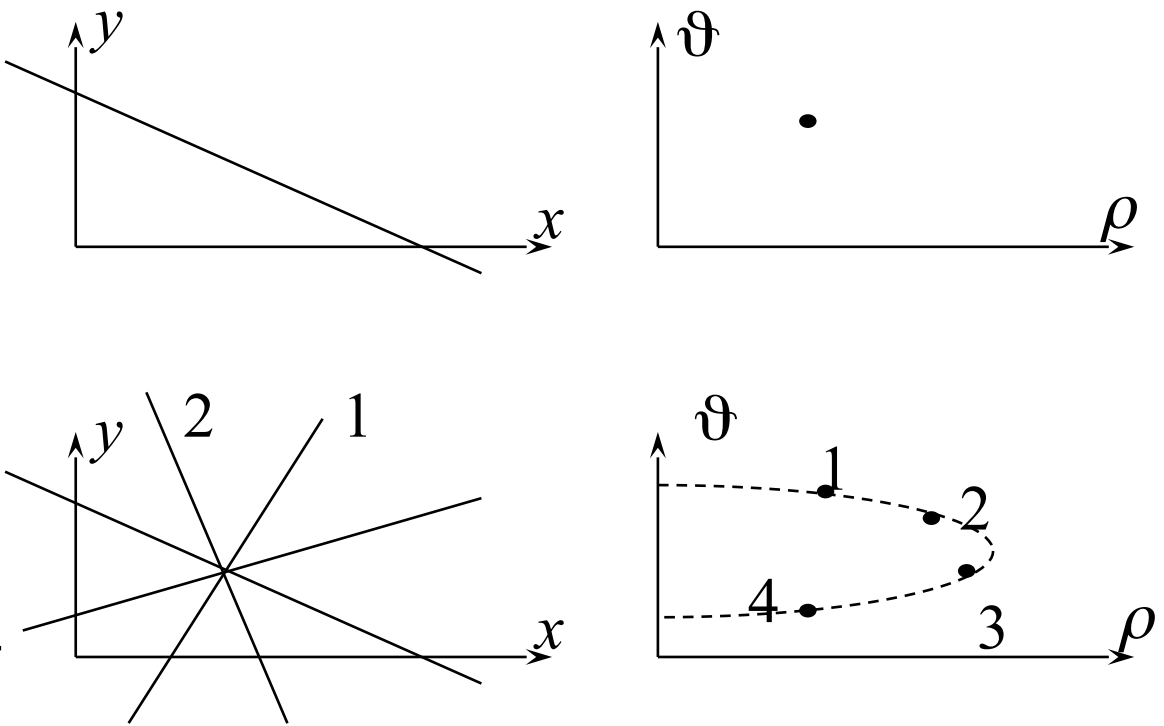
$$x\cos\theta + y\sin\theta = \rho$$

gdje je ρ udaljenost pravca od ishodišta a θ kut nagiba

- Hough transformacija pravca je točka u koordinatnom sustavu (ρ, θ)
- Familija pravaca koji prolaze kroz jednu točku se preslikava u skup točaka koje leže na sinusoidi

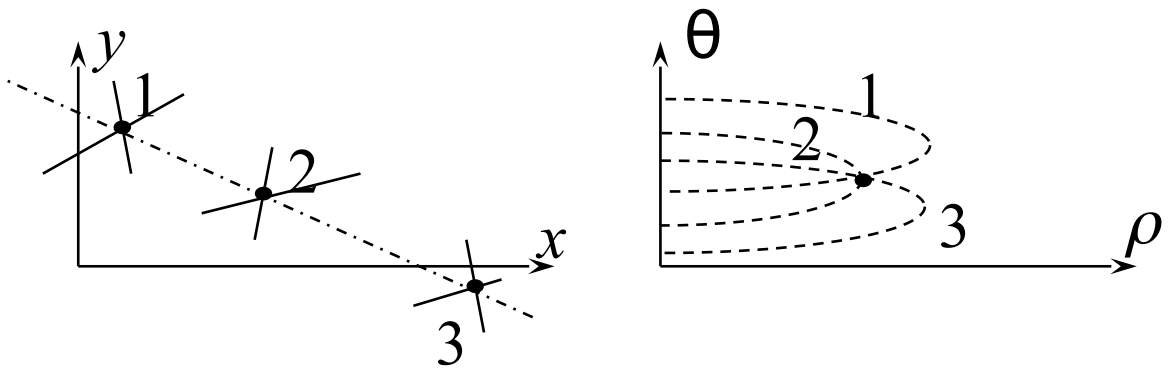
Ilustracija Hough-ove transformacije I

- Pravac se preslikava u točku
- Familija pravaca kroz točku se preslikava u sinusoidu



Ilustracija Hough-ove transformacije II

- Ako imamo tri kolinearne točke onda pravac na kojem one leže ima parametre sjecišta triju sinusoida
- Svaka sinusoida u parametarskom prostoru odgovara snopu pravaca određenog točkom



Algoritam Hough transformacije

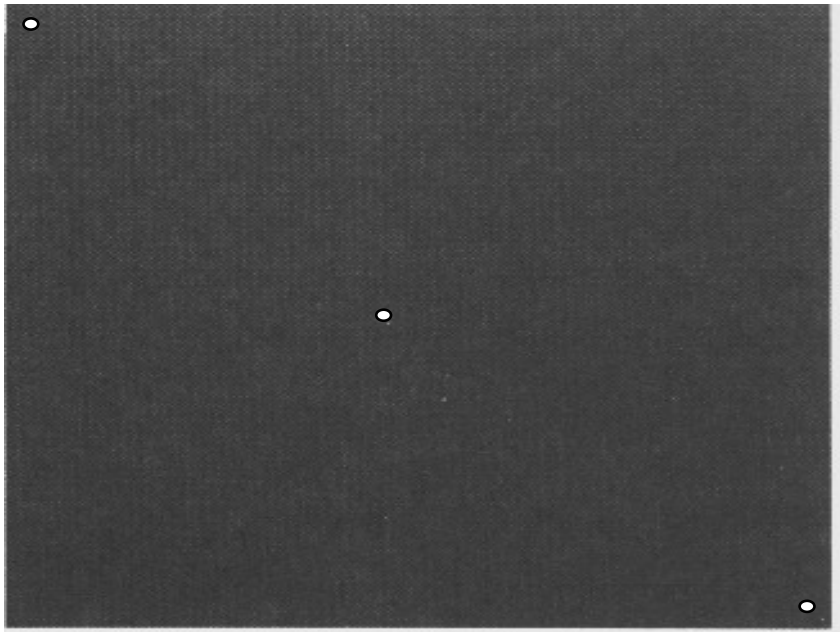
1. Inicijaliziraj Houghovo polje na nulu: A(p,q)=0
2. **Za** svaku točku (j,k) u slici za koju je F(j,k)=1
3. **Za** $p = 0$ do $p = p_{max}$
4. $$\rho = x_k \cos\theta_p + y_j \sin\theta_p$$
5. Kvantiziraj dobiveni ρ na vrijednost q
6. A(p,q) = A(p,q) + 1

Interpretacija

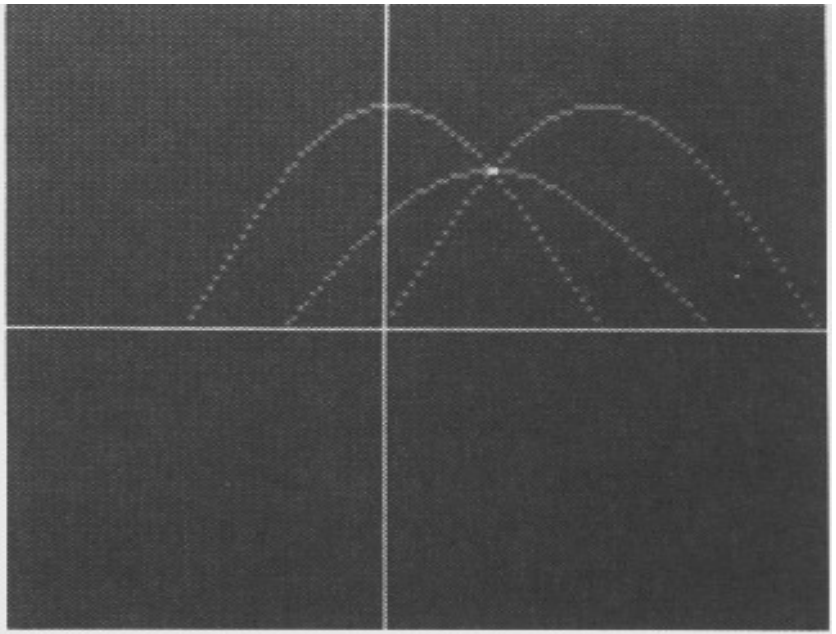
- Rezultat Hough-ove transformacije je polje brojeva A(p,q)
- Vrijednost A(p,q)=M znači da postoji M točaka koje leže na pravcu određenom parametrima ρ_q, Θ_p

Ako slika sadrži liniju (niz kolinearnih točaka) onda će Houghovo polje imati lokalni maksimum na mjestu koje odgovara parametrima pravca ρ_q, Θ_p

Primjer Hough transformacije I

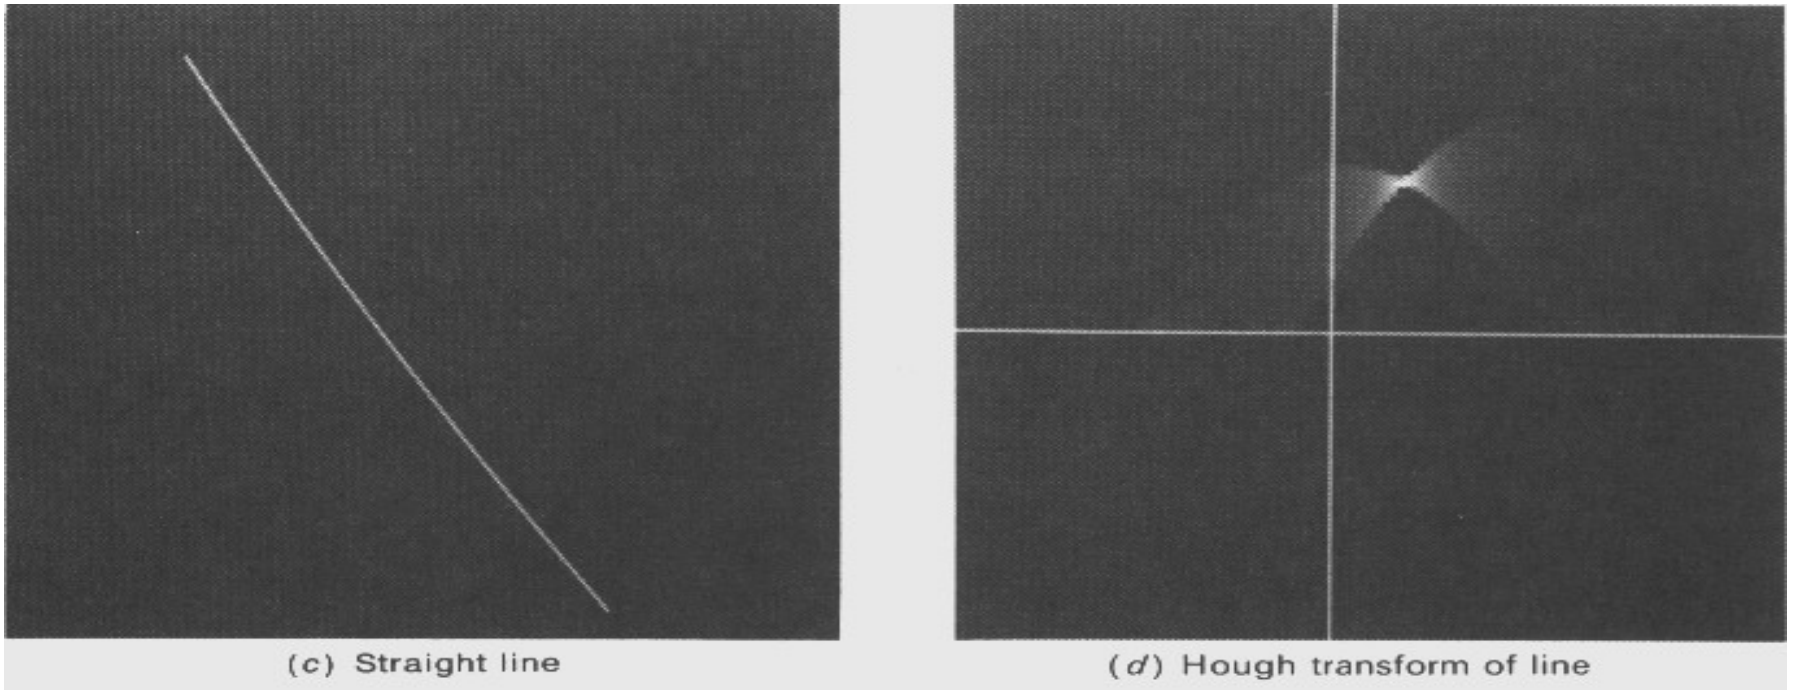


(a) Three dots: upper left, center, lower right



(b) Hough transform of dots

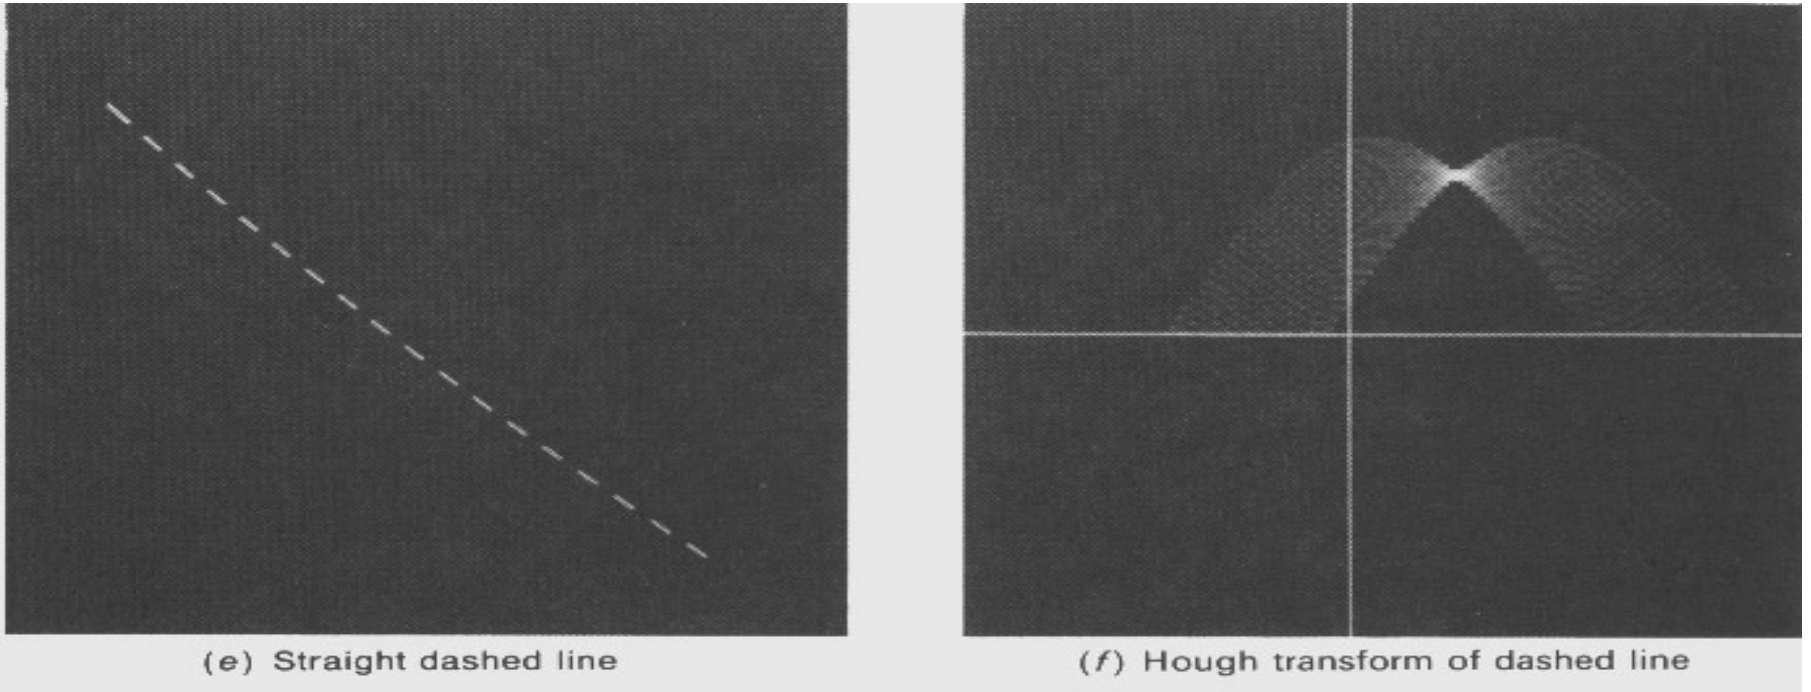
Primjer Hough transformacije II



(c) Straight line

(d) Hough transform of line

Primjer Hough transformacije III



(e) Straight dashed line

(f) Hough transform of dashed line

Metode segmentacije na osnovi unutrašnjosti objekta

- engl. region based methods
- Cilj ovih metoda je identificirati dijelove slike koje imaju slične značajke
- Dvije karakteristične metode su:
  - Izrastanje područja (region growing)
  - Metoda dijeljenja i stapanja (split and merge)

Segmentacija izrastanjem područja

- Problem segementacije izrastanjem područja sastoji se u određivanju uniformnih skupina točaka slike (regija)
- Algoritmi za izrastanje područja uspoređuju svojstva neklasificirane točke s dotad segmentiranom regijom da bi odlučili da li točka pripada regiji ili ne

Podjela tehnika izrastanja područja

- Tehnike izrastanja područja mogu se podijeliti (Haralick) u tri grupe s obzirom na način uspoređivanja točaka:
  - na osnovi sličnosti dvaju susjednih točaka
  - na osnovi sličnosti okolina dvaju susjednih točaka
  - na osnovi sličnosti točke i centroida regije

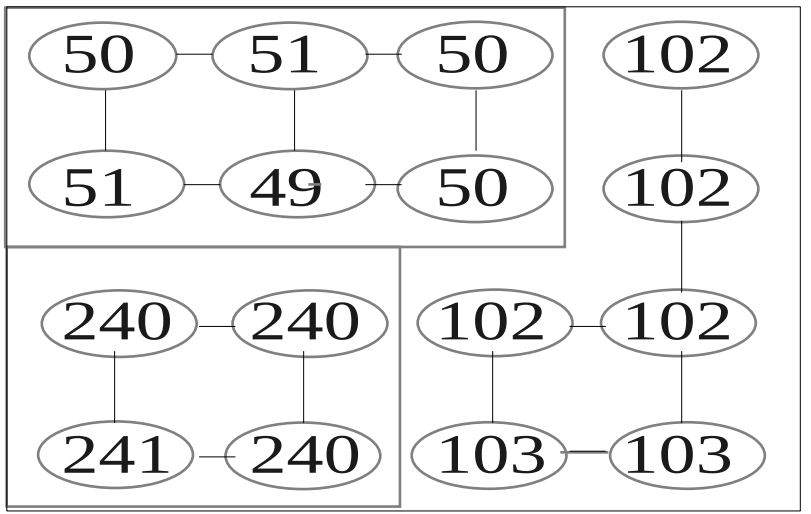
Metode pomoću sličnosti točaka

- engl. single linkage region growing
- svaka točka slike predstavlja čvor grafa
- susjedne točke sličnih svojstava povezuju se granom
- segmenti slike su maksimalni skupovi točaka koje pripadaju jednoj povezanom skupu

Primjer

- Primjer gdje se točke smatraju sličnima ako je razlika vrijednosti manja od 5
- Korišteno je 4-susjedstvo za definiciju povezanog područja

50	51	50	102
51	49	50	102
240	240	102	102
241	240	103	103



Dijeljenje i stapanje I

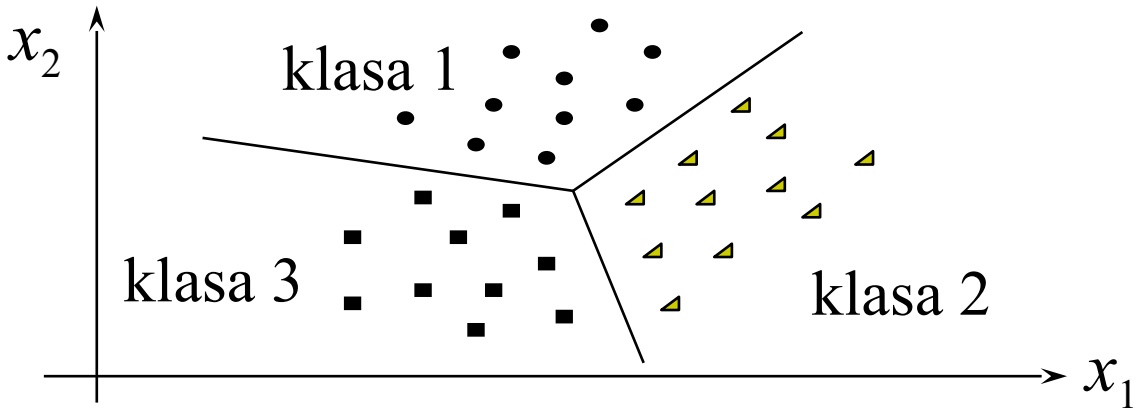
- engl. split and merge
- Horowitz i Pavlidis
- Kod metode dijeljenja i stapanja koristi se prikaz slike pomoću kvartarnog stabla gdje se svaka grana dijeli u četiri grane (engl. quad tree)
- Inicijalna segmentirana regija je cijela slika

Dijeljenje i stapanje II

- Ako je regija neuniformna onda se razbija u četiri podregije
- Ako su četiri susjedne regije uniformne onda se stapaju u jednu regije
- Uniformnost regije se mjeri npr. pomoću razlike svjetline najtamnije i najsvjetlije točke u regiji
- Chen i Pavlidis koristili su statističke testove za ispitivanje uniformnosti regija

Segmentacija grupiranjem

- engl. clustering segmentation methods
- Formulacija problema: Neka je **x** *N*-dimenzionalni vektor značajki slike u točki (*j,k*). Segmentacija treba grupirati vektore tako da značajke unutar jedne grupe budu uniformne



Grupiranje s K srednjih vrijednosti

- engl. *K*-means clustering
- Neka je broj grupa *K* poznat i neka je $\mathbf{u}_k(n)$ centar *k*-te grupe u *n*-toj iteraciji
- Inicijalno $\mathbf{u}_k(0)$ se postave na bilo koju vrijednost
- U *n*-toj iteraciji odabere se jedan vektor $\mathbf{x}_i$ i dodjeli se grupi čijem je centru najbliži:

$$x_i \in R_k \quad \Leftrightarrow \quad d\left(x_i, u_k(n)\right) = \min_{j=1,\ldots,K} \left\{ d\left(x_i, u_j(n)\right) \right\}$$

Grupiranje s K srednjih vrijednosti

- Zatim se ponovo izračunaju centri grupa kao vektori koji minimiziraju udaljenost za vektore iz pojedine grupe:

$$u_k(n+1): \quad \sum_{x_i \in R_k} d\left(x_i, u_k(n+1)\right) = \min_y \left\{ d\left(x_i, y\right) \right\}, \quad k = 1, \ldots, K$$

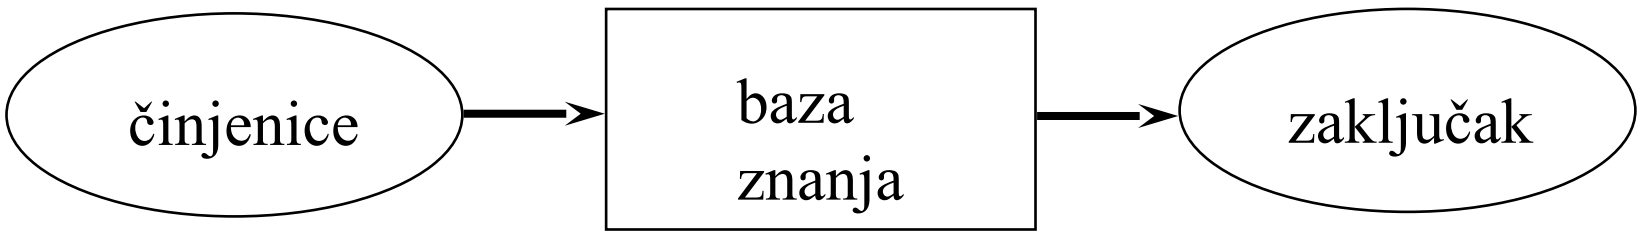
- Postupak se ponavlja sve dok se položaj centara više ne mijenja

Segmentacija ekspertnim sustavima

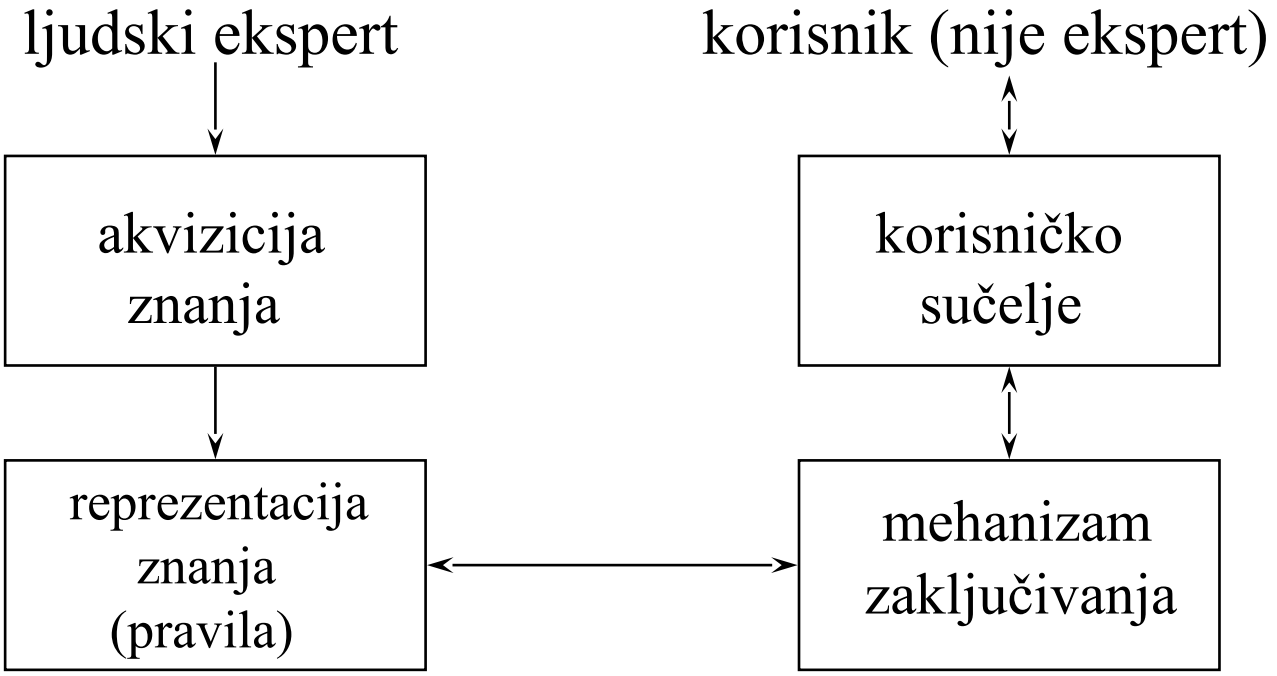
- Ideja ekspertnih sustava je da se umjetnim sustavom imitira znanje ljudskog eksperta odnosno omogući rješavanje raznih problema
- Najčešće su korišteni ekspertni sustavi temeljeni na pravilima (engl. rule-based expert systems)
- Ekspertni sustavi obično su usko specijalizirani
- Ekspertni sustavi koriste se u obradi, analizi i razumijevanju slika

Proces zaključivanja

- engl. inference mechanism
- Ulaz je skup činjenica (tvrdnji) iz kojih se procesom logičkog zaključivanja (inferencije) dolazi do zaključka
- Znanje je predstavljeno skupom pravila (logičkih implikacija)



Struktura ekspertnog sustava



Akvizicija znanja

- Akvizicija znanja je prijenos znanja od ljudskih eksperata i formulacija u oblik pogodan za upotrebu u ekspertnim sustavima na računalu
- Akvizicija znanja je spor i težak proces
- Ljudski eksperti često imaju problema u formuliranju svog znanja i u prijenosu znanja
- Znanje obično nije jednostavno prikazati pomoću nekoliko jednostavnih pravila

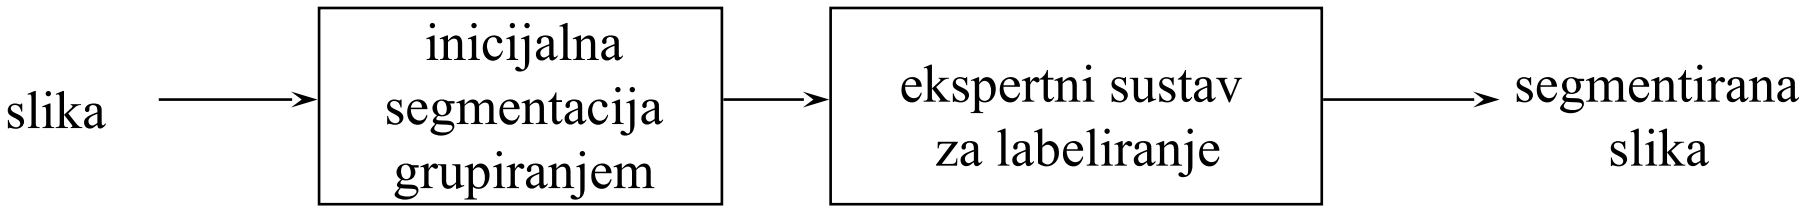
Reprezentacija znanja

- Problem reprezentacije znanja je predmet istraživanja i postoji više različitih metoda koje se koriste u analizi slike (Haralick):
  - vektor značajki
  - relacijske strukture
  - hijerarhijske strukture
  - pravila
  - okviri (engl. frames)

Mehanizam zaključivanja

- strategije upravljanja (engl. control strategies) određuju kako se znanje ekspertnog sustava koristi
- hijerarhijsko upravljanje:
  - bottom-up (ekstrakcija značajki - prepoznavanje)
  - top-down (hipoteza objekta - značajke ?)
  - hibridno
  - ploča (engl. blackboard) - više eksperata može pristupati ploči kada ocjene da je njihova ekspertiza korisna, te modificirati sadržaj ploče

Primjer sustava za segmentaciju ekspertnim sustavom



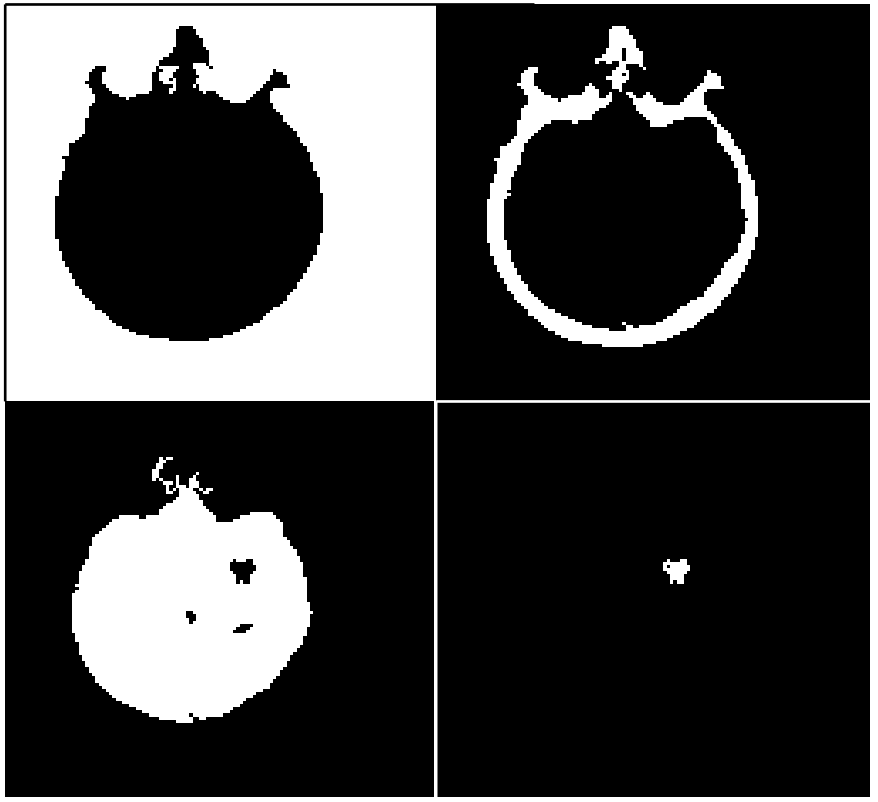
- Inicijalna segmentacija dijeli sliku u manje regije upotrebom grupiranja s K srednjih vrijednosti
- Baza znanja ekspertnog sustava sadrži moguće odnose među susjednim regijama i neke karakteristike regija

Rezultati



originalna slika (gore)

segmentirane slike:
pozadina, lubanja,
mozak, izljev krvi

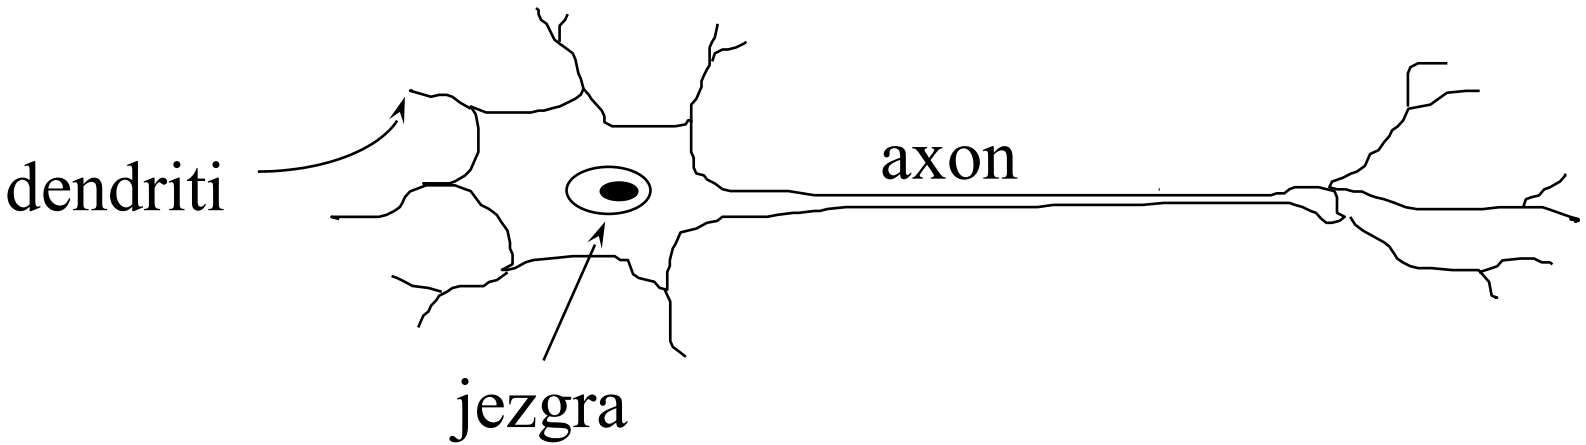


Segmentacija neuronskom mrežom

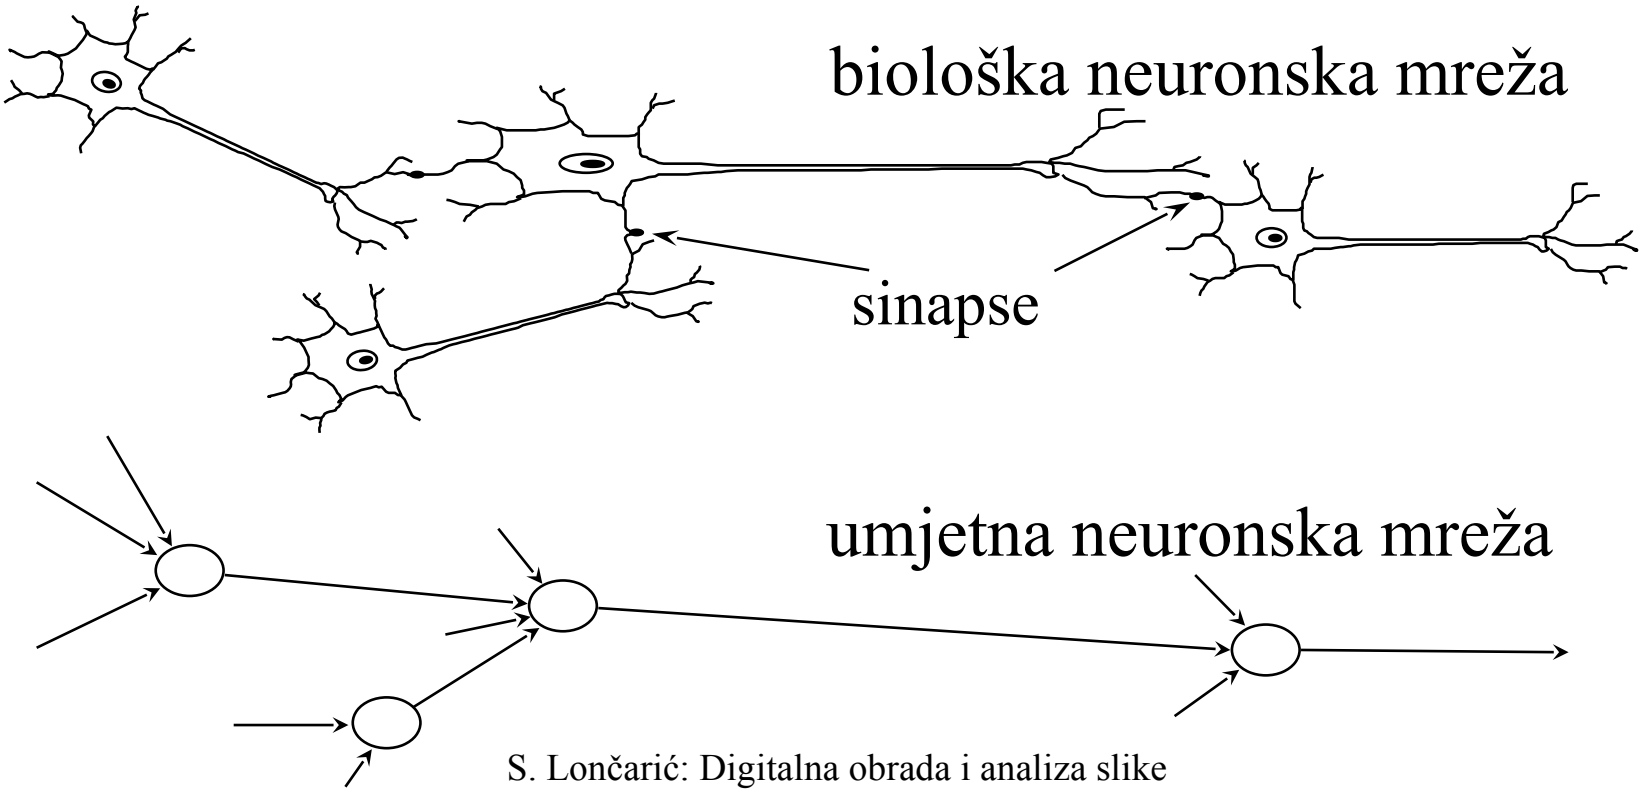
- Umjetne neuronske mreže su nelinearne mreže koje pokušavaju imitirati funkcioniranje bioloških neuronskih mreža
- Umjetne neuronske mreže se sastoje od modela neurona koji su međusobno povezani
- Postoji mnogo vrsta neuronskih mreža raznih topologija i načina rada i načina učenja
- Proces učenja koristi se za određivanje nepoznatih parametara mreže da bi se dobio željeni odziv

Biološki neuron

- dendriti prenose akcijski potencijal preko aksona do slijedećeg neurona

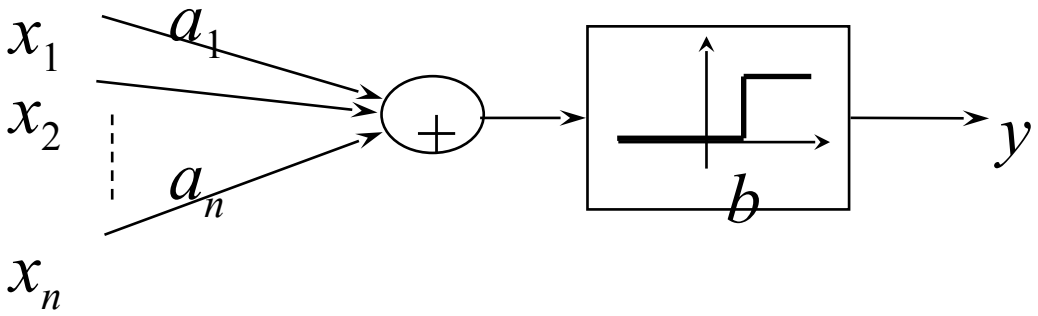


Međusobni spoj neurona



McCulloch-Pitts model neurona

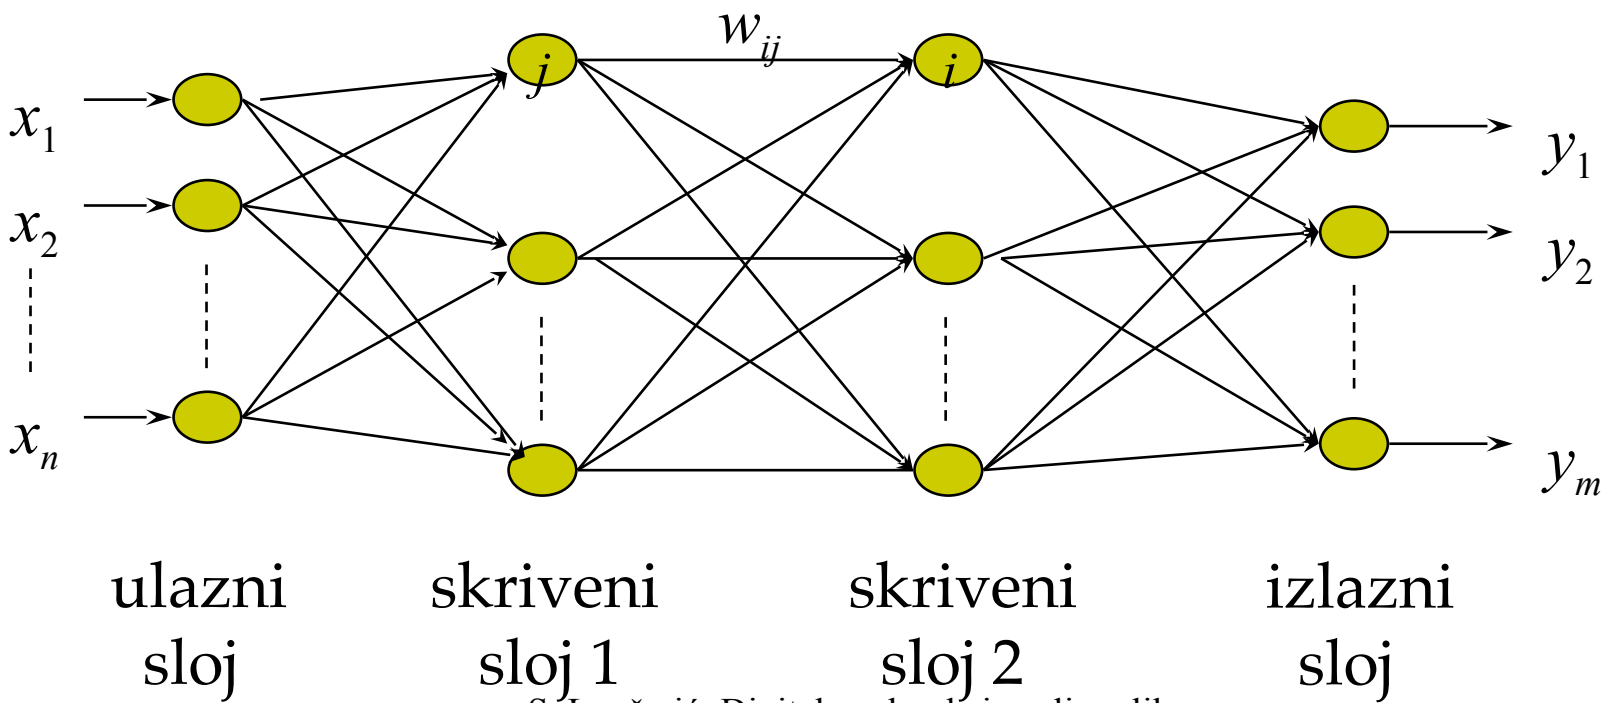
- McCulloch i Pitts su predložili ovaj jednostavan model biološkog neurona



$$y = S\left(\sum_i a_i x_i - b\right)$$

Perceptron

- engl. multi-layer feed-forward network



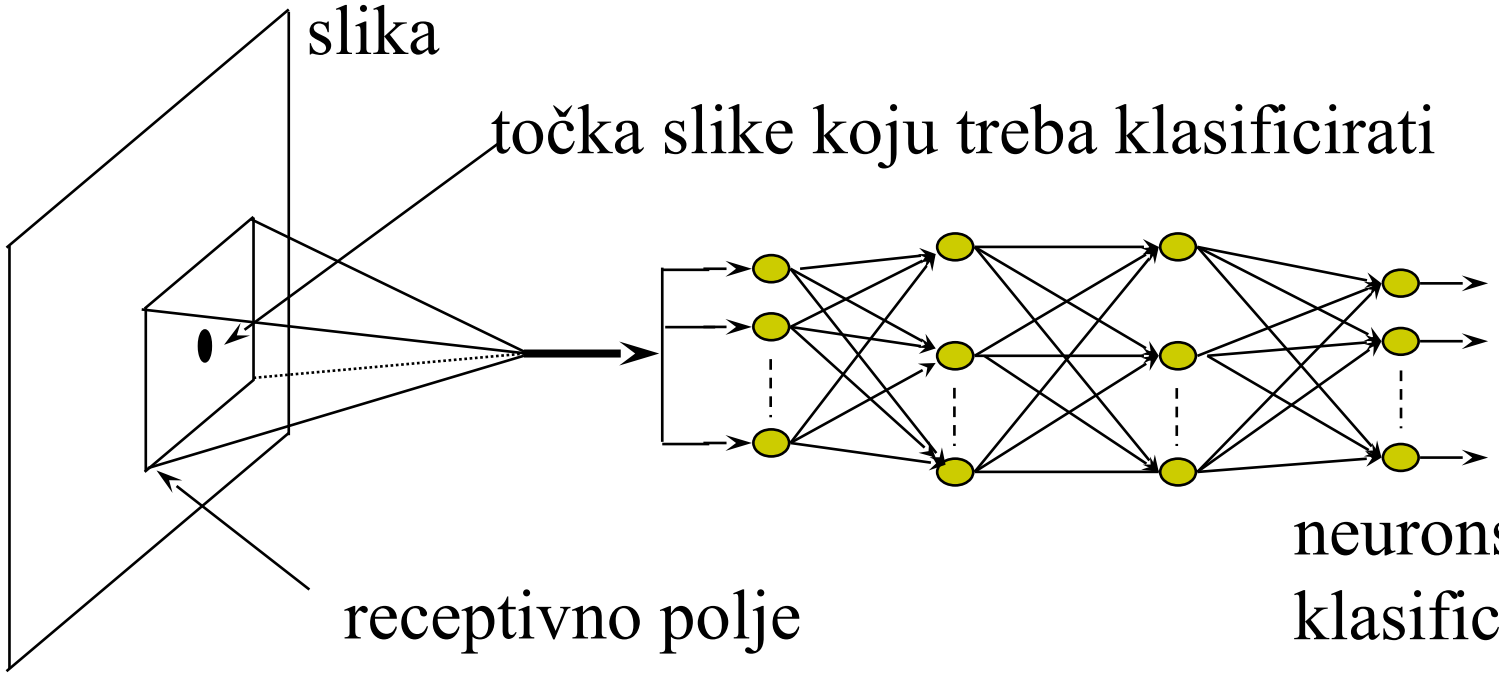
Učenje

- Problem učenja neuronske mreže sastoji se u određivanju vrijednosti nepoznatih konstanti w_{ij}
- Učenje pod nadzorom (supervised learning) se obavlja parovima vrijednosti ulaz-izlaz te iterativnim modificiranjem konstanti dok se ne dobije željeni izlaz za svaki dani ulaz u mrežu
- Za perceptron se najčešće koristi algoritam učenja s povratnom propagacijom pogreške
- Nakon što je učenje završeno, u fazi eksploatacije, mreža daje izlaz za nenaučene vrijednosti ulaza

Segmentacija neuronskom mrežom

- Neuronske mreže se mogu upotrijebiti u mnogim područjima digitalne obrade slike
- Primjer: segmentacija slika pomoću perceptrona
- Na ulaz mreže treba postaviti vrijednost točke (odnosno vrijednosti iz nekog susjedstva) koja se želi klasificirati te kroz postupak učenja mreže “naučiti” mrežu kojoj klasi dana točka pripada
- Nakon što je učenje gotovo na ulaz mreže dovede se nova slika koju mreža onda segmentira

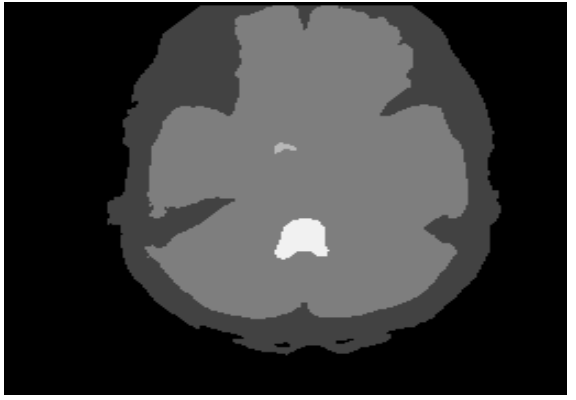
Primjer: Segmentacija CT slika neuronskom mrežom



Rezultati segmentacije-učenje

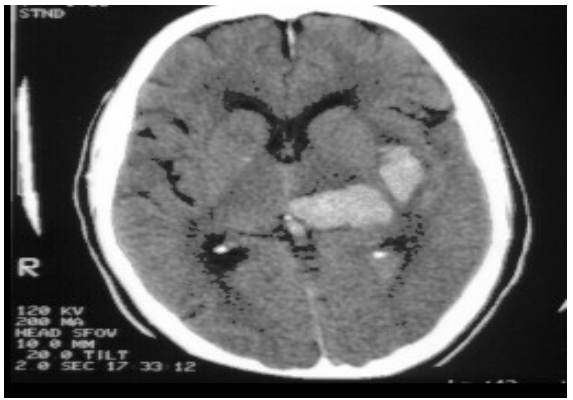


ulazna slika

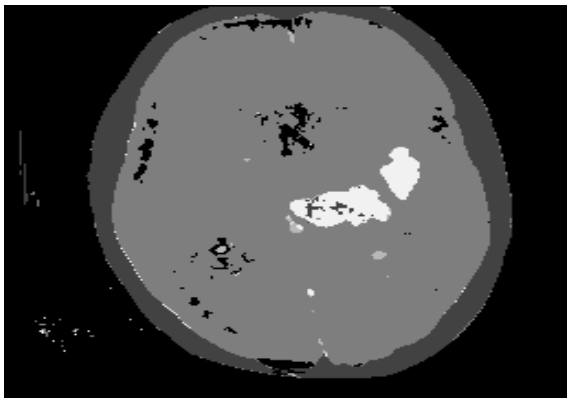


segmentirana slika

Rezultati segmentacije- eksploatacija



ulazna slika



segmentirana slika

Zaključak

- Predstavljene su neke karakteristične metode za segmentaciju slike:
  - Amplitudna segmentacija
  - Obilježavanje komponenti
  - Metode koje koriste granicu objekta
  - Metode koje koriste unutrašnjost objekta
  - Metode grupiranja
  - Segmentacija ekspertnim sustavima
  - Segmentacija neuronskom mrežom