Registracija slike

Pregled tema

- Uvod
- Primjene
- Klasifikacija metoda za registraciju
- Pregled geometrijskih transformacija
- Pregled algoritama za registraciju
- Zaključak

Uvod

- Engl. image registration, image matching
- Registracija slike je važan problem analize slike u mnogim primjenama:
  - kad imamo više slika jednog objekta dobivenih raznim načinima snimanja
  - kad imamo više slika jednog objekta snimljenih u različitim vremenskim trenucima
  - kad želimo usporediti slike više objekata
  - kad želimo usporediti sliku sa modelom (npr. atlasom)

Uvod

- Problem registracije dvaju slika sastoji se u određivanju geometrijske transformacije kojom se jedna slika preslikava u drugu
  - Drugim riječima, nakon registracije za svaku točku u prvoj slici poznato je koja joj je točka korespondentna u drugoj slici
- Ovo dakle pretpostavlja da je sadržaj dvije slike sličan u smislu da obje slike sadrže isti (ili slični) objekt koji je eventualno rotiran, translatiran ili izobličen elastičnom geometrijskom transformacijom

Motivacija

- Nakon što su dvije slike registrirane moguće je:
  - analizirati (detektirati) razlike između dvaju istovrsnih slika (npr. snimljenih u dva različita vremenska trenutka)
  - kombinirati (integrirati) informaciju sadržanu u dvjema raznovrsnim slikama (npr. snimljenim različitima načinima snimanja)

Integracija informacija

- Engl. information integration, image fusion
- Nakon što je obavljena registracija slika postavlja se pitanje kako kombinirati informaciju sadržanu u pojedinim slikama
- Tu postoji više teorija koje se oslanjaju na teoriju vjerojatnosti:
  - Bayesova integracija
  - Dempster-Schefer teorija

Područja: daljinska snimanja

- Problem registracije pojavljuje se u daljinskim snimanjima (remote sensing) gdje imamo slike istog područja na zemlji snimljene u raznim spektralnim područjima
- Kod praćenja razvoja i nadzora urbanih područja mopuće je snimati grad u vremenskim razmacima te onda uočiti koje su promjene nastale (npr. izgradnja novih kuća)

Područja: medicina

- Drugo veliko područje primjena danas je medicina
- Multimodalna snimanja u medicini (CT, MR, US, SPECT, PET) daju slike koje sadrže raznovrsnu informaciju o anatomiji i funkciji organizma

Područja: medicina

- Registracija medicinskih slika je potrebna kod:
  - različitih modaliteta snimanja (npr. MR/PET, MR/CT)
  - praćenja razvoja progresivnih bolesti (snimanje u određenim vremenskim intervalima i detekcija promjena, npr. kod praćenja tumora i evaluacije tretmana)
  - Kod računalom podržane kirurgije registriraju se preoperativne MR snimke sa intraoperativnim MR snimkama (npr. neurokirurgija)
  - usporedba snimljenih slika sa modelom
- U ovoj prezentaciji koncentrirat ćemo se najviše na primjene u medicini

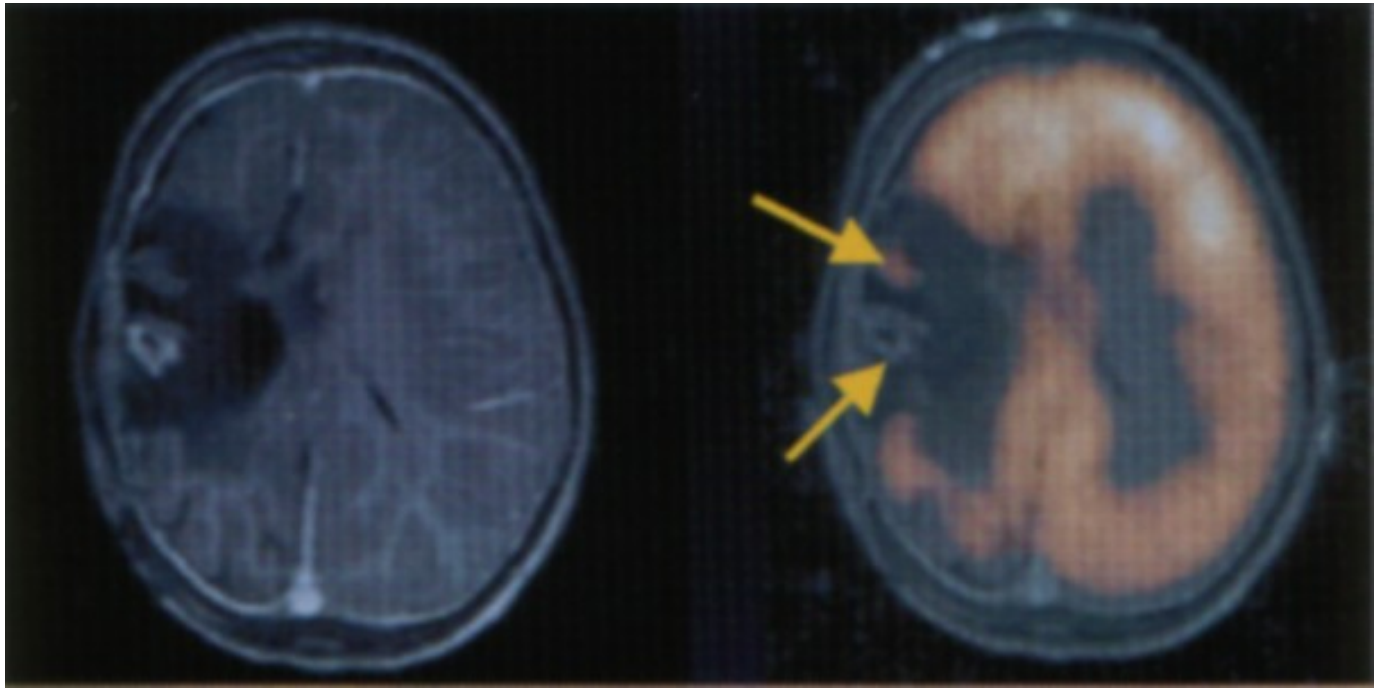
Primjer registracije šake

- Slika šake dobivena snimanjem nuklearnom medicinom superponirana u boji na crno bijelu rendgensku sliku šake
- Crvena boja odgovara najvećoj koncentraciji radioizotopa



Primjer registracije slika mozga

- Lijevo MR slika (anatomija), a desno PET FDG slika mozga (funkcija) superponirana na MR sliku



Klasifikacija metoda

- Metode registracije mogu se klasificirati s obzirom na nekoliko raznih kriterija:
  - dimenzionalnost (2-D, 3-D, 4-D)
  - značajke slika koja se uspoređuju (ekstrinzične i intrinzične metode)
  - način interakcije s korisnikom
  - vrsta geometrijske transformacije koja se koristi

Dimenzionalnost

- Registrirati možemo 2-D slike, 3-D slike, ili 4-D slike
- 3-D registracija može se raditi za dvije 3-D slike ili za vremenski niz 2-D slika
- Ako imamo niz 3-D slika onda to daje problem 4-D registracije
- Postoji i problem registracije 2-D slike (koja može biti perspektivna projekcija 3-D prostora) na 3-D sliku

Značajke slika

- S obzirom na značajke slika koje se uspoređuje:
  - ekstrinzične metode koriste umjetne vanjske objekte koji se stavljaju na glavu (npr. stereotaktičke okvire, markere za kožu)
  - intrinzične metode koriste samo vrijednosti piksela slike, anatomske karakteristične točke ili konture ili površine na slici

Interakcija sa korisnikom

- S obzirom na način interakcije s korisnikom metode registracije mogu biti:
  - interaktivne (zahtijevaju korisničku interakciju za definiranje transformacije)
  - poluautomatske (korisnička interakcija je potrebna samo za inicijalizaciju, vođenje ili zaustavljanje postupka registracije)
  - automatske (rade bez interakcije sa korisnikom)

Geometrijske transformacije

- Geometrijska transformacija kojom jednu sliku transformiramo u drugu može biti:
  - Rigidna ili neelastična (engl. rigid) - ako se udaljenost između bilo koje dvije točke sačuva (rotacija, translacija)
  - Afina (engl. affine) ako se ravna linija preslikava u ravnu liniju i paralelizam očuva
  - Projekcija (npr. perspektivna) je kao afina samo bez očuvanja paralelizma
  - Elastična ako se ravna linija ne preslikava u ravnu liniju

Geometrijske transformacije

- Neelastične transformacije su podskup afinih transformacija
- Afine transformacije su podskup projektivnih transformacija
- Projektivne transformacije su podskup elastičnih transformacija

Rigidne transformacije

- Neelastične transformacije vektora **x** = [x y z]^T se sastoje od translacije i rotacije:

$$\mathbf{x}' = \mathbf{R}\mathbf{x} + \mathbf{t}$$

gdje je **t** = [t_x t_y t_z]^T vektor translacije, a **R** je 3x3 ortogonalna matrica rotacije (α, β, i γ su kutevi rotacije oko z, y i x osi)

$$\mathbf{R} = \begin{bmatrix} \cos\alpha & -\sin\alpha & 0 \\ \sin\alpha & \cos\alpha & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \cos\beta & 0 & -\sin\beta \\ 0 & 1 & 0 \\ \sin\beta & 0 & \cos\beta \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos\gamma & -\sin\gamma \\ 0 & \sin\gamma & \cos\gamma \end{bmatrix}$$

Transformacije skaliranja

- Najjednostavnije afine transformacije su one koje imaju samo skaliranje, a ostatak transformacije je rigidan:

$$\mathbf{x}' = \mathbf{RSx} + \mathbf{t}$$

gdje je **S** = diag(s_x, s_y, s_z) matrica skaliranja u x, y i z smjerovima, **R** je matrica rotacije, a **t** vektor translacije

Afine transformacije

- Afine transformacije čuvaju linije i paralelnost i definirane su izrazom

$$\mathbf{x}' = \mathbf{A}\mathbf{x} + \mathbf{t}$$

gdje je **A** matrica afine transformacije koja može imati bilo koje vrijednosti elemenata, a **t** je vektor translacije

Afine transformacije

- Često se koristi prikaz u homogenim koordinatama:

$$\begin{bmatrix} x' \\ y' \\ z' \\ 1 \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & t_1 \\ a_{21} & a_{22} & a_{23} & t_2 \\ a_{31} & a_{32} & a_{33} & t_3 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

Projektivne transformacije

- Projektivne transformacije su slične kao afina (linije su sačuvane), samo nema očuvanja paralelizma između linija
- Imaju oblik:

$$x' = \left(\mathbf{A}\mathbf{x} + t \right) / \left(\mathbf{p} \cdot \mathbf{x} + \alpha \right)$$

Projektivne transformacije

- U homogenim koordinatama:

$$\begin{bmatrix} u_1' \\ u_2' \\ u_3' \\ u_4' \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & t_1 \\ a_{21} & a_{22} & a_{23} & t_2 \\ a_{31} & a_{32} & a_{33} & t_3 \\ p_1 & p_2 & p_3 & \alpha \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

gdje je $x' = u_1' / u_4'$, $y' = u_2' / u_4'$, $z' = u_3' / u_4'$,

Perspektivne transformacije

- Perspektivna transformacija transformira 3-D prostor u 2-D ravninu
- Primjeri: snimanje kamerom, rendgensko snimanje, mikroskopija
- Perspektivne transformacije su podskup projektivnih transformacija
- Projektivne transformacije općenito ne preslikavaju točke prostora u ravninu

Perspektivne transformacije

- Kod perspektivnih transformacija obično se uzima da je afini dio identiteta (**A** = **I**) i da je **t** = 0
- Nakon što vektor projekcije **p** prikažemo u obliku

$$\mathbf{p} = |\mathbf{p}|\hat{\mathbf{p}}$$

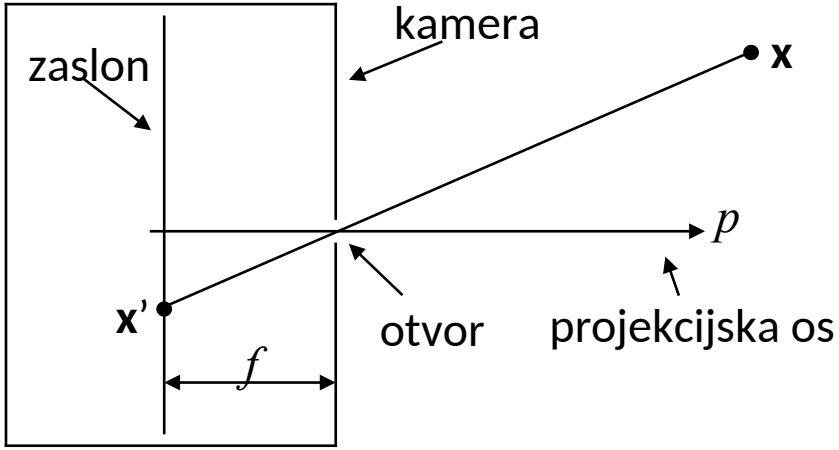
iz izraza za projektivnu transformaciju dobivamo

$$\mathbf{x}' = f\,\mathbf{x} / \left(\hat{\mathbf{p}} \cdot \mathbf{x} + \alpha f\right)$$

gdje je $f = 1/|\mathbf{p}|$

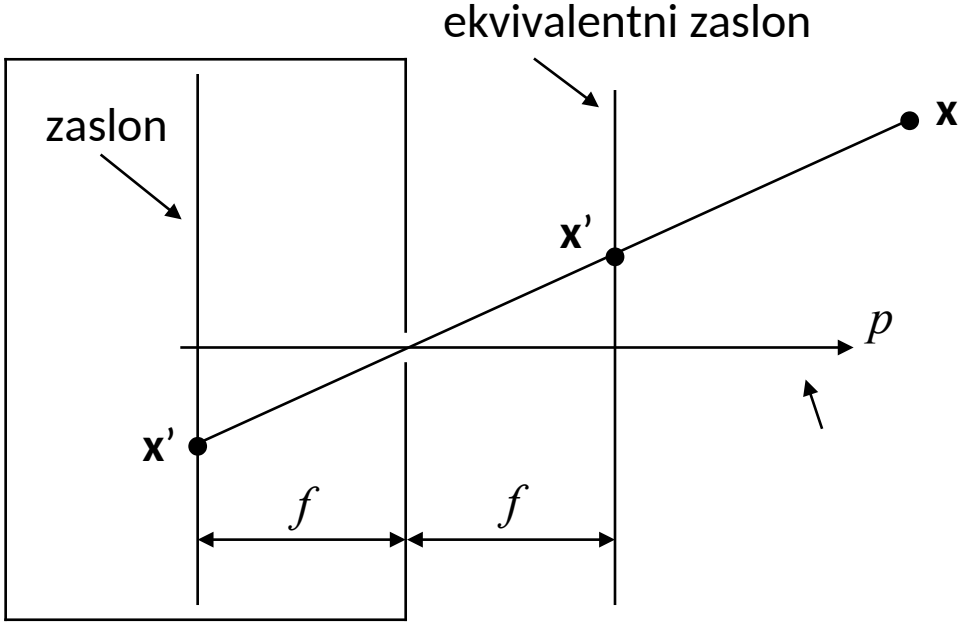
Perspektivne transformacije

- Navedeni izrazi vrijede za “pinhole” kameru gdje mala rupica zamjenjuje objektiv
- To je dobra aproksimacija realnih kamera



Perspektivne transformacije

- Slika na filmu je obrnuta pa se nekad koristi i ekvivalentni prikaz gdje se zaslon postavi ispred otvora kamere na udaljenosti f



Perspektivne transformacije

- Ako se ishodište koordinatnog sustava postavi na mjesto otvora kamere onda je $\alpha = 0$
- Ako je ishodište na sjecištu projekcijske osi i zaslona kamere onda je $\alpha = 1$
- Parametar f zove se fokusna daljina

Elastične transformacije

- Elastične transformacije ne čuvaju linije, dakle linija se može preslikati u krivulju
- Može biti definiran bilo kakvim nelinearnim preslikavanjem koordinata
- Najjednostavniji način prikaza je pomoću polinoma

$$x' = \sum_{i=0}^{I} \sum_{j=0}^{J} \sum_{k=0}^{K} c_{ijk} x^i y^j z^k$$

Elastične transformacije

- Rijetko se koristi I, J, $K > 2$ zbog oscilacija koje imaju polinomi višeg stupnja
- Često se ograničava da $I + J + K \leq 5$ iz istog razloga

Algoritmi za registraciju slika

- U sljedećem tekstu predstavit ćemo sljedeće tri grupe algoritama za 3-D registraciju biomedicinskih slika:
  - Algoritmi koji koriste korespondentne karakteristične točke
  - Algoritmi koji koriste korespondentne površine
  - Algoritmi koji rade direktno sa vrijednostima voksela i koriste razne mjere sličnosti temeljene na vokselima

Točke i Prokrustov problem

- Kod ovog načina registracije potrebno je u objema slikama koje se žele registrirati odrediti niz korespondentnih parova točaka
- U registraciji biomedicinskih slika to mogu biti npr. vanjski markeri ili neke karakteristične anatomske točke prepoznatljive u objema slikama
- Problem nalaženja transformacije koja će skup točaka iz prve slike preslikati u skup točaka iz druge slike nekad se naziva i Prokrustov problem

Prokrust

- Prokrust je bio lopov iz grčke mitologije koji je nudio prolaznicima prenoćište s krevetom koji perfektno pristaje svakom posjetitelju
- No, Prokrust je zapravo svakog gosta stavio u isti krevet te bi ga ili rastegnuo ili mu odsjekao neke djelove tijela da bi dobro pristajao u krevet
- Srećom, junak Tezej koji je putovao u Atenu (te usput ubio Minotaura i pobjedio mnoge nemani) je prekinuo tu praksu tako da je Prokrusta podvrgnu vlastitom tretmanu (odsjekao mu je glavu da stane u krevet)

Ortogonalni Prokrustov problem

- Daje rješenje problema rigidne registracije koje je optimalno u smislu najmanje kvadratne pogreške
- Definicija problema: Dana su dva skupa od po N točaka u D dimenzija: $\mathbf{P} = \{ \mathbf{p}_i \}$ i $\mathbf{Q} = \{ \mathbf{q}_i \}$.
  Potrebno je naći transformaciju T koja minimizira pogrešku:
  $$G(\mathrm{T}) = | \mathrm{T}(\mathbf{P}) - \mathbf{Q} |^2$$
- **P** i **Q** su matrice dimenzija $N \times D$ čiji su reci koordinate točaka $\mathbf{p}_i$ i $\mathbf{q}_i$, a T(**P**) je matrica transformiranih točaka $\mathbf{p}_i$

Ortogonalni Prokrustov problem

- Ako je T afina transformacija onda je ovo standardni problem najmanjih kvadrata čije rješenje je poznato iz linearne algebre
- U nastavku pokazujemo rješenje za slučaj kad je T rigidna transformacija, definirana matricom rotacije **R** i vektorom translacije **t**

Rješenje Prokrustovog problema

- Prvo zamijenimo skup vektora **P** i **Q** s skupom vektora koji imaju srednju vrijednost jednaku nuli:

$$p_i \rightarrow p_i - \bar{p}, \quad \bar{p} = \frac{1}{N}\sum_{i=1}^{N} p_i$$

$$q_i \rightarrow q_i - \bar{q}, \quad \bar{q} = \frac{1}{N}\sum_{i=1}^{N} q_i$$

- Ovo svodi problem na ortogonalni Prokrustov problem gdje treba odrediti ortogonalnu matricu rotacije **R** (vektor translacije je jednak nuli)

Rješenje Prokrustovog problema

- Ključ problema je korelacijska matrica $\mathbf{K} = \mathbf{P}^T\mathbf{Q}$ dimenzija $D \times D$ koja pokazuje koliko su točke u matrici **Q** korelirane s točkama u matrici **P**
- Ako je $\mathbf{P} = [\ \mathbf{p}_1\ \mathbf{p}_2 \ldots \mathbf{p}_N\ ]^T$ i $\mathbf{Q} = [\ \mathbf{q}_1\ \mathbf{q}_2 \ldots \mathbf{q}_N\ ]^T$ onda se može pisati $\mathbf{K} = \Sigma_i\ \mathbf{K}_i$, gdje je $\mathbf{K}_i = \mathbf{p}_i\ \mathbf{q}_i^T$
- Rastavimo matricu *K* u rastav pomoću singularnih vrijednosti i vektora (SVD): $\mathbf{K} = \mathbf{U}\ \mathbf{D}\ \mathbf{V}^T$
- Matrica **R** određena je izrazom $\mathbf{R} = \mathbf{V}\ \mathbf{\Delta}\ \mathbf{U}^T$, gdje je $\mathbf{\Delta} = \text{diag}(1, 1, \det(\mathbf{VU}^T))$

Rješenje Prokrustovog problema

- Vektor translacije **t** može se odrediti izrazom:

$$\mathbf{t} = \bar{\mathbf{q}} - \mathbf{R}\,\bar{\mathbf{p}}$$

- Ovim algoritmom osigurano je (iz determinante od $\mathbf{VU}^T$) da neće doći do refleksije nego samo do rotacije
  - Refleksija u mnogim aplikacijama (npr. biomedicinska registracija) nema smisla

Registracija površina

- Drugi pristup problemu 3-D registracije je registracija površina pripadnih 3-D objekata koji se registriraju
- Neki od poznatijih algoritama u ovoj klasi su:
  - Algoritam šešira i glave (engl. head and hat)
  - Algoritmi temeljeni na transformaciji udaljenosti
  - ICP (engl. iterative closest point) algoritam

Head and hat algoritam

- Razvili Pelizzari i ostali, 1989, za 3-D registraciju CT, MR i PET slika glave
- Prva površina (glava) dobije se iz modaliteta s većom rezolucijom i prikazana je u obliku stoga diskova
- Druga površina (šešir) prikazana je kao skup nepovezanih točaka u prostoru
- Registracija se obavlja iterativnom transformacijom (pomakom) šešira u 3-D prostoru dok se ne dobije najbolji položaj šešira

Head and hat algoritam

- Točnost registracije računa se pomoću udaljenosti šešira od glave u radijalnom smjeru iz centroida glave
- Za iterativnu optimizaciju koristi se Powell-ov algoritam za najbrži spust (engl. gradient descent) koji radi 1-D optimizaciju u svakoj od šest dimenzija
  - Za rigidnu registraciju krutog tijela korišteno je šest stupnjeva slobode (tri translacije i tri rotacije)
- Ovaj pristup je upotrebljiv samo kod sfernih oblika površina

Transformacija udaljenosti

- Head and hat algoritam može se poboljšati korištenjem transformacije udaljenosti
- Transformacija udaljenosti preslikava binarnu sliku u sliku udaljenosti gdje svaki piksel ima vrijednost udaljenosti od te pozicije do najbliže točke objekta u binarnoj slici
- Transformacija udaljenosti izračuna se za jednu od dvije površine, nakon čega se lako izračuna udaljenost druge površine od prve

ICP algoritam

- Iterative closest point (ICP) algoritam razvili su Besl i McKay, 1992, za 3-D registraciju
- Razvijen za opću primjenu, no postao je najpopularniji algoritam za registraciju površina u biomedicinskim aplikacijama
- Pretpostavljamo da imamo dvije površine:
  - Prva površina (nazovimo ju M) je model na koji registriramo
  - Druga površina je dana u obliku skupa točaka { $\mathbf{p}_i$ }

ICP algoritam

- **Ponavljaj**
- Korak 1: Za svaku točku $\mathbf{p}_i$ treba odrediti najbližu točku $\mathbf{q}_i$ na površini M
- Korak 2: Metodom najmanjih kvadrata odrediti rigidnu registraciju skupova točaka $\mathbf{p}_i$ i $\mathbf{q}_i$ po Prokrustovoj metodi
- **Dok** se kvadratna pogreška registracije površina ne prestane smanjivati

Metode temeljene na vrijednostima slike

- Engl. Intensity-based methods
- U dosad opisanim pristupima registracija se temeljila na skupovima točaka koji su na neki način morali ranije biti određeni
  - Prednost tih pristupa je da nije bilo važno o kakvim se vrstama slika radi, slike su mogle biti snimljene na potpuno različiti način
  - Mana tih pristupa je da je bio potreban dodatan korak određivanja skupova točaka, što uključuje dodatnu mogućnost pogreške

Metode temeljene na vrijednostima slike

- Kod metoda temeljenih na direktnoj upotrebi vrijednosti piksela (voksela) nije potrebno određivati skupove točaka, što je prednost
- Mana je da slike koje se registriraju ne mogu biti različite (npr. snimljene različitim načinima)
- Ovaj pristup je najprirodniji kad se radi o istovrsnim slikama (npr. u medicini registracija CT i CT slika)
- Ove methode koriste razne mjere sličnosti slika (engl. voxel similarity measures)

Mjere sličnosti slika

- Korištene su različite vrste kriterija za sličnost dvaju slika koje se registriraju, temeljene na vrijednostima piksela
  - Kvadratna razlika intenziteta
  - Korelacijske tehnike
  - Uniformnost kvocjenta slika
  - Kriteriji temeljeni na teoriji informacija (zajednička entropija, međusobna informacija, normalizirana m.i.)

Kvadratna razlika intenziteta

- Jedna od najjednostavnijih mjera razlike između dvaju slika je kvadratna razlika definirana izrazom

$$\frac{1}{N}\sum_{x\in S}\left|A\left(x\right)-B\left(x\right)\right|^2$$

  gdje je N = card (S), a $S \subseteq Z^n$ je regija presjeka domena dvaju slika
- Mana: Mjera je jako osjetljiva na mali broj točaka s velikom razlikom svjetlina

Korelacijski koeficijent

- Mjera sličnosti temeljena je na prostornoj korelaciji dana je korelacijskim koeficijentom:

$$\frac{\sum_{x \in S} \left(A(x) - \bar{A}\right)\left(B(x) - \bar{B}\right)}{\left\{\sum_{x \in S} \left(A(x) - \bar{A}\right)^2 \sum_{x \in S} \left(B(x) - \bar{B}\right)^2\right\}^{1/2}}$$

- Ova mjera dopušta linearni odnos svjetlina nakon što su slike registrirane

Uniformnost kvocjenta slika

- Ideja je da se maksimizira uniformnost kvocjenta dvaju slika koje se registriraju
- Kad su slike registrirane kvocjent će biti uniformniji nego kad su slike neregistrirane

$$R(x)=\frac{A(x)}{B(x)},\quad x\in S \qquad \bar{R}=\frac{1}{N}\sum_{x\in S}R(x)$$

$$\mathrm{RIU}=\frac{1}{\bar{R}}\sqrt{\frac{1}{N}\sum_{x\in S}\left(R(x)-\bar{R}\right)^2}$$

Mjere iz teorije informacija

- Ove se mjere sličnosti temelje na pojmu entropije nekog izvora informacija koji šalje *N* mogućih poruka svaka s vjerojatnošću p_i:

$$H = \sum_{i=1}^{N} p_i \log p_i$$

Entropija slike

- Entropiju slike možemo izračunati ako zamislimo da je slika izvor informacija gdje svaka poruka korespodira pikselu s nekom vrijednošću
- Ukupni broj poruka je jednak broju piksela u slici
- Vjerojatnost pojedine poruke (vjerojatnost piksela s nekim iznosom intenziteta *a*) može se procjeniti na temelju histograma prvog reda *p*(*a*)

$$H(A) = \sum_{a} p(a) \log p(a)$$

Zajednička entropija dvaju slika

- Engl. joint entropy
- Zajednička entropija dvaju slika je mjera zajedničke informacije sadržane u tim slikama:

$$H(A,B)=\sum_{a}\sum_{b} p(a,b)\log p(a,b)$$

- Može se vidjeti ako da ako su dvije slike statistički nezavisne onda vrijedi da je:

$$H(A,B)=H(A)+H(B)$$

Zajednička entropija dvaju slika

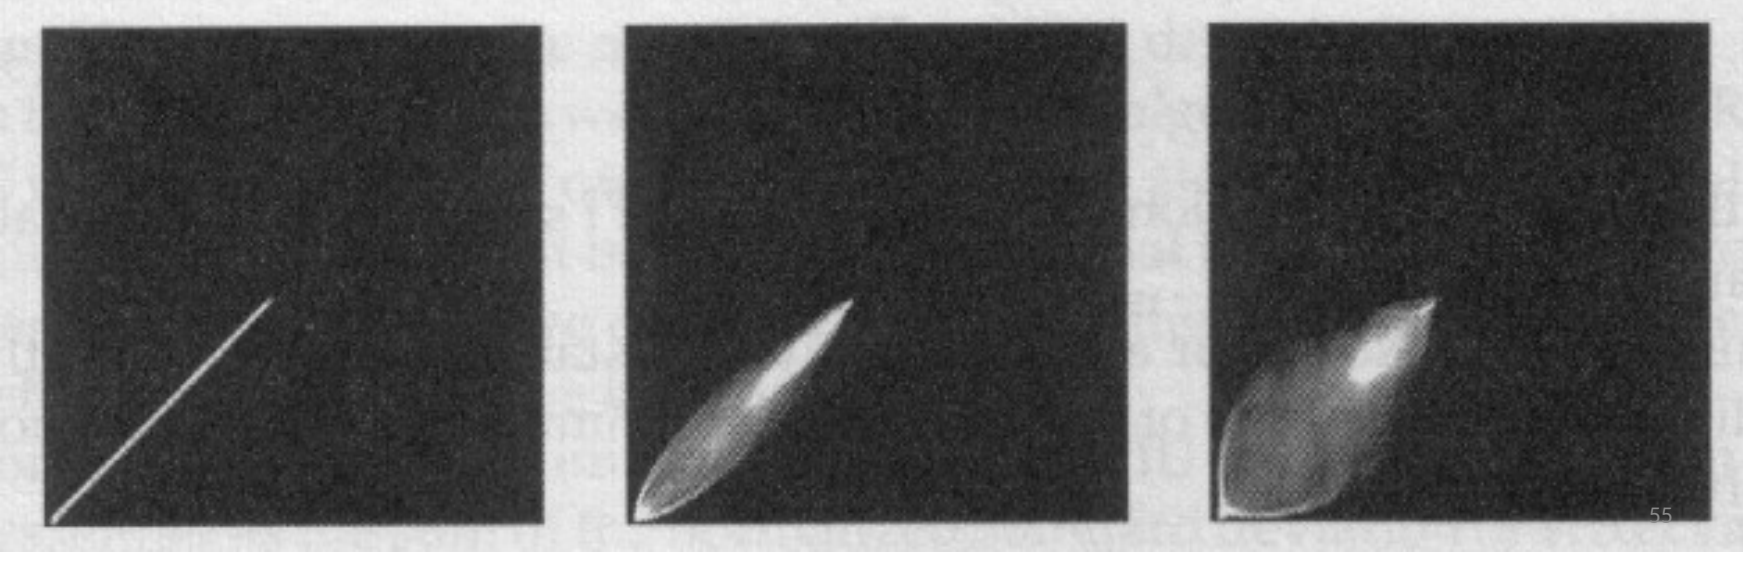
- Uvijek vrijedi da je:

$$H(A,B) \leq H(A) + H(B)$$

- Što su slike sličnije (tj. manje nezavisne) to će njihova zajednička entropija biti manja
- Na tome se temelji ideja korištenja zajedničke entropije kao mjere sličnosti slika
  - Kod točno registriranih slika zajednička entropija će biti minimalna
  - Pogrešna registracija povećava zajedničku entropiju

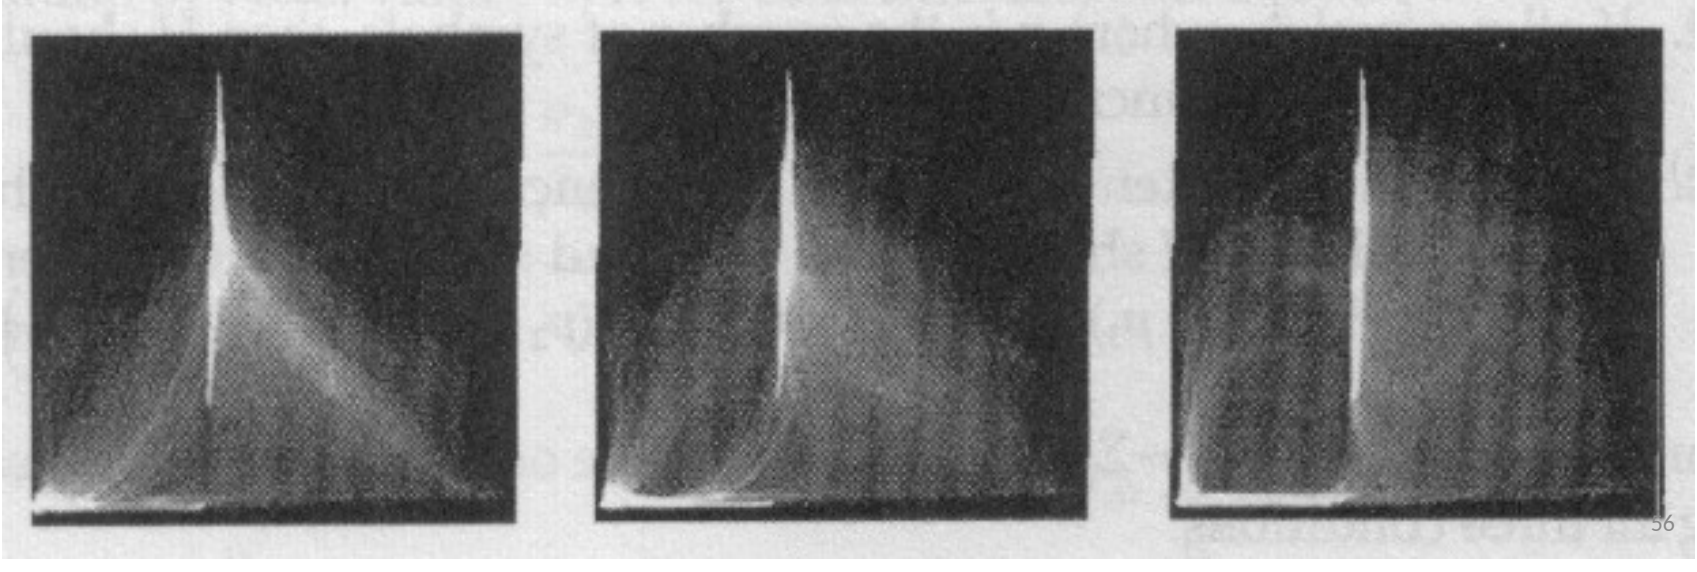
Primjer histograma drugog reda

- Za dvije jednake MR slike glave:
  - Lijevo: točno registrirano
  - Sredina: 2mm pomak jedne slike u odnosu na drugu
  - Desno: 5 mm pomak jedne slike u odnosu na drugu



Primjer histograma drugog reda

- Za CT i MR sliku glave:
  - Lijevo: točno registrirano
  - Sredina: 2mm pomak jedne slike u odnosu na drugu
  - Desno: 5 mm pomak jedne slike u odnosu na drugu



Međusobna informacija

- Engl. mutual information (MI)
- Alternativna i bolja mjera sličnosti je MI:

$$I(A,B)=H(A)+H(B)-H(A,B)$$

- To je mjera koja pokazuje koliko dobro jedna slika opisuje drugu (u smislu koliko dobro možemo procjeniti jednu sliku na temelju druge)

Normalizirana međusobna informacija

- U određenim slučajevima MI se ne ponaša dobro tako da je predloženo nekoliko načina normalizacije MI:

$$I_1(A,B) = \frac{2I(A,B)}{H(A)+H(B)}$$

$$I_2(A,B) = H(A,B) - I(A,B)$$

$$I_3(A,B) = \frac{H(A)+H(B)}{H(A,B)}$$

Zaključak

- Registracija slike je područje s mnogo primjena
- Intenzivna istraživanja u zadnjem desetljeću
- U predavanju je dan pregled osnovnih aspekata i problema registracije slike

- Za detaljnije informacije pogledati literaturu u nastavku

Literatura

- M. Sonka, J. M. Fitzpatrick, Eds., Handbook of Medical Imaging, Volume 2. Medical Image Processing and Analysis, SPIE, 2000
- J. V. Hajnal, D. L. G. Hill, D. J. Hawkes, Eds., Medical Image Registration, CRC Press, 2001