Postojanost boja

Nikola Banić

Sven Lončarić

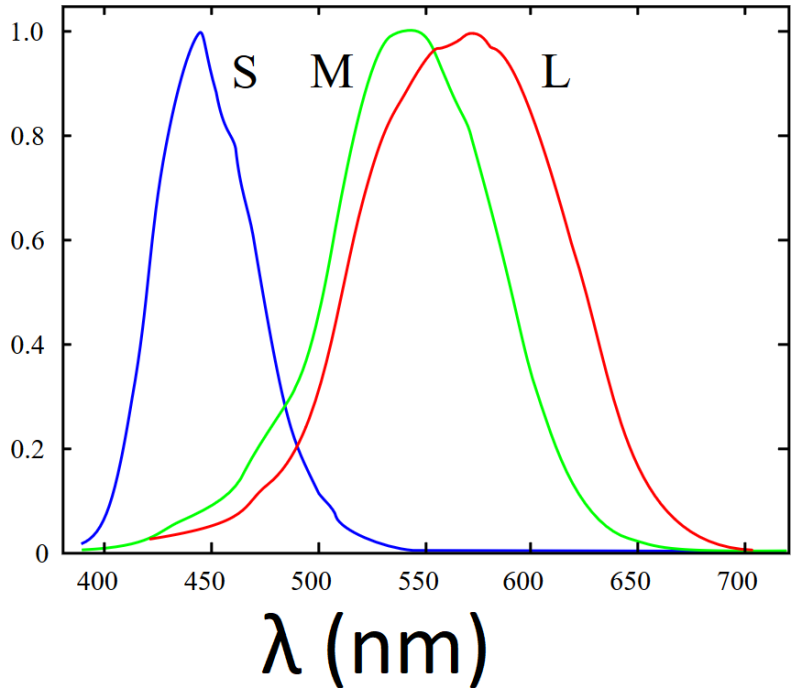
10. travnja 2018.

Sadržaj

- Boje
- Postojanost boja
- Ručno podešavanje boja
- Algoritmi za automatsko podešavanje boja
- Algoritmi razvijeni na zavodu

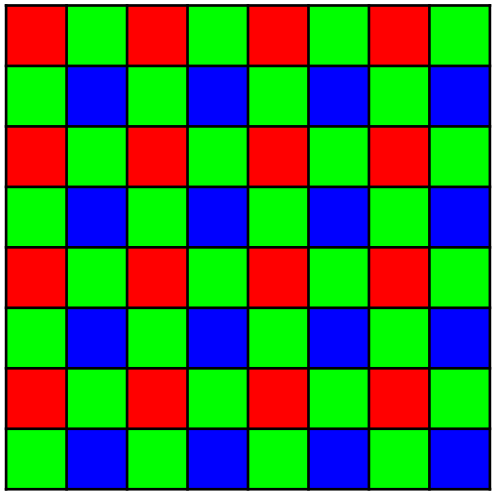
Boje

- Svjetlosni fenomen
- Trikromatska teorija – tri komponente
- Različiti prostori boja:
  RGB, XYZ, Lab, HSV, YUV, CMYK...



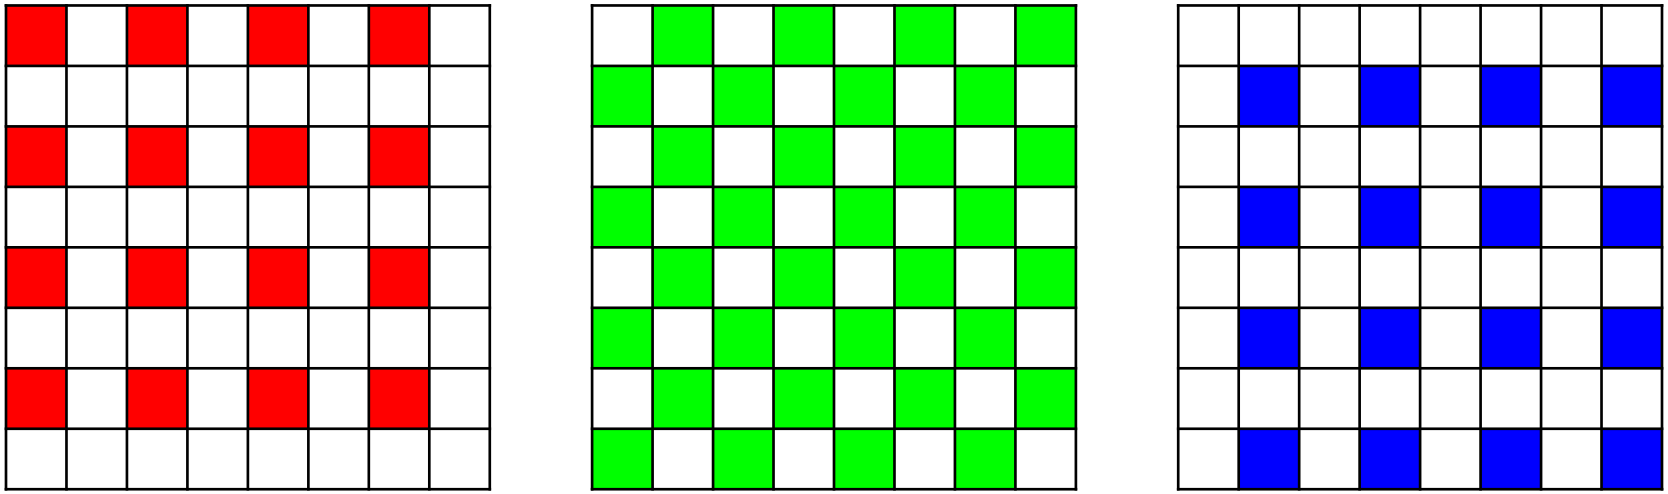
Normalizirani odzivi pojedinih čunjića u oku

Boje na kamerama



Senzor za boje – Bayerov raspored

Boje na kamerama



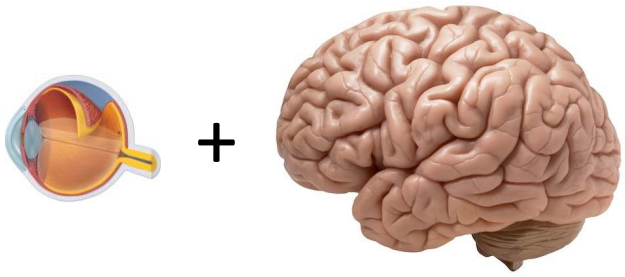
Senzor za boje – Bayerov raspored

Doživljaj boja



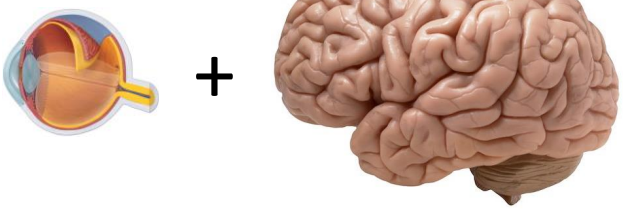
Ljudski doživljaj boja

Doživljaj boja

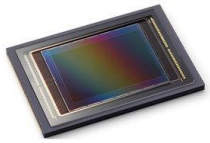


Ljudski doživljaj boja

Doživljaj boja

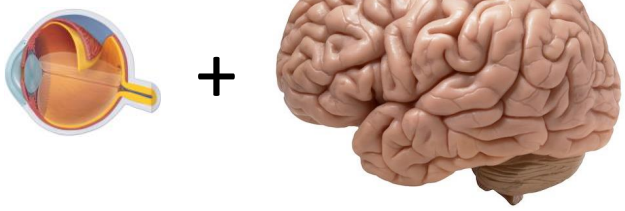


Ljudski doživljaj boja

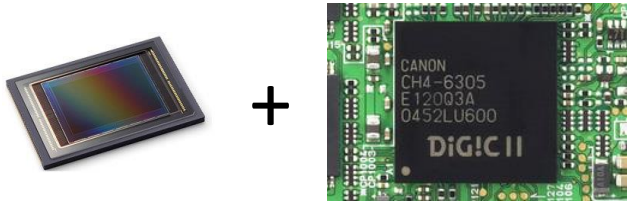


Boje na digitalnoj kameri

Doživljaj boja



Ljudski doživljaj boja



Boje na digitalnoj kameri

Doživljaj boja



≠



Doživljaj boja



≠



Doživljaj boja



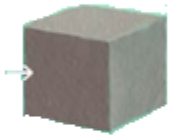
Ista scena pod različitim osvjetljenjima

Doživljaj boja





Doživljaj boja





Postojanost boja

- Sposobnost ljudskog vizualnog sustava da prepozna boje objekata neovisno o boji osvjetljenja scene

- Još nije poznato kako točno radi

- Kako postići računalnu postojanost boja?

Model formiranja slike

$$f_c(\mathbf{x})$$

- $f_c(\mathbf{x})$ – vrijednost na poziciji **x** za kanal $c \in \{R, G, B\}$

Model formiranja slike

$$f_c(\mathbf{x}) = \int_{\omega} R(\mathbf{x}, \lambda) \, d\lambda$$

- $f_c(\mathbf{x})$ – vrijednost na poziciji **x** za kanal $c \in \{R, G, B\}$
- ω – vidljivi spektar
- $R(\mathbf{x}, \lambda)$ – odsjaj površine na poziciji **x** za valnu duljinu λ

Model formiranja slike

$$f_c(\mathbf{x}) = \int_{\omega} R(\mathbf{x}, \lambda)\rho_c(\lambda)d\lambda$$

- $f_c(\mathbf{x})$ – vrijednost na poziciji **x** za kanal $c \in \{R, G, B\}$
- ω – vidljivi spektar
- $R(\mathbf{x}, \lambda)$ – odsjaj površine na poziciji **x** za valnu duljinu λ
- $\rho_c(\lambda)$ – osjetljivost senzora kamere na valnu duljinu λ za kanal c

Model formiranja slike

$$f_c(\mathbf{x}) = \int_{\omega} I(\lambda, \mathbf{x}) R(\mathbf{x}, \lambda) \rho_c(\lambda) d\lambda$$

- $f_c(\mathbf{x})$ – vrijednost na poziciji **x** za kanal $c \in \{R, G, B\}$
- ω – vidljivi spektar
- $R(\mathbf{x}, \lambda)$ – odsjaj površine na poziciji **x** za valnu duljinu λ
- $\rho_c(\lambda)$ – osjetljivost senzora kamere na valnu duljinu λ za kanal c
- $I(\lambda)$ – spektralna razdioba izvora svjetlosti – pretpostavlja se uniformno osvjetljenje

Računalna postojanost boja

1. Procjena osvjetljenja

Računalna postojanost boja

1. Procjena osvjetljenja

2. Kromatska adaptacija

Računalna postojanost boja

1. Procjena osvjetljenja
    - Teži i važniji korak
    - Različite dodatne pretpostavke
2. Kromatska adaptacija

Računalna postojanost boja

1. Procjena osvjetljenja
   - Teži i važniji korak
   - Različite dodatne pretpostavke
2. Kromatska adaptacija
   - Ispravljanje boja u slici korištenjem procjene osvjetljenja
   - Lakši korak

Procjena osvjetljenja

$$\mathbf{e}(\mathbf{x}) = \begin{pmatrix} e_R(\mathbf{x}) \\ e_G(\mathbf{x}) \\ e_B(\mathbf{x}) \end{pmatrix} = \int_\omega I(\lambda, \mathbf{x}) \rho(\lambda) d\lambda$$

- **e** – promatrani izvor osvjetljenja – to nas zanima

Procjena osvjetljenja

$$\mathbf{e}(\mathbf{x}) = \begin{pmatrix} e_R(\mathbf{x}) \\ e_G(\mathbf{x}) \\ e_B(\mathbf{x}) \end{pmatrix} = \int_\omega I(\lambda, \mathbf{x}) \rho(\lambda) d\lambda$$

- **e** – promatrani izvor osvjetljenja – to nas zanima
- U idealnom slučaju – bijelo svjetlo: $e_R = e_G = e_B$

Procjena osvjetljenja

$$\mathbf{e}(\mathbf{x}) = \begin{pmatrix} e_R(\mathbf{x}) \\ e_G(\mathbf{x}) \\ e_B(\mathbf{x}) \end{pmatrix} = \int_\omega I(\lambda, \mathbf{x})\rho(\lambda)d\lambda$$

- **e** – promatrani izvor osvjetljenja – to nas zanima
- U idealnom slučaju – bijelo svjetlo: $e_R = e_G = e_B$
- Matematički loše postavljen problem – I i ρ su nepoznati

Loše postavljen problem

- Što bi moglo biti na slici?
  - Slika bijelog zida pod žutim svjetlom?
  - Slika žutog zida pod bijelim svjetlom?
  - Nešto treće?



Procjena osvjetljenja

$$\mathbf{e}(\mathbf{x}) = \begin{pmatrix} e_R(\mathbf{x}) \\ e_G(\mathbf{x}) \\ e_B(\mathbf{x}) \end{pmatrix} = \int_\omega I(\lambda, \mathbf{x})\rho(\lambda)d\lambda$$

- **e** – promatrani izvor osvjetljenja – to nas zanima
- U idealnom slučaju – bijelo svjetlo: $e_R = e_G = e_B$
- Matematički loše postavljen problem – I i ρ su nepoznati

Procjena osvjetljenja

$$\mathbf{e}(\mathbf{x}) = \begin{pmatrix} e_R(\mathbf{x}) \\ e_G(\mathbf{x}) \\ e_B(\mathbf{x}) \end{pmatrix} = \int_\omega I(\lambda, \mathbf{x}) \rho(\lambda) d\lambda$$

- **e** – promatrani izvor osvjetljenja – to nas zanima
- U idealnom slučaju – bijelo svjetlo: $e_R = e_G = e_B$
- Matematički loše postavljen problem – I i ρ su nepoznati
- Potrebne su **dodatne pretpostavke**

Procjena osvjetljenja

- Ako je **e** procjena, a **c** stvarno osvjetljenje, onda se pogreška procjene izražava kao kut između vektora:

$$\varphi = \cos^{-1} \frac{\boldsymbol{c}^T \boldsymbol{e}}{\|\boldsymbol{c}\| \|\boldsymbol{e}\|}$$

- Pogreška je prihvatljiva ako je manja od 3°

- Procjena može biti „ručna” ili automatska

Kromatska adaptacija

- Početno osvjetljenje: **e** = $(e_R, e_G, e_B)^T$
- Kanonsko osvjetljenje: **c** = $(c_R, c_G, c_B)^T$
- Boja pod početnim osvjetljenjem: $(R_n, G_n, B_n)^T$
- Boja pod kanonskim osvjetljenjem: $(R_c, G_c, B_c)^T$

$$\begin{pmatrix} R_c \\ G_c \\ B_c \end{pmatrix} = \begin{pmatrix} d_1 & 0 & 0 \\ 0 & d_2 & 0 \\ 0 & 0 & d_3 \end{pmatrix} \begin{pmatrix} R_n \\ G_n \\ B_n \end{pmatrix} = \begin{pmatrix} \frac{c_R}{e_R} & 0 & 0 \\ 0 & \frac{c_G}{e_G} & 0 \\ 0 & 0 & \frac{c_B}{e_B} \end{pmatrix} \begin{pmatrix} R_n \\ G_n \\ B_n \end{pmatrix}$$

Kromatska adaptacija

```
function result=scaleChannels(img, c, normalize)

    if (nargin<3)
        normalize=1;
    end

    if (normalize~=0)
        c=c/(sum(c)/3);
    end

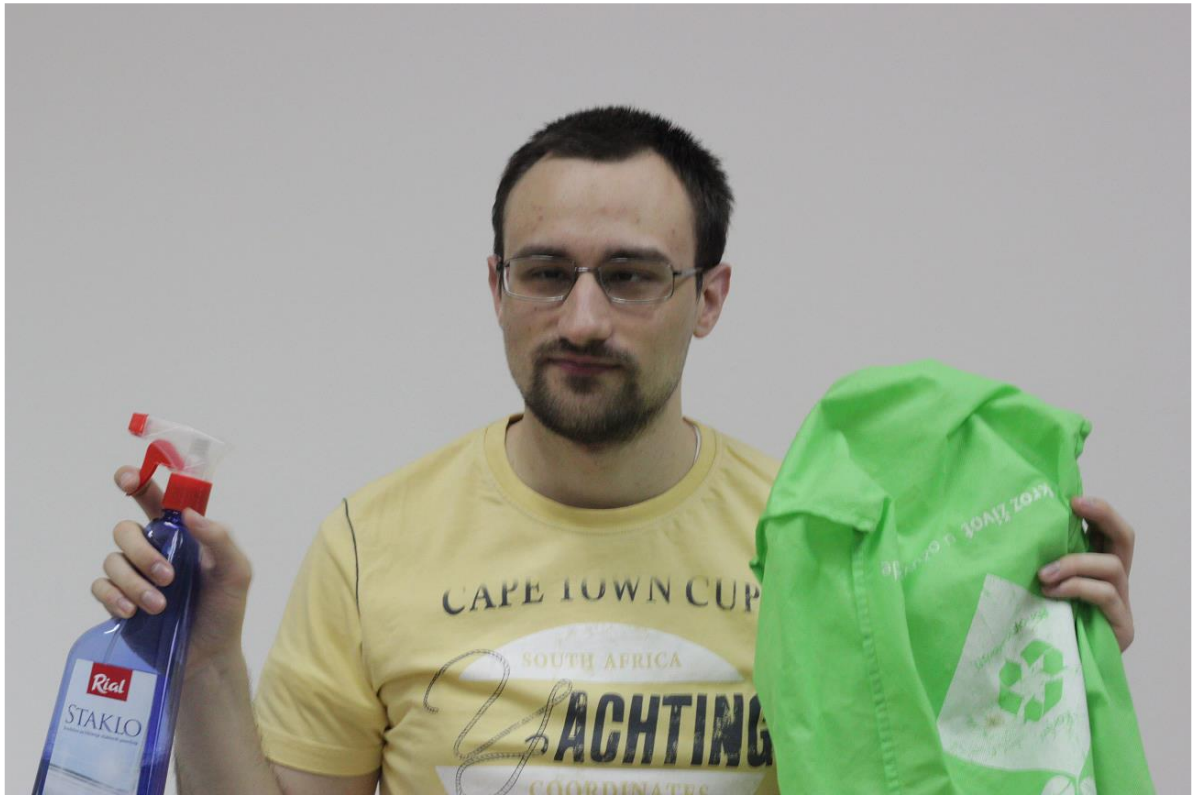
    result=img;
    for i=1:3
        result(:, :, i)=c(i)*img(:, :, i);
    end
end
```

Ručna procjena osvjetljenja



Ako znamo (**PRETPOSTAVIMO**) da bi zid u pozadini trebao biti bijel, možemo koristiti njegovu boju kao procjenu osvjetljenja

Ručna procjena osvjetljenja



Ručna procjena osvjetljenja



https://web.archive.org/web/20180410064414/https://narod.hr/wp-content/uploads/2018/04/H20180321000634.jpg

Ručna procjena osvjetljenja



https://web.archive.org/web/20180410064414/https://narod.hr/wp-content/uploads/2018/04/H20180321000634.jpg

Ručna procjena osvjetljenja


AGROKOR
AGROKOR
AGROKOR

Ručna procjena osvjetljenja



Korištenje kalibracijskog objekta (kocka s akromatskim površinama) za određivanje boje osvjetljenja scene

Ručna procjena osvjetljenja



Ručna procjena osvjetljenja

```
function ie=manualAWB(img)

    figure();
    imshow(img);
    m=impoly();
    m=m.createMask();

    imgd=double(img);
    red=imgd(:, :, 1);
    green=imgd(:, :, 2);
    blue=imgd(:, :, 3);

    mr=red(m);
    mg=green(m);
    mb=blue(m);

    ie=mean([mr(:), mg(:), mb(:)]);

end
```

Automatska procjena osvjetljenja

- Statističke metode

- Metode temeljene na učenju

Automatska procjena osvjetljenja

- Statističke metode
  - Brže i jednostavnije za implementaciju
  - Koriste statistiku u pikselima
  - Među poznatijima: White-patch (Max-RGB) i Gray-world
- Metode temeljene na učenju

Automatska procjena osvjetljenja

- Statističke metode
  - Brže i jednostavnije za implementaciju
  - Koriste statistiku u pikselima
  - Među poznatijima: White-patch (Max-RGB) i Gray-world
- Metode temeljene na učenju
  - Koriste se različiti algoritmi učenja
  - Sporije, ali točnije

Automatska procjena osvjetljenja

- Statističke metode
  - Brže i jednostavnije za implementaciju
  - Koriste statistiku u pikselima
  - Među poznatijima: White-patch (Max-RGB) i Gray-world
- Metode temeljene na učenju
  - Koriste se različiti algoritmi učenja
  - Sporije, ali točnije
- Otvoreno područje istraživanja

Stvarni svijet



https://www.youtube.com/watch?v=cn9MY2HNJwo

Stvarni svijet



https://www.youtube.com/watch?v=cn9MY2HNJwo

Stvarni svijet



https://www.youtube.com/watch?v=cn9MY2HNJwo

Stvarni svijet



https://www.youtube.com/watch?v=cn9MY2HNJwo

Stvarni svijet



White-patch (Max-RGB)

- **pretpostavlja** da je izvor svjetlosti moguće odrediti uzimanjem maksimalnih odziva u pojedinim kanalima
- intuitivno dobra ideja
- kod primjene originalnog oblika je točnost mala
- velika osjetljiv na šum i previše eksponirane piksele
- previše eksponirani pikseli u barem jednom kanalu imaju maksimalnu vrijednost i njih se lako i redovito zaobilazi
- uz dodatna poboljšanja postiže dobre rezultate

White-patch (Max-RGB)

```
function ie=wp(img, upperBound)

    if (nargin<2)
        upperBound=255;
    end

    imgd=double(img);

    r=imgd(:, :, 1);
    g=imgd(:, :, 2);
    b=imgd(:, :, 3);

    r=r(:);
    g=g(:);
    b=b(:);

    mask=(r<upperBound) | (g<upperBound) | (b<upperBound);

    r=r(mask);
    g=g(mask);
    b=b(mask);

    ie=max([r(:), g(:), b(:)]);
    ie=ie/sum(ie);
end
```

Gray-world

- **pretpostavlja** da je svijet u prosjeku siv (akromatski)
- nejednakost prosječnih vrijednosti pojedinih kanala je prema toj pretpostavci uzrokovana izravno bojom izvora svjetlosti
- zato se za procjenu osvjetljenja uzima srednja vrijednost svih kanala
- osnovni oblik nije precizan kao mnogi izvedeni oblici (Shades-of-Gray: proizvoljna norma kod računanja prosjeka, Gray-edge: gradijent umjesto slike)

Gray-world

```
function ie=gw(img)
    r=img(:, :, 1);
    g=img(:, :, 2);
    b=img(:, :, 3);
    ie=mean([r(:), g(:), b(:)]);
    ie=ie/sum(ie)*3;
end
```

Primjer



Primjer



Za procjenu je korišten Gray-world.

Primjer



https://web.archive.org/web/20180410063823/http://s3-us-west-2.amazonaws.com/warisboring.com/images/Trident_Juncture_2015_-_Personnel_of_the_Spanish_7th_Airborne_Field_Artillery_division_prepare_a_Howitzer_for_live_firing._21807144593.jpg

Primjer



Za procjenu je korišten Gray-world.

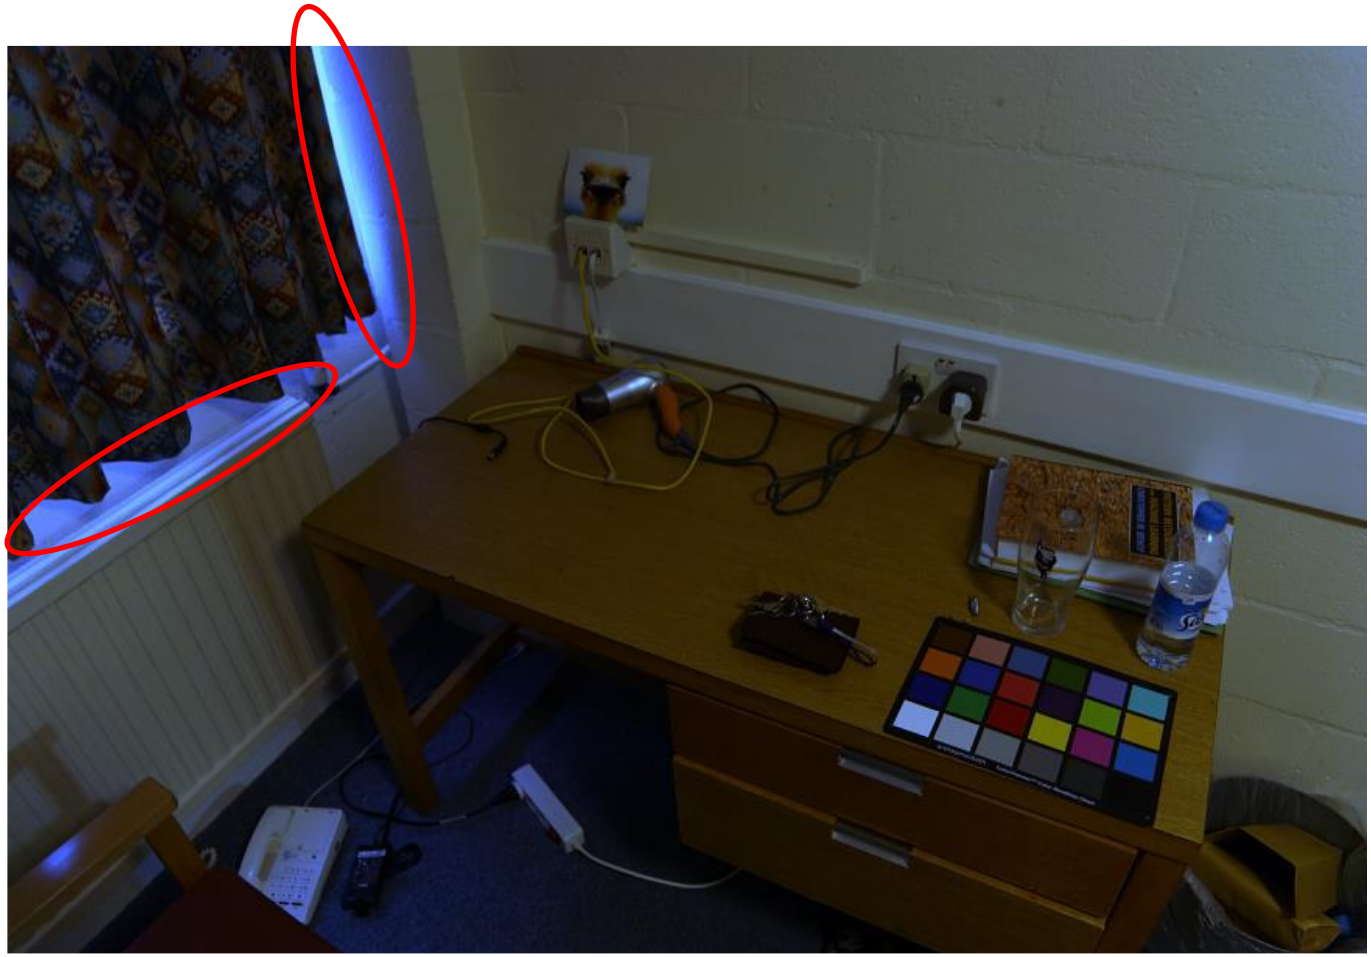
Problemi



Problemi



Problemi



Problemi



Problemi



Vlastite metode – procjena osvjetljenja

- Color Sparrow (CS) i Color Rabbit (CR)
  - koriste više lokalnih procjena
  - kombiniranje u jednu završnu globalnu
- Improved White Patch (IWP)
  - uklanjanje osjetljivosti na šum
  - dodatno ubrzanje izvođenja
- Color Cat, Smart Color Cat, Color Dog, Color Tiger
  - metode temeljene na učenju
  - veća točnost
  - korištenje distribucije mogućih boja svjetlosti

Vlastite metode – lokalno poboljšanje

- Light Random Sprays Retinex (LRSR)
  - svaki piksel se prilagođava svojem susjedstvu
  - susjedstvo se određuje slučajnim sprejem oko piksela

- Smart Light Random Memory Sprays Retinex (SLRMSR)
  - naprednijainačica
  - značajno veća brzina – lokalno dijeljenje informacija
  - bolja kvaliteta slika

Početna slika



LRSR



SLRMSR



Početna slika



LRSR



SLRMSR



Vezano za področje

- http://colorconstancy.com/
- http://ipg.fer.hr/ipg/resources/color_constancy
- http://www.comp.nus.edu.sg/~whitebal/illuminant/illuminant.html

Bitno za zapamtiti

- Kojim se dvama koracima ostvaruje računalna postojanost boja?
- Kako se uz poznati izvor svjetlosti najčešće računa pogreška procjene osvjetljenja?
- Kako radi White-Patch (Max-RGB) algoritam?
- Kako radi Gray-World algoritam?

Gray-World algoritam procjenjuje svjetlost tako da za svaki kanal uzme procjenu vrijednosti u njemu (uz eventualno izbjegavanje previše eksponiranih piksela). Npr. ako je dana slika s 8 bitova po kanalu (dakle, maksimalna vrijednost po kanalu je 255)koja ima crveni (R), zeleni (G) i plavi kanal (B) s vrijednostima $R = \begin{bmatrix} 123 & 207 & 134 \\ 53 & 245 & 56 \\ 12 & 227 & 11 \end{bmatrix}$, $G = \begin{bmatrix} 35 & 117 & 14 \\ 54 & 255 & 156 \\ 172 & 37 & 10 \end{bmatrix}$, $B = \begin{bmatrix} 22 & 207 & 135 \\ 253 & 75 & 36 \\ 112 & 27 & 255 \end{bmatrix}$. Ako ne izbjegavamo previše eksponirane piksele (koliji služi), onda je procjena boje osvjetljenja $\rho = [119.78, 94.44, 124.78]^T$. Ako izbjegavamo previše eksponirane piksele (koliji služi), onda je procjena boje osvjetljenja $\rho = [91.33, 65, 86.11]^T$ pri čemu su iz računa isključena dva previše eksponirana piksela. Iako je rezultat dobiven dijeljenjem vrijednosti pojedinih kanala brojem 9, ne bi bila pogreška ni da se dijelilo brojem 7 zbog odlučivanja dvaju previše eksponiranih piksela) jer je na kraju bitan jedino omjer procjene osvjetljenja. Štovše, ne bi bila pogreška ni da se uspješnije dijelilo, ali je s dijeljenjem „ljepše" ☺


That's all Folks!