Segmentacija i praćenje katetera tijekom endovaskularnih zahvata

Digitalna obrada i analiza slike



Tomislav Petković
Sven Lončarić

Sveučilište u Zagrebu

Svibanj 2012.

Sadržaj

O problemu praćenja
- Implementacijski zadaci

Praćenje katetera
- Detekcija linija
- Praćenje pozadine

Prezentacija ima 17 prikaznice.

O problemu praćenja

Definicija (Praćenje)

Praćenje jest nalaženje putanje odabranog pokretnog objekta na temelju niza slika.

Rezultat praćenja se može zapisati kao preslikavanje, npr. ako želimo pratiti 2D poziciju težišta tijela na slici tada je rezultat praćenja preslikavanje $f(n) : \mathbb{Z} \to \mathbb{R}^2$ gdje svakom koraku n pridružujemo položaj $f(n) = \big(x(n), y(n)\big)$ u n-toj slici.

Osim 2D položaja možemo pratiti i orijentaciju opisanu kutom zakreta te je tada rezultat praćenja preslikavanje $f(n) : \mathbb{Z} \to \mathbb{R}^3$ gdje svakom koraku n pridružujemo položaj $f(n) = \big(x(n), y(n), \theta(t)\big)$.

Dva važna podzadatka

Rezultat praćenja je putanja objekta, dakle moramo znati položaj objekta na svakoj slici.

1. Kako pronalazimo objekt koji pratimo – zadatak *segmentacije*?
2. Kako uspostavljamo korespondenciju između pokretnih objekata u slikama – zadatak *korespondencije*?

Praćenje katetera u stvarnom vremenu

Projekt je bio ostvaren u suradnji s tvrtkom Philips Healthcare iz Nizozemske. Na projektu su sudjelovali:

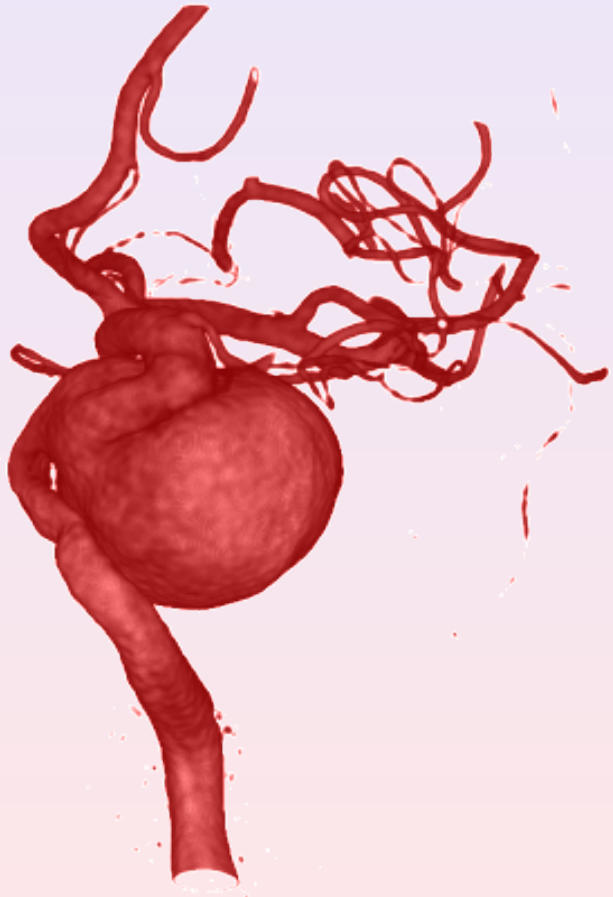
Tomislav Petković
Tomislav Devčić
Sven Lončarić
Vjekoslav Levačić
Hrvoje Bogunović

Robert Homan
Draženko Babić



PHILIPS

Zašto pratimo kateter



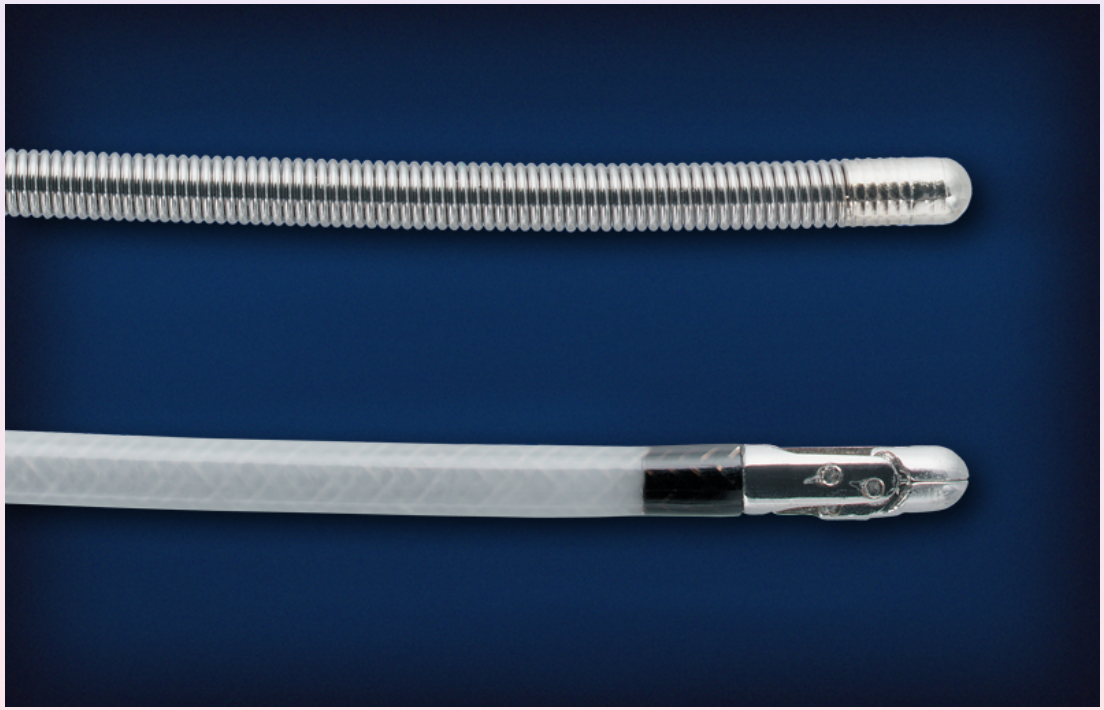
Aneurizma je izraženo proširenje krvne žile.

Mogući oblici liječenja:

1. klasična operacija, i
2. endovaskularni zahvati.

Kateteri

Osnovni instrumenti koji se koriste tijekom endovaskularnih zahvata su *kateteri*.



Kako snimamo kateter



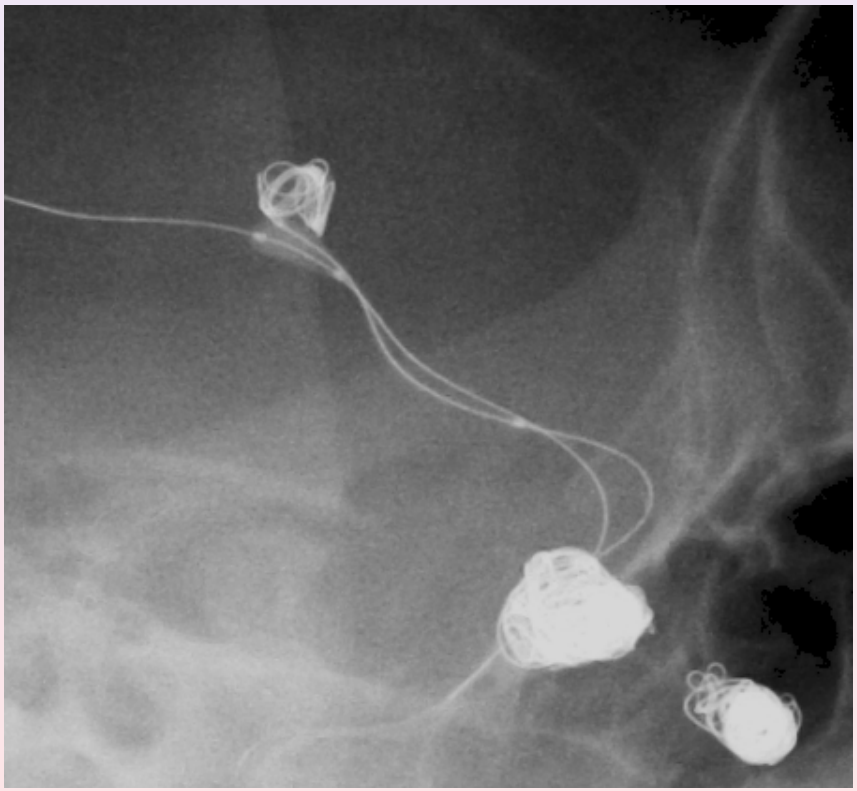
Uređaj za snimanje je jednoravninski rendgenski uređaj s C-lukom.

Pacijent *nepomično* leži na stolu.

C-luk se koristi prije zahvata za dobivanje 3D rekonstrukcije krvnih žila od interesa.

Zadatak

Trebamo pratiti i rekonstruirati položaja katetera tijekom zahvata korištenjem *jednoravninskog* rendgenskog snimanja u *stvarnom vremenu*.



Relani primjer

Pokazati praćenje i rekonstrukciju 3D položaja i orijentacije katetera na primjeru PHILIPS XtraVision paketa.

Hessianova matrica

Za detekciju linija na slici obično se koristi Hessianova matrica (matrica parcijalnih drugih derivacija).

Definicija (Hessianova matrica)

Neka je $I(x, y) : \mathbb{Z} \times \mathbb{Z} \to \mathbb{R}$ *ulazna slika. Hessianova matrica na skali* σ *je kvadratna matrica dimenzija* 2×2 *s vrijednostima*

$$\mathbf{H}_\sigma(x, y) = \begin{bmatrix} I(x, y) * \frac{\partial^2 g(x)}{\partial x^2} * g(y) & I(x, y) * \frac{\partial g(x)}{\partial x} * \frac{\partial g(y)}{\partial y} \\ I(x, y) * \frac{\partial g(x)}{\partial x} * \frac{\partial g(y)}{\partial y} & I(x, y) * g(x) * \frac{\partial^2 g(y)}{\partial y^2} \end{bmatrix},$$

pri čemu je $g(\cdot)$ *Gaussova FGV nultog očekivanja i devijacije* σ.

Svojstvene vrijednosti Hessianove matrice

Izračunamo li za svaku točku slike svojstvene vrijednosti i svojstvene vektore Hessianove matrice možemo točke klasificirati ovisno o vrijednostima svojstvenih vrijednosti.

λ_1	λ_2	uzorak u 2D slici
jako mala	jako mala	nema preferirane strukture
mala	velika pozitivna	svijetla linijska struktura
mala	velika negativna	tamna linijska struktura
velika pozitivna	velika pozitivna	svijetla kružna struktura
velika negativna	velika negativna	tamna kružna struktura

Tablica: Mogući uzorci svojstvenih vrijednosti λ_1 i λ_2, $|\lambda_1| < |\lambda_2|$ i interpretacija istih. Kvalifikatori *mala* i *velika* ovise o slici.

Analiza svojstvenih vrijednosti Hessianove matrice

Iz određenih svojstvenih vrijednosti se može konstruirati mjera na intervalu $[0, 1]$ koja mjeri koliko je struktura u slici nalik liniji (eng. vesselness measure, A. F. Frangi et al., *Multiscale vessel enhancement filtering*, MICCAI '98).

Mjera za svojstvene vrijednosti Hessianove matrice λ_1 i λ_2, $|\lambda_1| < |\lambda_2|$, na skali σ je

$$\mathcal{V}(\sigma) = \exp\Big(-\frac{\lambda_1^2}{\lambda_2^2}\frac{1}{2\alpha^2}\Big)\Big(1 - \exp\Big(-\frac{\lambda_1^2 + \lambda_2^2}{2\beta^2}\Big)\Big), \tag{1}$$

gdje su α i β parametri koji ovise o ulaznoj slici.

Model statičke pozadine

Ako je pozadina stalna te ako raspolažemo s n slika pozadine optimalna procjena pozadine je aritmetička sredina. Označimo li slike pozadine kao $I_1(x, y), \ldots, I_n(x, y)$ procjena vrijednosti pozadine je

$$b_n(x, y) = \frac{1}{n} \sum_{k=1}^{n} I_k(x, y).$$

Ako nam postane dostupna nova slika $I_{n+1}(x, y)$ nije potrebno računati novu aritmetičku sredinu već je dovoljno izvršiti korekciju

$$b_{n+1}(x, y) = \frac{n}{n+1} b_n(x, y) + \frac{1}{n+1} I_{n+1}(x, y) = \frac{1}{n+1} \sum_{k=1}^{n+1} I_k(x, y)$$

Konveksna kombinacija pozadine i nove slike

Dobiveni izraz se poopćava na računanje konveksne kombinacije s faktorom $0 \leq \alpha \leq 1$ za svaku novu sliku kao

$$b_{n+1}(x, y) = \alpha b_n(x, y) + (1 - \alpha) I_{n+1}(x, y),$$

gdje α mjeri koliko vjerujemo staroj pozadini $b_n(x, y)$, a koliko novoj slici $I_{n+1}(x, y)$.

Opisani postupak se provodi samo za točke slike koje odgovaraju pozadini. Najjednostavnije ih prepoznajemo kao točke koje značajno ne odstupaju od stare vrijednosti pozadine.

Veza s Kalmanovim filtrom

Opisani postupak konceptualno odgovara Kalmanovom filtru uz stalni model pozadine koji također traži optimalnu procjenu kao konveksnu kombinaciju prethodne procjene i nove slike.

No kod Kalmanovog filtra parametar α se ne određuje proizvoljno već se odabire tako da rezultat bude optimalan!

Stranica namjerno ostavljena praznom.