Profilometrija projiciranjem pruga i korištenjem boje

Tomislav Petković

Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva





Zagreb, 10. travnja 2018.

Sadržaj

Uvod
- 3D skeniranje površine
- Binokularni vid
- Strukturirano svjetlo

Profilometrija projiciranjem pruga
- Sinusoidalne pruga
- Važnost faze
- Odmatanje faze
- Mali rječnik pojmova

Profilometrija projiciranjem pruga i korištenjem boje
- Korištenje boje
- De Bruijnov niz
- Koraci obrade
- Zaključak

Sadržaj

Uvod
- 3D skeniranje površine
- Binokularni vid
- Strukturirano svjetlo

Profilometrija projiciranjem pruga
- Sinusoidalne pruga
- Važnost faze
- Odmatanje faze
- Mali rječnik pojmova

Profilometrija projiciranjem pruga i korištenjem boje
- Korištenje boje
- De Bruijnov niz
- Koraci obrade
- Zaključak

Sadržaj

Uvod
- 3D skeniranje površine
- Binokularni vid
- Strukturirano svjetlo

Profilometrija projiciranjem pruga
- Sinusoidalne pruga
- Važnost faze
- Odmatanje faze
- Mali rječnik pojmova

Profilometrija projiciranjem pruga i korištenjem boje
- Korištenje boje
- De Bruijnov niz
- Koraci obrade
- Zaključak

Sadržaj

Uvod
- 3D skeniranje površine
- Binokularni vid
- Strukturirano svjetlo

Profilometrija projiciranjem pruga
- Sinusoidalne pruga
- Važnost faze
- Odmatanje faze
- Mali rječnik pojmova

Profilometrija projiciranjem pruga i korištenjem boje
- Korištenje boje
- De Bruijnov niz
- Koraci obrade
- Zaključak

3D skeniranje površine

3D skeniranje površine jest procedura kojom mjerimo koordinate (oblik) površine nekog predmeta.

- 3D skeniranje površine
  - druga imena su 3D profilometrija, mjernje raspona, senziranje dubine
  - postupci kojima mjerimo položaj površine
  - mjerimo koordinate (x, y, z) neke površine
  - ponekad mjerimo koeficijent reflekcije ili albedo površine
  - primjer: profilometrija projiciranjem pruga
- 3D oslikavanje
  - postupci kojima dobivamo istinske 3D podatke
  - mjerimo neku veličinu p za svaku točku (x, y, z) unutar konačnog volumena
  - primjeri: CT, MRI, 3DRA

3D skeniranje površine

3D skeniranje površine jest procedura kojom mjerimo koordinate (oblik) površine nekog predmeta.

- 3D skeniranje površine
  - druga imena su 3D profilometrija, mjernje raspona, senziranje dubine
  - postupci kojima mjerimo položaj površine
  - mjerimo koordinate (x, y, z) neke površine
  - ponekad mjerimo koeficijent reflekcije ili albedo površine
  - primjer: profilometrija projiciranjem pruga
- 3D oslikavanje
  - postupci kojima dobivamo istinske 3D podatke
  - mjerimo neku veličinu p za svaku točku (x, y, z) unutar konačnog volumena
  - primjeri: CT, MRI, 3DRA

3D skeniranje površine

3D skeniranje površine jest procedura kojom mjerimo koordinate (oblik) površine nekog predmeta.

- 3D skeniranje površine
  - druga imena su 3D profilometrija, mjernje raspona, senziranje dubine
  - postupci kojima mjerimo položaj površine
  - mjerimo koordinate (x, y, z) neke površine
  - ponekad mjerimo koeficijent reflekcije ili albedo površine
  - primjer: profilometrija projiciranjem pruga
- 3D oslikavanje
  - postupci kojima dobivamo istinske 3D podatke
  - mjerimo neku veličinu p za svaku točku (x, y, z) unutar konačnog volumena
  - primjeri: CT, MRI, 3DRA

3D skeniranje površine

3D skeniranje površine jest procedura kojom mjerimo koordinate (oblik) površine nekog predmeta.

- 3D skeniranje površine
  - druga imena su 3D profilometrija, mjernje raspona, senziranje dubine
  - postupci kojima mjerimo položaj površine
  - mjerimo koordinate (x, y, z) neke površine
  - ponekad mjerimo koeficijent reflekcije ili albedo površine
  - primjer: profilometrija projiciranjem pruga
- 3D oslikavanje
  - postupci kojima dobivamo istinske 3D podatke
  - mjerimo neku veličinu p za svaku točku (x, y, z) unutar konačnog volumena
  - primjeri: CT, MRI, 3DRA

3D skeniranje površine

3D skeniranje površine jest procedura kojom mjerimo koordinate (oblik) površine nekog predmeta.

- 3D skeniranje površine
  - druga imena su 3D profilometrija, mjernje raspona, senziranje dubine
  - postupci kojima mjerimo položaj površine
  - mjerimo koordinate (x, y, z) neke površine
  - ponekad mjerimo koeficijent reflekcije ili albedo površine
  - primjer: profilometrija projiciranjem pruga
- 3D oslikavanje
  - postupci kojima dobivamo istinske 3D podatke
  - mjerimo neku veličinu p za svaku točku (x, y, z) unutar konačnog volumena
  - primjeri: CT, MRI, 3DRA

Ključni koncept: triangulacija

Triangulacija znači određivanje položaja neke točke konstrukcijom trokuta prema toj točci iz najmanje dvije poznate točke.

Ako želimo rekonstruirati položaj neke točke na površini predmeta tada moramo tu točku vidjeti iz barem dva različita gledišta.

Najčešće se koriste dvije kamere: binokularni vid.

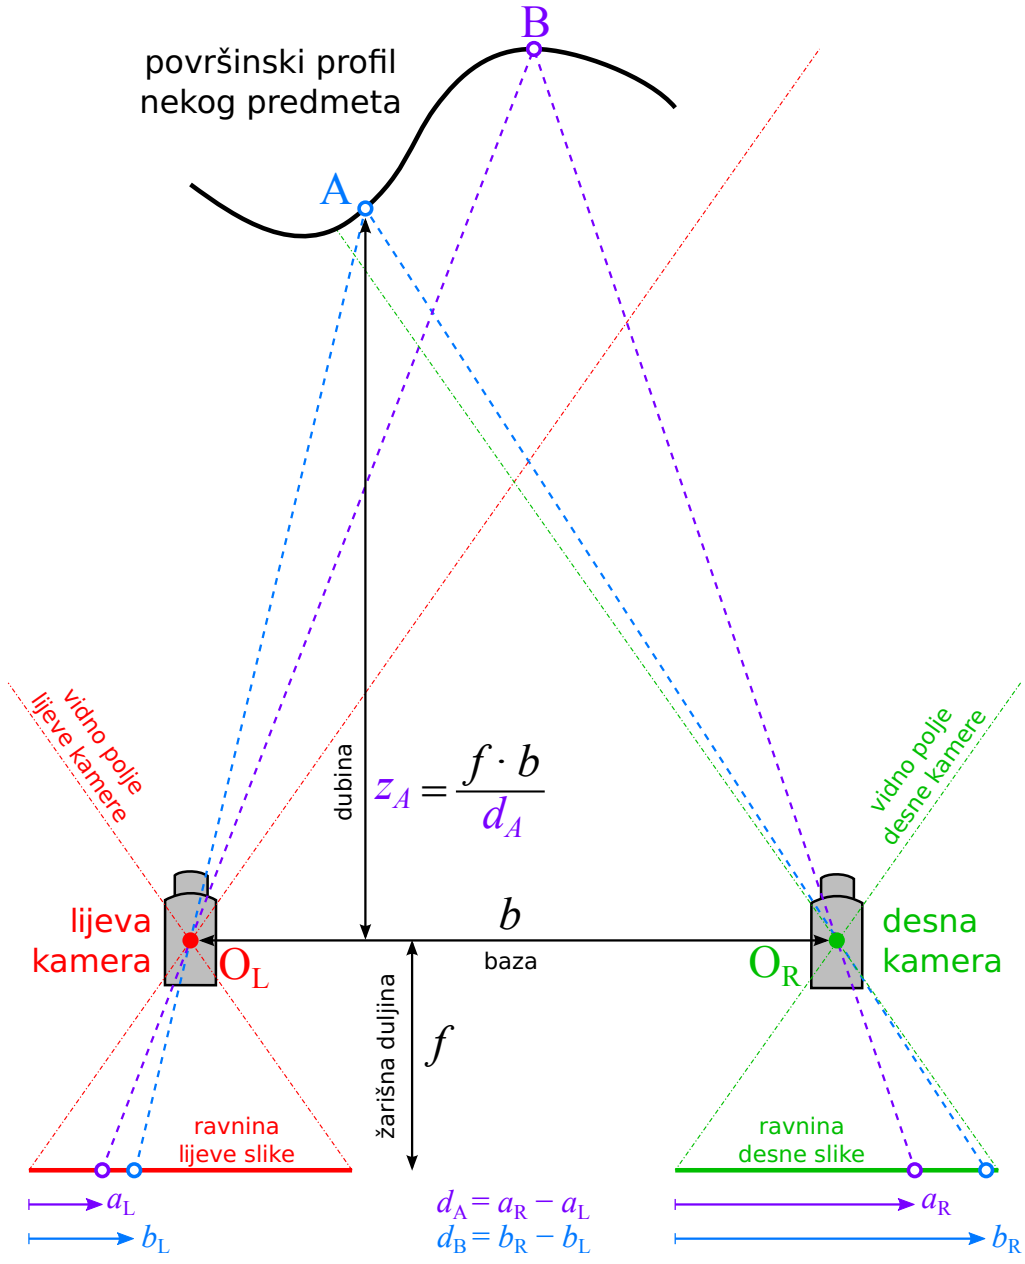
Binokularni vid

Koristimo dvije kamere za mjerenje dubine.

Koraci obrade:

1. uklanjanje distorzije;
2. stereo rektifikacija;
3. nalaženje korespondentnih točaka;
4. triangulacija.

Nedostatak: ne radi za površine bez teksture.



Strukturirano svjetlo

Ako zamijenimo jednu kameru s projektorom dobivamo: *strukturirano svjetlo*.

Projektor projicira posebno pripremljenu sliku koju nazivamo *uzorkom strukturiranog svjetla*.

Princip strukturiranog svjetla jest rekonstrukcija površinskog profila nekog predmeta temeljem distorzije projiciranog uzorka strukturiranog svjetla.

Pri usporedbi s binokularnim vidom kod 3D skeniranja strukturiranim svjetlom zadatak pronalaženja korespondentnih točaka u dvije slike je zamijenjen zadatkom dekodiranja projiciranog uzorka iz jedne slike.

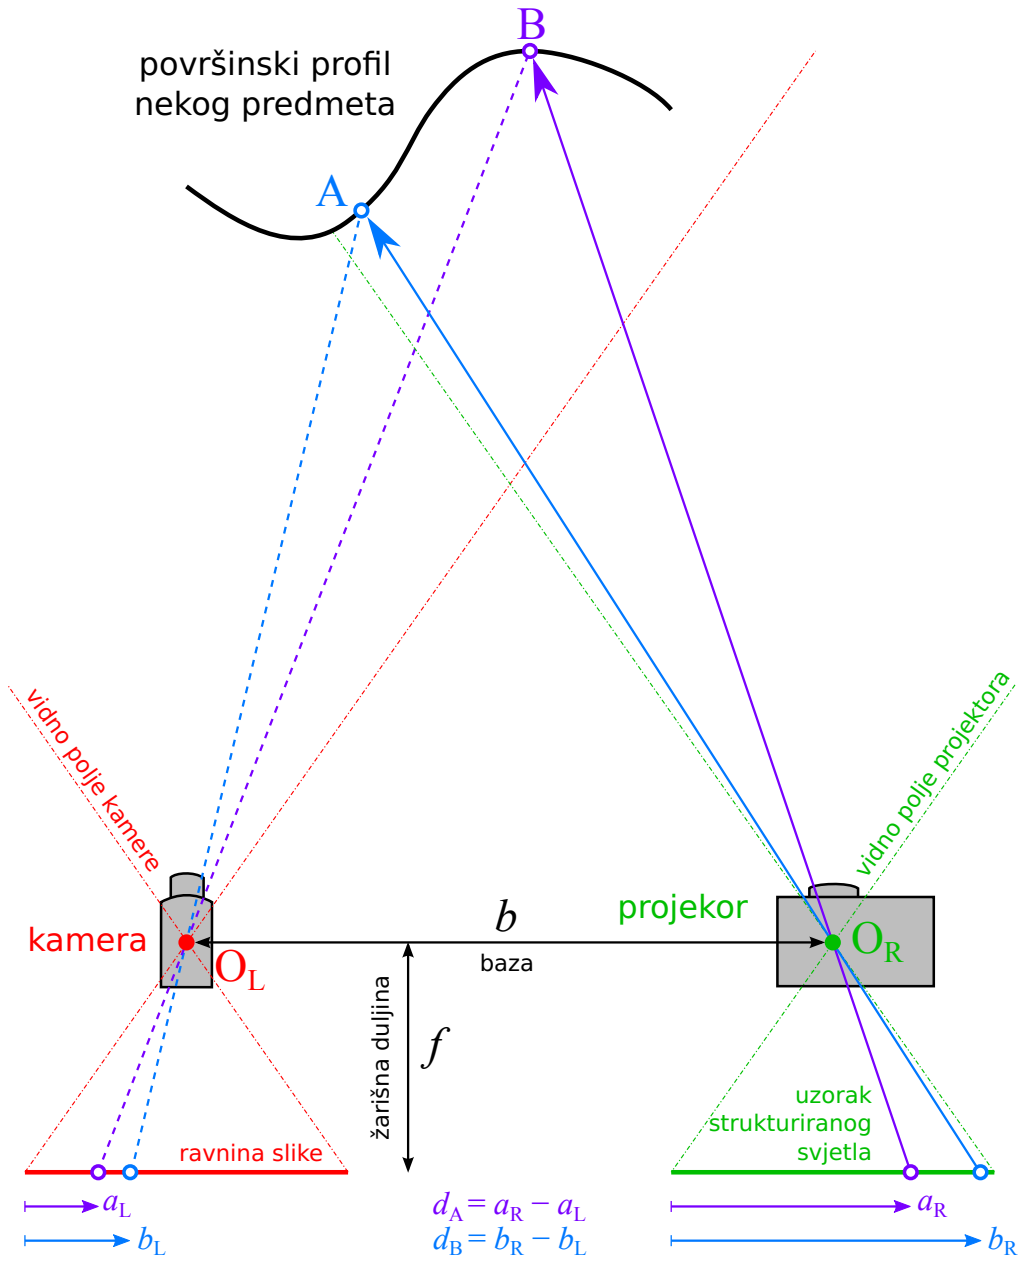
Strukturirano svjetlo

Promatramo deformaciju projiciranog uzorka.

Koraci obrade:

1. dekodiranje uzorka (dobivanje koordinata projektora);
2. uklanjanje distorzije;
3. triangulacija.

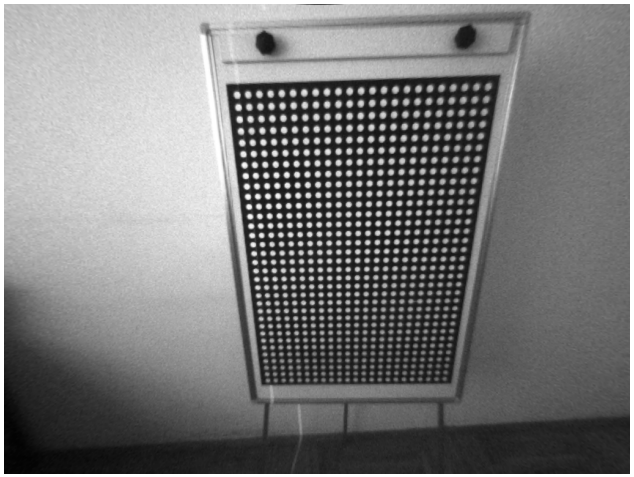
Problemi: ambijentalno svjetlo i albedo predmeta.



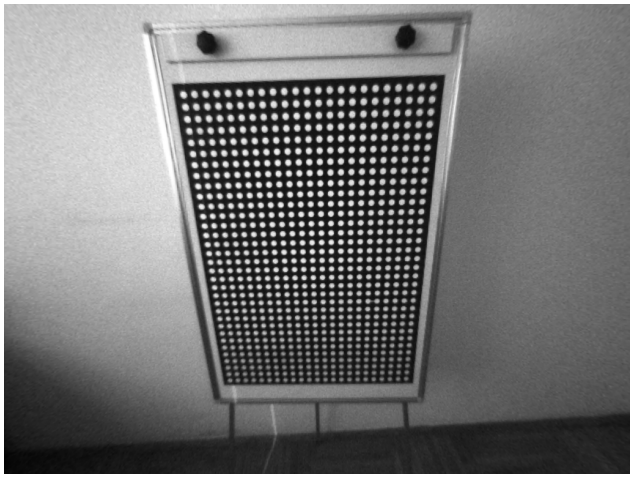
Strukturirano svjetlo u odnosu na binokularni vid

Binokularni vid

lijeva kamera

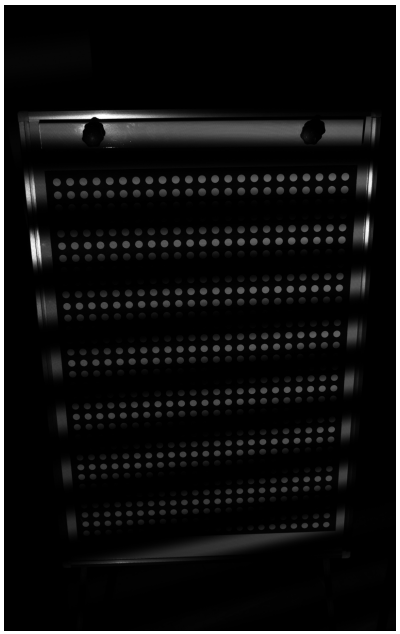


desna kamera

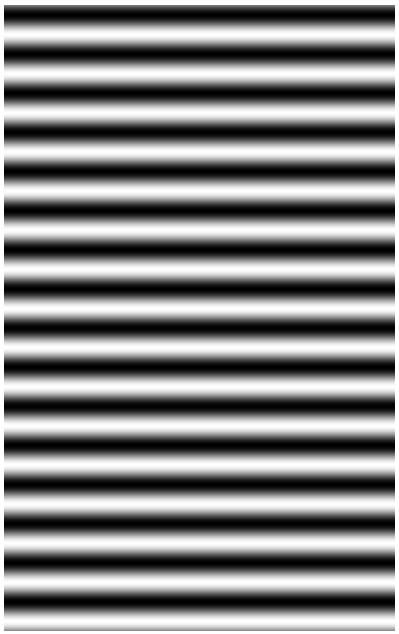


Strukturirano svjetlo

kamera



uzorak (projektor)



Uzorci strukturiranog svjetla

Kod skeniranja površine strukturiranim svjetlom možemo projicirati jedan ili više uzoraka:

1) jednostruki uzorak
   - rekonstrukcija iz jedne slike
   - predmet se smije micati
   - prostorno dekodiranje uzorka
   - rekonsturkcija je rijetka/nisko-rezolucijska

2) višestruki uzorci
   - više slika je projicirano slijedno u vremenu
   - predmet mora biti nepomičan
   - vremensko dekodiranje uzoraka
   - rekonstrukcija je gusta/visoko-rezolucijska

Uzorci strukturiranog svjetla

Kod skeniranja površine strukturiranim svjetlom možemo projicirati jedan ili više uzoraka:

1) jednostruki uzorak
   - rekonstrukcija iz jedne slike
   - predmet se smije micati
   - prostorno dekodiranje uzorka
   - rekonsturkcija je rijetka/nisko-rezolucijska

2) višestruki uzorci
   - više slika je projicirano slijedno u vremenu
   - predmet mora biti nepomičan
   - vremensko dekodiranje uzoraka
   - rekonstrukcija je gusta/visoko-rezolucijska

Uzorci strukturiranog svjetla

Kod skeniranja površine strukturiranim svjetlom možemo projicirati jedan ili više uzoraka:

1) jednostruki uzorak
   - rekonstrukcija iz jedne slike
   - predmet se smije micati
   - prostorno dekodiranje uzorka
   - rekonsturkcija je rijetka/nisko-rezolucijska

2) višestruki uzorci
   - više slika je projicirano slijedno u vremenu
   - predmet mora biti nepomičan
   - vremensko dekodiranje uzoraka
   - rekonstrukcija je gusta/visoko-rezolucijska

Uzorci strukturiranog svjetla

Kod skeniranja površine strukturiranim svjetlom možemo projicirati jedan ili više uzoraka:

1) jednostruki uzorak
   - rekonstrukcija iz jedne slike
   - predmet se smije micati
   - prostorno dekodiranje uzorka
   - rekonsturkcija je rijetka/nisko-rezolucijska

2) višestruki uzorci
   - više slika je projicirano slijedno u vremenu
   - predmet mora biti nepomičan
   - vremensko dekodiranje uzoraka
   - rekonstrukcija je gusta/visoko-rezolucijska

Uzorci strukturiranog svjetla

Kod skeniranja površine strukturiranim svjetlom možemo projicirati jedan ili više uzoraka:

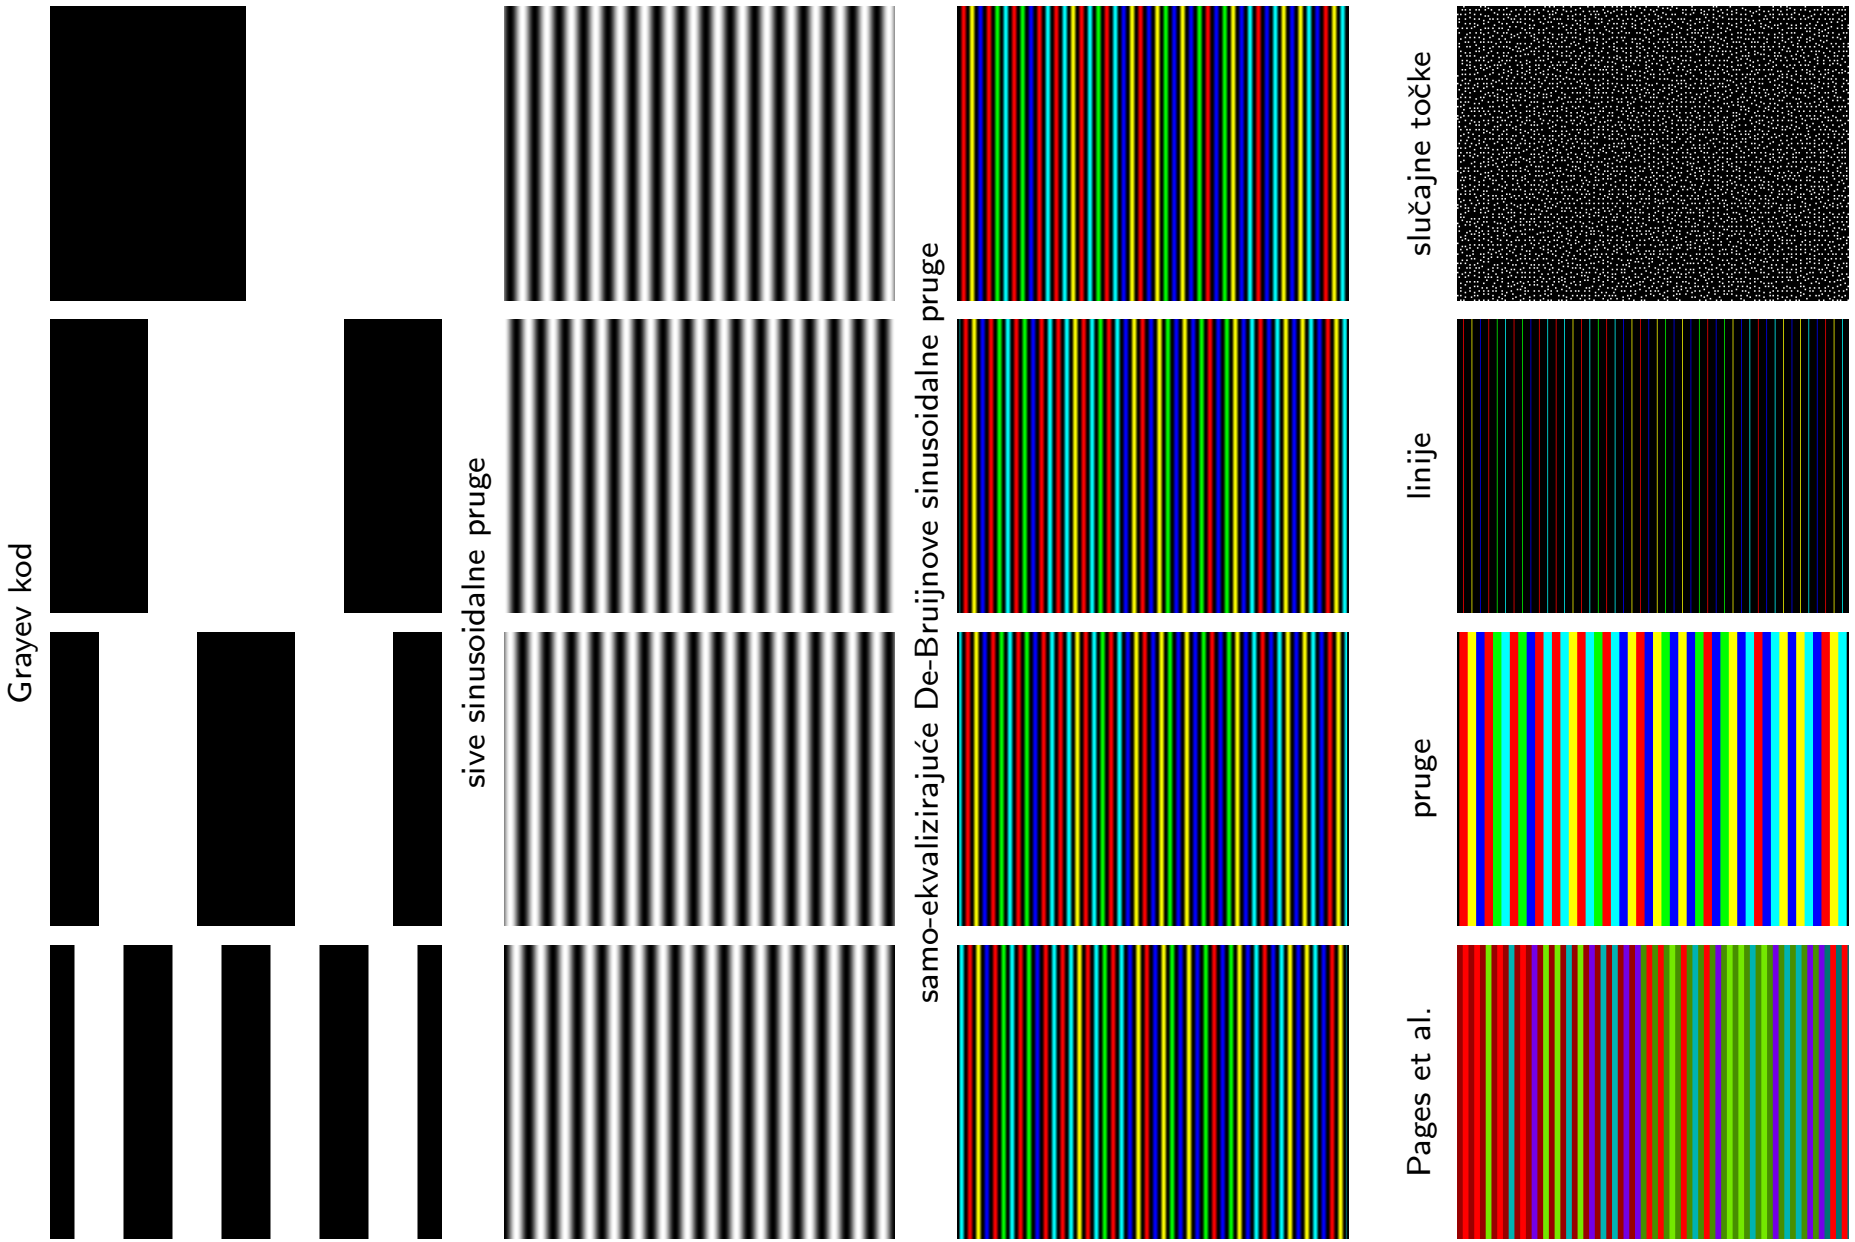
1) jednostruki uzorak
   - rekonstrukcija iz jedne slike
   - predmet se smije micati
   - prostorno dekodiranje uzorka
   - rekonsturkcija je rijetka/nisko-rezolucijska

2) višestruki uzorci
   - više slika je projicirano slijedno u vremenu
   - predmet mora biti nepomičan
   - vremensko dekodiranje uzoraka
   - rekonstrukcija je gusta/visoko-rezolucijska

Primjeri uzoraka strukturiranog svjetla

Višestruki uzorci

Jednostruki uzorci



Sadržaj

Uvod
- 3D skeniranje površine
- Binokularni vid
- Strukturirano svjetlo

Profilometrija projiciranjem pruga
- Sinusoidalne pruga
- Važnost faze
- Odmatanje faze
- Mali rječnik pojmova

Profilometrija projiciranjem pruga i korištenjem boje
- Korištenje boje
- De Bruijnov niz
- Koraci obrade
- Zaključak

Sinusoidalne pruga

Najčešće korišteni uzorak sivih sinusoidalnih pruga je

$$I_p(x, y) = I_0\big(1 - \cos(2\pi x/\lambda + \varphi_n)\big)/2, \tag{1}$$

gdje su (x, y) koordinate projektora u pikselima, I_0 je najveći intenzitet uzorka, λ je valna duljina pruge (u px), i φ_n je fazni pomak.

Za jednostruki uzorak se koristi samo jedna slika ($\varphi_n = 0$).

Za višestruki uzorak koristi se zbir od N slika ($0 \leq n < N$). Svaka slika ima drugačiji fazni pomak φ_n.



$n = 0,\ \varphi_n = 0$



$n = 1,\ \varphi_n = \frac{\pi}{2}$



$n = 2,\ \varphi_n = \pi$



$n = 3,\ \varphi_n = 3\pi/2$

Važnost faze

Višestruki uzorak sivih sinusoidalnih pruga jest:

$$I_{p,\text{stupac}}(x,y) = I_0\big(1-\cos(2\pi x/\lambda_{\text{stupac}}+\varphi_n)\big)/2, \quad 0 \le n < N$$
$$I_{p,\text{redak}}(x,y) = I_0\big(1-\cos(2\pi y/\lambda_{\text{redak}}+\varphi_m)\big)/2, \quad 0 \le m < M$$

Stupac x i redak y projektora su enkodirani u fazi.

Enkodiranje koordinata projektra u fazi nam daje nekoliko važnih prednosti:

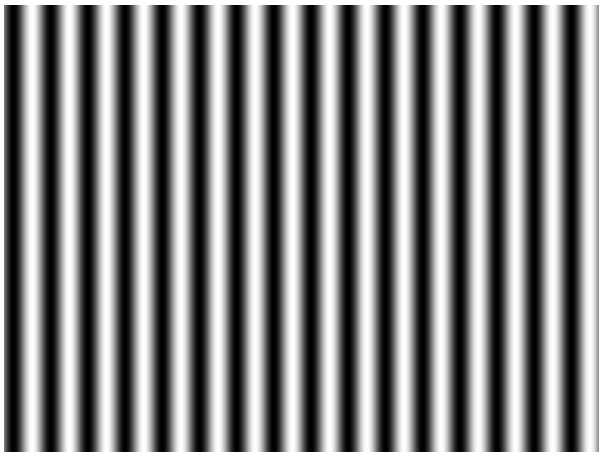
1. neosjetljivost na ambijentalno svjetlo;
2. neosjetljivost na albedo (boju); i
3. neosjetljivost na zamućenje/defokusiranje.

Određivanje faze

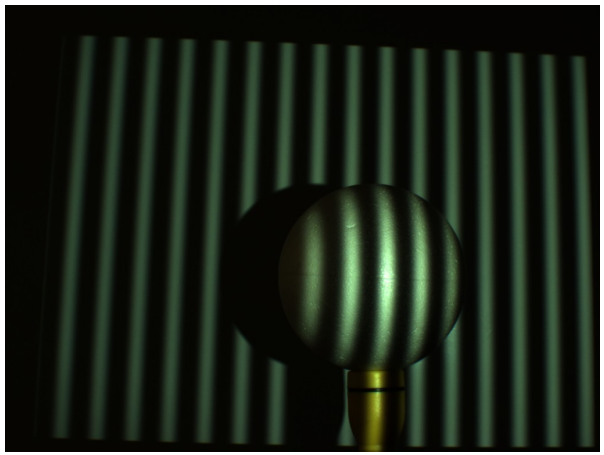
Fazu određujemo:

1. za višestruke uzorke korištenjem vremenske analize:
   - 1.1 algoritam u tri koraka (poseban slučaj za $N = 3$);
   - 1.2 postupak najmanjih kvadrata;
   - 1.3 Schwider-Hariharanov algoritam (otežani najmanji kvadrati);
2. za jednostruke uzorke korištenjem prostorne analize:
   - 2.1 metode u prostornoj domeni;
   - 2.2 metode u domeni transformacije.

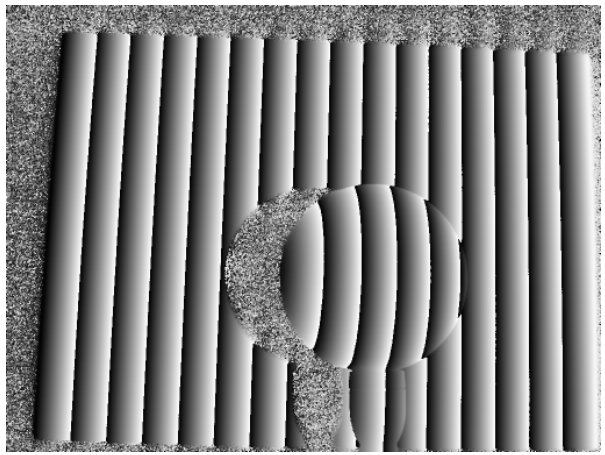
Primjer određivanja faze



projicirani I_p za $n = 0$



snimljeni I_p za $n = 0$



određena faza

Odmatanje faze

Fazu možemo odrediti samo modulo-2π.

Formalno, neka je Φ prava vrijednost faze te neka je ϕ faza izmjerena modulo-2π; tada

$$\Phi = \phi + 2\pi k, \tag{2}$$

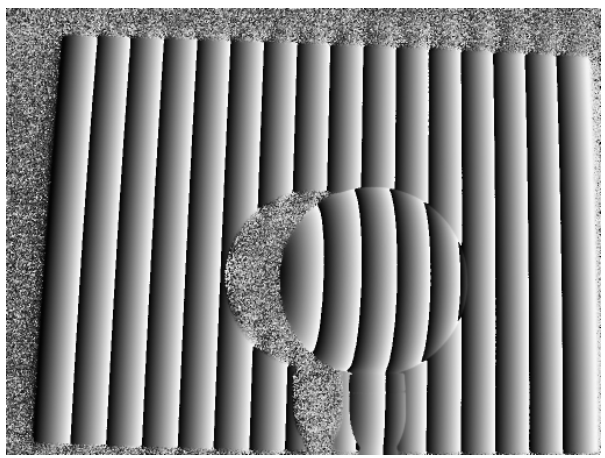
gdje je Φ prava ili apsolutna faza, gdje je ϕ zamotana ili glavna faza, i gdje je $k \in \mathbb{Z}$ nepoznati cijeli broj koji modelira neodređenost faze te kojeg ponekad nazivamo rednim brojem perioda ili rednim brojem pruge.

Zadaća odmatanja faze jest odmotati zamotanu fazu ϕ i odrediti pravu fazu Φ.

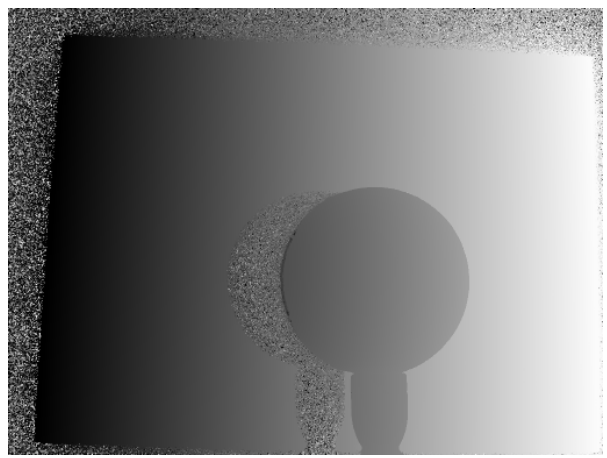
Odmatanje faze

Pristupi problemu odmatanja faze mogu se podijeliti u dvije odvojene skupine:

1. prostorno odmatanje faze (za jednostruke uzorke),
2. vremensko odmatanje faze (za višestruke uzorke).

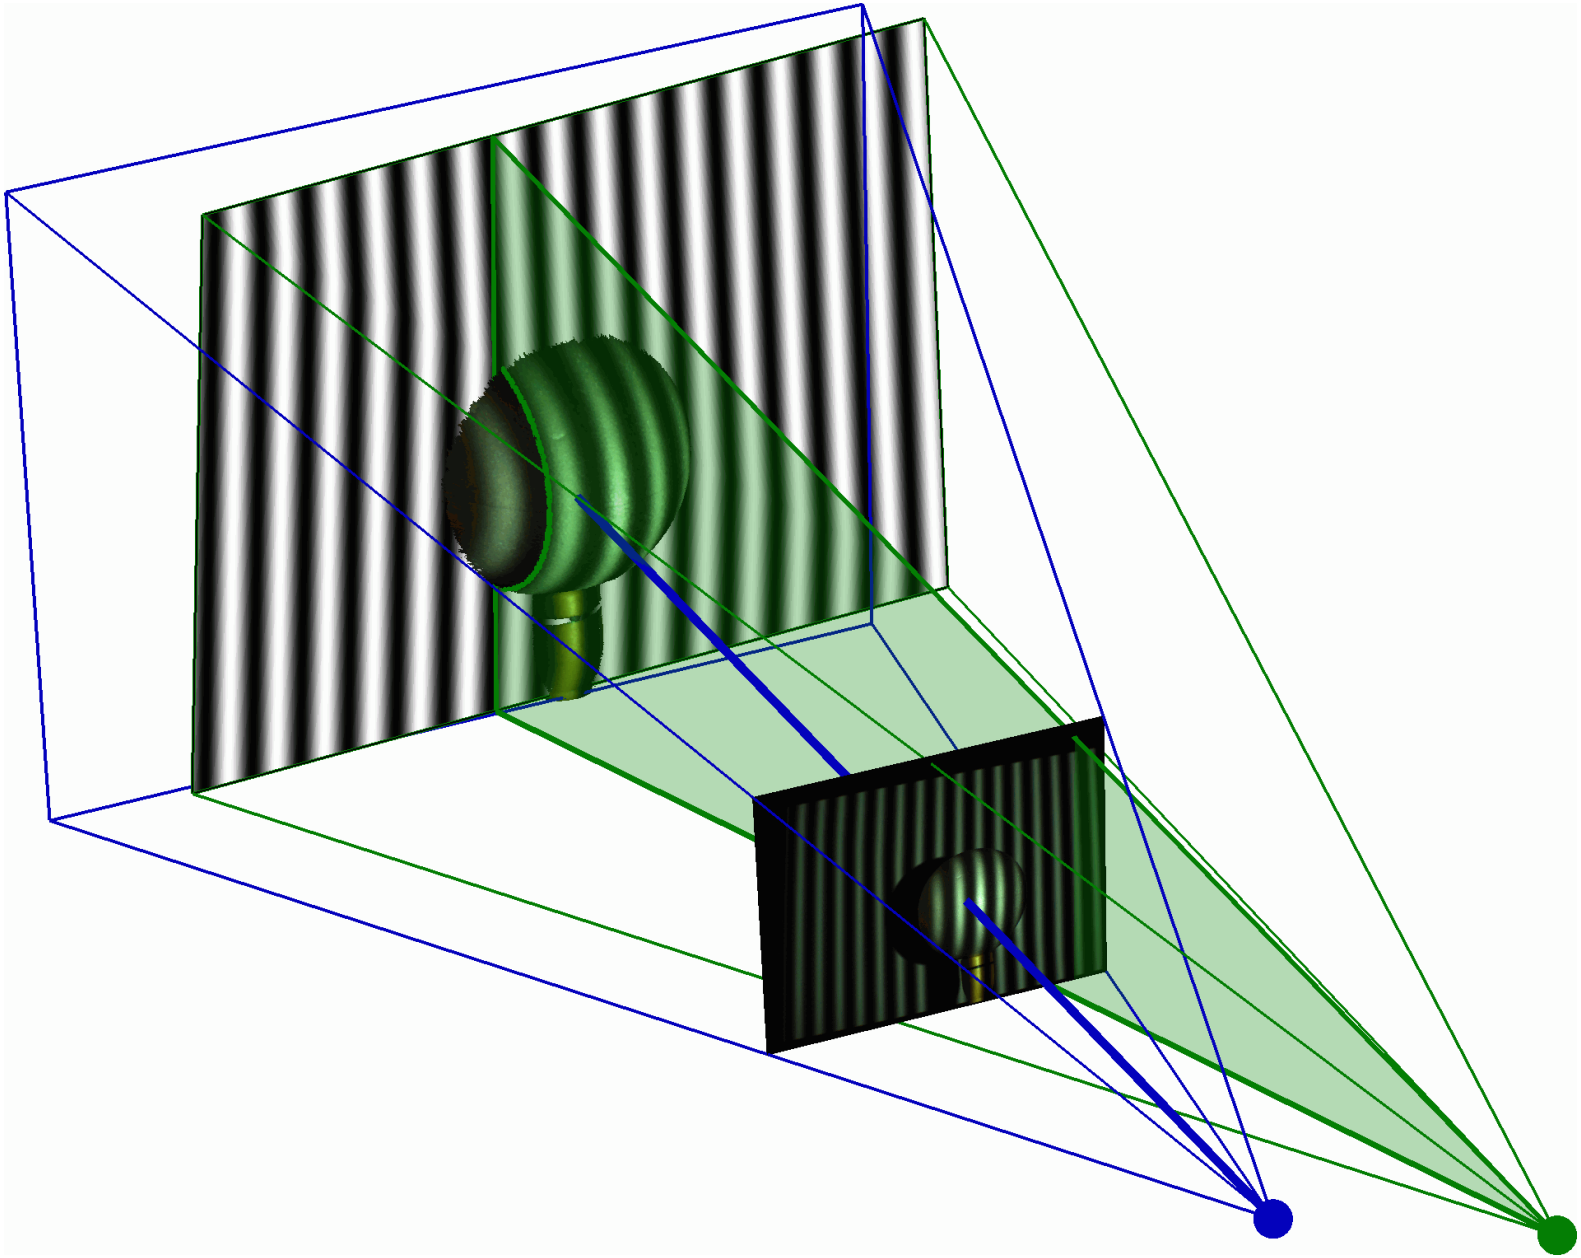


zamotana faza ϕ



odmotana faza Φ

Triangulacija



Mali hrvatsko-engleski rječnik pojmova

Engleski	Hrvatski
3D surface scanning	3D skeniranje površine
3D imaging	3D oslikavanje
structured light	strukturirano svjetlo
structured light pattern	uzorak strukturiranog svjetla
stero vision	binokularni vid (ili stereo vid)
one-shot pattern	jednostruki uzorak
multi-shot pattern	višestruki uzorak
profilometry	profilometrija
fringe projection profilometry	profilometrija projekcijom pruga
sinusoidal fringe	sinusoidalna pruga
phase unwrapping	odmatanje faze
wrapped phase	zamotana faza
principal phase	glavna faza
unwrapped phase	odmotana faza
absolute phase	apsolutna faza
period-order number	redni broj perioda
fringe-order number	redni broj pruge

Sadržaj

Uvod
- 3D skeniranje površine
- Binokularni vid
- Strukturirano svjetlo

Profilometrija projiciranjem pruga
- Sinusoidalne pruga
- Važnost faze
- Odmatanje faze
- Mali rječnik pojmova

Profilometrija projiciranjem pruga i korištenjem boje
- Korištenje boje
- De Bruijnov niz
- Koraci obrade
- Zaključak

Ostatak ove prezentacije opisuje rad objavljen u časopisu IEEE Transactions on Image Processing, svezak 25, broj 11 iz studenoga 2016.: doi:10.1109/TIP.2016.2603231:



Single-Shot Dense 3D Reconstruction Using Self-Equalizing De Bruijn Sequence

T. Petković, *Member, IEEE*, T. Pribanić, *Member, IEEE*, and M. Đonlić, *Student Member, IEEE*

***Abstract*—Single-shot dense 3D reconstruction using colored structured light is a difficult problem due to the undesired effects of ambient lighting, object albedo, non-equal channel gains, and channel cross-talk. We propose a novel single-shot dense 3D reconstruction using colored structured light. Our method combines the self-equalizing De Bruijn sequence, scale-space analysis, and bandpass complex Hilbert filters to achieve insensitivity to ambient lighting, object albedo, and non-equal channel gains. The proposed method reconstructs about 85% of points compared to time-multiplexing structured light strategies and the decoding error in the recovered projector coordinate is less than one projector pixel for about 90% of reconstructed points.**

***Index Terms*—3D scanning, structured light, phase estimation, De Bruijn sequence, Hilbert transform filter.**

I. Introduction

THE three-dimensional surface profile of an object may be measured using various non-invasive optical techniques [1] including structured light. Structured light (SL) utilizes a projector to actively illuminate an object of interest using a designed pattern. The surface profile of an object is then recovered by examining the deformation of the projected pattern. There are two major classes of patterns used in SL: *single-shot* patterns that enable reconstruction from a single image and *multi-shot* patterns that require more than one image. Multi-shot patterns require the object to be stationary and are mostly used when an accurate high-resolution surface profile is needed, for example in industrial quality control. Single-shot patterns are of particular interest as they enable 3D reconstructions of moving objects making them applicable in various fields such as body structure analysis, biometrics, and human-computer interaction, to name but a few. Among single-shot patterns of particular interest are those using *color* as the majority of available projectors and cameras use color. Such a pattern would enable construction of simple 3D scanners comprised of ubiquitous low-cost components: a projector, a camera, and a personal computer.

The largest group of single-shot SL methods using color extends the well-known grayscale sinusoidal fringe patterns [2]. We divide these depending on the approach to color processing: (1) available color channels are analyzed in a device colorspace (e.g. RGB); and (2) available color channels are analyzed in a perceptual colorspace (e.g. HSV). In the first approach fringes having different phases and/or frequencies are embedded in each of device color channels: Wust and Capson [3] project same-frequency fringes shifted in phase and use classical three-step decoding; and Zhang et al. [4] project multi-frequency fringes and extract both 3D surface and rough texture as a mixture of object albedo and ambient lighting. In the second approach most often a sinusoidal fringe is placed in the value channel and fringes are colored to enable absolute pattern decoding: Chen et al. [5] color the fringes by changing color exactly at the maximum of each fringe thus making each fringe two-colored; Fernandez and Salvi [6] color the fringes by changing color exactly at the minima between fringes thus making each fringe single-colored; and Su [7] colors several adjacent stripes using the same color and changes their maximum intensity to enable absolute decoding. In addition, we mention grid patterns pioneered by Salvi et al. [8] and extended by Sagawa et al. [9], which provide additional robustness compared to sinusoidal fringes as both projector coordinates are encoded. However, dense reconstruction using grid patterns requires interpolation as information about surface changes between projected grid lines is lost. For complete codification of single-shot SL patterns using color, including M-arry codes and frequency multiplexing, we refer the reader to a review by Salvi et al. [10].

Major problems when using color in SL are: ambient lighting, object albedo, non-equal color channel gains, and cross-talk between color channels. The color imaging model of Caspi et al. [11] is sufficient to capture and mitigate all of the aforementioned effects; however, for the model to be applicable all of its parameters must be known. This is difficult in practice as only some parameters are determined by the projector and camera, while the remaining crucial parameters depend on object albedo and ambient lighting. Most of the aforementioned works require a color calibration to get all parameters of the model. Specifically, to obtain the parameters describing object albedo and ambient lighting, partial color calibration must be performed prior to every imaging to achieve robustness; this fact severely limits the practical applicability of the mentioned SL methods. There are approaches that try to avoid this by inferring the missing model parameters from the data under the assumption of a constant object albedo [12], [13]. However, such an assumption is severely limiting in practice. Once the parameters of the color imaging model are known the color is most often decoded

Manuscript received March 8, 2016; revised June 21, 2016; accepted July 31, 2016. Date of publication August 26, 2016; date of current version September 13, 2016. This work was supported by the Croatian Science Foundation under Project IP-11-2013-3717. The associate editor coordinating the review of this manuscript and approving it for publication was Prof. Jing-Ming Guo.

The authors are with the Faculty of Electrical Engineering and Computing, University of Zagreb, Zagreb 10000, Croatia (e-mail: tomislav.petkovic.jr@fer.hr).

Color versions of one or more of the figures in this paper are available online at http://ieeexplore.ieee.org.

Digital Object Identifier 10.1109/TIP.2016.2603231

1057-7149 © 2016 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission.
See http://www.ieee.org/publications_standards/publications/rights/index.html for more information.

T. Petković, T. Pribanić, M. Đonlić

Single-Shot Dense 3D Reconstruction Using Self-Equalizing De Bruijn Sequence

Motivacija

- Strukturirano svjetlo jest robustni postupak 3D profilometrije
- Želimo ostvariti robustno 3D skeniranje korištenjem svepristune potrošačke elektronike
  - projektor i kamera ugrađeni u mobilni uređaj
  - kućni DLP projektor i web kamera
- Gotovo svi takvi uređaju koriste boju

Problem boje

Korištenje obojenog strukturiranog svjetla je teško:

1. projektor mora vjerno reproducirati boju
2. kamera mora precizno snimiti boju
3. predmet ne smije promijeniti boju uzorka
4. cijeli sustav mora biti neosjetljiv na ambijentalno svjetlo

previše zelene



automatsko podešavanje bijele (AWB)



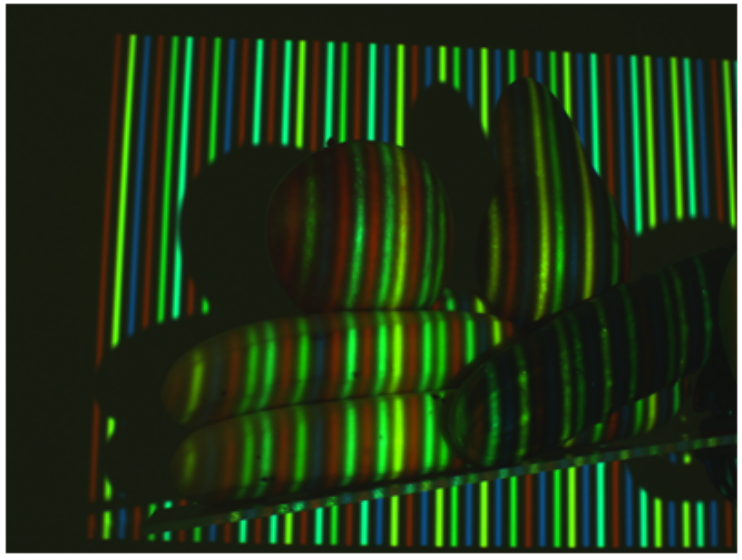
previše plave



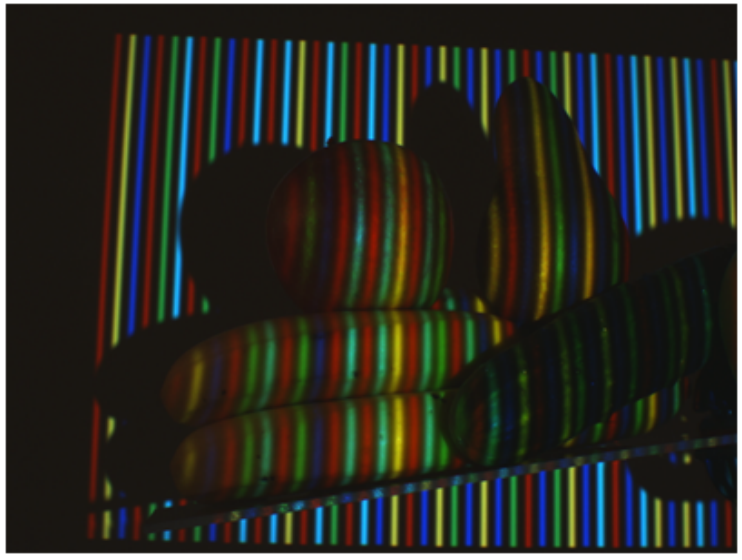
kalibrirano korištenjem SpyderCUBE-a



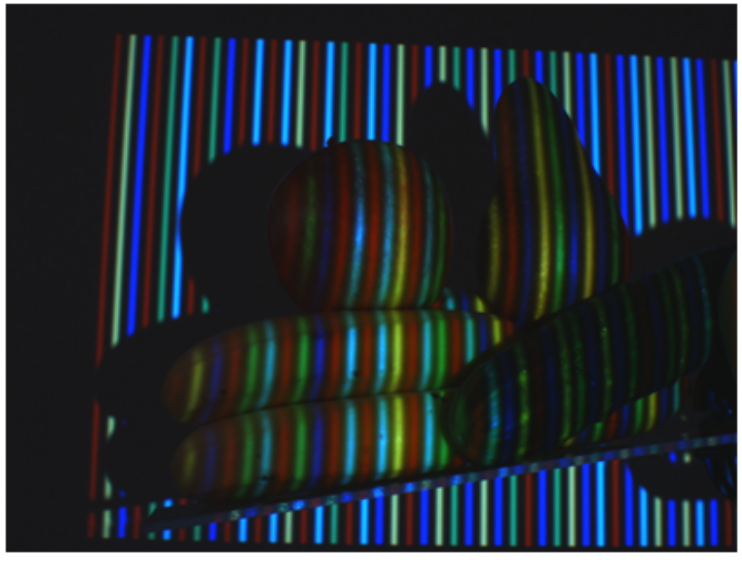
previše zelene



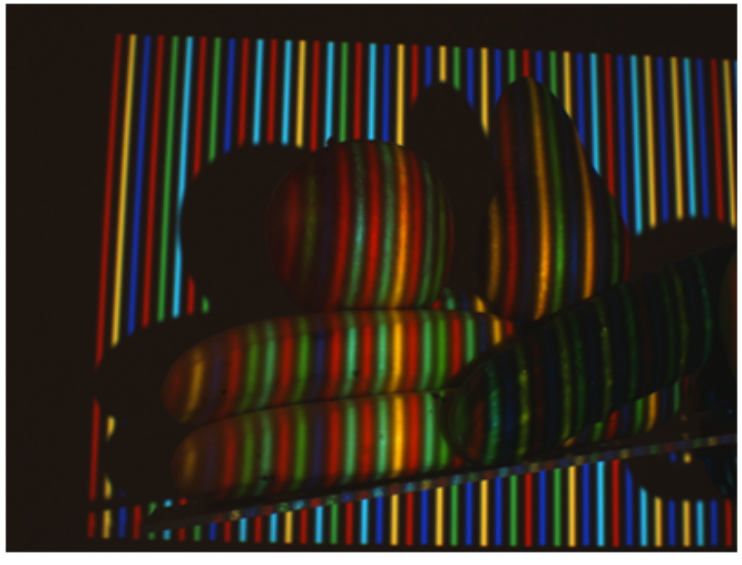
automatsko podešavanje bijele (AWB)



previše plave



kalibrirano korištenjem SpyderCUBE-a



Model boje

Model za RGB prostor boja u strukturiranom svjetlu jest:

$$\underbrace{\begin{bmatrix} R \\ G \\ B \end{bmatrix}}_{I_c} = \underbrace{\begin{bmatrix} a_{RR} & a_{RG} & a_{RB} \\ a_{GR} & a_{GG} & a_{GB} \\ a_{BR} & a_{BG} & a_{BB} \end{bmatrix}}_{A} \underbrace{\begin{bmatrix} k_R & 0 & 0 \\ 0 & k_G & 0 \\ 0 & 0 & k_B \end{bmatrix}}_{K} f\Big(\underbrace{\begin{bmatrix} r \\ g \\ b \end{bmatrix}}_{I_p}\Big) + \underbrace{\begin{bmatrix} R_0 \\ G_0 \\ B_0 \end{bmatrix}}_{I_0}, \quad (3)$$

gdje je I_c boja koju vidi kamera, gdje je I_p kod boje koju šaljemo projektoru, gdje je A prijenosna matrica kanala boja, gdje je K matrica albeda, gdje je f monotona funkcija koja modelira nelinearnost projektora, i gdje je I_0 ambijentalno svjetlo.

Korištenje boje u profilometriji projiciranjem pruga je teško jer svaki predmet i svaka svena ima drugačiji i općenitno nepoznat albedo K.

Rješenje: Konstuirajmo uzorak strukturiranog svjetla I_p na takav način da svi nužni parametri modela (3) mogu biti estimirani iz snimljene slike.

Samo-ekvalizirajući De Bruijnov niz

De Bruijnov niz

k-znamenkasti De Brujinov niz reda n je ciklički niz duljine $L = k^n$ nad abecedom od k simbola u kojem se svaki podniz duljine n, kojeg nazivamo prozor, pojavljuje točno jednom unutar ciklusa.

Samo-ekvalizirajuće ograničenje

Samo-ekvalizirajuće ograničenje zahtijeva da svi kanali boja koriste cjelokupni raspoloživi dinamički opseg unutar svakog De Bruijnovog prozora.

Primjer za niz duljine 42:

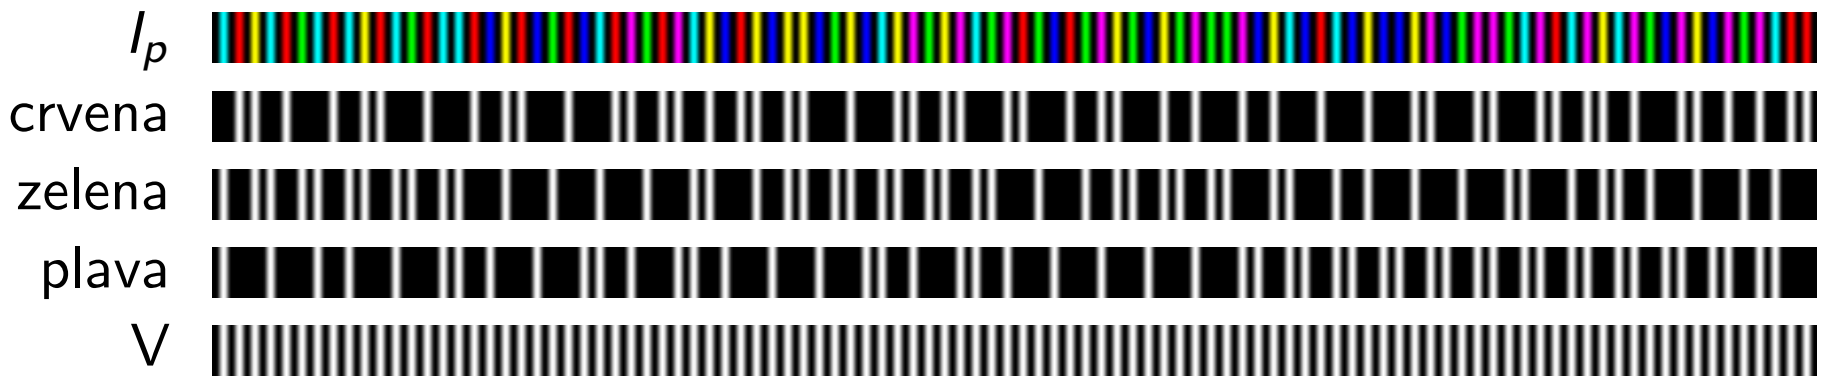
CRMCYRCYBCYMGYMCGMYCBYMBYCMRCMGCMYBMYGMCRY

Uzorak strukturiranog svjetla

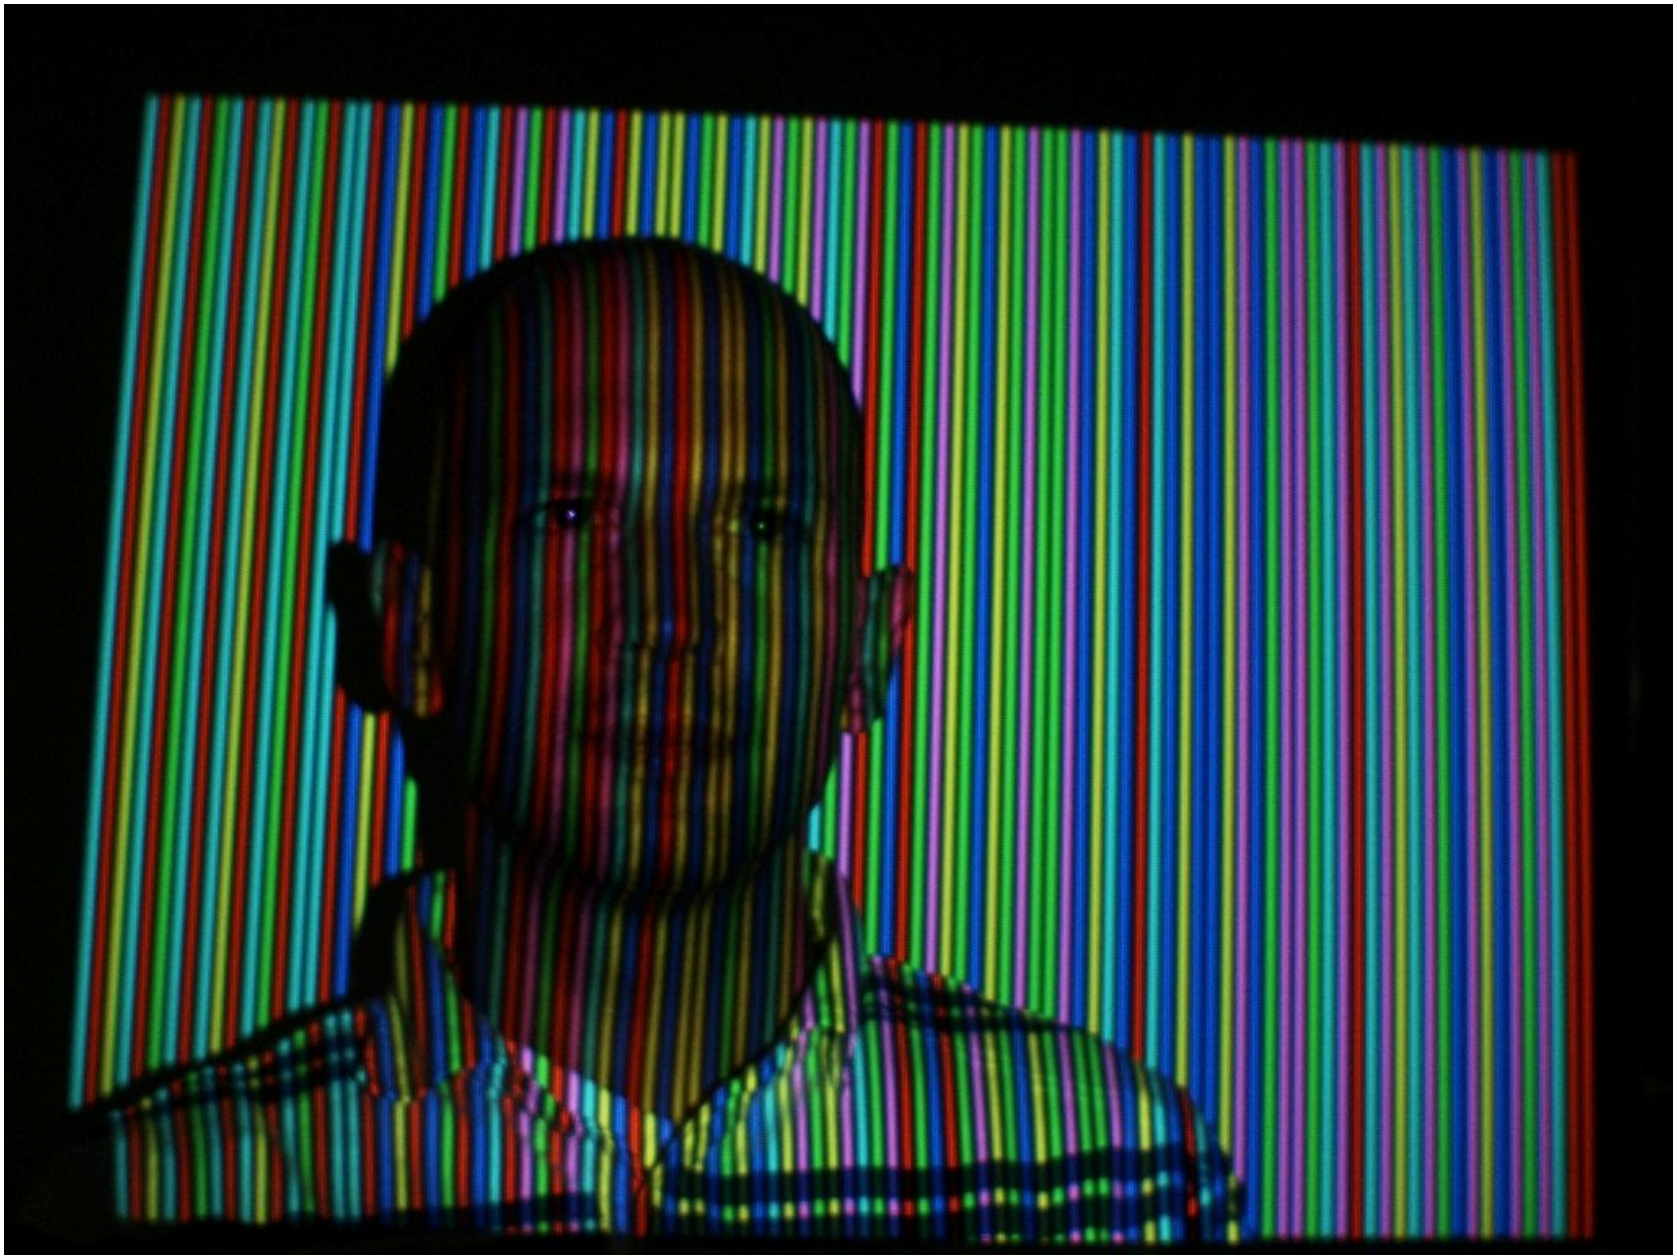
Najveća duljina ternarnog De Brujinovog niza reda $n = 3$ jest $k^n = 6^3 = 216$ članova.

Samo-ekvalizirajuće ograničenje uklanja sve prozore za koje parametri modela boje ne mogu biti određeni što skraćuje duljinu niza na 102 člana:

CRYCRGCRCYRCGRCCRBYRBGRBCRMGRMCYBRYBYYBGYBCYMGYMCG-
MRGBRGMYGBYGMGGMBYCBRCBYBBYMBGMMGCMRCMYCMGBMYBMGMC-
RR



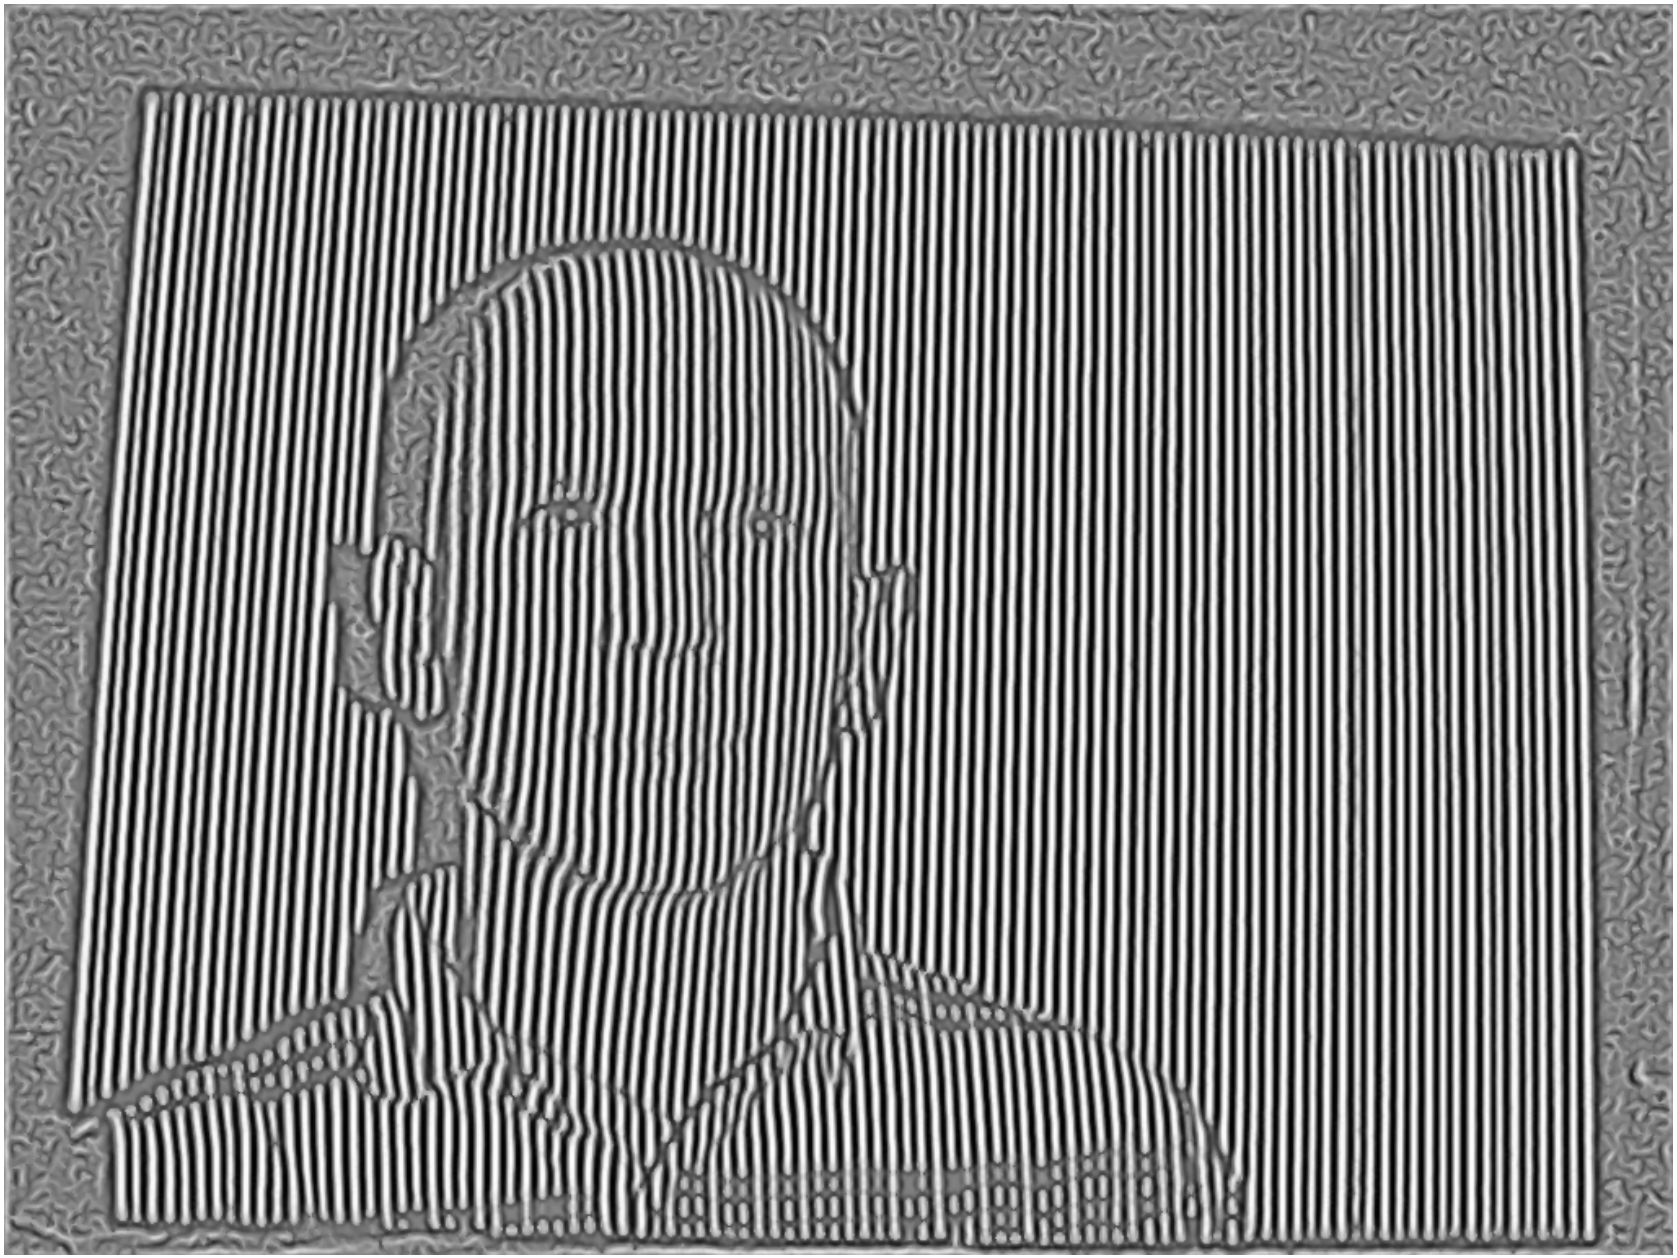
Ulazna slika



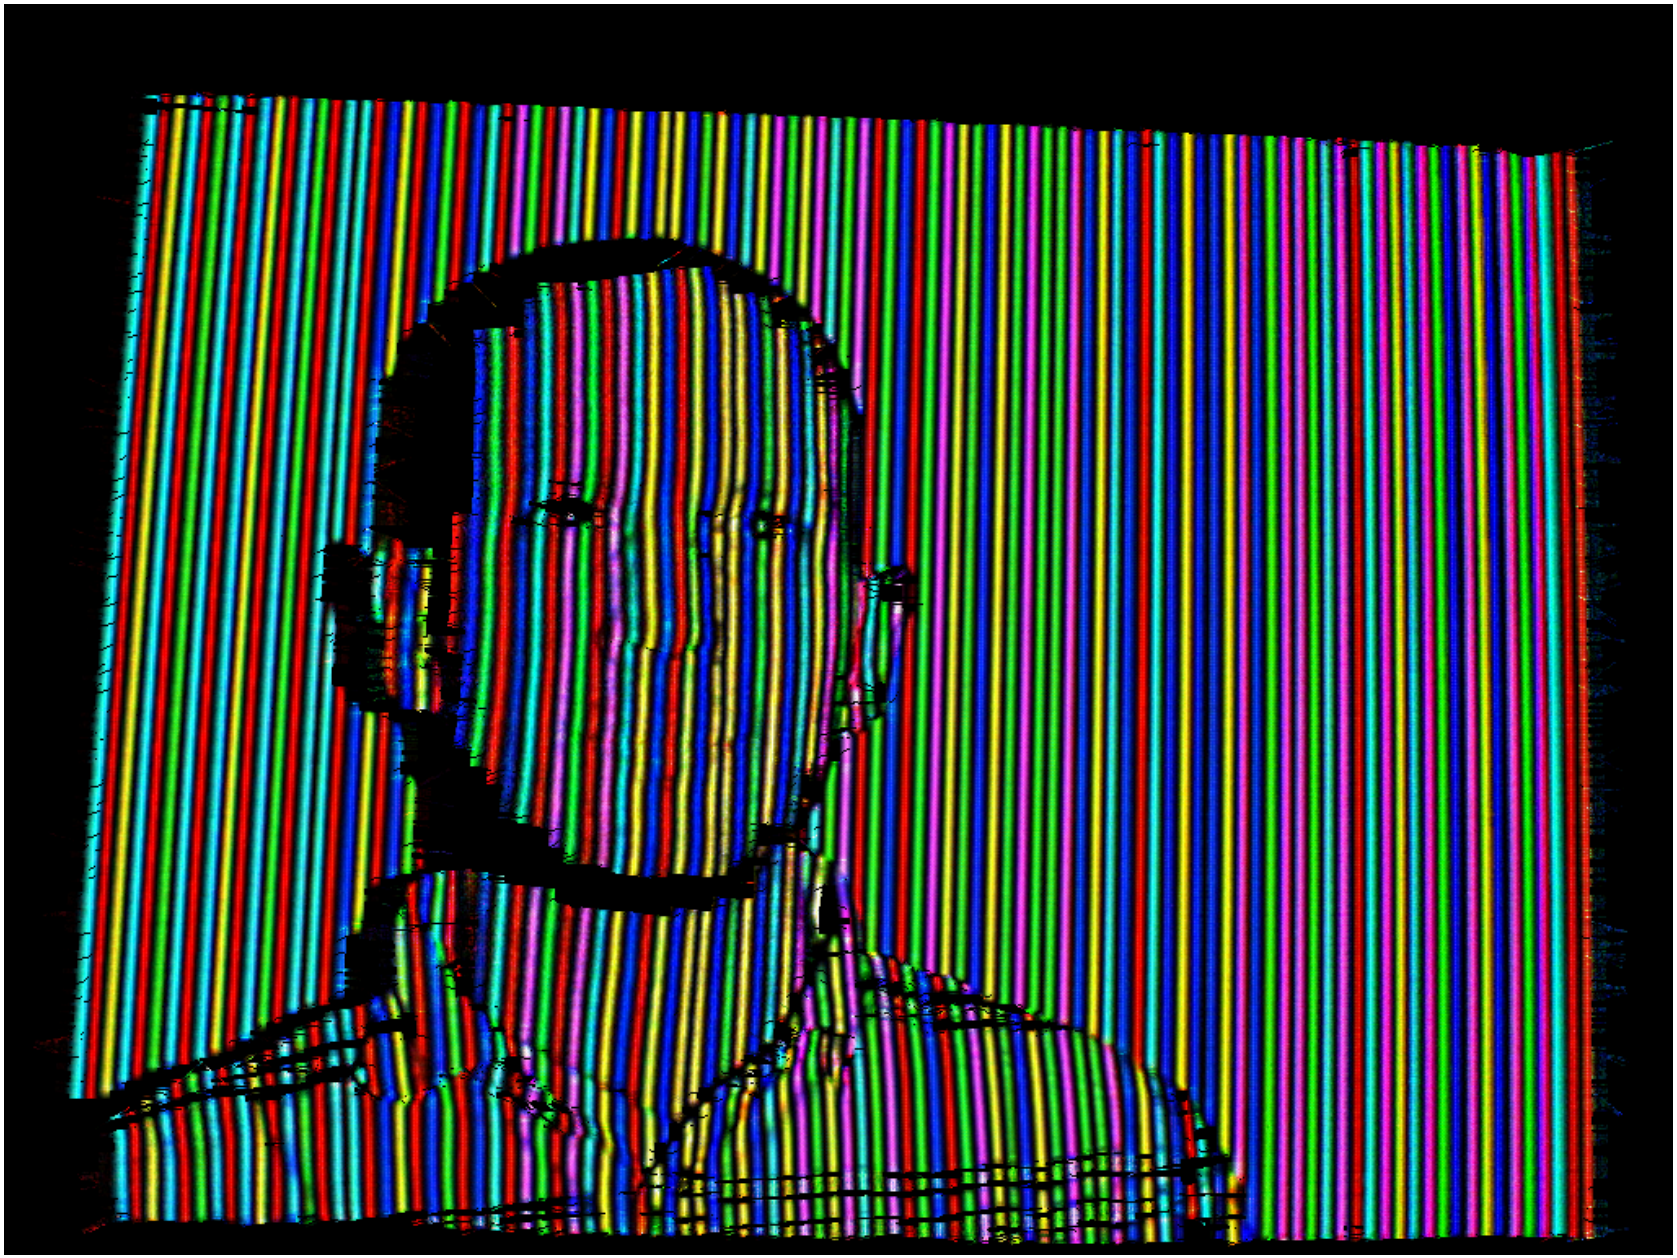
Zbroj svih ulaznih kanala



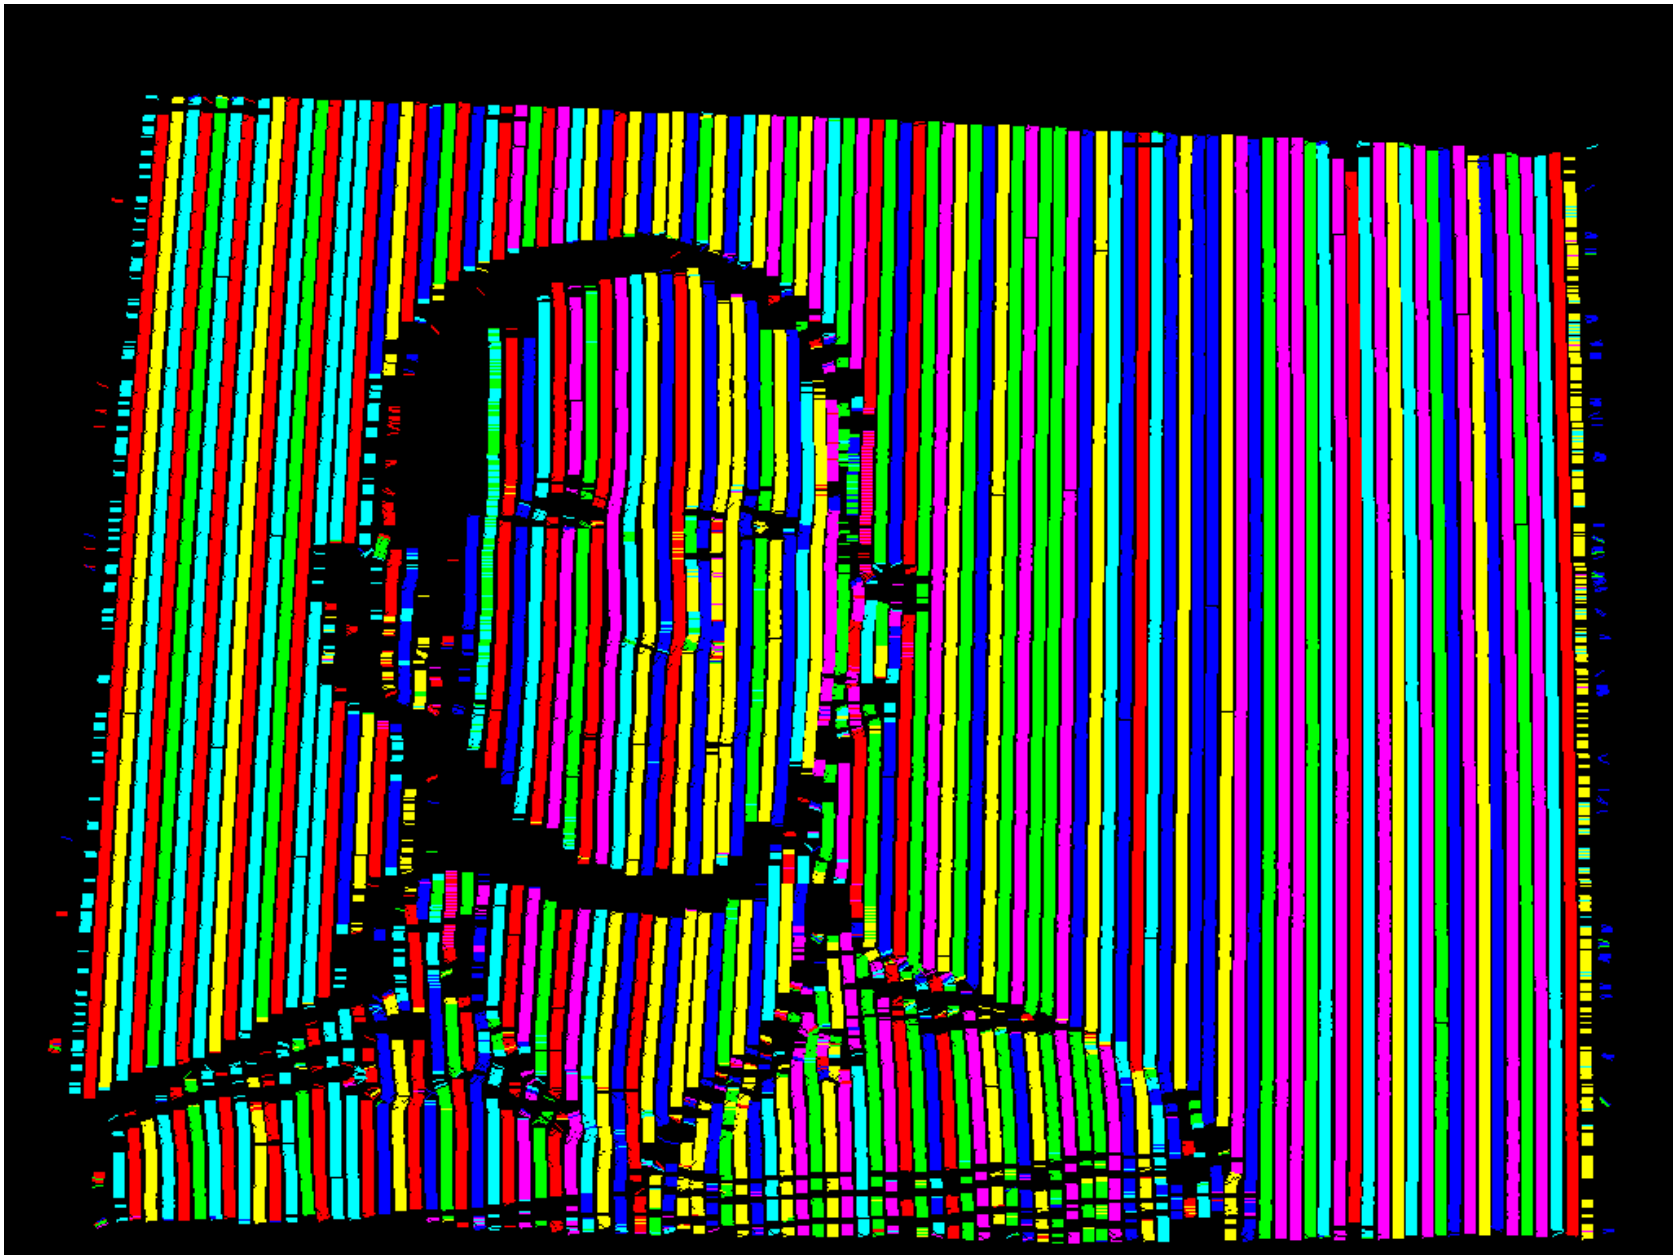
Detekcija pruga



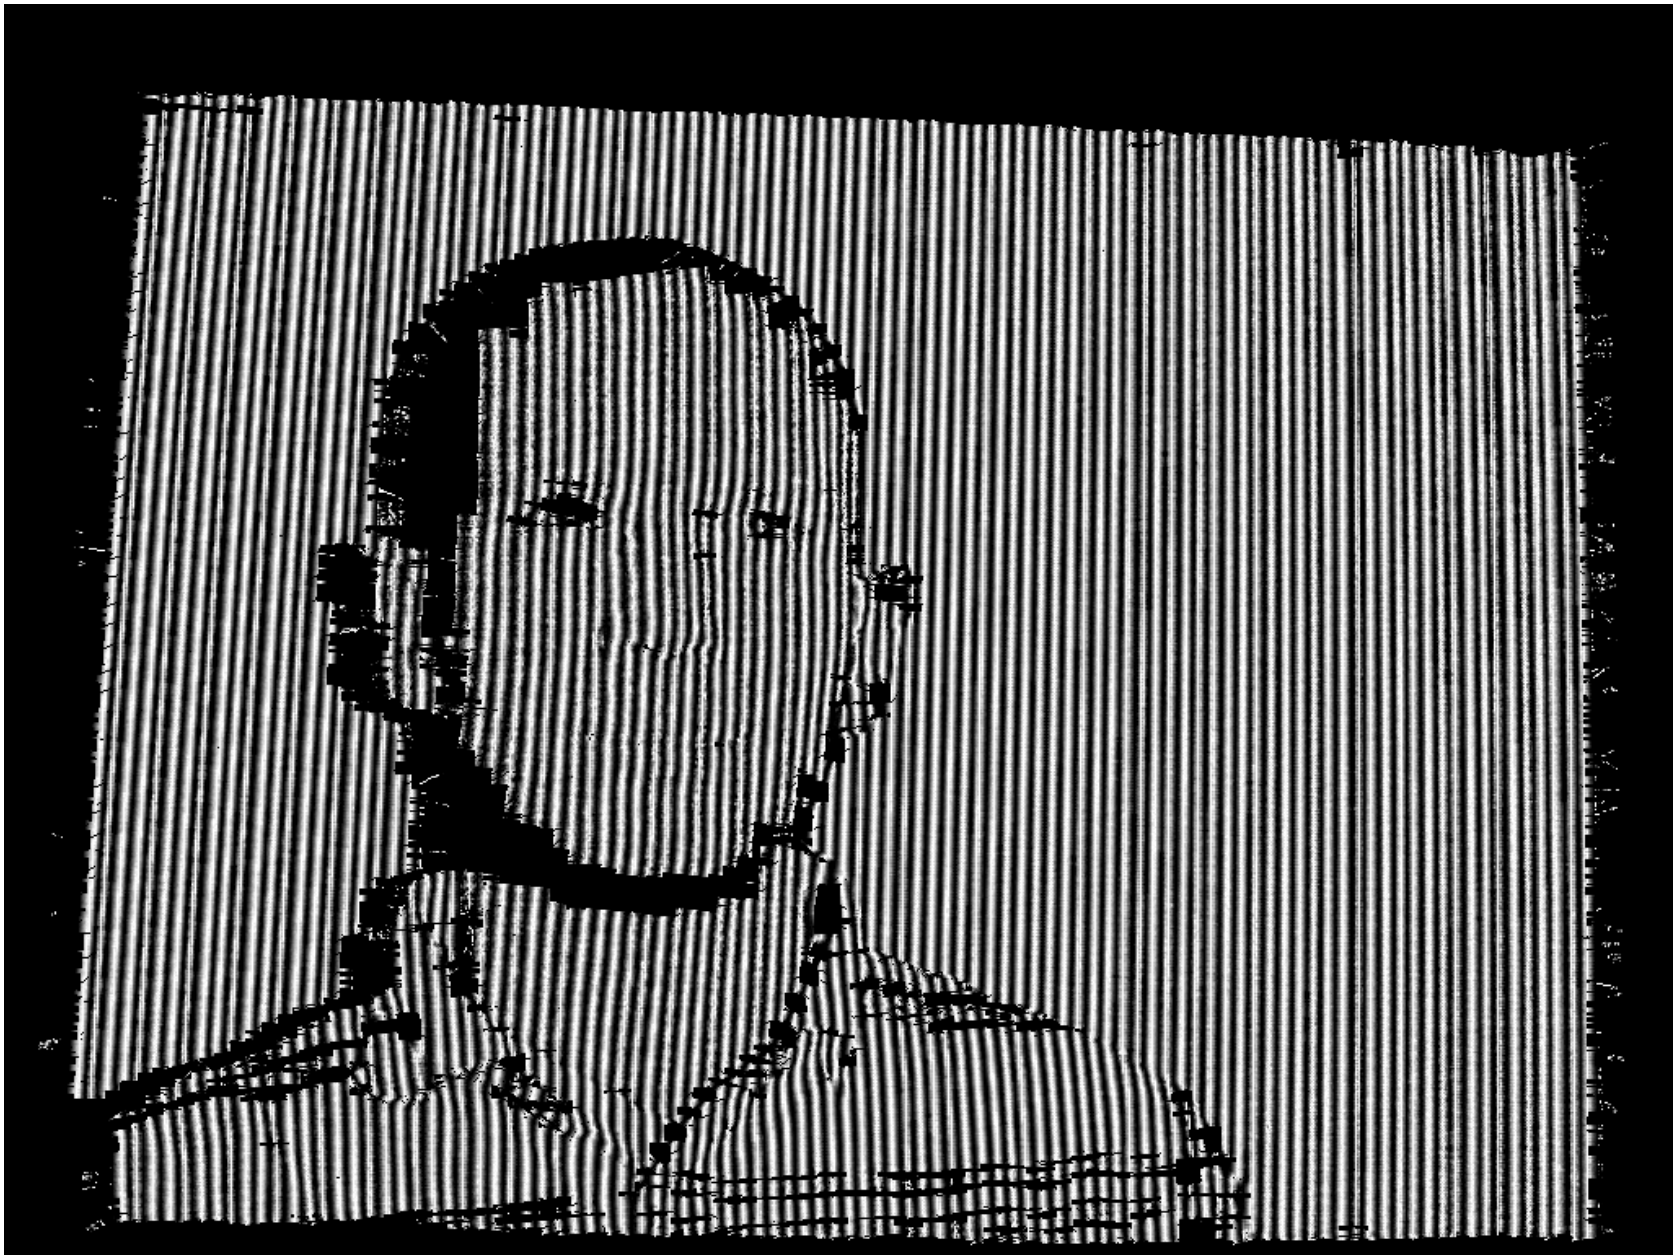
Ekvalizacija boja (uklanjanje vanjskih faktora)



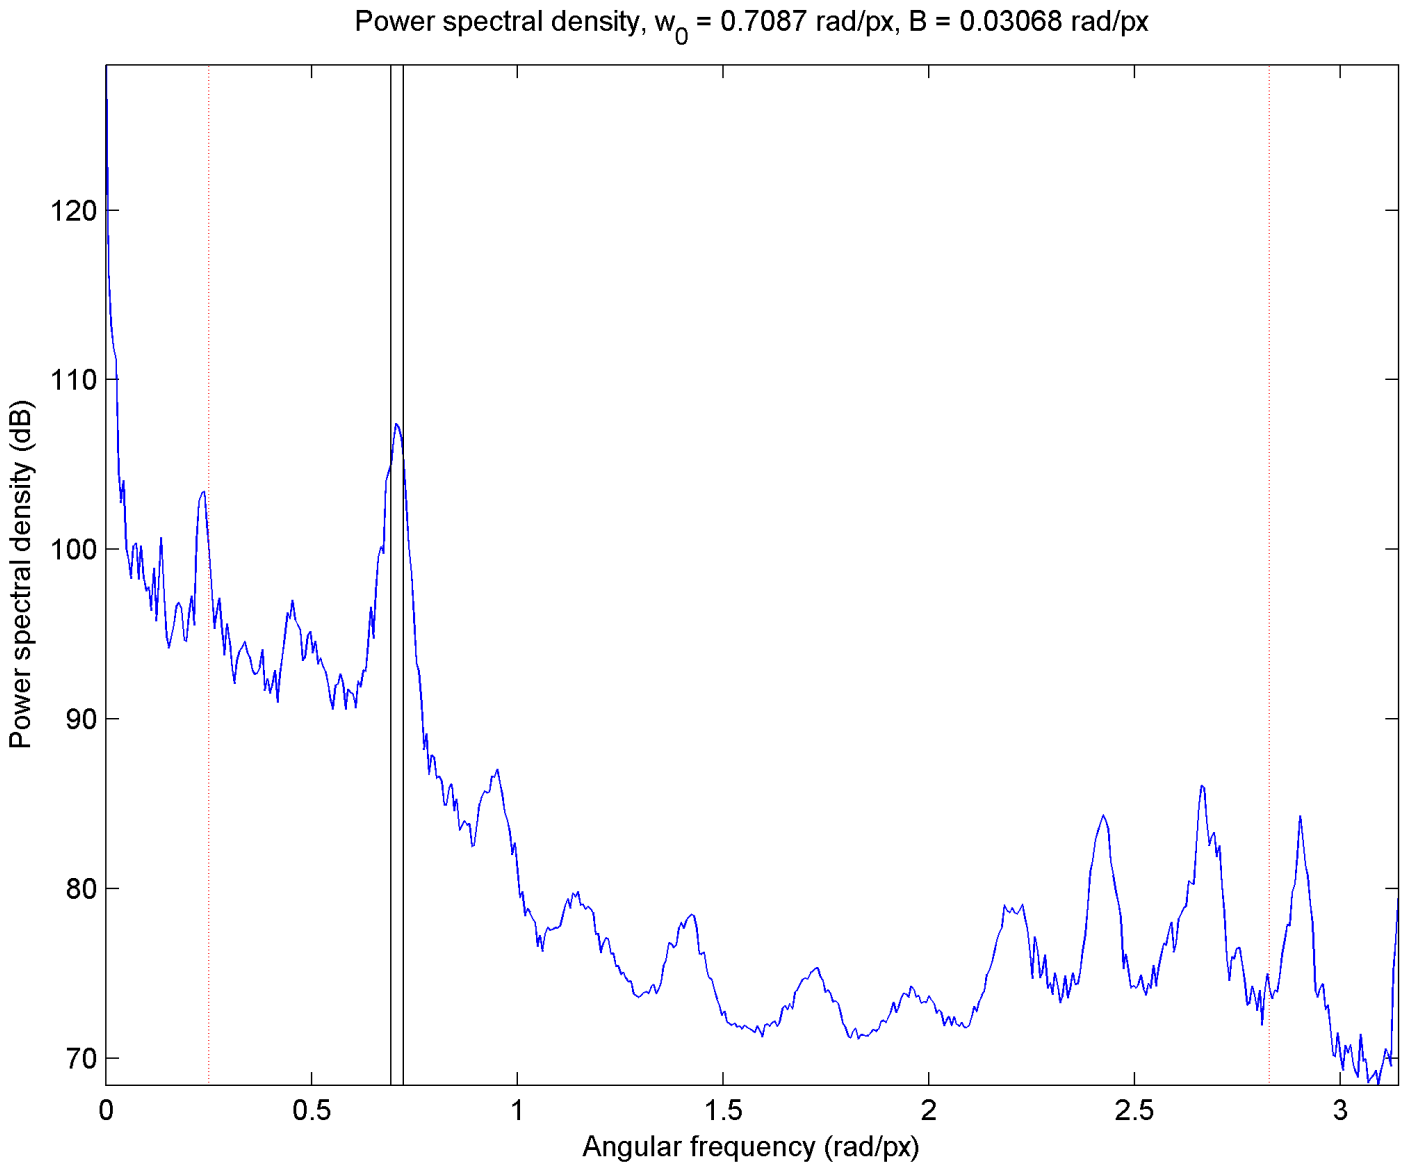
Raspoznata projicirana boja



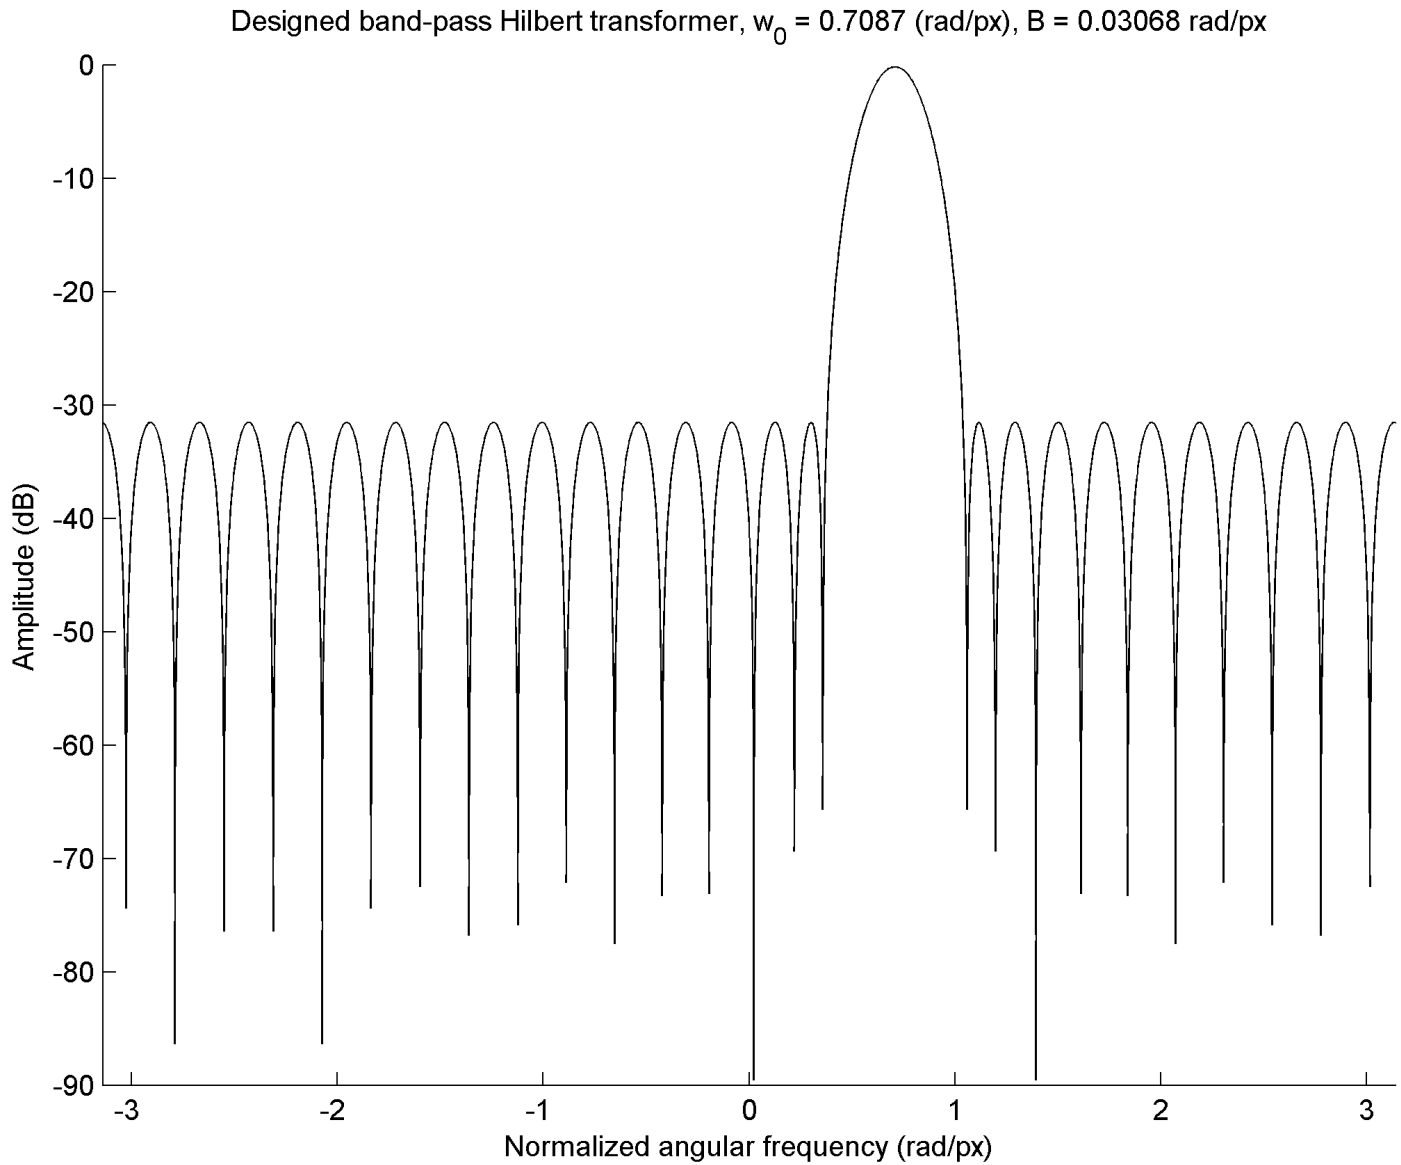
Izdvojen i ekvaliziran V kanal



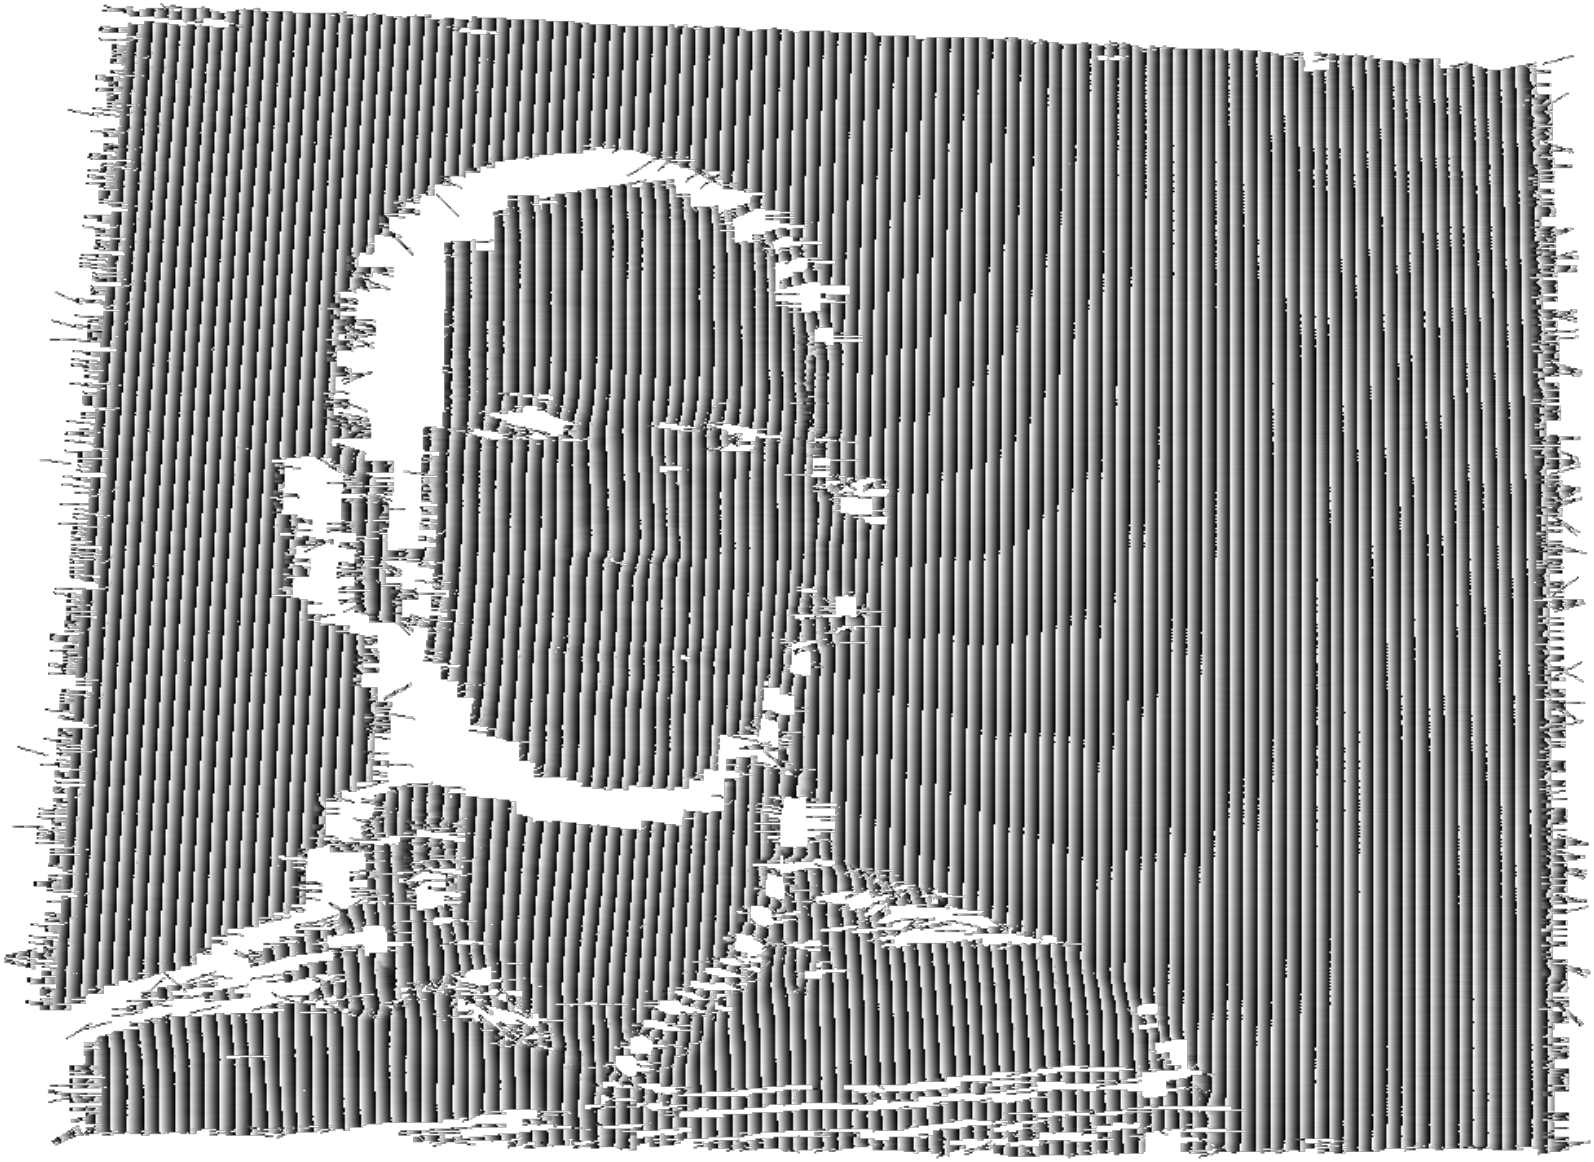
Projektiranje pojasno-propusnog Hilbertovog filtra (I)



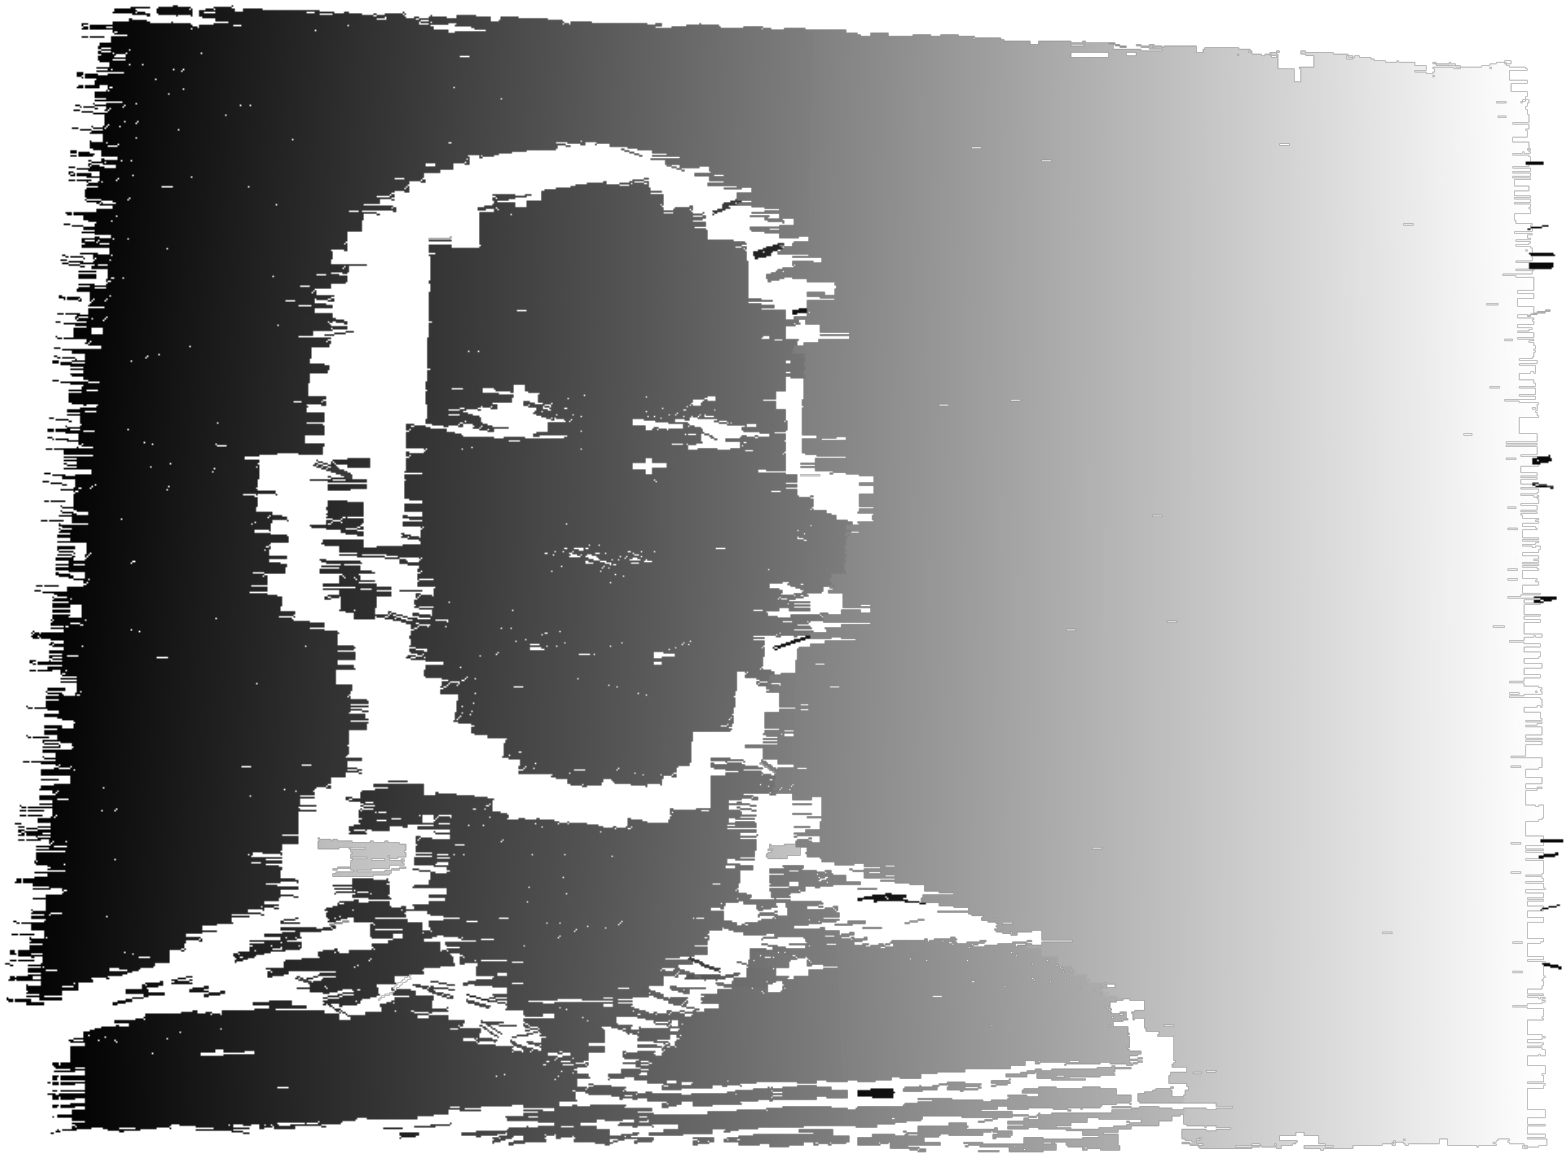
Projektiranje pojasno-propusnog Hilbertovog filtra (II)



Estimirana zamotana faza



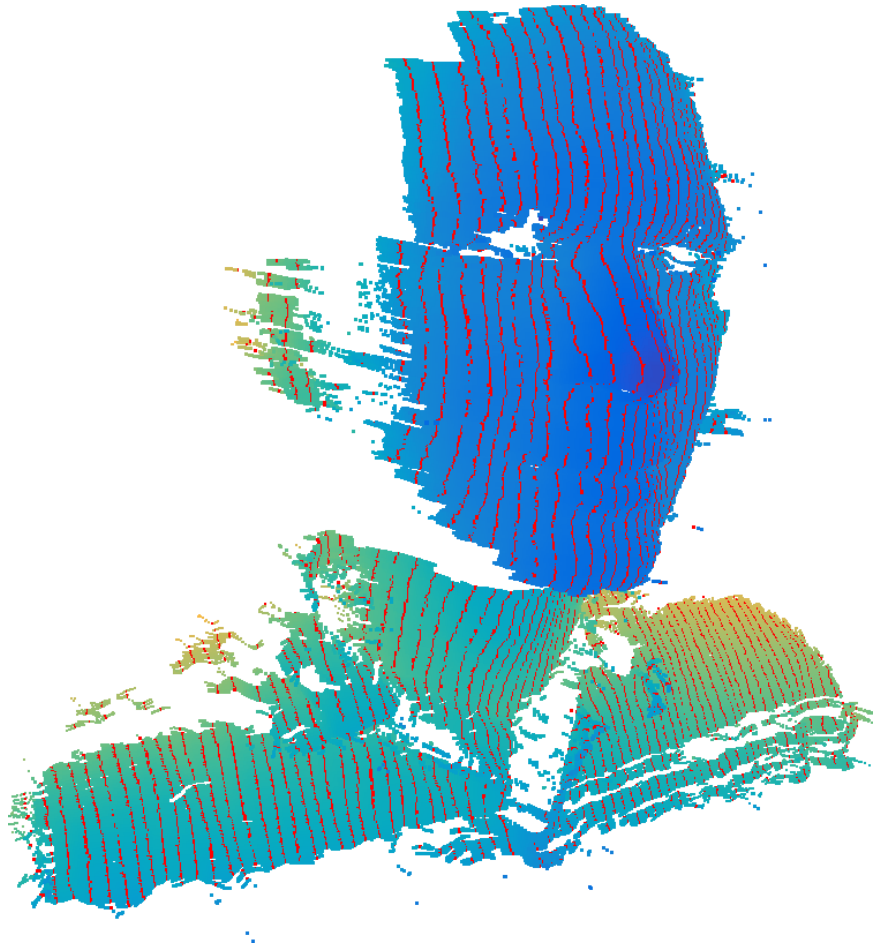
Odmotana faza (korištenjem De Bruijnovog svojstva)



Konačna 3D rekostrukcija (površina)



Usporedba guste i rijetke 3D rekonstrukcije



Zaključak

Samo-ekvalizirajući De Bruijnov niz omogućava:

1. uklanjanje ambijentalnog svjetla,
2. uklanjanje albeda predmeta, i
3. ekvalizaciju pojačanja pojedinih kanala boja.

Pametna kombinacija stanardnih tehnika iz obrade signala (analiza Hessianove matrice na više skala i kompleksni PP Hilbertovi filtri) omogućava nam *vrlo gustu* 3D rekonstrukciju koja daje između 80% i 90% točaka u usporedbi s postupcima koji koriste vremensko multipleksiranje, a pri tome je zadržana izvrsna preciznost jer oko 90% rekonstruiranih točaka ima pogrešku određivanja koordinate projektora manju od 1 px.