Rana detekcija dijabetičke retinopatije na slikama očne pozadine

Pavle Prentašić

Fakultet elektrotehnike i računarstva

pavle.prentasic@fer.hr

12.4.2016

Sadržaj

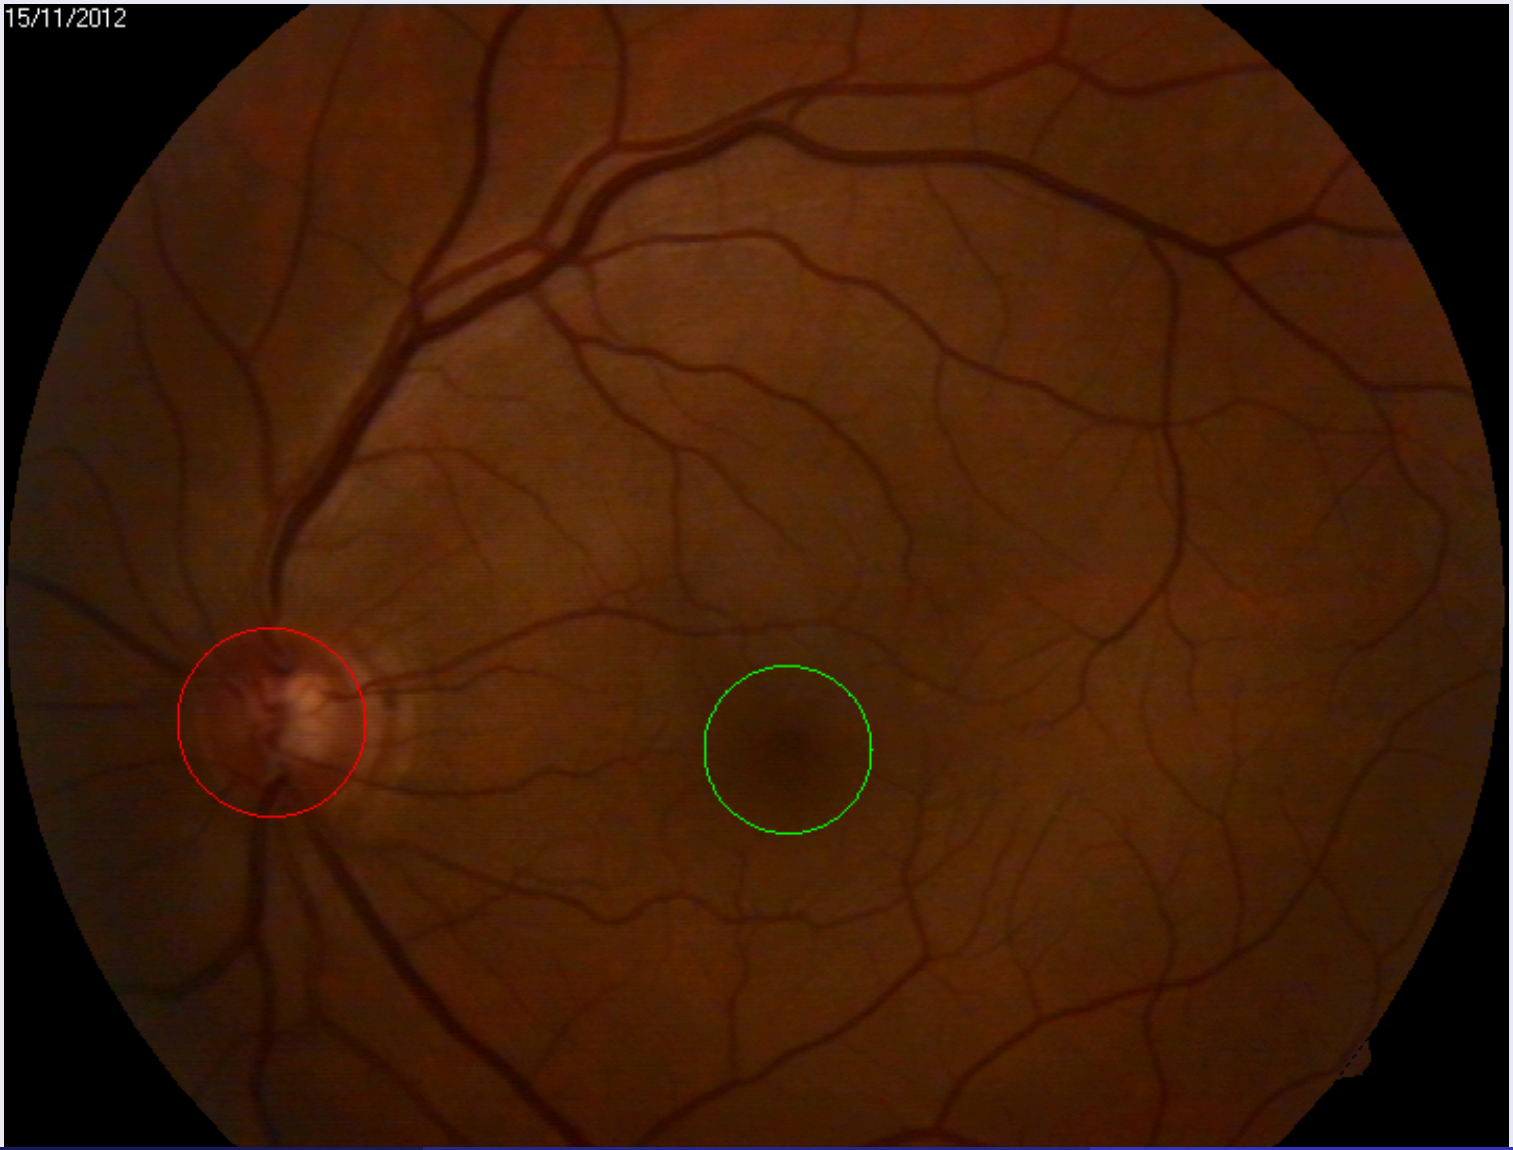
1. Dijabetička retinopatija
2. Očna pozadina
3. Automatska detekcija dijabetičke retinopatija
4. Baza slika
5. Detekcija eksudata

Dijabetička retinopatija

- Dijabetes
- Glavni uzročnik sljepoće kod odraslih
- Lagano se kontrolira
- Problem-nema dovoljno stručnjaka oftalmologa

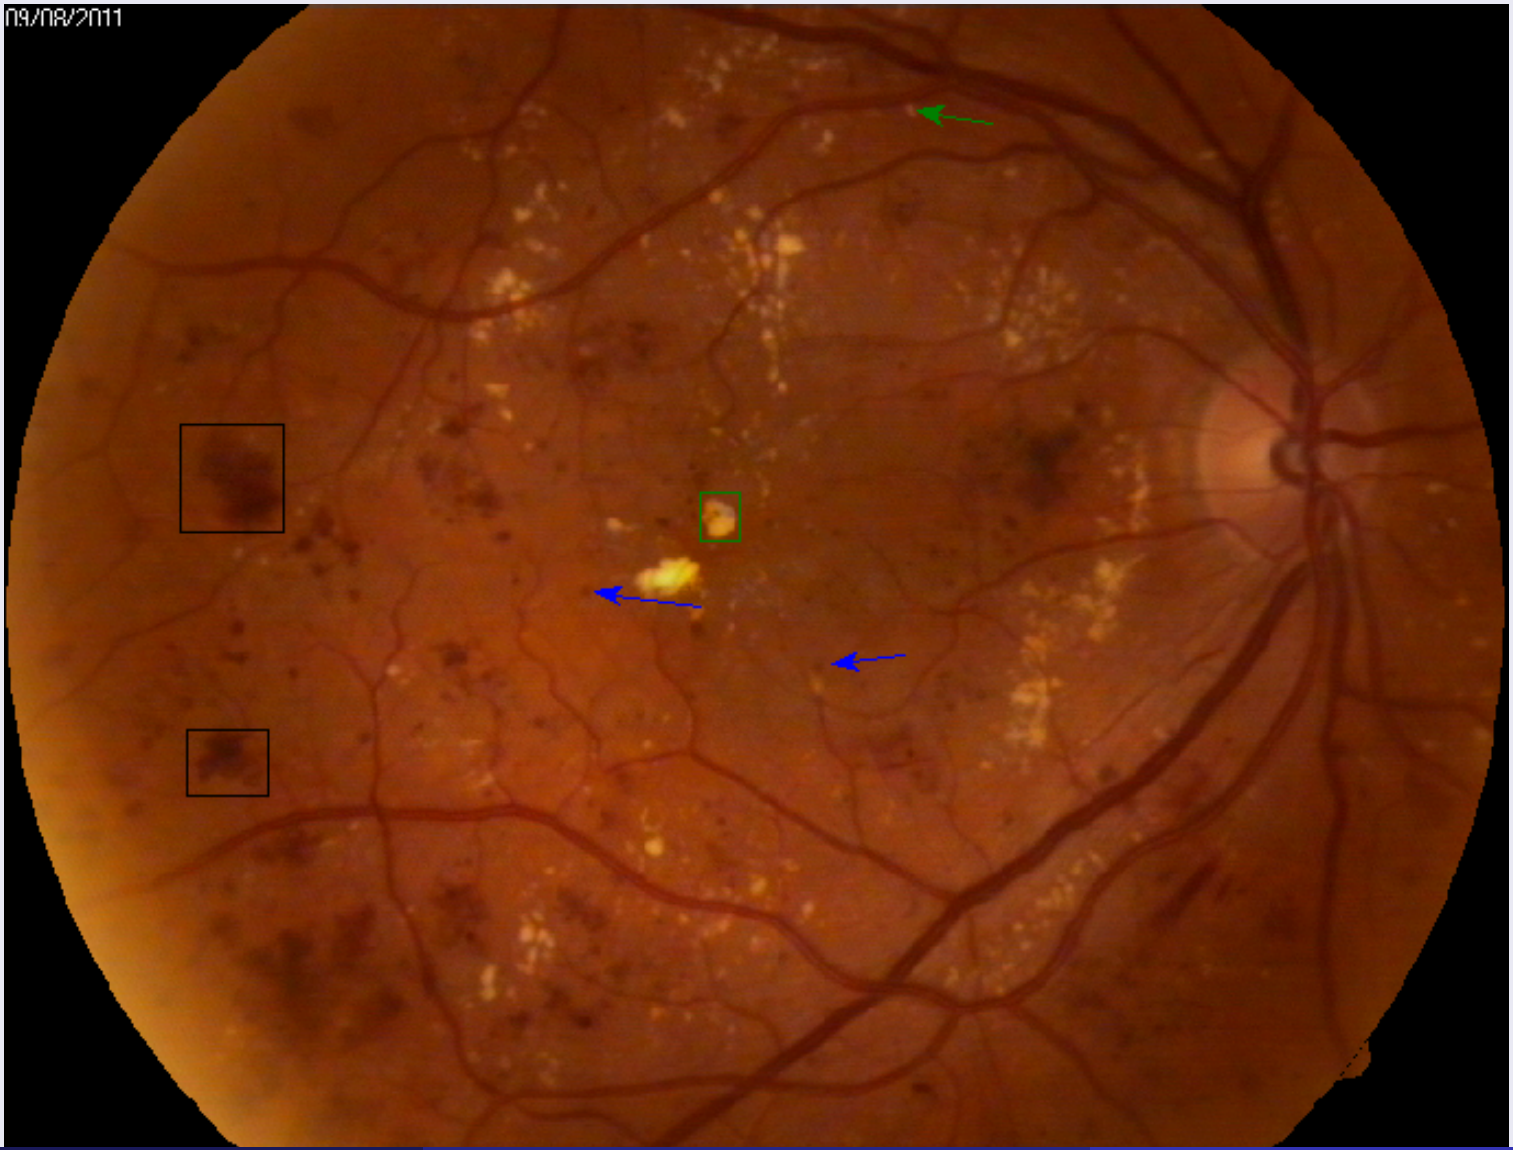
Očna pozadina

Primjer zdrave očne pozadine



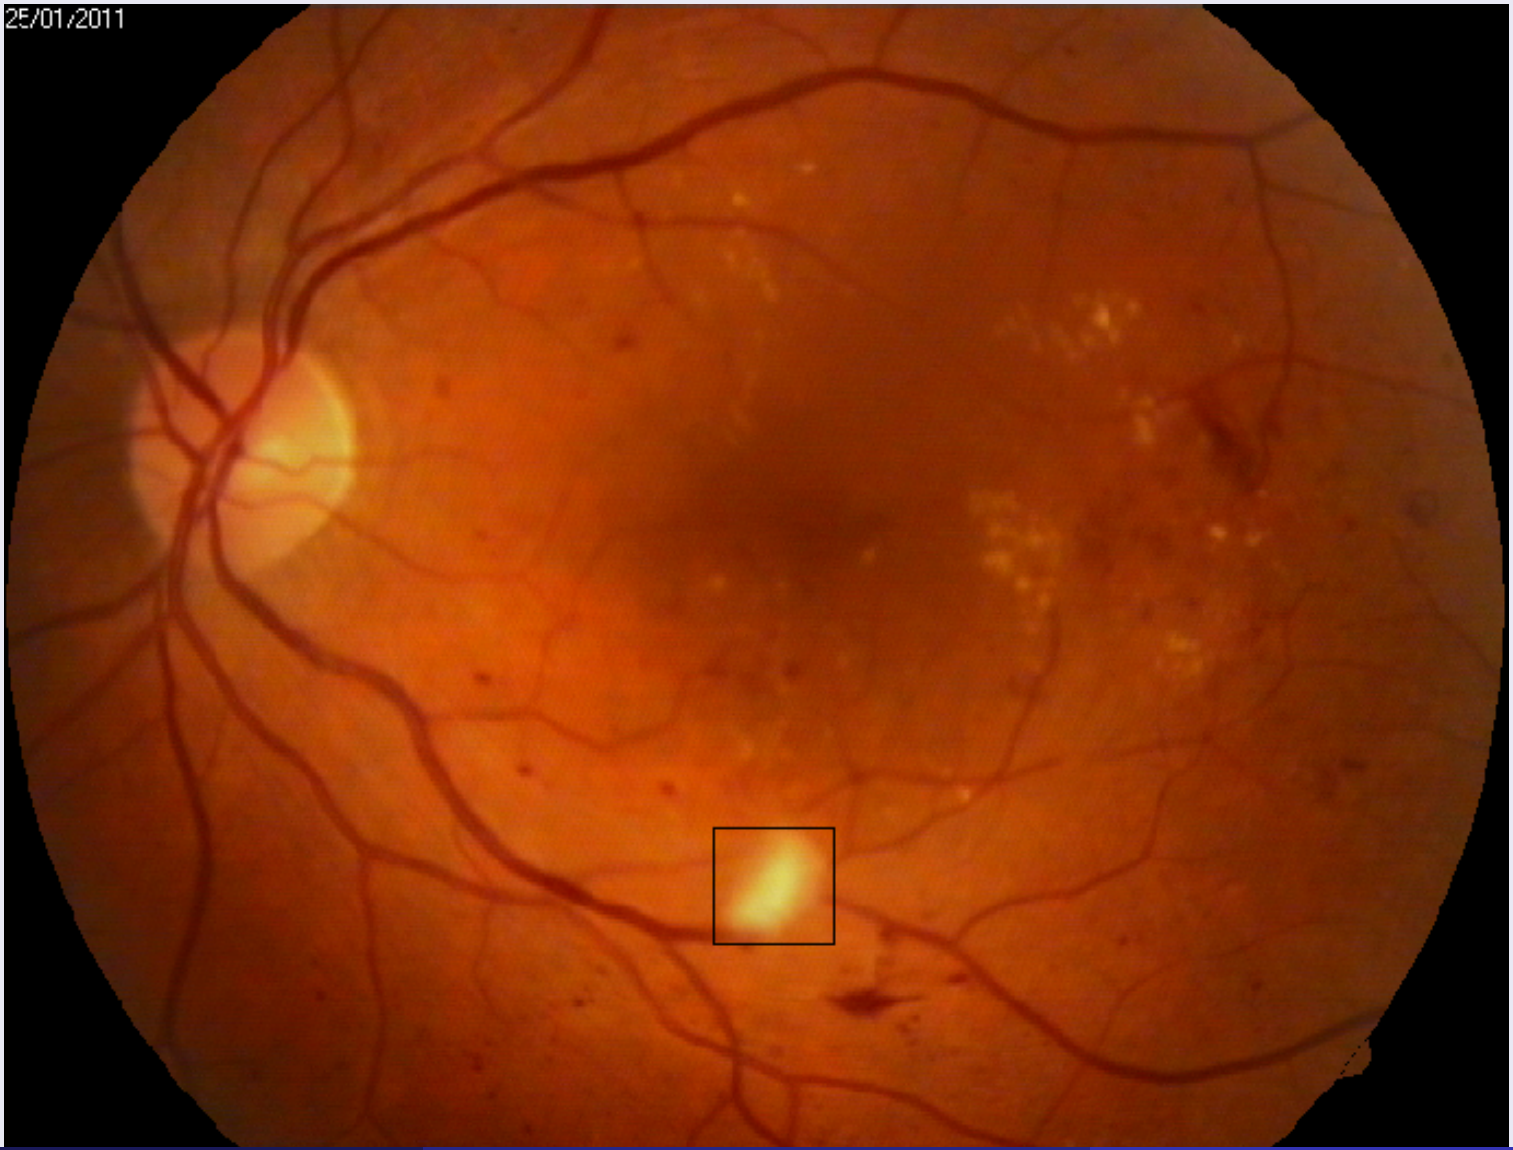
Očna pozadina

Primjer bolesne očne pozadine



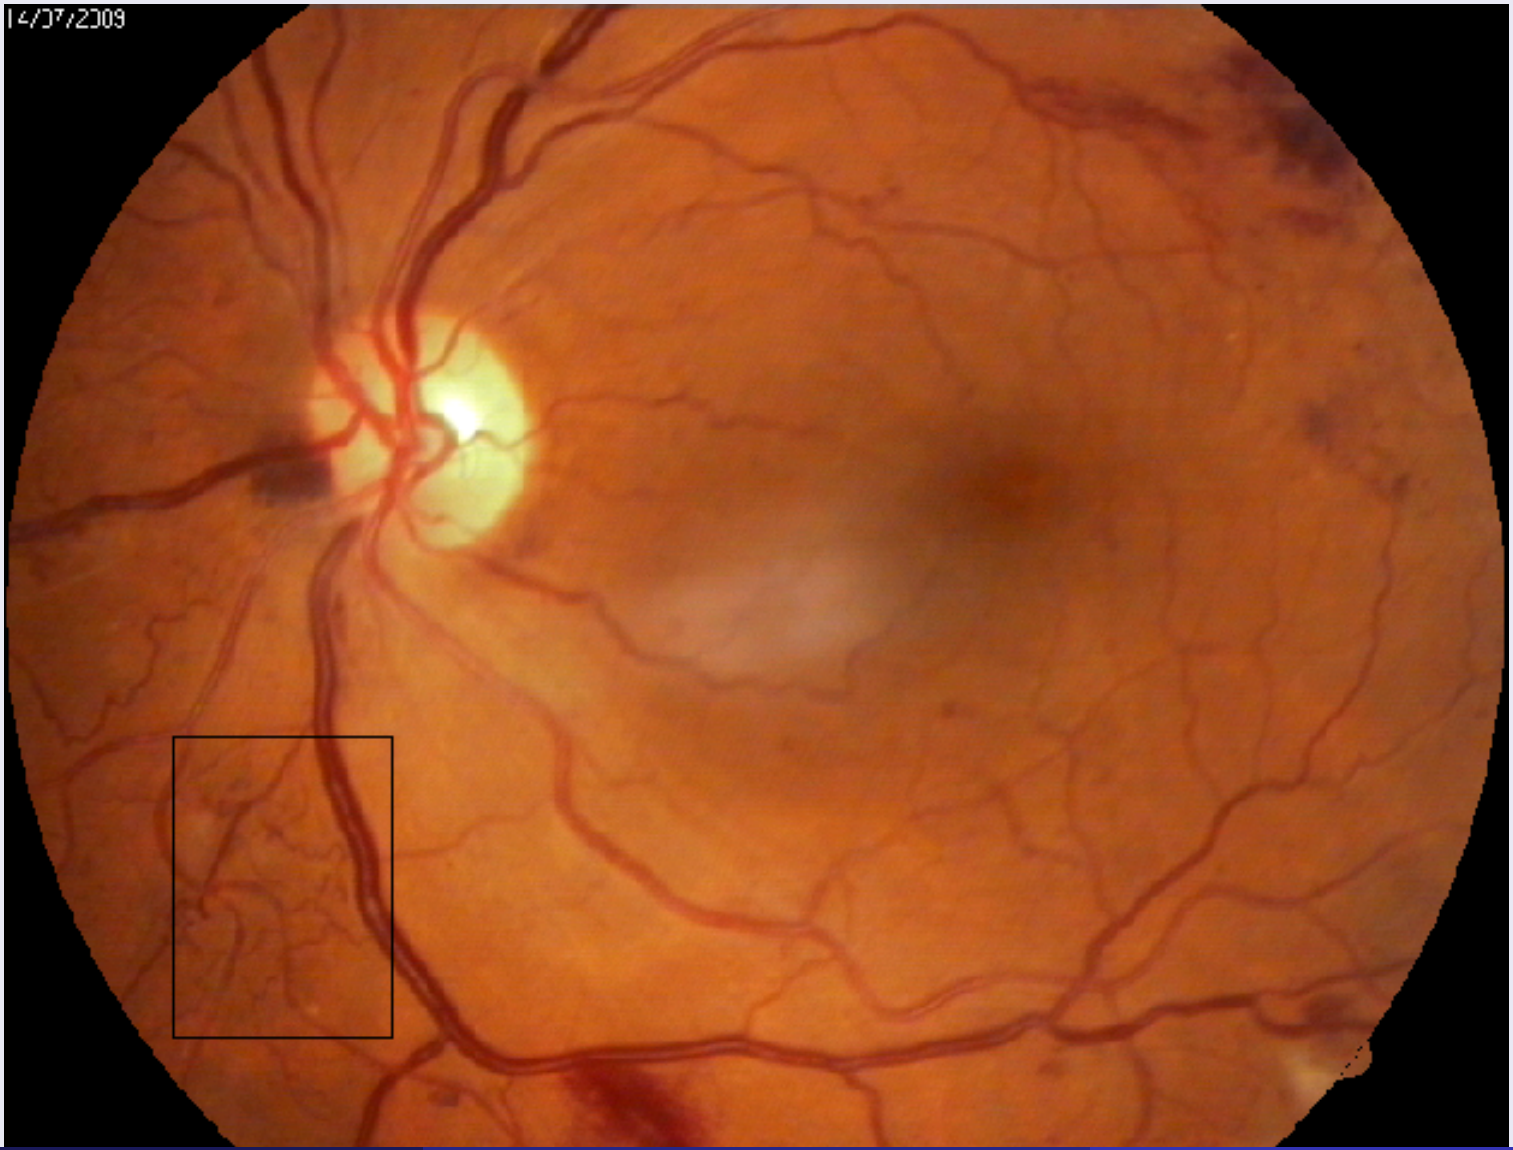
Očna pozadina

Primjer bolesne očne pozadine



Očna pozadina

Primjer bolesne očne pozadine



Osnovne strukture

- Krvne žile
- Slijepa pjega
- Žuta pjega

Patologije

- Tvrdi eksudati
- Meki eksudati
- Točkasta krvarenja
- Mrljata krvarenja
- Neovaskularizacije

Problemi

- Neuniformno osvjetljenje
- Loša rezolucija slika
- Puno šuma
- Zlatni standard

Baza za učenje i testiranje

- 50 slika
- Zdravi i bolesni pacijenti
- Prisutne sve patologije
- Označene sve osnovne strukture(krvne žile, slijepa i žuta pjega)
- 5 doktora
- Izrada alata za pomoć pri izradi baze slika

Alat za potpomognuto označavanje krvnih žila

Problem

Ručno označavanje krvnih žila je spor i naporan proces

Cilj

Smanjiti vrijeme potrebno za ručno označavanje stabla krvnih žila u slikama očne pozadine

Ideja

Označavanjem početne i konačne točke u slici krvnih žila program automatski računa putanju i širine

Alat za potpomognuto označavanje krvnih žila

Kriterijska funkcija

- Ovisi o početnoj točki
- Ovisi o putu

Metoda optimiranja

Dijkstrin algoritam za traženje najkraćeg puta

Detekcija eksudata

- Preprocesiranje slike
- Učenje klasifikatora
- Klasifikacija

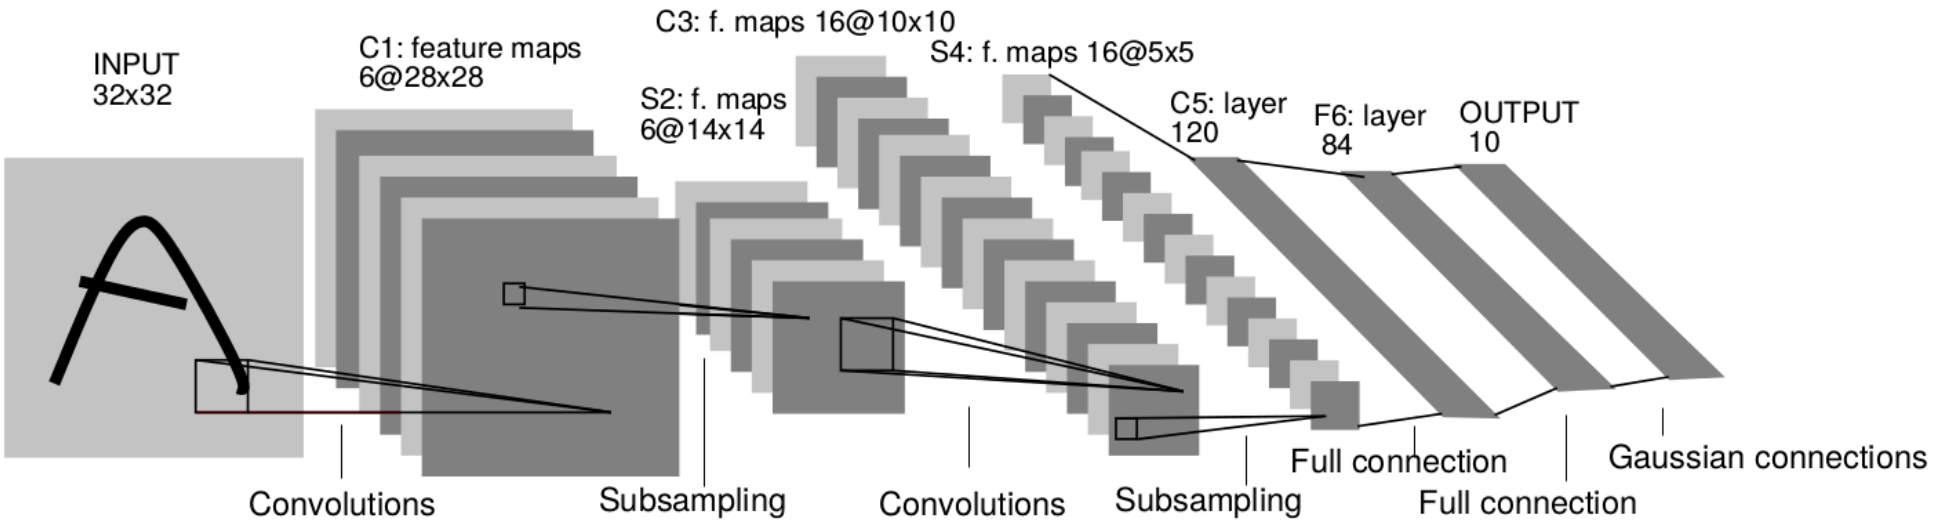
Preprocesiranje slike

- Uzimanje zelenog kanala
- Filtriranja usrednjavanjem
- CLAHE
- Ujednačanje svjetline
- Modeliranje pozadine

Duboke neuronske mreže

- Puno više slojeva u odnosu na konvencionalne neuronske mreže
- Izmjenjuju se konvolucijski i max-pool slojevi
- Konvolucijski slojevi služe za izlučivanje značajki
- Max-pool slojevi služe za agregiranje značajki
- Nekoliko potpuno povezanih slojeva nakon sekvence konvolucijskih i max pool slojeva

Arhitekura duboke neuronske mreže



Učenje mreže

- Izrezuje se prozor veličine 65×65 piksela kao primjer za učenje
- Potrebno balansirati pozitivnih i negativnih primjera
- Povećanje broja primjera za učenje rotiranjem i zrcaljenjem prozora za klasifikaciju
- Back-propagation za učenje

Primjer segmentirane slike



Pitanja?