

Strojno učenje 1

1. Uvod u strojno učenje

prof. dr. sc. Jan Šnajder

Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva

Ak. god. 2023./2024.

Sadržaj

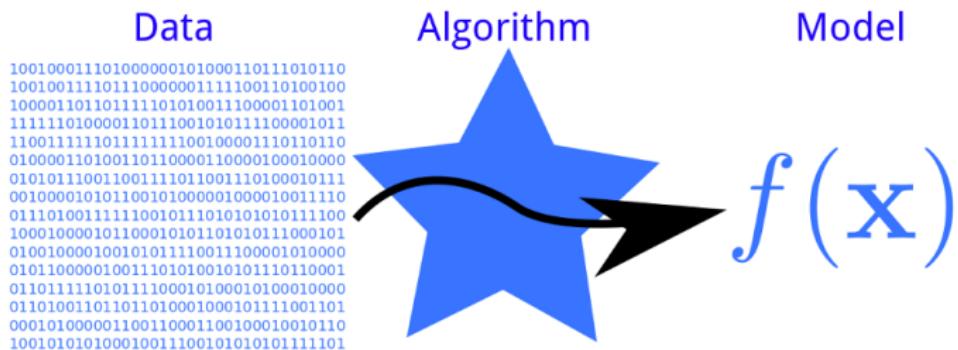
- 1 Što i zašto?
- 2 Pristupi strojnom učenju
- 3 Organizacija predmeta

Motivacija

- “We are drowning in data, but we are starved for knowledge”
– John Naisbitt, *Megatrends*
- Podatci = sirove informacije
- Znanje = uzorci u podatcima ili modeli koji ih objašnjavaju



Strojno učenje



- Algoritmi za (polu)automatsku ekstrakciju novog i korisnog znanja – u obliku **pravila, uzoraka ili modela** – iz proizvoljnih skupova podataka

Strojno učenje

Strojno učenje (Alpaydin 2009)

Strojno učenje je programiranje računala na način da optimiziraju neki kriterij uspješnosti temeljem podatkovnih primjera ili prethodnog iskustva.

- Raspolažemo modelom koji je definiran do na neke parametre
- Učenje: optimizacija parametara modela temeljem podataka
- Na temelju viđenih podataka, model mora moći predvidjeti svojstva novih, još neviđenih podataka
- Cilj strojnog učenja: izgraditi modele koji dobro generaliziraju

Interdisciplinarnost strojnog učenja

- Umjetna inteligencija
- Teorija vjerojatnosti
- Statistika
- Optimizacija
- Teorija informacije
- Teorijska računarska znanost
- Baze podataka
- Pretraživanje informacija (engl. *information retrieval*)
- Psihologija, neurobiologija, kognitivna znanost

Svi putevi vode k... strojnom učenju

- **Matematika: statistika**

- ▶ 17. stoljeće: Vjerojatnost
- ▶ 18. stoljeće: Prvi Bayesovski pristupi
- ▶ 20. stoljeće: Frekventisti
- ▶ 1980.: Značajan razvoj Bayesovskih pristupa (MCMC)

- **Elektrotehnika: Obrada signala**

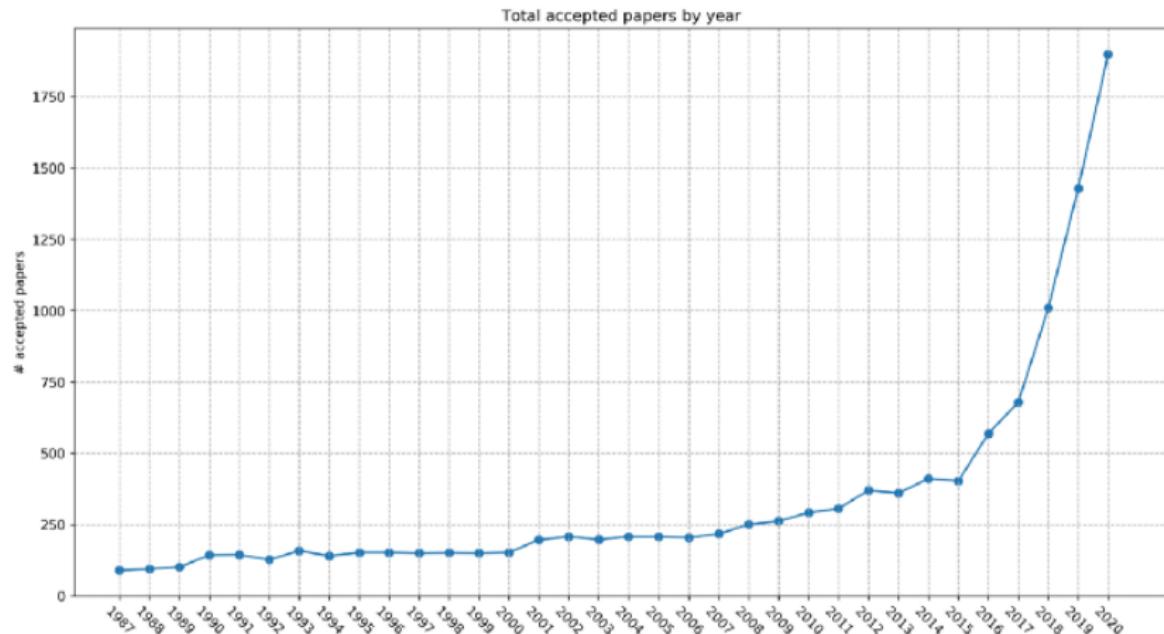
- ▶ Početci u drugome svjetskom ratu
- ▶ 1960.–1970.: FFT, projektiranje filtara
- ▶ 1980.–1990.: Očitavanje signala, obrada slike

Svi putevi vode k... strojnom učenju

- **Računarstvo: UI**
 - ▶ 1940.: Perceptron
 - ▶ 1960.–1970.: Logičko programiranje
 - ▶ 1980.: Backpropagation, PAC, Bayesove mreže
 - ▶ 2000.+: SVM, PGM, Transfer learning, Structured learning, Online learning, Deep learning, ...
- **Računarstvo: Razne komplementarne ideje**
 - ▶ Baze podataka: Dubinska analiza podataka, statističke baze podataka (OLAP), probabilističke baze podataka
 - ▶ Pretraživanje informacija: PageRank
 - ▶ Računalni sustavi: MapReduce, Hadoop

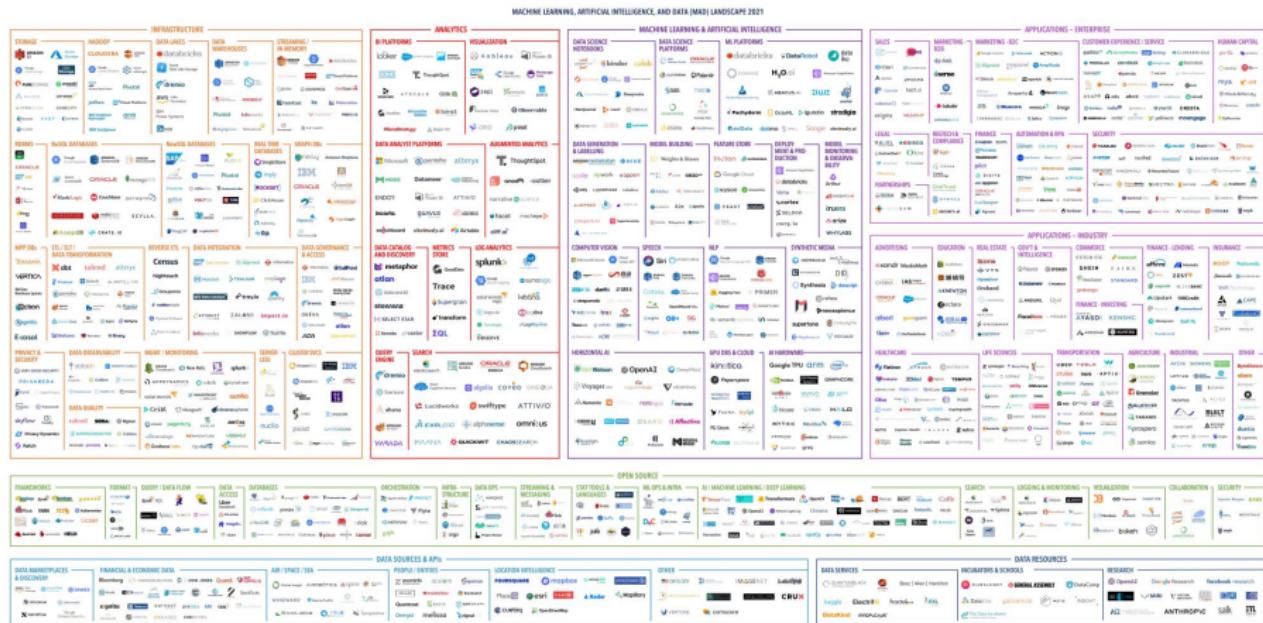
Strojno učenje danas

Broj radova na konferenciji NeurIPS



<https://towardsdatascience.com/neurips-conference-historical-data-analysis-e45f7641d232>

Krajolik alata strojnog učenja



Version 3.0 - November 2021

© Matt Turck (@mattturck), John Wu (@john_d_wu) & FirstMark (@firstmarkcap)

mattturck.com/data2021

FIRSTMARK
DATA SCIENCE & MACHINE LEARNING

<https://mattturck.com/data2021/>

Primjene strojnog učenja

- ① **Složeni problemi** – ne postoji ljudsko znanje o procesu ili ljudi ne mogu dati objašnjenje procesa (npr. raspoznavanje govora)
 - ▶ problemi koje nije moguće riješiti na klasičan algoritamski način (*Ul-potpuni problemi*)
- ② **Sustavi koji se dinamički mijenjaju**
- ③ **Ogromne količine podataka** – ima li znanja u njima?
 - ▶ otkrivanje znanja u skupovima podataka (engl. *data mining*)

Slučaj 1: Teški problemi

- Raspoznavanje uzorka
- Računalni vid
- Obrada prirodnog jezika
- Raspoznavanje govora
- Robotika
- ...



Slučaj 2: Dinamički prilagodivi sustavi

- Inteligentni računalni sustavi moraju se moći **prilagoditi svojoj okolini**
 - Sustav koji je sposoban učiti može se bolje prilagoditi novim situacijama
-
- Robotika
 - Višeagentni sustavi
 - Inteligentna korisnička sučelja
 - ... ali zapravo bilo kakav inteligentni agent (računalni program koji djeluje u pravoj ili stvarnoj okolini, npr., virtualni asistent, algoritam za igru Go, dron za spašavanje...)



Slučaj 3: Od podataka do znanja

- Podatci → informacije → znanje → odluka
- **Podataka** ima u izobilju (web, tekst, eksperimentalni podatci, skladišta podataka *deep web, logovi*)
- S druge strane, **znanja** nema puno i ono je skupo
- Cilj: izgradnja modela koji objašnjavaju podatke i omogućavaju zaključivanje/predviđanje

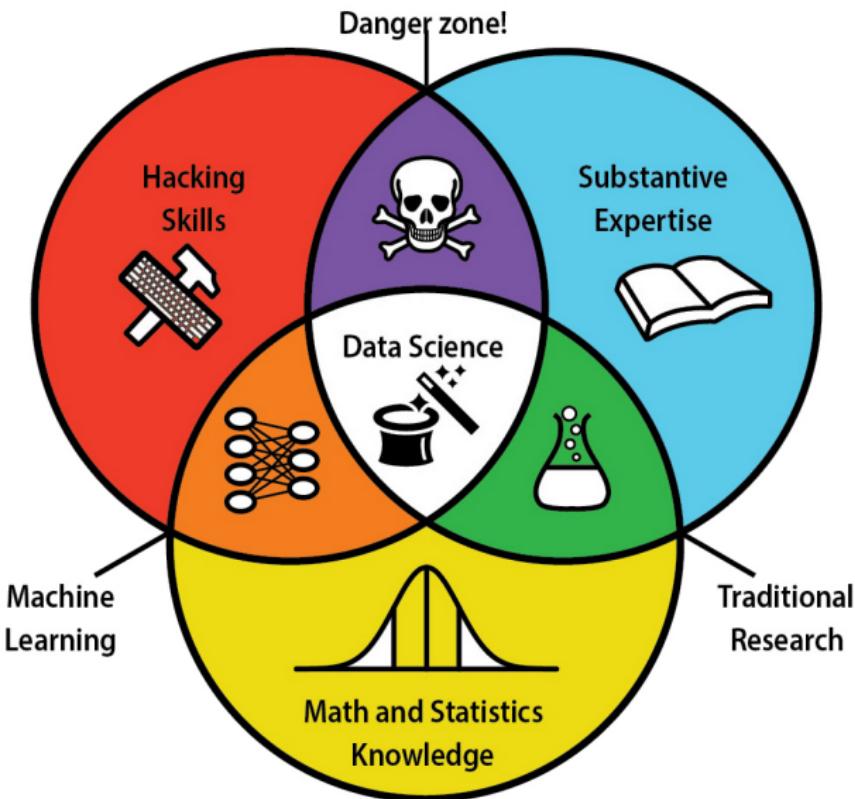


Dubinska analiza podataka

Dubinska analiza podataka (engl. *data mining*) ili **otkrivanje znanja u skupovima podataka** (engl. *knowledge discovery in datasets*) – primjena strojnog učenja na (polu)strukturirane baze podataka

- Prodaja: analiza potrošačke košarice, CRM
- Financije: određivanje kreditne sposobnosti, detekcija zlouporaba kartica
- Proizvodnja: optimizacija, *troubleshooting*
- Medicina: postavljanje dijagnoza, prevencija
- Telekomunikacije: optimizacija usluga
- Bioinformatika: analiza izražajnosti gena, poravnavanje gena
- Text mining: klasifikacija teksta, ekstrakcija informacija
- ...

Znanost o podatcima (engl. *Data Science*)



<http://berkeleysciencereview.com/how-to-become-a-data-scientist-before-you-graduate/>

Sadržaj

- 1 Što i zašto?
- 2 Pristupi strojnom učenju
- 3 Organizacija predmeta

Tri pristupa strojnom učenju

(1) Nadzirano učenje (engl. *supervised learning*)

Podatci su parovi (*ulaz, izlaz*) = (x, y) , treba pronaći $\hat{y} = f(x)$

- Ako je y je diskretna/nebrojčana vrijednost: **klasifikacija**
- Ako je y kontinuirana/brojčana vrijednost: **regresija**

(2) Nenadzirano učenje (engl. *unsupervised learning*)

Dani su podatci bez ciljne vrijednosti, treba naći pravilnost u podatcima

- **grupiranje** (engl. *clustering*)
- **procjena gustoće** (engl. *density estimation*)
- **smanjenje dimenzionalnosti** (engl. *dimensionality reduction*)

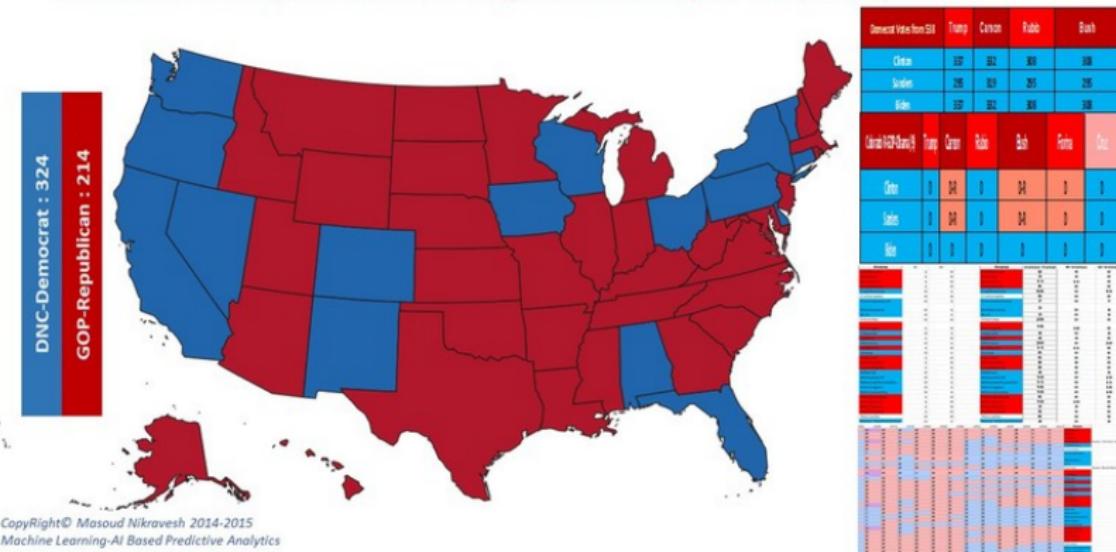
(3) Podržano/ojačano učenje (engl. *reinforcement learning*)

Učenje **optimalne strategije** na temelju pokušaja s odgođenom nagradom

Primjena klasifikacije: predviđanje ishoda izbora

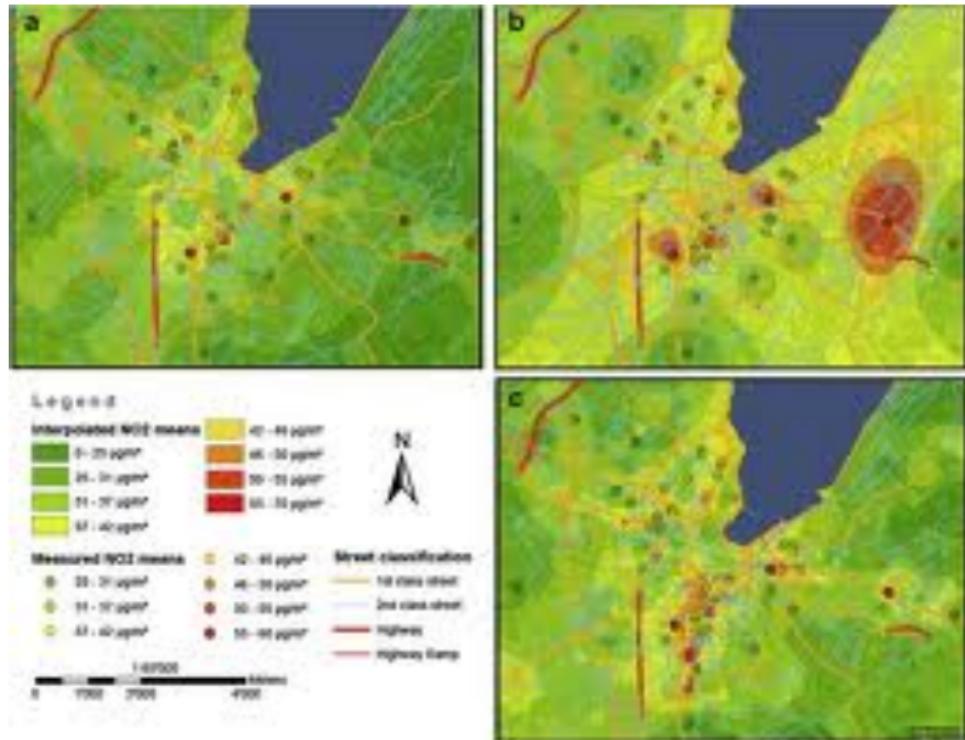
2016 Presidential Election Prediction

A Predictive-Descriptive Artificial Intelligence-Based Expert Computer System



Election Analytics (https://www.experfy.com/uploads/ckeditor/pictures/132/content_NikraveshSlide3.JPG)

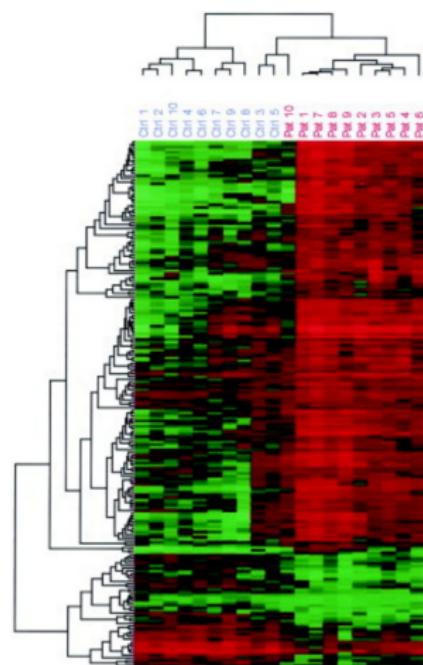
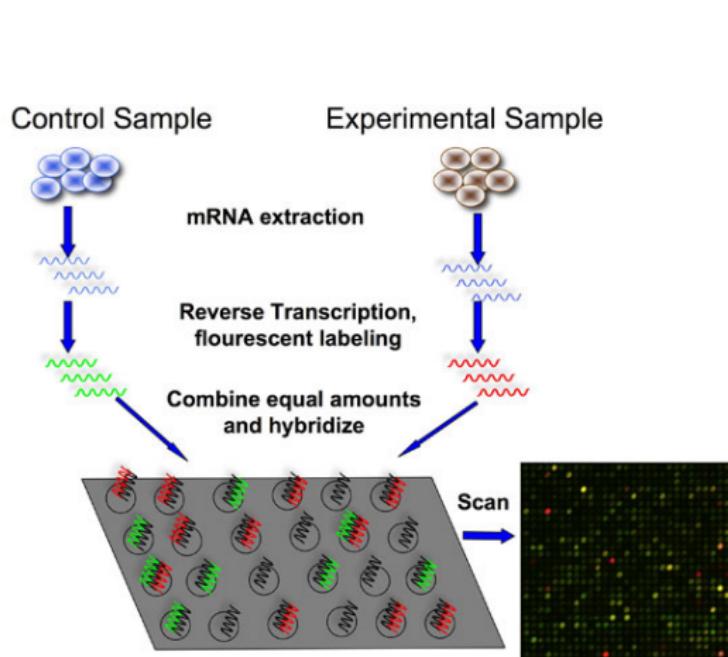
Primjena regresije: predviđanje razine emisije NO₂



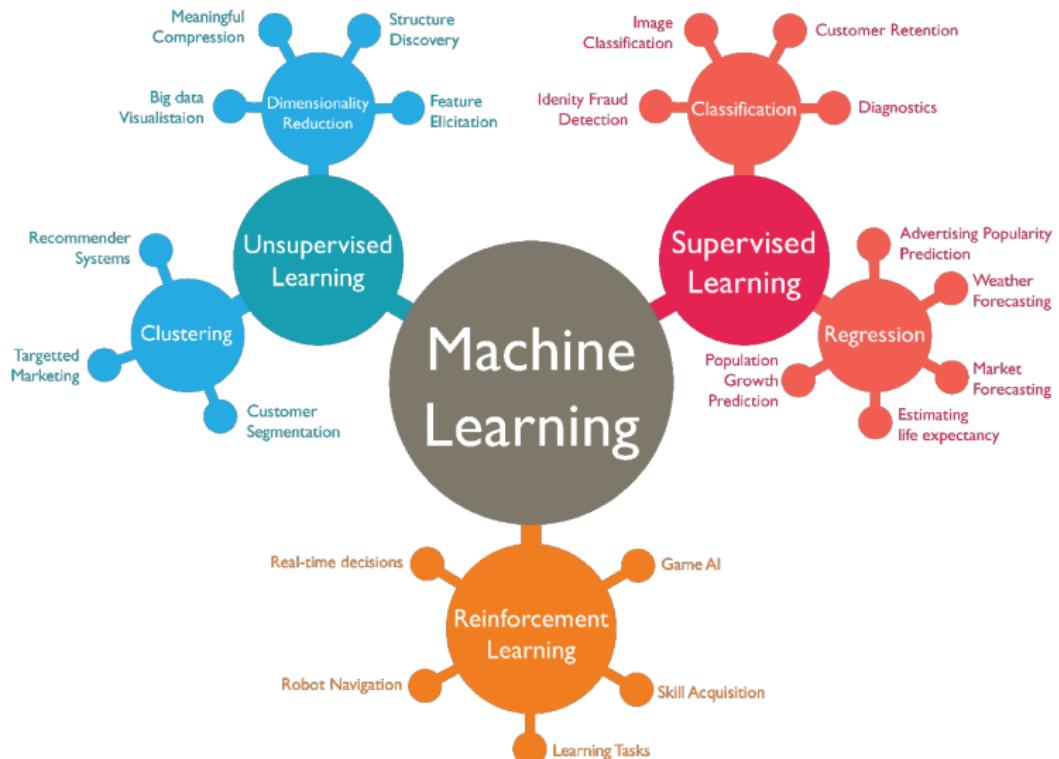
Exposure models for traffic related NO₂ (<http://www.sciencedirect.com/science/article/pii/S1352231011009629>)

Primjena grupiranja: analiza DNK-mikropolja

Cilj: grupiranje gena sa sličnom izražajnošću
(slična izražajnost – slična funkcionalnost)



Pristupi, zadatci, primjene



<https://vitalflux.com/great-mind-maps-for-learning-machine-learning/>

Primjene, zadatci, modeli i algoritmi

Applications

Fraud Detection

...

Demand Planning

Tasks

Classification

...

Regression

...

Clustering

Models

Decision Trees

Artificial Neural Networks

...

Partitioning

Algorithms

C4.5

CART

Back propagation

K-Means

Pet škola strojnog učenja

Pedro Domingos: The Master Algorithm



Škola	Temelji	Glavni algoritam
Symbolists	Logika, filozofija	Indukcija
Connectionists	Neuroznanost	Backpropagation
Evolutionaries	Evolucijska biologija	Genetičko programiranje
Bayesians	Statistika	Probabilističko zaključivanje
Analogizers	Psihologija	Jezgreni strojevi

Pet škola strojnog učenja

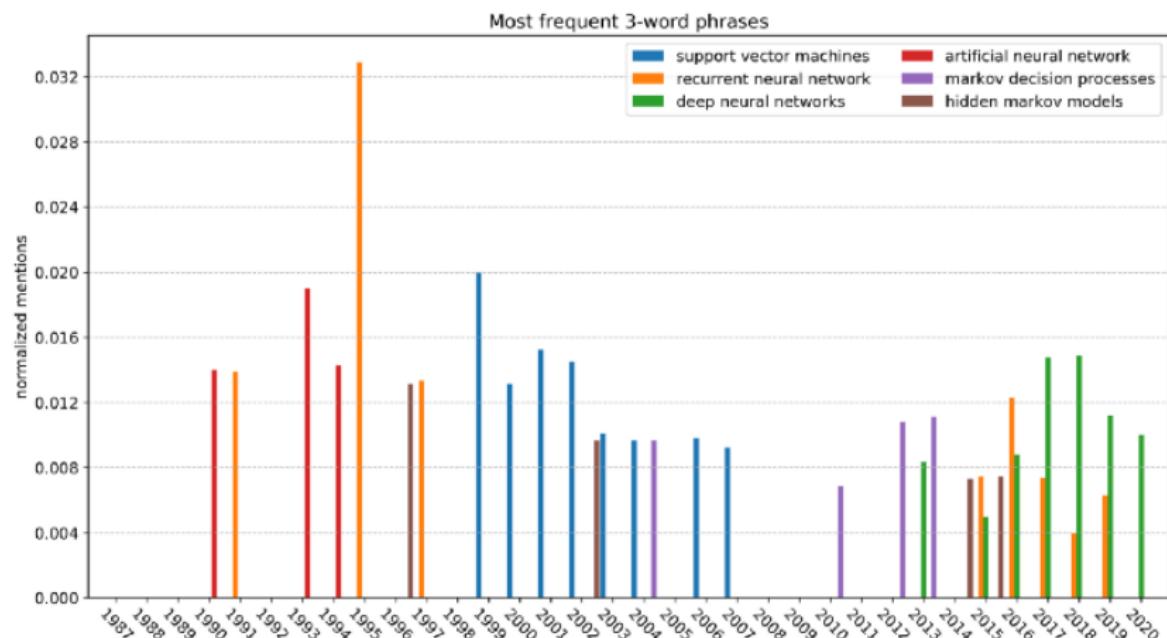
Pedro Domingos: The Master Algorithm



Škola	Cilj
Symbolists	Popunjavanje rupa u znanju
Connectionists	Emulacija mozga
Evolutionaries	Simulacija evolucije
Bayesians	Sustavno smanjivanje neizvjesnosti
Analogizers	Uočavanje sličnosti između staroga i novoga

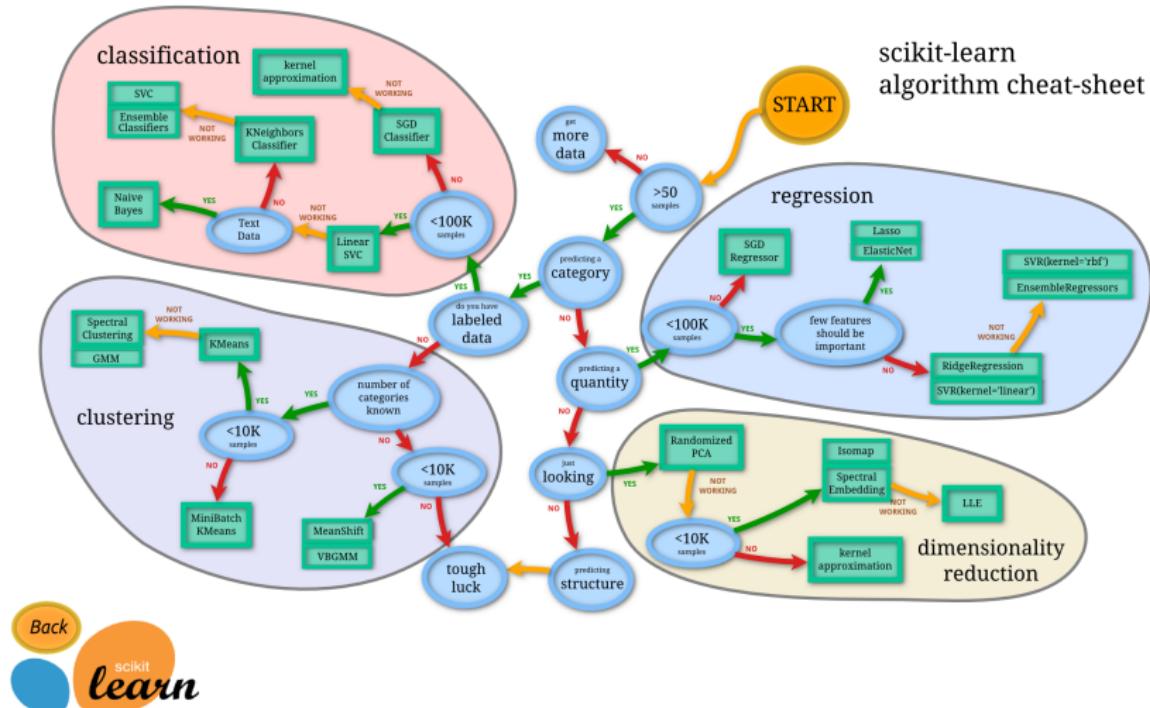
Trendovi

Najčešće fraze u radovima na konferenciji NeurIPS



<https://towardsdatascience.com/neurips-conference-historical-data-analysis-e45f7641d232>

Karta strojnog učenja



https://scikit-learn.org/stable/tutorial/machine_learning_map/

Još primjera...

Jupyter-bilježnica 1: Uvodni primjer
<https://tinyurl.com/2s4j5x35>

Svi primjeri dostupni su na:
<https://github.com/jsnajder/StrojnoUcenje>

Sažetak

- **Strojno učenje** bavi se rješavanjem problema koje je teško riješiti klasičnim UI pristupima
- Podataka ima u izobilju – izazov je transformirati podatke u **znanje** tako da možemo **zaključivati i predviđati**
- Strojno učenje povezano je sa statistikom, računarskom znanosti, umjetnom inteligencijom, ...
- Učenje se svodi na **optimizaciju parametara modela** na temelju **podataka**
- Dva osnovna pristupa: **nadzirano učenje** (zadaci klasifikacije i regresije) i **nenadzirano učenje** (zadaci grupiranja, procjene gustoće, smanjenje dimenzionalnosti)



Sljedeća tema: Osnovni koncepti

Sadržaj

- 1 Što i zašto?
- 2 Pristupi strojnom učenju
- 3 Organizacija predmeta

Izvođači

Predavači:

- Prof. dr. sc. Jan Šnajder
- Doc. dr. sc. Marko Đurasević

Asistenti:

- Josip Jukić, mag. ing. (glavni asistent)
- Laura Majer, mag. ing. (zamjenica)
- Ivan Bilić, David Dukić, Miha Keber, Josipa Lipovac

Demosi:

- Andrija Gorup, David Kerman, Filip Krišković, Gabriela Vitez, Karlo Šutalo, Lara Miholić, Luka Družijanić, Mihael Miličević, Noah Marko Mesić, Petra Dunja Gruijć Ostojić, Tihomir Pavić, Tin Mišić

O predavačima



Prof. dr. sc. Jan Šnajder

<http://www.zemris.fer.hr/~jan/>

- Diplomirao (2002) i doktorirao (2010) računarsku znanost na FER-u
- Poslijedoktorski na Sveučilištu u Heidelbergu, znanstveno usavršavanje na Sveučilištu u Stuttgartu, NICT Kyoto i Sveučilištu u Melbourneu
- Istraživački interesi: obrada prirodnog jezika (NLP) i strojno učenje (neuronski NLP modeli, tekstna analitika, računalna društvena znanost)

O predavačima



Doc. dr. sc. Marko Đurasević
<https://www.fer.unizg.hr/marko.djurasevic>

- Diplomirao (2014) i doktorirao (2018) računarstvo na FER-u
- Znanstveno usavršavanje na Sveučilištu u Oviedu
- Istraživački interesi: evolucijski računarstvo, optimizacija i strojno učenje

O nama



TakeLab

Text Analysis and Knowledge Engineering Lab

<http://takelab.fer.hr>

Plan nastave

23 teme organizirane u 6 cjelina:

- (1) Uvod u strojno učenje, Osnovni koncepti, Linearna regresija
- (2) Linearni diskriminativni modeli, Logistička regresija
- (3) Stroj potpornih vektora, Jezgrene metode, Neparametarske metode
- (*) Opcionalno: Ansamblji

Međuispit

- (4) Procjena parametara, Bayesov klasifikator
- (5) Probabilistički grafički modeli
- (6) Grupiranje, Vrednovanje modela
- (*) Opcionalno: Odabir značajki

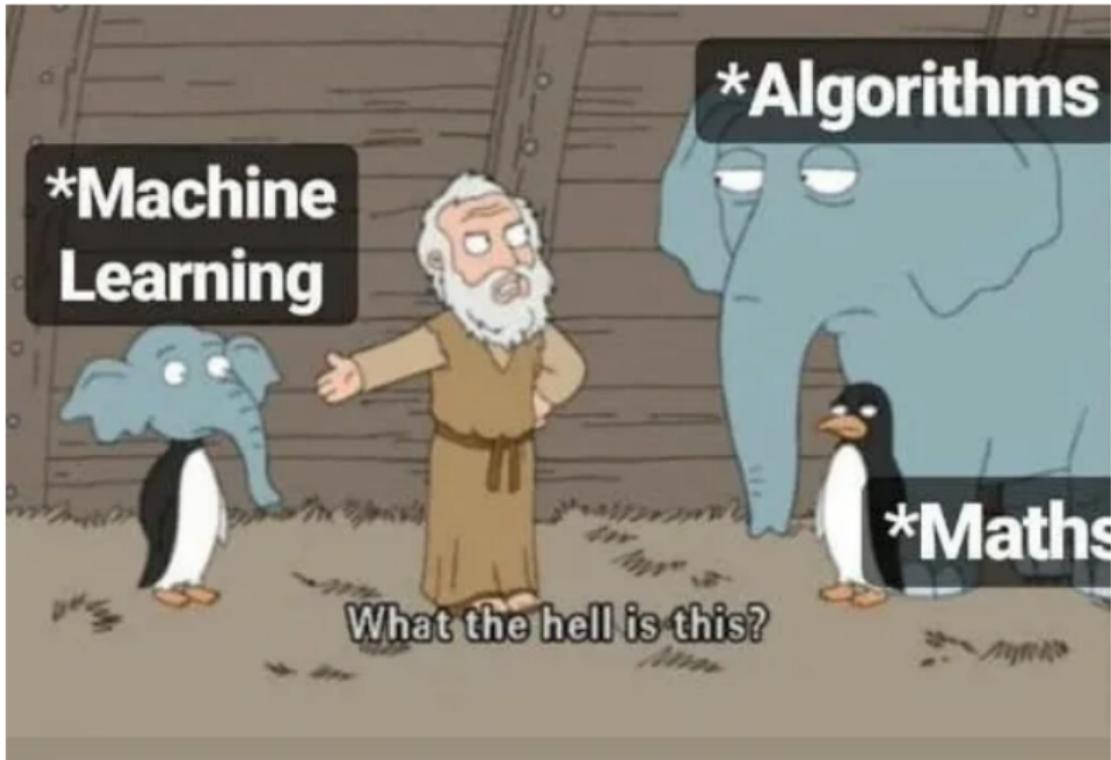
Završni ispit

Ishodi učenja

- Definirati osnovne pojmove strojnog učenja
- Objasniti teorijske pretpostavke, matematičke osnove te prednosti i nedostatke temeljnih algoritama (ne)nadziranog strojnog učenja
- Primijeniti temeljne algoritme klasifikacije, regresije i grupiranja na jednostavnije probleme
- Primijeniti postupak odabira i evaluacije točnosti modela
- Analizirati i usporediti temeljne algoritme strojnog učenja s obzirom na njihove komponente i računalnu složenost
- Razlikovati temeljne pristupe strojnom učenju (generativni/diskriminativni, parametarski/neparametarski, bayesovski/frekventistički) te objasniti poveznice
- Procijeniti prikladnost temeljnih algoritama strojnog učenja za zadani zadatak
- Oblikovati i implementirati jednostavnije algoritme za klasifikaciju, regresiju i grupiranje

U konačnici, želimo da...

- ① Razumijete **osnovne ideje i razine apstrakcije**
- ② Razumijete tipičnu **matematiku** ispod toga
- ③ Shvatite **algoritme i metode** tako da ih implementirate ili ispitate na jednostavnim primjerima
- ④ Izgradite svoju **kartu područja** i dobijete **putokaze** za samostalno učenje



MATH + ALGORITHM = MACHINE LEARNING

Princip 1: Kod učenja nema prečica

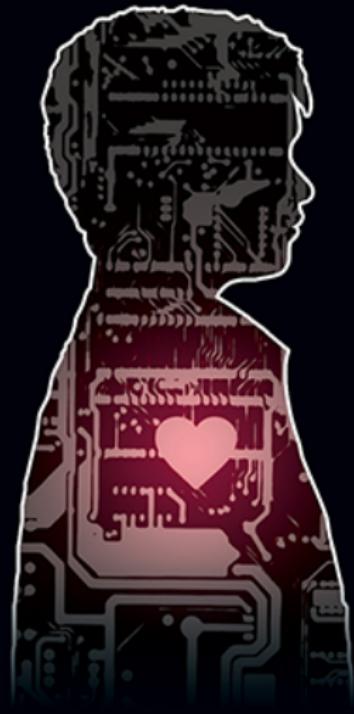


Princip 2: Fleksibilne strukture trebaju čvrst temelj



Princip 3: Dajemo strukturu, detalje popunjavate sami





Self-education is, I firmly believe,
the only kind of education there is.
— Isaac Asimov

Nastavne aktivnosti

Predavanja/vježbe:

- HR: ponedjeljkom 10–12 sati i srijedom 8–10 sati u B1
- EN: utorkom 16–18 sati u A211 i četvrtkom 12–14 sati u D152

Domaće zadaće:

- 6 zadaća koje predajete online

Laboratorijske vježbe:

- 4 vježbe koje predajete online pa demonstrirate asistentima

Demonstracije:

- dodatni termini u kojima demosi rješavaju zadatke s ispita

Konzultacije:

- Petkom 14–15 sati u D334

Ispiti:

- Međuispit + završni ispit (kontinuirano) ili pismeni ispit (ispitni rok)

Predavanja

- **20 predavanja i 6 rekapitulacija**
- Klasična predavanja (ja objašnjavam na ploči, vi pratite, radite bilješke i pitate ako nešto nije jasno)
- Podijeljena u 6 cjelina, nakon svake cjeline radimo **rekapitulaciju** i rješavamo nekoliko zadatka s prošlogodišnjih ispita (aka auditorne vježbe)
- Kratka **kviz-pitanja** na satu (za motivaciju i formativnu povratnu informaciju), preko Moodlea, za ukupno najviše **10 bodova**
- Preporučamo da dolazite na predavanja

Materijali za učenje

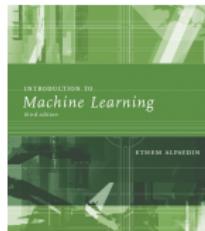
- ① Videopredavanja
- ② Skripte s predavanja (tekst predavanja s primjerima, dodatnim bilješkama i literaturom za one koji žele znati više ☺)
- ③ Natuknice s predavanja (vrlo sažeta predavanja)
- ④ Zadatci za učenje i vježbu (uključivo zadatci s ispita)
- ⑤ Laboratorijske vježbe

Sve je javno dostupno na

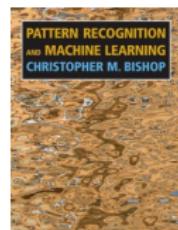
<https://www.fer.unizg.hr/predmet/struce1/materijali>

Dodatna literatura

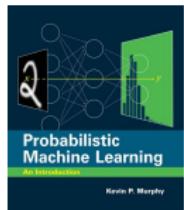
- Ethem Alpaydin:
Introduction to Machine Learning,
3rd edition, MIT Press, 2015.



- Christopher Bishop:
Pattern Recognition and Machine Learning,
Springer, 2006.



- NEW Kevin P. Murphy: *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.



Dodatna dodatna literatura

Osnovno:

- Hastie, Tibshirani, Friedman: *Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2003.
- Deisenroth, Faisal, Ong: *Mathematics for Machine Learning*. Cambridge University Press, 2020.
- Marsland: *Machine Learning: An Algorithmic Perspective*, Chapman and Hall/CRC, 2009.
- Duda, Hart, Stork: *Pattern Classification*, Wiley-Interscience, 2000.

Napredno:

-  Murphy: *Probabilistic Machine Learning: Advanced Topics*, MIT Press, 2022.
- Mohri, Rostamizadeh, Talwalkar: *Foundations of Machine Learning*, MIT Press, 2012.
 - Shalev-Shwartz, Ben-David: *Understanding machine learning: From theory to algorithms*, Cambridge University Press, 2014.

Specifično:

- Koller, Friedman: *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.
- Goodfellow, Bengio, Courville: *Deep Learning*, MIT Press, 2016.

Domaće zadaće

- **6 domaćih zadaća**, radite ih nakon rekapitulacije
- Zadatci za vježbu koje rješavate rukom na papiru i uploadate sken na Moodle kao jedan PDF file
- Peer review: ako predate zadaću, trebate pregledati i ocijeniti druge dvije zadaće
- Bodovanje: ukupno najviše **10 bodova** za 6 zadaća
- Domaće zadaće rješavajte **samostalno**. Možete se, naravno, konzultirati s drugima, ali drugi ne smiju rješavati zadaće umjesto vas
- Domaće zadaće usklađene su s **ishodima učenja** predmeta, dok ispit provjeravaju te iste ishode učenja. To znači da, ako rješavate domaće zadaće, vjerojatno ćete dobro riješiti ispit

Laboratorijske vježbe

- **4 laboratorijske vježbe**, radite ih u Pythonu u okruženju **SciPy** korištenjem biblioteke **scikit-learn** i Jupyter-bilježnice
- Svrha vježbi je stecanje dubljeg razumijevanje rada algoritama. Svrha vježbi **nije** stjecanje iskustva rada na stvarnom projektu strojnog učenja (za to postoje drugi predmeti)
- Rješenja **demonstrirate asistentima** u svom terminu demonstracije
- Bodovanje: maks. 7.5 bodova po vježbi, ukupno najviše **30 bodova**
- Promjena termina moguća je jedino u parovima studenata; molimo, ne dolazite u druge termine (iznimka: slučaj više sile)
- Trebate biti sposobni na zahtjev **mijenjati programski kôd te razumijeti svu teoriju** na kojima se temelje modeli/algoritmi
- **Laboratorijske vježbe trebate raditi samostalno**

Laboratorijske vježbe su samostalan rad

Pravila samostalnog rada

- ① Zadatake rješavate sami
- ② Dozvoljeno je konzultirati se s drugim studentima **prije** rješavanja zadataka (navesti njihova imena)
- ③ Možete koristiti materijale s interneta za općenite dijelove koda (koji nisu specifični za lab. zadatak), ali onda morate **referencirati** (kao komentare u kodu) sve internetske izvore koje ste koristili
- ④ **Nije dozvoljeno** korištenje UI-asistenata za kodiranje (uključivo alata generativne UI, kao što je ChatGPT)
- ⑤ Ne smijete iskoristiti kôd ili dio kôda koji imate otprije, a niste ga radili potpuno samostalno
- ⑥ Povreda bilo kojeg od gornjih pravila smatra se prevarom ili plagijatom te povlači **akademske sankcije**

Ako postoje ikakvi problemi, trebate doći na **konzultacije**. Tu smo za vas.

Ekosustav SciPy



IPython



Sympy



machine learning in Python



Laboratorijske vježbe i domaće zadaće – savjeti

- ① Krenite raditi na vrijeme.
- ② Ne precjenujte svoje sposobnosti. Nemojte krenuti raditi vježbu i zadaću tek na vikend uoči predaje.
- ③ Ako ipak niste stigli napraviti vježbu ili zadaću, nemojte je prepisati i takvu predati. Umjesto toga, naučite nešto iz toga i drugi puta krenite ranije.
- ④ Uračunajte nepredvidive okolnosti. Možda nešto neće raditi isprve, ili će vam trebati više vremena da nešto shvatite. Ako si ostavite dovoljno vremena za takve situacije, izbjjeći ćete stres.
- ⑤ Ponovite teorijske osnove iza svake lab. vježbe. Svrha laboratorijskih zadataka je upravo da povežu teoriju s praksom. Asistenti će vas zato pitati i teoriju iza svakog zadatka.
- ⑥ Proučite **nultu laboratorijsku vježbu**, premda se ne predaje, pa čak i ako (mislite da) ste jako dobri u Pythonu.

Ispit

- Ispit provjerava **ishode učenja**
- Ispit je obliku **pitanja s ponuđenim odgovorima** (teorijska, problemska i numerička pitanja)
- Ukupno 22 pitanja, za 100% bodova dovoljno je točno riješiti njih 20
- Točan odgovor nosi +1 bod, a netočan $-1/3$ boda
- Vrednuju se isključivo odgovori naznačeni na ispitnom obrascu (postupak se ne pregledava niti ne vrednuje)
- Trajanje ispita je 180 minuta
- Čuvari na ispitu ne smiju odgovarati na pitanja o ispitnim pitanjima
- Primjeri prošlogodišnjih ispita dostupni su na stranici predmeta

Elementi ocjene

	MI+ZI		Ispitni rok	
	Prag	Udio	Prag	Udio
Domaće zadaće				
Kvizovi na satu		10%		10%
Laboratorijske vježbe	30%	30%	30%	30%
Međuispit		30%		
Završni ispit	50%	30%		
Pismeni ispit			50%	60%

- Domaće zadaće ukupno nose 10 bodova, kvizovi ukupno nose 10 bodova, ali ove dvije aktivnosti u zbroju nose najviše **10 bodova**
- Prag na lab. vježbama je **9 bodova** (30% od 30 bodova)
- Prag na ispitima je **30 bodova** na MI+ZI (50% od 30+30 bodova) ili **30 bodova** na ispitu (50% od 60 bodova)
- Bodovi unutar svake aktivnosti zaokružuju se na 2 decimale

Ocjenvivanje



"A grade of 76 or higher will get you favorable mention on my blog."

00.00 – 49.99	Nedovoljan (1)
50.00 – 62.99	Dovoljan (2)
63.00 – 75.99	Dobar (3)
76.00 – 88.99	Vrlo dobar (4)
89.00 – 100.00	Izvrstan (5)

Ukupni bodovi zaokružuju se na 2 decimale.

Za pozitivnu ocjenu potrebno je ostvariti najmanje 50.00 bodova.

Komunikacija

- Zbog velikog broja studenata, nažalost **nismo u mogućnosti odgovarati na e-mailove**
- Kontaktirajte nas online putem [kontakt-obrasca](#)
- Ako imate upit koji nije pokriven ovim obrascem, molim dođite osobno u terminu konzultacija, gdje ćemo rado odgovoriti na Vaša pitanja
- **Općenito, u slučaju bilo kakvih problema koji iziskuju dodatnu komunikaciju, dođite na konzultacije**

Rasprava o međusipitu/završnom ispitu

- Nakon međuispita i nakon završnog ispita provest ćemo upitnik o ispitu
- Nakon toga organizirat ćemo **sastanak** na kojima ćemo sa zainteresiranim studentima raspraviti rezultate ispita i eventualne intervencije, ako su opravdane
- Za sudjelovanje na sastanku moći ćete se **prijaviti** online. U slučaju većeg interesa prednost će imati studenti koji su se prijavili prvi

U slučaju poteškoća ili nedoumica

Ako imate poteškoća sa studiranjem (probleme koje ne možete riješiti sami ili za koje trebate savjet), možete se javiti **Savjetničkoj službi FER-a:** www.fer.unizg.hr/zivot_na_fer-u/zdravlje_i_dobrobit/savjetnicka_sluzba

Ako su problemi povezani s ovim predmetom, dođite na konzultacije.

Otvorene konzultacije

- Svaki **četvrtak, 14:15–15 sati, u D334**
- U tom terminu uvijek možete doći bez najave i razgovarati sa mnom o bilo kojoj temi, ne nužno povezanoj sa SU1 (pitanja, pomoć, savjeti, rasprave itd.)

Web-stranica predmeta i materijali

- <https://www.fer.unizg.hr/predmet/struce1>
- <https://www.fer.unizg.hr/predmet/struce1/obavijesti>
- <https://www.fer.unizg.hr/predmet/struce1/materijali>
 - ▶ Kalendar predmeta
 - ▶ Ishodi učenja (detaljno za svaku od 23 teme)
 - ▶ Pitanja i odgovori (+ poveznica na kontakt-obrazac)
 - ▶ Videopredavanja (za 18 tema)
 - ▶ Predavanja (skripte, za 18 tema)
 - ▶ Natuknice za predavanja
 - ▶ Zadatci za vježbu
 - ▶ Laboratorijske vježbe
 - ▶ Prošlogodišnji ispiti

HAPPY DATA SCIENTIST DOING MACHINE LEARNING

