



SVEUČILIŠTE U ZAGREBU
Fakultet elektrotehnike i računarstva

PARALELNO PROGRAMIRANJE

Poglavlje 06 – Kvantitativna analiza



OCJENA PERFORMANSI

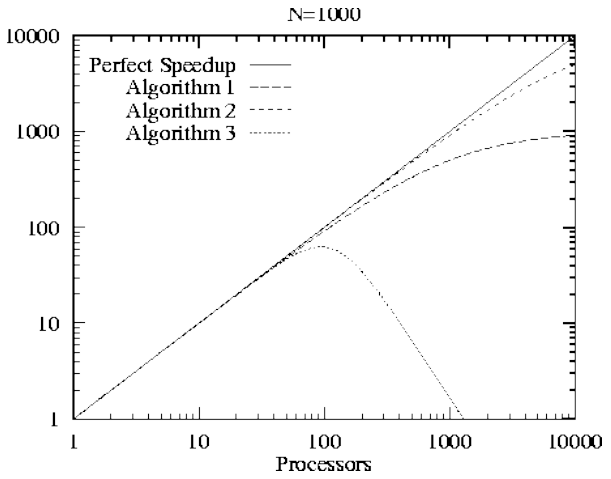
- Kriteriji: ovisni o primjeni
  - multimedija: **kapacitet**, **protočnost** (engl. *throughput*)
  - sustav upravljanja: trajanje **odziva** (engl. *latency*)
  - plaćanje računanja: **učinkovitost**

- U ovom poglavlju:
  - ukupno **trajanje izvođenja** programa (T)
  - **skalabilnost**
    - prilagodba većem problem
    - prilagodba većem broju procesora

NAČIN OPISA PERFORMANSI

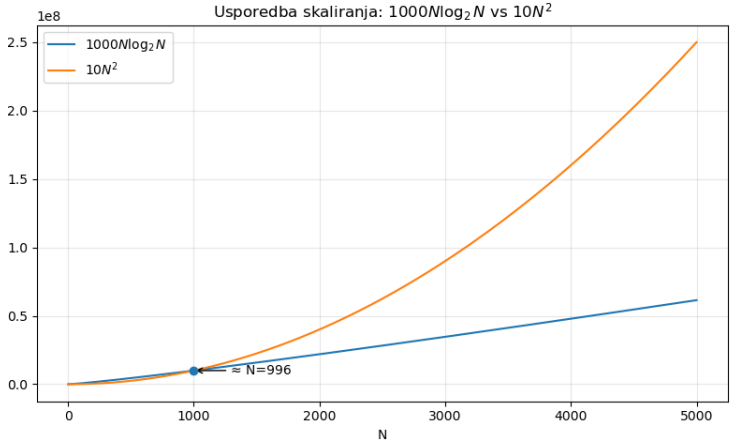
A. Amdahlov zakon

- opisuje *moguće* 'ubrzanje' paralelnog u odnosu na slijedni program
- problem: **različiti načini paralelizacije** programa
- ograničenja na skalabilnost: komunikacija, međusobno čekanje, uvišestručeno računanje



B. Opažanje iz primjera

- mjerenje u zadanom okruženju
- problem: **nepotpuna informacija**



C. Asimptotska analiza

- problem: **idealizirani modeli** (PRAM) ≠konkretno paralelno računalo

MODEL OCJENE PERFORMANSI

- **Trajanje izvođenja** (engl. *execution time*)
  - komponente:
    - **računanje**
    - **komunikacija**
    - **čekanje**

- Pretpostavke:
  - **multiračunalo (sustav zadataka i kanala)**
  - **zanemarujemo topologiju**
  - **bez ograničenja propusnosti**

RAČUNANJE

- **Trajanje računanja T_R**
  - ukupno vrijeme koje **svi procesori** utroše na izvođenje algoritma
  - može se odrediti:
    - **trajanjem slijednog algoritma** (*ako je slijedni program istovjetan paralelnom uz izvođenje na jednom procesoru*)
    - analitički kao **funkcija veličine problema**
  - ako paralelni algoritam uvišestručuje računanje → ovisi i o **broju zadataka**
  - u raznorodnom (heterogenom) sustavu ovisi i o **raspodjeli** zadataka po procesorima (ne rade svi procesori istom brzinom)

KOMUNIKACIJA

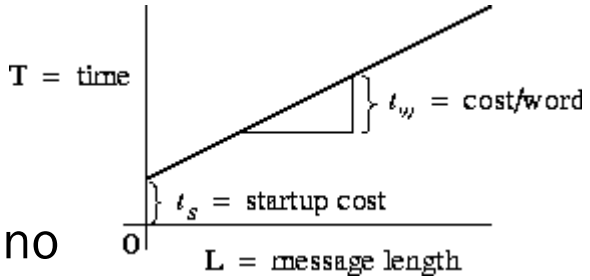
- **Trajanje komunikacije T_K**
  - ukupno vrijeme koje **svi zadaci** utroše na komunikaciju
- Dvije vrste komunikacija:
  - unutarprocesna
  - međuprocesna (na jednom ili između više računala)

Zbog jednostavnosti, pretpostavljamo da su obje vrste usporedive

- Model poruke:
  - **postavljanje** poruke (*message startup time*) – t_s
  - trajanje **prijenosa** jedne riječi – t_w

$$T_{MSG} = t_s + t_w L$$

  - parametri se obično određuju eksperimentalno



ČEKANJE

- **Trajanje čekanja $T_č$**
  - teško za procijeniti
  - uzorci
    - nedostatak posla (nebalansiranost)
    - nedostatak podataka (ovisnost o drugim procesorima)
  - smanjenje
    - bolja raspodjela zadataka
    - preraspodjela podataka

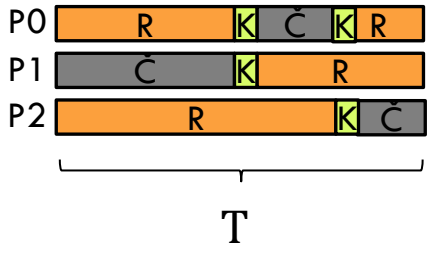
- Složeniji pristup: ako je moguće, projektirati zadatke da obavljaju neki drugi posao dok čekaju na podatke (npr. neblokirajuća komunikacija u MPI)

MODEL OCJENE PERFORMANSI

- **Trajanje izvođenja** definiramo kao
  - količina vremena utrošena na **jednom procesoru** ili kao **zbroj trajanja** na svim procesorima podijeljen s brojem procesora

$$\mathrm{T} = T_R^i + T_K^i + T_{\check{\mathrm{C}}}^i = \frac{T_R + T_K + T_{\check{\mathrm{C}}}}{P}$$

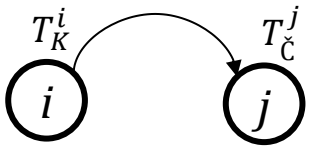
$$T = \frac{1}{P}\left(T_R + T_K + T_{\check{C}}\right) = \frac{1}{P}\left(\sum_{i=1}^{P} T_R^i + \sum_{i=1}^{P} T_K^i + \sum_{i=1}^{P} T_{\check{C}}^i\right)$$

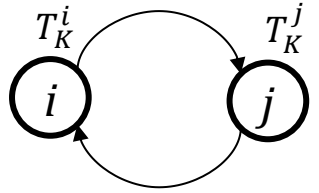


Način komunikacije:

a. jedan zadatak šalje drugome (jedan šalje, drugi čeka)

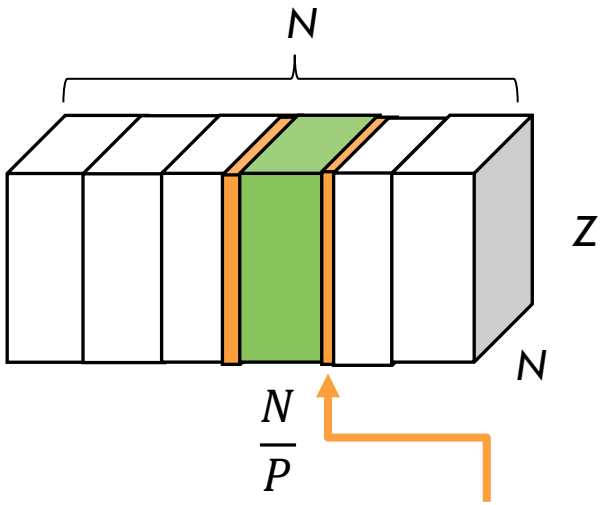
b. **dva zadatka međusobno šalju (istovremeno)**
   - *defaultna pretpostavka*





PRIMJER: 1D ATM. MODEL

- Pretpostavimo 3D mrežu čvorova dimenzije $N * N * Z$, uz P procesora
  - t_c - trajanje računanja za jednu točku u mreži
  - količina računanja jednaka za sve točke
  - procesori jednakih brzina (*čekanje se može zanemariti*); P<N/2



svakom zadatku pridruženo N/P uspravnih ravnina

komuniciraju se samo dva rubna sloja (ravnine) od svakog susjeda

$$T_R = t_c N^2 Z \qquad T_{\check{C}} = 0$$

$$T_{1D,atm.} = \frac{T_R + T_K + T_{\check{C}}}{P} = t_c \frac{N^2 Z}{P} + 2t_s + 4t_w NZ$$

UČINKOVITOST I UBRZANJE

- Učinkovitost

$$E = \frac{T_1}{P * T_p}$$

- Ubrzanje

$$S = P \cdot E = \frac{T_1}{T_P}$$

  - **relativno**: u odnosu na isti algoritam
  - **apsolutno**: u odnosu na najbolji slijedni algoritam

PRIMJER: 1D ATMOSFERSKI MODEL

- Relativna učinkovitost

$$E = \frac{T_1}{P * T_p} = \frac{T_R}{P * \frac{T_R + T_K}{P}} = \frac{t_c N^2 Z}{t_c N^2 Z + 2P(t_s + t_w 2NZ)}$$

ANALIZA SKALABILNOSTI

- Neka pitanja:
  - Odgovara li program zahtjevima za trajanje izvođenja i drugim kriterijima na odredišnom računalu?
  - Kako se program prilagođava povećanjima količine računanja ili broja procesora?
  - Koliko je program osjetljiv na računalne parametre (npr. t_S ili t_W)?
  - Koji je odnos performansi programa s postojećim algoritmima

- **Ponašanje uz stalnu veličinu problema**
- **Ponašanje uz promjenjivu veličinu problema**

PONAŠANJE UZ STALNU VELIČINU PROBLEMA

- Kako se program ponaša (***T_P, E***) uz povećan broj procesora ***(P)*** i konstantnu količinu računanja (***N, T_1= konst.***)

$$E = \frac{T_1}{P * T_p}$$

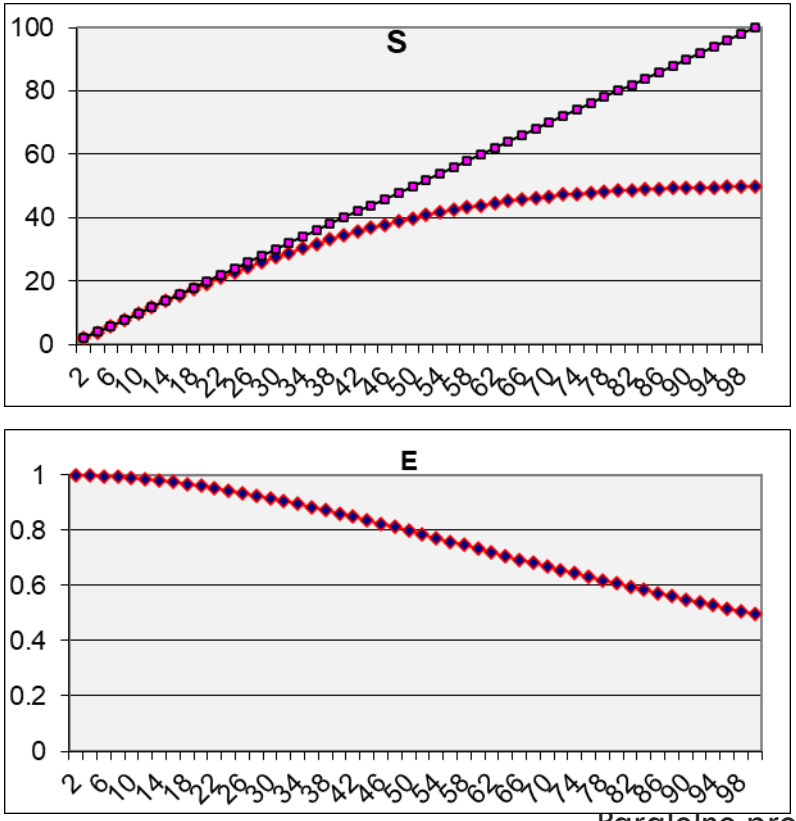
➔ *T_P bi morao padati jednako onoliko koliko P raste da bi učinkovitost ostala ista*

- Učinkovitost u principu monotono opada s povećanjem procesora jer je u praksi gotovo nemoguće postići da troškovi paralelnog rada (komunikacija, sinkronizacija, čekanje) ne ovise o broju procesora
- Motivacija: npr. budžetiranje rada na paralelnom računalu

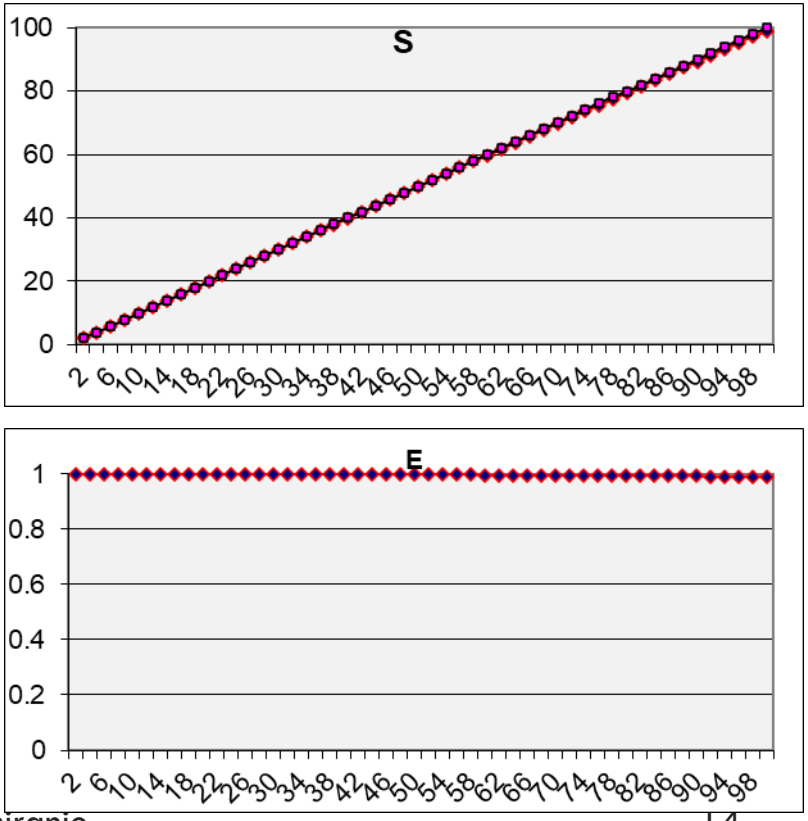
PRIMJER: UČINKOVITOST

$$T=\frac{N}{P}+\frac{N^2}{P}+P \qquad E=\frac{T_1}{PT_p}$$

N=99 (problem srednje veličine)



N=999 (veliki problem)



ZADATAK 1

Paralelno računalo plaća se 1€ po procesoru po satu. Trajanje slijednog algoritma iznosi T_1=10 dana, a učinkovitost par. alg. $E = \frac{3}{2+P}$.

Ako nam je budžet 500€, koje je minimalno trajanje koje možemo platiti i na koliko procesora?

Koje je min. trajanje programa uz proizvoljan broj procesora?

$$P_{MAX} = 4;\ T_P = 120h; C = 480€;\ \lim_{P\to\infty} T_P = \frac{T_1}{3}$$

ZADATAK 2

Paralelno računalo plaća se 1€ po procesoru po satu.

Trajanje izvođenja paralelnog programa je $T_P = 50 + \frac{150}{P}$ sati. Prihod od rezultata izvođenja je $PR = 18(T_1 - T_p)$.

Koje trajanje izvođenja donosi najveću moguću zaradu (dobit) i na koliko procesora?

$P_{MAX} = 7;\ T_P = 71{,}43h$

PONAŠANJE UZ PROMJENJIVU VELIČINU PROBLEMA

- Kako se mora mijenjati veličina posla (**količina računanja T_R**) uz povećanje broja procesora kako bi učinkovitost ostala jednaka?

$$N = f(P); \quad E = \frac{T_1}{P * T_p} = konst.$$

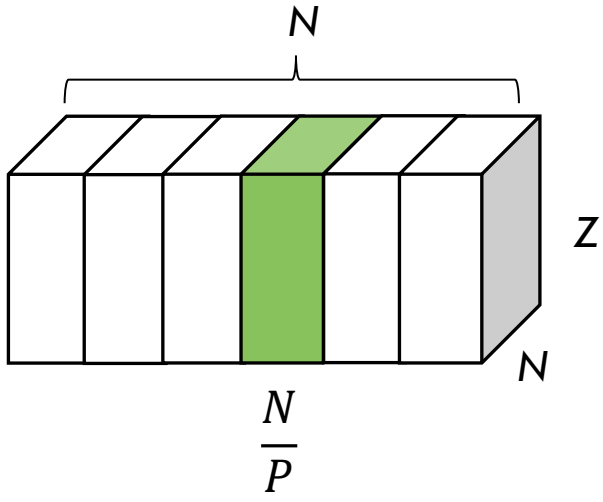
- **IZOUČINKOVITOST:** promjena veličine posla (N) u ovisnosti o broju procesora za stalnu učinkovitost
  - izražava se ***O()* notacijom** ovisnosti o broju procesora
  - ima smisla samo za određene paralelne algoritme, tj, ako ne postoje čvrsta vremenska ograničenja za završetak posla ili ako je moguće povećati problem (*npr. kod obrade slike ne možemo dodati piksele…*)

PRIMJER: 1D ATMOSFERSKI MODEL

Za 1D atm. model odredite kako se mora mijenjati veličina posla u ovisnosti o broju procesora da bi učinkovitost ostala ista?

$$E = \frac{t_c N^2 Z}{t_c N^2 Z + 2 t_s P + 4 t_w N Z P} \approx konst.$$

$N = f(P) = ?$



Za N=P ➔ $t_c Z \approx E\left(t_c Z + t_s \frac{2}{P} + t_w 4Z\right)$

za veliki P teži 0

$T_R = t_c N^2 Z \sim N^2 \sim P^2$ ➔ **IZOUČINKOVITOST: O(P²)**

PROVJERA MODELA I IMPLEMENTACIJE

- Usporedba predviđenog i stvarnog ponašanja
- Uzroci razlike:

  a) model netočan ili neprecizan

  b) program nije u skladu s modelom

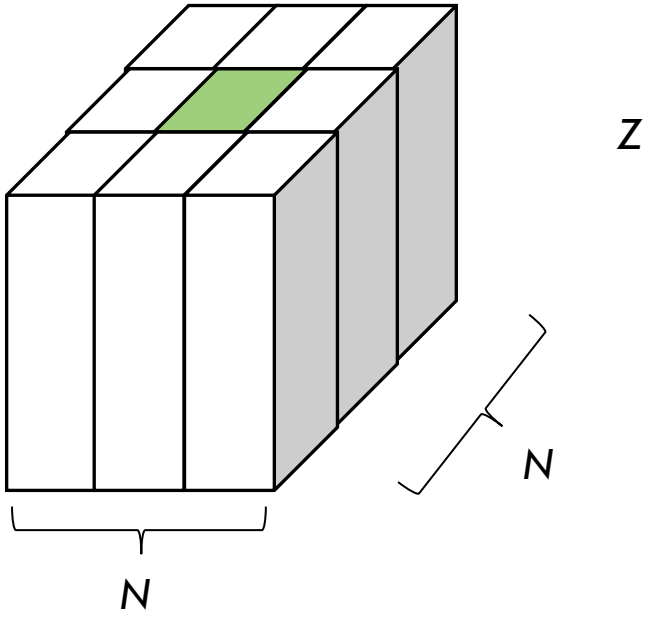
  c) rezultati ili mjerenje nepouzdano
- Mogući nedostaci modela (a):
  - nejednako opterećenje u radu
  - uvišestručeno računanje
  - neprikladni programski alat
  - ograničeni kapacitet komunikacije

NEPRAVILNOSTI UBRZANJA ALGORITMA

- Anomalija ubrzanja: program traje kraće od predviđenog, a razlika je veća za veći P
- Ubrzanje veće od broja procesora: superlinearno ubr.
- Mogući uzroci:
  - priručna memorija (cache, virtualna memorija)
  - anomalije pretrazivanja (search anomaly): (stohasticki) algoritmi pretrazivanja

ZADATAK 3

Odredite trajanje, učinkovitost i izoučinkovitost za 2D atmosferski model.



ZADATAK 4

Odredite učinkovitost i izoučinkovitost za operaciju kvadriranja matrice *N*N*. Matrica je podijeljena na zadatke tako da svaki od P zadataka ima podmatricu jednake veličine. Pretpostavite da je $P=q^2$ i da je *N* djeljiv s *q*.

Trošak jedne operacije množenja je t_c.

$$T = \frac{t_c N^3}{P} + 2(\sqrt{P} - 1)(t_s + t_w \frac{N^2}{P})$$

$$E = \frac{t_c N^3}{t_c N^3 + 2(\sqrt{P} - 1))(t_s P + t_w N^2)}$$

Za $N = \sqrt{P}$ ➔ Izoučinkovitost $O(P\sqrt{P})$

ZADATAK 5

Paralelni program računa nove vrijednosti matrice veličine n x n tako da transponira matricu, a zatim izračuna novu vrijednost svakog elementa (računanje vrijednosti jednog elementa traje t_c). Izrazite trajanje izvođenja ove operacije na P procesora te učinkovitost i izoučinkovitost algoritma ako je matrica na procesore podijeljena:

a) po stupcima (svaki processor ima jednak broj stupaca)

b) po podmatricama jednake veličine

Pretpostavite da je $P=q^2$ i da je N djeljiv s q.

ZADATAK 6

Na svakom od P procesa nalazi se jednaki dio niza veličine N. Sve elemente niza potrebno je dostaviti na proces 0. Koliko je trajanje ove operacije, ako se komunikacija odvija po uzorku binarnog stabla? Napomene: N je djeljivo s P, P je potencija broja 2, a parametri komunikacije su t_s i t_w.

ZADATAK 7

Paralelni algoritam iterativno računa elemente matrice veličine N*N. Nova vrijednost elementa računa se uz pomoć neposrednih vrijednosti elemenata gore i lijevo, s tim da matrica ima ‘spojene’ sve bridove (vrijednost elementa A[1,1] računa se pomoću A[N,1] i A[1,N] . Pretpostavite da stanje svakog elementa omogućuje istovremeno računanje novih vrijednosti za sve elemente matrice. Trošak računanja jednog elementa iznosi t_c, a parametri komunikacije su t_s i t_w. Izrazite trajanje izvođenja jedne iteracije na P procesora te učinkovitost i izoučinkovitost algoritma ako je matrica na procesore podijeljena:

a. po stupcima (svaki procesor ima jednak broj stupaca),

b. po podmatricama jednake veličine.

ZADATAK 9

Paralelni algoritam iterativno računa nove vrijednosti elemenata matrice NxN. Nova vrijednost elementa računa se s pomoću vrijednosti svih elemenata u istom stupcu, *iznad* promatranog elementa. Trošak računanja jednog elementa iznosi t_c. Izrazite trajanje izvođenja jedne iteracije na P procesora te učinkovitost algoritma ako je matrica na procesore podijeljena:

a) po retcima (svaki procesor ima jednak broj redaka);

b) po podmatricama jednakih dimenzija;

c) predložite podjelu matrice uz koju se postiže najbolja učinkovitost paralelnog algoritma i odredite iznos takve učinkovitosti.