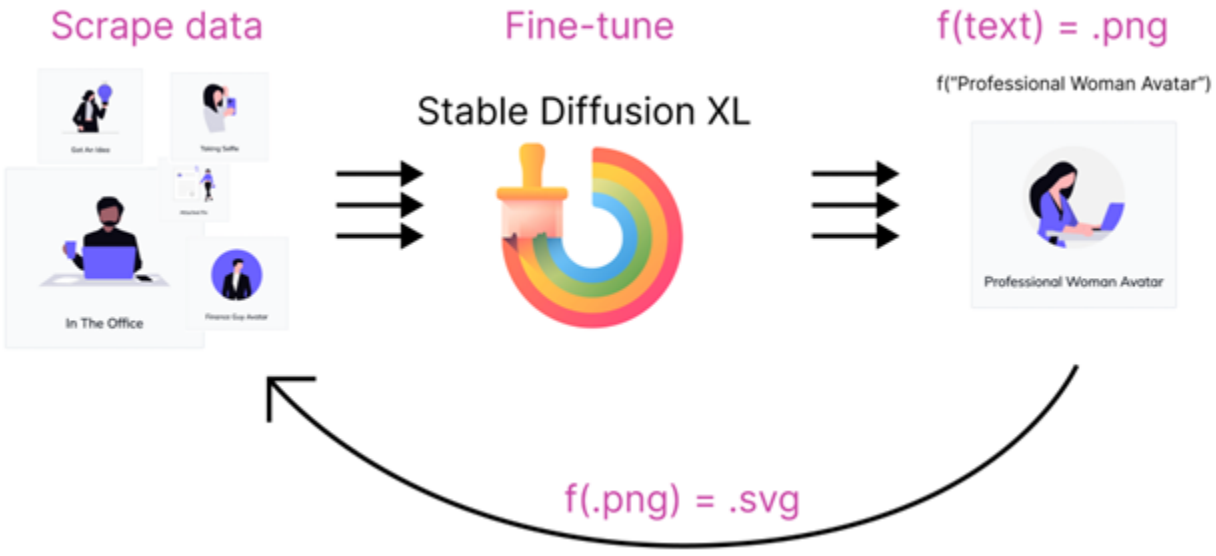
Primjena strojnog učenja u generiranju ilustracija u SVG formatu

Uvod:
U okviru kolegija Seminar 1, istražene su metode strojnog učenja za generiranje ilustracija u SVG formatu. Konkretno, istražene su mogućnosti prilagodbe open-source modela za generiranje slika te njegova optimizacija za kreiranje stiliziranih ilustracija koje zadržavaju prepoznatljivu strukturu i jednostavnost boja.

Opis problema i ciljevi istraživanja:
Razvijanje sustava koji omogućuje pretvorbu teksta u SVG ilustracije s predefiniranim stilom. Taj proces potrebno je realizirati kroz nekoliko faza:

- **Prikupljanje podataka:** Prikupljene su ilustracije i popratni tekstualni opisi s web stranice undraw.co/illustrations. Dobiveni podaci sadrže SVG reprezentacije slika te opisne tekstualne oznake.
- **Fino podešavanje generativnog modela:** Korišten je open-source model poput Stable Diffusiona, koji je fino podešen na skupu prikupljenih podataka kako bi generirao slike u zadanom stilu.
- **Segmentacija slika i konverzija u SVG:** Nakon generiranja slika u raster formatu, primijenjeni su algoritmi segmentacije koji omogućuju njihovu vektorizaciju i pretvorbu u SVG format.



Metodologija:

- **Analiza postojećih rješenja:** Pregledana je znanstvena i stručna literatura vezana uz generativne modele, segmentaciju slika i obradu SVG formata.

- **Eksperimentalna evaluacija:** Uspoređene su različite arhitekture modela i metode optimizacije kako bi se odredila najprikladnija konfiguracija za postizanje željenih rezultata.
- **Implementacija i testiranje:** Razvijen je programski sustav koji povezuje generativne modele s postupkom segmentacije i vektorizacije.

Očekivani doprinos i zaključak:
Ovo istraživanje doprinosi boljem razumijevanju prilagodbe generativnih modela za specifične stilove ilustracija te njihovoj automatskoj pretvorbi u SVG format. Razvijeni model ima potencijalnu primjenu u web dizajnu, web razvoju, marketingu, te srodnim područjima.