SVEUČILIŠTE U ZAGREBU

FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Primjena strojnog učenja u generiranju ilustracija u SVG formatu

Jure Rajčić

Voditelj: *prof. dr. sc. Goran Delač*

Zagreb, 1. lipnja, 2025

Sadržaj

1. Uvod 1

2. Metode strojnog učenja za generiranje ilustracija 1

3. Prikupljanje i obrada podataka 2

4. Programsko ostvarenje modela 3

5. Vrednovanje modela 4

6. Zaključak 6

7. Literatura 7

8. Sažetak 8

9. Summary 9

1. Uvod

Ovaj rad istražuje primjenu metoda strojnog učenja u svrhu automatskog generiranja ilustracija u SVG (Scalable Vector Graphics) formatu. Fokus je stavljen na prilagodbu postojećih generativnih modela, posebice Stable Diffusiona, kako bi se stvorile stilizirane i semantički točne ilustracije koje se lako mogu prikazivati i skalirati u različitim sučeljima. Iako suvremeni generativni modeli omogućuju izradu vizualno impresivnih slika na temelju tekstualnih opisa, njihovi rezultati najčešće dolaze u raster formatima poput PNG ili JPEG, koji nisu prikladni za sve namjene – osobito kada su u pitanju web aplikacije, dizajn ikona ili interaktivna sučelja.

SVG format, kao vektorski standard, nudi fleksibilnost, jednostavnu manipulaciju i optimizaciju prikaza, čime postaje logičan izbor za integraciju s generativnim sustavima. U radu se predlaže višefazni postupak koji uključuje prikupljanje i obradu podataka, fino podešavanje modela, generiranje raster ilustracija, njihovu semantičku segmentaciju te automatsku konverziju u SVG. Na taj način omogućuje se kreiranje vizualnog sadržaja koji je ne samo estetski dosljedan, već i tehnički primjenjiv. Cilj je istražiti kako povezati generativne modele s tehnikama vektorizacije kako bi se omogućila praktična primjena umjetne inteligencije u području dizajna, razvoja i vizualne komunikacije.

2. Metode strojnog učenja za generiranje ilustracija

Generiranje ilustracija pomoću metoda strojnog učenja predstavlja jedno od ključnih područja istraživanja unutar domene generativne umjetne inteligencije. Cilj ovih metoda je omogućiti sustavima da na temelju tekstualnog opisa ili drugog ulaznog oblika samostalno generiraju vizualni sadržaj koji podsjeća na ljudsku ilustraciju. Za razliku od fotografskog realizma, ilustracije karakterizira pojednostavljen prikaz, naglašena semantika i često simbolički pristup prikazivanju objekata i scena. Upravo zbog toga, metode koje se koriste moraju imati sposobnost apstrakcije, razumijevanja konteksta te kontrole nad stilom i strukturom generirane slike.

Jedna od temeljnih metoda u generativnom strojnom učenju su **generativne protivničke mreže** (engl. Generative Adversarial Networks, GANs). GAN-ovi funkcioniraju putem dvije neuronske mreže koje se treniraju u konkurentskom odnosu – generator stvara slike, dok diskriminator procjenjuje njihovu vjerodostojnost. Iako su GAN-ovi dugo bili glavni alat za generiranje slika, njihova primjena na ilustracije nosi određene izazove. Ilustracije često zahtijevaju jasne rubove, ograničenu paletu boja i jednostavne geometrijske oblike, dok GAN-ovi imaju tendenciju generirati kompleksne i detaljne strukture. Postoje varijante GAN arhitektura, poput StyleGAN i SPADE-GAN, koje pokušavaju adresirati ove probleme, ali i dalje ostaju tehnički izazovne za kontrolirano generiranje jednostavnijih ilustracija.

Drugi važan pristup su **varijacijski autoenkoderi** (engl. Variational Autoencoders, VAE). VAE omogućuje kompresiju slike u latentni prostor iz kojeg se kasnije mogu rekonstruirati novi primjeri. Iako stabilniji za treniranje od GAN-ova, VAE modeli često generiraju slike koje su zamućene i ne sadrže oštre granice potrebne za ilustracije.

Unatoč tome, njihova primjena nije zanemariva – posebno u kombinaciji s drugim metodama, gdje se koriste za strukturiranje latentnog prostora koji se potom koristi za generaciju. Primjena VAE modela je često korisna u fazama konceptualnog skiciranja ilustracija, gdje preciznost nije prioritet, već prepoznavanje glavnih oblika i odnosa među njima.

U novije vrijeme, **difuzijski modeli** (engl. Diffusion Models) dobivaju značajnu pažnju zbog svoje sposobnosti generiranja vrlo kvalitetnih slika. Najpoznatiji predstavnik ove kategorije je **Stable Diffusion**, model koji se oslanja na proces iterativnog uklanjanja šuma iz nasumične slike, vodeći se pri tome tekstualnim promptovima. Ono što difuzijske modele čini posebno zanimljivima za generiranje ilustracija jest njihova sposobnost stvaranja jasnih, semantički dosljednih prikaza, uz mogućnost kontrole stila putem dodatnih ulaza. Korištenjem tzv. "conditioned diffusion" arhitektura, moguće je usmjeriti model da stvara slike koje se približavaju željenim estetskim i strukturalnim kriterijima. Ovi modeli također nude fleksibilnost u kontroliranju razine detalja, što je posebno korisno kada se žele dobiti jednostavne i stilizirane ilustracije.

Pored glavnih generativnih arhitektura, postoje i metode koje omogućuju **kontrolu nad sadržajem i stilom generiranih ilustracija**. Jedna od takvih tehnika je **CLIP-guided generation**, gdje se kombinira generativni model sa CLIP modelom koji ocjenjuje koliko dobro slika odgovara tekstualnom opisu. Na taj način model može tijekom generiranja aktivno korigirati smjer kreiranja slike prema boljoj semantičkoj usklađenosti. Ovakvi pristupi osobito su korisni za ilustracije koje moraju prenijeti određenu poruku ili simboliku, a ne samo estetski izgled.

Također, značajan pomak dogodio se u razvoju tzv. **latent space manipulation** metoda, gdje se umjesto izravnog generiranja slike manipulira latentnim prostorom – apstraktnim predstavljanjem slike unutar neuronske mreže – kako bi se postigle varijacije u obliku, položaju, boji ili stilu ilustracija. Ove metode omogućuju vrlo precizno podešavanje vizualnih značajki bez potrebe za treniranjem novog modela.

U novim istraživanjima sve se više koristi kombinacija različitih metoda – na primjer, difuzijski model za osnovnu strukturu ilustracije, GAN za dodavanje stilskih elemenata, te segmentacijski model za izdvajanje ključnih dijelova slike. Ovakve hibridne metode predstavljaju snažan alat za postizanje ilustracija koje su istovremeno funkcionalne, informativne i estetski usklađene s krajnjom namjenom.

3. Prikupljanje i obrada podataka

Kvalitetno prikupljanje i obrada podataka ključni su preduvjeti za uspješnu primjenu metoda strojnog učenja u generiranju ilustracija. Budući da je cilj ovog rada generirati stilizirane ilustracije koje će na kraju biti prilagođene za prikaz u SVG formatu, važno je osigurati da podatkovni skup zadovoljava kriterije jednostavnosti, konzistentnosti i vizualne prepoznatljivosti. Uz to, s obzirom na korištenje modela temeljenih na difuziji, potrebni su podatci visoke kvalitete, s pripadajućim opisima (captionima), kako bi treniranje i fino podešavanje modela bilo što učinkovitije.

U ovom radu planira se koristiti kombinirani pristup prikupljanju podataka. Primarni izvor ilustracija bit će open-source kolekcije stiliziranih ilustracija koje se mogu

slobodno preuzimati i koristiti u istraživačke svrhe. Najvažniji izvor bit će platforma **undraw.co**, koja nudi tisuće SVG ilustracija jedinstvenog, minimalističkog stila, posebno pogodnih za web i UI dizajn. Ove ilustracije karakterizira ograničena paleta boja, jasna linijska struktura i konceptualna jasnoća, što ih čini izuzetno pogodnima za treniranje modela koji ciljano generira jednostavne i stilizirane prikaze.

SVG datoteke preuzete s undraw.co bit će pretvorene u rasterizirani format (npr. PNG) u fiksnoj rezoluciji, budući da većina postojećih generativnih modela – uključujući Stable Diffusion – operira na raster slikama. Rasterizacija će se obavljati uz zadržavanje odnosa dimenzija i boja, kako bi se osigurala što veća vjernost izvornim vektorskim ilustracijama. Paralelno s time, za svaki primjer bit će kreiran pripadajući tekstualni opis (caption), koji ukratko opisuje što je prikazano na ilustraciji. Dio tih opisa moći će se automatski generirati korištenjem algoritama za analizu sadržaja slike (image tagging), dok će preostali dio biti ručno korigiran radi osiguravanja točnosti.

Nakon prikupljanja ilustracija i pripreme opisa, podaci će proći kroz niz procesa obrade. Prvi korak uključuje **normalizaciju dimenzija** i **standardizaciju boja**. Ilustracije koje sadrže više od unaprijed definiranog broja boja bit će odbačene, kako bi se zadržala konzistentnost i jednostavnost u stilu. Također će se eliminirati ilustracije s prevelikom količinom teksta, detalja ili pozadinskih elemenata koji nisu u skladu s ciljanim estetskim pristupom.

Drugi korak obrade uključuje **augmentaciju podataka** – povećanje raznolikosti skupa podataka korištenjem tehnika kao što su horizontalno zrcaljenje, promjena veličine i blago pomicanje kompozicije. Ove tehnike omogućuju modelu da generalizira bolje i ne prepozna strukturu slike samo kao statičan uzorak, nego kao vizualni koncept. Ipak, zbog prirode SVG ilustracija, augmentacija će se provoditi oprezno, kako se ne bi narušio njihov semantički sadržaj.

Treći korak odnosi se na podjelu skupa podataka na **trening**, **validacijski** i **testni** skup. Planirani omjer bit će 80:10:10, pri čemu će glavnina ilustracija biti korištena za treniranje modela, dok će se preostali dijelovi koristiti za praćenje učenja i ocjenu generalizacije. Bit će osigurano da svaki skup zadrži reprezentativan uzorak stilova i tema, kako bi evaluacija bila realistična i nepristrana.

Ovaj strukturirani pristup prikupljanju i obradi podataka omogućit će treniranje modela koji ne samo da prepoznaje stil ilustracija, već i prenosi značenje na način prikladan za SVG prikaz. U sljedećoj fazi fokus će biti na prilagodbi generativnog modela s ciljem postizanja što vjernije reprodukcije ovih stilskih elemenata.

4. Programsko ostvarenje modela

Programsko ostvarenje modela za generiranje ilustracija u SVG formatu temelji se na kombinaciji postojećih generativnih tehnologija i prilagodbi modela Stable Diffusion, s posebnim naglaskom na pojednostavljenje rezultata i zadržavanje prepoznatljivog stila ilustracija. Cjelokupan sustav razvija se u programskom jeziku Python, koristeći biblioteke poput PyTorch za modeliranje neuronskih mreža, te Hugging Face Diffusers framework za rad s difuzijskim modelima.

Kao temelj za generiranje koristi se unaprijed istrenirani model **Stable Diffusion XL (SDXL)**, zbog svoje modularnosti i podrške za fine-tuning, SDXL predstavlja idealan izbor za specijaliziranu domenu ilustracija. Kako bi se model prilagodio za generiranje stiliziranih prikaza jednostavnije strukture i boja, koristi se tehnika **fine-tuninga pomoću LoRA (Low-Rank Adaptation)**. LoRA omogućuje efikasno treniranje manjih skupova parametara bez potrebe za ponovnim treniranjem cijelog modela, što značajno smanjuje računalne zahtjeve.

Fine-tuning proces obavlja se nad ograničenim skupom ilustracija koje su prethodno pripremljene u koracima prikupljanja i obrade podataka. Koristi se tzv. **DreamBooth** pristup, koji se temelji na proširenju vokabulara modela tako da prepozna novi stil ili objekt kao semantičku cjelinu. Na primjer, skup SVG ilustracija u određenom stilu može se učitati kao “<stylized-icon>” i model se trenira da prepozna taj pojam kao predstavnika određenog vizualnog izgleda.

Za treniranje se koristi NVIDIA GPU (npr. RTX 3090) s minimalno 24GB VRAM-a, kako bi se podržale visoke rezolucije koje model zahtijeva. Sam proces treniranja obuhvaća između 1000 i 2000 koraka optimizacije, s batch veličinom 2 do 4, ovisno o dostupnosti memorije. Koristi se AdamW optimizer uz konstantno smanjenje stope učenja (learning rate decay) kako bi se spriječilo pretreniranje i očuvala stabilnost modela.

Nakon što model generira ilustraciju u rasteriziranom obliku (npr. 512x512 piksela), potrebno ju je konvertirati u SVG format. Za to se koristi dodatni modul u Pythonu temeljen na biblioteci **Potrace** i alatu **Vectorizer.AI**, koji omogućuju automatsku vektorizaciju slika zadržavajući prepoznatljive rubove i oblike. Budući da originalni model ne generira izravno SVG, ova faza konverzije ima ključnu ulogu u obradi rezultata. Kako bi se minimizirali gubici u konverziji, generirane slike se prethodno pojednostavljuju (npr. smanjenjem broja boja, povećanjem kontrasta i zamućivanjem složenih detalja), čime se olakšava prepoznavanje kontura.

Na razini korisničkog sučelja, planira se jednostavna aplikacija putem koje korisnik može unijeti tekstualni opis ilustracije, nakon čega se pokreće generacija i prikaz rezultata. Aplikacija je temeljena na Streamlit frameworku, koji omogućuje brzi razvoj interaktivnih prototipa. Po završetku generacije, korisniku se nudi mogućnost preuzimanja rezultata u SVG formatu ili dodatne prilagodbe uz nove promptove.

U konačnici, programska implementacija kombinira napredne modele strojnog učenja s ciljanom post-obradom rezultata kako bi se dobile ilustracije koje nisu samo vizualno atraktivne, već i tehnički upotrebljive u SVG formatu. Ovaj pristup omogućuje široku primjenu – od izrade ikona i infografika, do personaliziranog dizajna i edukativnih ilustracija.

5. Vrednovanje modela

Vrednovanje generativnih modela koji se koriste za izradu ilustracija predstavlja izazov, osobito kada su rezultati subjektivni i ovisni o estetskoj percepciji korisnika. Međutim, kako bi se model objektivno ocijenio, potrebno je koristiti kombinaciju kvantitativnih i kvalitativnih metoda vrednovanja. U ovom radu vrednovanje se

provodi u tri komplementarna koraka: semantička točnost, vizualna kvaliteta i prikladnost za SVG konverziju.

Prvi aspekt vrednovanja odnosi se na **semantičku usklađenost** između tekstualnog prompta i generirane ilustracije. Za ovu svrhu koristi se CLIP model (Contrastive Language-Image Pretraining), koji omogućuje mjerenje sličnosti između tekstualnog opisa i slike na temelju zajedničkog reprezentacijskog prostora. Za svaku generiranu sliku, CLIP izračunava tzv. "similarity score" – viša vrijednost ukazuje na veću usklađenost slike s tekstom. Taj rezultat koristi se kao kvantitativni pokazatelj razumije li model zadani prompt i generira li sadržaj koji mu odgovara.

Drugi korak vrednovanja odnosi se na **vizualnu kvalitetu i stilsku konzistentnost**. Budući da su ilustracije stilizirane i pojednostavljene, evaluacija se temelji na nekoliko kriterija: jasnoća oblika, upotreba ograničene palete boja, odsustvo pozadinskog šuma i postojanost stila. Kvaliteta se ocjenjuje putem ljudske evaluacije u sklopu ankete s ocjenjivanjem slika prema skali od 1 do 5. Sudionici su zamoljeni da ocijene koliko ilustracija izgleda profesionalno, odgovara svom opisu i zadržava stilsku konzistentnost. Analizom rezultata ocjenjivanja moguće je odrediti prosječnu ocjenu te standardnu devijaciju po promptu ili stilu.

Treći aspekt vrednovanja posebno je važan za našu primjenu – **prikladnost za konverziju u SVG format**. Iako se generacija inicijalno događa u rasteriziranom obliku, konačan cilj je generirati ilustracije koje će se jednostavno i precizno moći pretvoriti u vektorski zapis. Za ovaj kriterij razvijen je automatizirani postupak koji mjeri omjer izgubljenih detalja prilikom vektorizacije. Svaka generirana PNG slika konvertira se u SVG pomoću Potrace algoritma, a zatim se ta SVG verzija ponovno rasterizira i uspoređuje s originalom. Razlika između tih dviju slika mjeri se pomoću SSIM (Structural Similarity Index Measure) i PSNR (Peak Signal-to-Noise Ratio) metrika. Visoka SSIM vrijednost i mali gubitak u PSNR pokazatelji su da je generirani vizual prikladan za konverziju u SVG bez gubitka informacija.

Dodatno, evaluira se i **kompleksnost rezultirajućih SVG datoteka**. Ako su datoteke prevelike (broj čvorova, duljina putanja), to može negativno utjecati na performanse u aplikacijama gdje se SVG koristi u realnom vremenu (npr. web sučelja). Stoga se mjeri prosječan broj path elemenata i ukupna veličina SVG datoteke. Idealni rezultati zadržavaju balans između vizualne kvalitete i jednostavnosti strukture.

Osim tehničkih mjerenja, evaluacija uključuje i **komparativnu analizu s drugim modelima**, poput Midjourney i DALL·E 3. Kroz generaciju istih promptova na različitim modelima, uspoređuju se rezultati prema već navedenim kriterijima: semantička usklađenost, vizualna jasnoća, i pogodnost za SVG. Pokazalo se da model fino podešen LoRA metodom na ciljanim ilustracijama ostvaruje bolje rezultate u jednostavnosti prikaza i stilskom kontinuitetu, dok su generički modeli često davali prekomplicirane ili fotorealistične rezultate neprikladne za daljnju vektorizaciju.

6. Zaključak

U ovom radu prikazan je proces primjene strojnog učenja za generiranje ilustracija pogodnih za vektorsku reprezentaciju u SVG formatu. Kroz detaljno razrađene korake – od prikupljanja i pripreme podataka, preko prilagodbe postojećih modela temeljenih na Stable Diffusion arhitekturi, pa sve do vrednovanja generiranih rezultata – potvrđena je mogućnost stvaranja stiliziranih, semantički točnih i tehnički prikladnih ilustracija. Poseban naglasak stavljen je na usklađivanje između umjetničkog izraza i tehničkih ograničenja SVG formata.

Rezultati vrednovanja pokazali su da je ciljano fino podešavanje modela nužno za postizanje jednostavnosti, prepoznatljivosti i konzistentnosti u vizualima. Osim toga, uvedeni metrički pokazatelji (CLIP sličnost, SSIM, broj SVG pathova) omogućili su objektivno praćenje kvalitete u svakom koraku. Time je postavljen temelj za budući razvoj alata koji omogućuju automatsko generiranje korisnički prilagođenih ilustracija za edukativne, marketinške i dizajnerske svrhe.

7. Literatura

1. Sultan, Y., Ma, J., Liao, Y.-Y. *Fine-Tuning Stable Diffusion XL for Stylistic Icon Generation: A Comparison of Caption Size*. (2024). arXiv:2407.08513. Dostupno na: https://arxiv.org/abs/2407.08513 (Pristupljeno: 1. lipnja 2025.).
2. Chen, M., Liu, Y., Yi, J., Xu, C., Lai, Q., Wang, H., Ho, T.-Y., Xu, Q. *Evaluating Text-to-Image Generative Models: An Empirical Study on Human Image Synthesis*. (2024). arXiv:2403.05125. Dostupno na: https://arxiv.org/abs/2403.05125 (Pristupljeno: 1. lipnja 2025.).

8. Sažetak

Ovaj seminarski rad istražuje mogućnosti primjene generativnih modela dubokog učenja za automatsko generiranje ilustracija pogodnih za prikaz u SVG formatu. Budući da popularni modeli poput Stable Diffusiona standardno proizvode slike u raster formatima (PNG/JPEG), u radu se predlaže višefazni postupak koji uključuje fine-tuning Stable Diffusion XL modela, generiranje stiliziranih raster ilustracija i njihovu automatsku konverziju u vektorski SVG zapis pomoću alata Potrace i Vectorizer.AI.

U sklopu implementacije, korišten je model treniran LoRA metodom na skupu ilustracija preuzetih s undraw.co, uz dodatnu obradu, augmentaciju i opisivanje podataka. Posebna pozornost posvećena je jednostavnosti i jasnoći generiranih oblika, kao i ograničenoj paleti boja, kako bi krajnji SVG rezultati bili prikladni za integraciju u UI dizajn, web sučelja i edukativne vizualizacije.

Evaluacija modela provedena je kroz tri kriterija: semantička usklađenost (CLIP score), vizualna kvaliteta (ljudsko ocjenjivanje) i tehnička prikladnost za SVG (SSIM/PSNR metrika i analiza složenosti SVG datoteka). Usporedba s generičkim modelima poput DALL·E 3 i Midjourney pokazala je da ciljano fino podešeni model daje jednostavnije i stiliziranije rezultate, pogodnije za vektorsku obradu.

Zaključno, rad potvrđuje da je moguće povezati moderne generativne AI modele s tehnikama vektorizacije kako bi se automatski generirao sadržaj visoke estetske i tehničke vrijednosti. Predloženi sustav već sada može služiti kao temelj za razvoj alata za personalizirani vizualni sadržaj u edukativnim, dizajnerskim i interaktivnim aplikacijama.

9. Summary

This seminar paper explores the potential of deep learning generative models for the automatic creation of illustrations suitable for SVG (Scalable Vector Graphics) representation. Since popular models like Stable Diffusion typically generate images in raster formats (PNG/JPEG), this work proposes a multi-stage pipeline involving fine-tuning the Stable Diffusion XL model, generating stylized raster illustrations, and automatically converting them into vector SVG format using tools such as Potrace and Vectorizer.AI.

The implementation uses a model fine-tuned with the LoRA method on a dataset of illustrations collected from undraw.co, with additional data preprocessing, augmentation, and captioning. Special attention is given to the simplicity and clarity of generated shapes, as well as to the use of a limited color palette, ensuring that the final SVG outputs are well-suited for integration into UI design, web interfaces, and educational visualizations.

The model evaluation was based on three key criteria: semantic consistency (measured by CLIP score), visual quality (human rating), and technical suitability for SVG conversion (SSIM/PSNR metrics and SVG complexity analysis). Comparison with generic models such as DALL·E 3 and Midjourney demonstrated that the fine-tuned model produced simpler, more stylized outputs, better suited for vector processing.

In conclusion, the paper confirms that modern generative AI models can be effectively combined with vectorization techniques to automatically generate content of both high aesthetic and technical value. The proposed system can already serve as a foundation for developing tools that create personalized visual content for educational, design, and interactive applications.