Klasifikacija i segmentacija 3D objekata

Petra Buršić
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
petra.bursic@fer.hr

Matea Bušić
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
matea.busic@fer.hr

Jure Rajčić
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
jure.rajcic@fer.hr

Ivan Sesar
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
ivan.sesar@fer.hr

Hana Šlipogor
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
hana.slipogor@fer.hr

***Sažetak*—**U ovom radu prikazana je primjena PointNet neuronske mreže za klasifikaciju i segmentaciju trodimenzionalnih objekata temeljenih na skupovima točaka. Model je evaluiran na skupovima podataka ModelNet10 i ShapeNet. Eksperimentalni rezultati pokazuju da predloženi pristup omogućuje učinkovitu obradu 3D podataka i postiže zadovoljavajuću točnost.

Ključne riječi*—3D, PointNet, klasifikacija, segmentacija*

I. Uvod

Trodimenzionalni objekti često su predstavljeni skupovima točaka dobivenima 3D senzorima ili simulacijama. Takav oblik zapisa omogućuje precizan opis geometrije objekta, ali istovremeno predstavlja izazov zbog neuređene strukture i promjenjivog broja točaka. Klasični pristupi obradi 3D podataka temelje se na pretvorbi u voksele (trodimenzionalni ekvivalent piksela) ili mrežne strukture, što može dovesti do gubitka informacija i povećanja računske složenosti. Razvojem dubokog učenja razvijeni su modeli koji omogućuju izravnu obradu skupova točaka. Jedan od takvih modela je PointNet, koji koristi neuronske mreže za ekstrakciju globalnih i lokalnih značajki bez potrebe za dodatnom transformacijom podataka.

U ovom radu primjenjuje se PointNet arhitektura za zadatke klasifikacije i segmentacije trodimenzionalnih objekata. U nastavku rada opisan je korišteni skup podataka i arhitektura modela, zatim su prikazani eksperimentalni rezultati te provedena analiza dobivenih rezultata.

II. Pregled problema i postojećih rješenja

A. Reprezentacije 3D podataka u dubokom učenju

U literaturi se problem obrade trodimenzionalnih objekata rješava korištenjem različitih reprezentacija 3D podataka. Jedan od ranijih pristupa temelji se na vokselizaciji, pri čemu se objekt prikazuje kao volumetrijska mreža pogodna za primjenu trodimenzionalnih konvolucijskih neuronskih mreža. Drugi čest pristup koristi višestruke 2D projekcije 3D objekta, koje se zatim obrađuju standardnim 2D konvolucijskim mrežama. Iako takve metode omogućuju korištenje postojećih arhitektura dubokog učenja, često dovode do gubitka geometrijskih informacija te povećane računske i memorijske složenosti.

B. PointNet kao pristup temeljen na točkastim skupovima

Zbog nestrukturirane prirode točkastih skupova i njihove permutacijske neovisnosti, razvijeni su modeli koji omogućuju njihovu izravnu obradu. Jedan od najznačajnijih takvih modela je PointNet, predložen kao rješenje koje obrađuje skupove točaka bez potrebe za transformacijom u regularne strukture. PointNet obrađuje svaku točku neovisno pomoću višeslojnih perceptrona te koristi simetričnu funkciju za agregaciju značajki, čime se osigurava neovisnost o redoslijedu točaka. Na taj način uče se globalne značajke objekta koje se koriste za zadatke klasifikacije i segmentacije.

C. Proširenja PointNet pristupa i alternativne metode

Na temelju osnovne PointNet arhitekture razvijena su brojna proširenja s ciljem poboljšanja učenja lokalnih značajki i obrade složenijih geometrija. Jedan od najpoznatijih primjera je PointNet++, koji uvodi hijerarhijski pristup i lokalna susjedstva točaka. Osim point-based metoda, u literaturi se pojavljuju i modeli temeljeni na grafovima te transformatorima, koji nastoje bolje modelirati lokalne i globalne odnose između točaka. Unatoč tome, PointNet i njegove izvedenice često se koriste kao referentni modeli u istraživanjima klasifikacije i segmentacije 3D točkastih skupova.

III. Opis rješenja

A. Klasifikacija

Arhitektura originalne PointNet mreže opisana u [1] temelji se na obradi na razini pojedine točke, pri čemu se svaka točka mapira u prostor značajki pomoću istog višeslojnog perceptrona, a zatim se informacije iz svih točaka agregiraju simetričnom funkcijom. Time se izbjegava potreba za vokselizacijom i sličnim postupcima diskretizacije koji su bili česti u ranijim pristupima. Ta je ideja preuzeta i u pojednostavljenoj varijanti PointNeta implementiranoj u ovom radu. Dodatni izazov predstavlja prostorna orijentacija objekta zbog koje se značajke instanci iste klase mogu jako

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

razlikovati u višedimenzionalnom prostoru. Zbog toga originalni PointNet uvodi T-Net modul, čija je uloga naučiti transformaciju na razini pojedinog primjera kako bi se smanjile razlike uzrokovane orijentacijom i kako bi daljnji dio mreže dobio konzistentniji ulaz. U ovom radu implementirane su varijante mreže s T-Net modulom i bez njega radi usporedbe performansi na korištenom skupu podataka. Arhitektura implementirane PointNet mreže nalazi se u tablici 1.

Blok	Sloj	Tip sloja	ulaz - izlaz
mlp1	1	Linear	3 - 64
mlp1	2	BatchNorm1d	64 - 64
mlp1	3	ReLU	64 - 64
mlp1	4	Linear	64 - 128
mlp1	5	BatchNorm1d	128 - 128
mlp1	6	ReLU	128 - 128
mlp2	7	Linear	128 - 32
mlp2	8	BatchNorm1d	32 - 32
mlp2	9	ReLU	32 - 32
mlp2	10	Dropout (p=0.5)	32 - 32
mlp2	11	Linear	32 - 10

Tablica 1: Konfiguracija PointNet klasifikacijskog modela

Pojednostavljena mreža sastoji se od višeslojnog perceptrona koji mapira XYZ koordinate u 64 i 128-dimenzionalni prostor uz ReLU i batch-normalizaciju, nakon čega slijedi *max pooling* preko svih točaka koji daje globalni vektor od 128 značajki. Taj vektor predstavlja sažetak cijelog oblaka točaka u kojem svaka od 128 komponenti označava koliko je u objektu prisutan određeni naučeni uzorak, pri čemu se maksimumom preko svih točaka zadržava najizraženiji odgovor za svaku značajku. Na taj način globalna reprezentacija hvata najbitnije informacije o obliku objekta neovisno o redoslijedu točaka. Taj vektor se zatim prosljeđuje drugom višeslojnom perceptronu koji ga mapira u 10 izlaznih vrijednosti koje predstavljaju logite za 10 klasa, uz dropout kao regularizaciju tijekom učenja. U verziji s T-Net modulom, za svaki se primjer predvidi matrica 3×3 koja se primjenjuje na ulazne točke, a njezini se parametri uče zajedno s ostatkom mreže kroz istu funkciju gubitka. T-Net se sastoji od per-point MLP-a (3–64–128), globalne agregacije *max poolingom* i završnog MLP-a (128–256–9), pri čemu izlaznih 9 vrijednosti čini elemente matrice 3×3. Dodatno se koristi ortogonalna regularizacija koja potiče da matrica bude blizu ortogonalne, čime se smanjuje rizik neželjenih skaliranja i izobličenja. Obje varijante mreže se treniraju uz CrossEntropyLoss za funkciju gubitka i pomoću Adam optimizera.

B. Segmentacija

U okviru PointNet arhitekture rješava se kao problem klasifikacije na razini pojedine točke, pri čemu je cilj svakoj točki u oblaku pridružiti oznaku dijela objekta kojem pripada. Za razliku od klasifikacije, gdje se koristi isključivo globalna reprezentacija objekta, kod segmentacije je potrebno zadržati i lokalne informacije vezane uz svaku pojedinu točku. Zbog toga se u PointNet pristupu globalni vektor značajki dobiven max poolingom nad svim točkama konkatenira s lokalnim značajkama svake točke. Arhitektura PointNet mreže za segmentaciju nalazi se u tablici 2.

Blok	Sloj	Tip sloja	ulaz - izlaz
Encoder	1	Conv1d + BN + ReLU	3 - 64
Encoder	2	Conv1d + BN + ReLU	64 - 64
Encoder	3	Conv1d + BN + ReLU	64 - 128
Encoder	4	Conv1d + BN + ReLU	128 - 1024
Fuzija	5	Concat	64 + 1024 + broj_kategorija
Seg head	6	Conv1d + BN + ReLU	(1088 + K) - 512
Seg head	7	Conv1d + BN + ReLU	512 - 256
Seg head	8	Conv1d + BN + ReLU	256 - 128
Output	9	Conv1d	128 - C

Tablica 2: Konfiguracija PointNet segmentacijskog modela

Konkretno, nakon izračuna globalnog vektora značajki, isti se replicira za sve točke i spaja s per-point značajkama dobivenima u ranijim slojevima mreže. Tako svaka točka dobiva kombinaciju lokalnog i globalnog konteksta, čime se omogućuje donošenje odluke o pripadnosti određenom dijelu objekta uz uvažavanje cjelokupne geometrije. Dobiveni vektori zatim se prosljeđuju dodatnom višeslojnom perceptronu koji za svaku točku predviđa vjerojatnosti pripadnosti pojedinim segmentima.

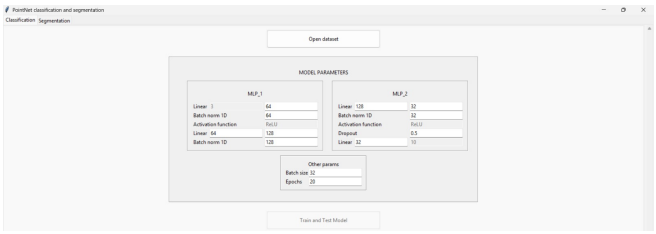
Na taj način PointNet omogućuje segmentaciju bez potrebe za eksplicitnim modeliranjem lokalnih susjedstava ili grafa povezanosti između točaka. Iako takav pristup ima ograničenja u hvatanju finih lokalnih struktura, pokazao se učinkovitim za osnovne zadatke segmentacije te predstavlja temelj za kasnije nadogradnje poput PointNet++ arhitekture.

U varijanti s T-Net modulom koristi se input T-Net koji za svaki primjer predviđa matricu 3×3 i primjenjuje je na ulazne koordinate točaka radi poravnanja oblaka. T-Net je građen od shared MLP slojeva (Conv1d k–64–128-1024), *max poolinga* i završnog MLP-a (Linear 1024-512-256-k^2) koji generira elemente transformacije, pri čemu se dodaje identitetska matrica za stabilnu inicijalizaciju. Dodatno se nakon drugog sloja koristi T-Net koji uči transformaciju 64×64 u prostoru značajki, a na tu transformaciju primjenjuje se ortogonalna regularizacija kako bi se izbjegla neželjena izobličenja.

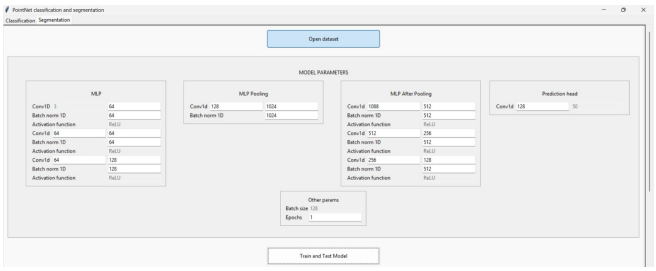
C. Grafičko sučelje

Model je implementiran kao aplikacija s grafičkim korisničkim sučeljem koja omogućuje korisniku postavljanje arhitekture mreže i hiperparametara prije pokretanja treniranja i testiranja. Sučelje omogućuje učitavanje skupa podataka, definiranje parametara pojedinih slojeva mreže te osnovnih postavki treniranja, poput veličine mini-serije i broja epoha. Takav pristup omogućuje jednostavnu prilagodbu modela i predstavlja temelj za daljnje nadogradnje arhitekture, poput proširenja prema PointNet++ modelu.

Na slici 1 prikazano je korisničko sučelje za konfiguraciju klasifikacijskog PointNet modela, dok je na slici 2 prikazano sučelje za konfiguraciju segmentacijskog modela.



Slika 1: Korisničko sučelje za konfiguraciju PointNet klasifikacijskog modela

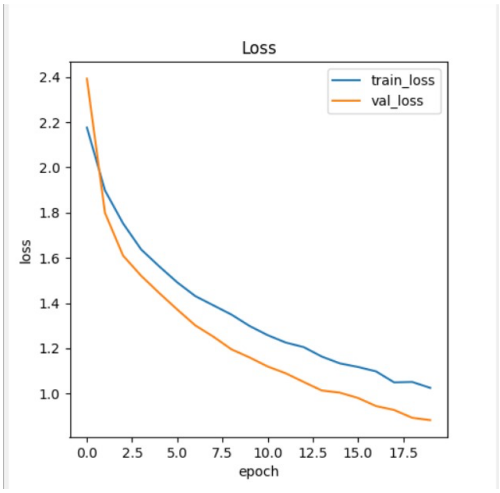


Slika 2: Korisničko sučelje za konfiguraciju konfiguraciju PointNet segmentacijskog modela

IV. Eksperimentalni rezultati

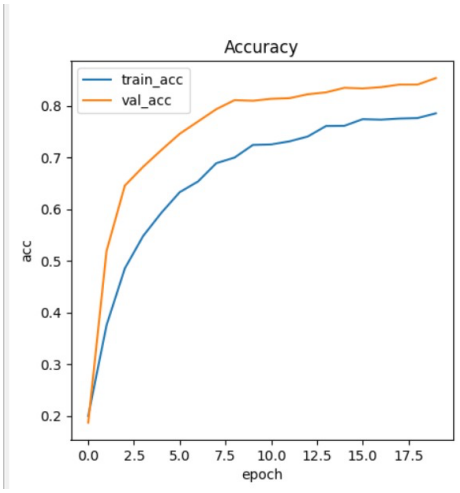
A. Rezultati treniranja modela za klasifikaciju

Modeli za klasifikaciju 3D objekata trenirani su tijekom 20 epoha, pri čemu je praćen tijek funkcije gubitka i točnosti na skupu za učenje i validaciju. Promjena vrijednosti gubitka kroz epohe za model bez T-Net modula prikazana je na slici 3. Vidljivo je da se gubitak na skupu za učenje i validaciju postupno smanjuje, što upućuje na stabilan proces učenja bez izraženih znakova divergencije. Validacijski gubitak tijekom cijelog treniranja ostaje niži od gubitka na skupu za učenje, što se može pripisati korištenju regularizacijskih tehnika poput dropouta.



Slika 3: Promjena vrijednosti funkcije gubitka tijekom treniranja.

Na slici 4 prikazana je promjena točnosti modela kroz epohe. Točnost na skupu za učenje raste postupno i na kraju doseže približno 78 %, dok validacijska točnost doseže oko 85 %. Razlika između trenirajuće i validacijske točnosti ukazuje na dobru sposobnost generalizacije modela te izostanak značajnog preučenja na korištenom skupu podataka.



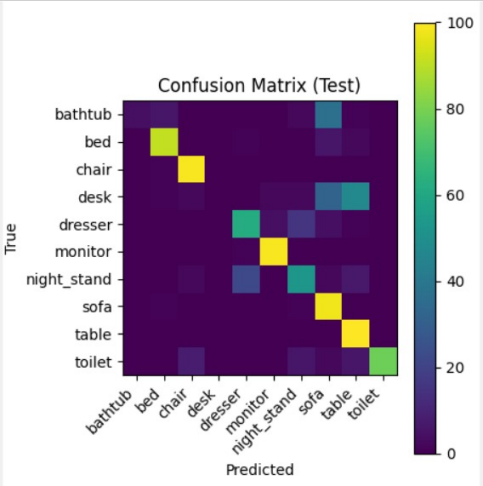
Slika 4: Promjena točnosti modela tijekom treniranja

Model bez T-Net modula postiže ukupnu točnost od 75.77 % na testnom skupu. Evaluacija je provedena metrikama po klasi te rezultati otkrivaju značajne razlike među klasama - primjerice, klase *bed, chair, monitor, table i toilet* imaju vrlo visok recall (0.95–0.98) i visoke F1 vrijednosti, što upućuje na pouzdano prepoznavanje. S druge strane, klase poput *desk* i *night_stand* imaju znatno niži recall (0.17 i 0.44), što ukazuje na poteškoće u njihovoj klasifikaciji. Model sa T-Net modulom pak na testnom skupu ostvaruje točnost od 83.92 % što je 8.15 % poboljšanja u odnosu na mrežu bez naučenog poravnavanja. S obzirom da učenje dodatnog T-Net modula ne predstavlja dodatne izazove što se tiče komputacijskih ili vremenskih zahtjeva, njegovo uključivanje u mrežu pokazalo se kao dobar način za poboljšanje performansi modela.

B. Analiza rezultata klasifikacije

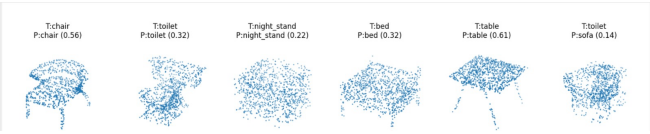
Uspješnost klasifikacije dodatno je analizirana pomoću matrice zabune prikazane na slici 5. Najbolji rezultati

ostvareni su za klase *chair*, *monitor*, *sofa*, *table* i *toilet*, kod kojih je većina uzoraka ispravno klasificirana. S druge strane, uočene su pogreške između geometrijski sličnih klasa, primjerice između *desk* i *table* te između *night_stand* i *dresser*, što je očekivano s obzirom na sličnosti u obliku i strukturi objekata.



Slika 5: Matrica zabune za klasifikaciju na testnom skupu.

Na slici 6 prikazani su primjeri pojedinačnih predikcija modela zajedno s pripadajućim vjerojatnostima. U većini slučajeva model ispravno predviđa klasu objekta, no često s umjerenom razinom pouzdanosti. Također su vidljivi i primjeri pogrešne klasifikacije, primjerice kada je objekt klase *toilet* pogrešno klasificiran kao *sofa*, što dodatno potvrđuje izazove razlikovanja vizualno sličnih 3D oblika na temelju ograničenog broja točaka.

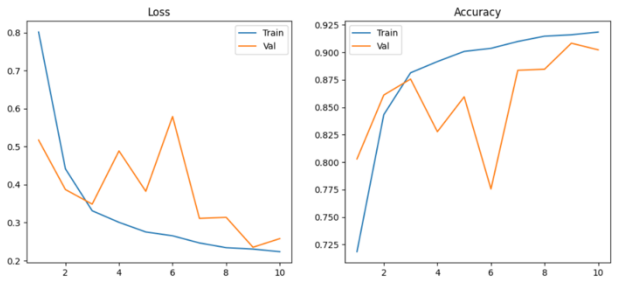


Slika 6: Primjeri klasifikacija 3D objekata.

C. *Rezultati treniranja modela za segmentaciju*

Modeli za segmentaciju 3D objekata trenirani su tijekom 10 epoha na ShapeNet skupu podataka, pri čemu je praćen tijek funkcije gubitka i točnosti na skupu za učenje i validaciju. Za usporedbu su implementirane dvije varijante modela: PointNet s uključenim T-Net modulom i PointNet bez T-Net modula.

Promjena vrijednosti gubitka kroz epohe za model s T-Net modulom prikazana je na slici 7 koji pokazuju stabilan proces učenja, pri čemu se gubitak na skupu za učenje i validaciju postupno smanjuje kroz epohe. Točnost na skupu za učenje raste od početnih 71.9 % u prvoj epohi do 91.8 % u desetoj epohi, dok validacijska točnost doseže 80.3 % u prvoj epohi i 90.2 % u posljednjoj epohi. Promjena točnosti modela kroz epohe prikazana je na grafovima koji pokazuju konzistentno poboljšanje performansi. Razlika između trenirajuće i validacijske točnosti ukazuje na dobru sposobnost generalizacije modela, uz blago preučenje koje se očituje u konačnim epohama.

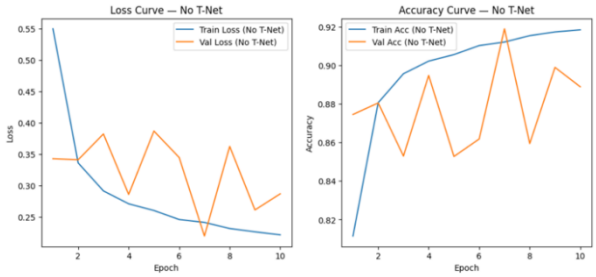



```
val_miou   = compute_shapenet_miou(model, val_loader)
print("Validation mIoU:", val_miou)
```

```
Validation mIoU: 0.7294984801318416
```

Slika 7: Kvalitativni rezultati segmentacije na ShapeNet skupu podataka za PointNet model s T-Net modulom.

Varijanta modela bez T-Net modula pokazuje nešto drugačiji obrazac učenja (slika 8). Model bez T-Net modula postiže početnu točnost od 81.1 % na skupu za učenje i 87.5 % na validacijskom skupu u prvoj epohi, što ukazuje na brže početno učenje u odnosu na model s T-Net modulom. Kroz epohe, točnost na skupu za učenje raste do 91.8 % u desetoj epohi, dok validacijska točnost doseže 88.9 % u posljednjoj epohi.




```
miou_no_tnet = compute_shapenet_miou(model_no_tnet, val_loader)

print(f"Validation mIoU: {miou_no_tnet:.4f}")
```

```
Validation mIoU: 0.8141
```

Slika 8: Kvalitativni rezultati segmentacije na ShapeNet skupu podataka za PointNet model bez T-Net modula.

D. *Analiza rezultata segmentacije*

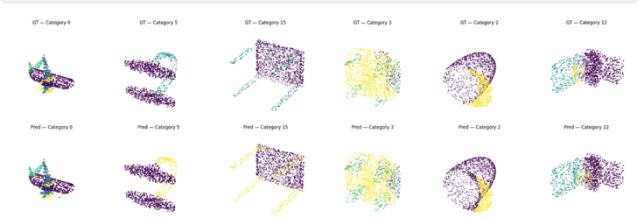
Zanimljivo je primijetiti da model bez T-Net modula postiže nešto nižu konačnu validacijsku točnost u odnosu na model s T-Net modulom (88.9 % naspram 90.2 %), što sugerira da T-Net modul doprinosi boljoj generalizaciji u zadatku segmentacije kada se promatra točnost na razini pojedinačnih točaka.

Međutim, kada se promatra mean Intersection over Union (mIoU), standardna metrika za procjenu kvalitete segmentacije, koja mjeri preklapanje između predviđenih i stvarnih segmenata za pojedine dijelove objekata, model bez T-Net modula postiže značajno bolji rezultat od 0.8141 u odnosu na model s T-Net modulom koji postiže mIoU od

0.7295. Ovaj rezultat ukazuje na to da, iako T-Net modul može poboljšati točnost na razini pojedinačnih točaka, može negativno utjecati na preciznost segmentacije kada se promatra preklapanje između predviđenih i stvarnih segmenata. Pritom je važno napomenuti da je mIoU osjetljivija metrika jer snažnije kažnjava pogreške na manjim segmentima, dok točnost može ostati visoka ako su dominantni (veći) dijelovi objekta dobro predviđeni. Takav rezultat može značiti da dodatno učenje transformacije kroz T-Net, iako korisno za poravnanje, u ovom eksperimentalnom postavu ne donosi nužno dobitak u mIoU (npr. zbog već kanoniziranih podataka) te može uvoditi dodatnu varijabilnost u učenju.

Oba modela pokazuju sposobnost efikasnog učenja reprezentacija za zadatak segmentacije, uz razlike u konačnim performansama koje ukazuju na različite prednosti i ograničenja svakog pristupa. Rezultati potvrđuju da osnovna PointNet arhitektura predstavlja učinkovitu polaznu točku za zadatke segmentacije 3D točkastih skupova, dok razlike u performansama između varijanti s i bez T-Net modula ukazuju na važnost pažljivog odabira arhitekturnih komponenti ovisno o specifičnim zahtjevima zadatka.

Na slici 9 prikazana je usporedba ground truth (GT) i predikcije modela (Pred) za odabrane kategorije, pri čemu su točke obojene prema pripadajućim segmentima. Uočava se da model u većini slučajeva dobro rekonstruira glavnu strukturu i raspodjelu segmenata.



Slika 9: Primjeri segmentacije 3D objekata.

V. Usporedba ostvarenih i postojećih rezultata

A. Klasifikacija

Arhitektura originalne PointNet mreže, opisana u radu Qi i suradnika [1], postiže točnost klasifikacije od približno 89 % na ModelNet10 skupu podataka. U ovom radu ostvarena je maksimalna validacijska točnost od oko 85 %, što predstavlja nešto slabiji rezultat u odnosu na originalni rad. Razlika u performansama može se pripisati pojednostavljenoj implementaciji arhitekture, ograničenom broju epoha treniranja te izostanku pojedinih dodatnih modula i tehnika optimizacije korištenih u originalnom radu.

Unatoč tome, dobiveni rezultati potvrđuju da i pojednostavljena verzija PointNet arhitekture zadržava sposobnost učinkovite klasifikacije 3D objekata. Analiza matrice zabune pokazuje da su klase s izraženim i karakterističnim geometrijskim značajkama, poput *chair*, *table* i *toilet*, klasificirane s visokom točnošću, što je u skladu s opažanjima iz literature. Pogreške se ponajprije javljaju kod geometrijski sličnih klasa, što je također zabilježeno u izvornom PointNet radu.

B. Segmentacija

Arhitektura PointNet mreže opisana u radu Qi i suradnika [1], postiže vrijednost mean Intersection over Union (mIoU) od približno 83.7 %. U ovom radu, PointNet model s uključenim T-Net modulom ostvario je vrijednost mIoU od 0.73 (73 %), dok je varijanta modela bez T-Net modula postigla mIoU od 0.8141 (81.41 %). Rezultati pokazuju da model bez T-Net modula postiže rezultate usporedive s PointNetom u spomenutom radu, dok model s T-Net modulom postiže nešto niže performanse.

Razlika u performansama u odnosu na rad Qi i suradnika [1] može se pripisati pojednostavljenoj implementaciji arhitekture, ograničenom broju epoha treniranja (10 epoha naspram većeg broja u originalnom radu), te razlikama u hiperparametrima i tehnikama optimizacije.

VI. Zaključak

U ovom radu prikazana je primjena PointNet arhitekture za zadatke klasifikacije i segmentacije trodimenzionalnih točkastih skupova. Provedeni eksperimenti pokazali su da i pojednostavljena implementacija PointNet mreže omogućuje stabilno učenje i dobru sposobnost generalizacije na korištenom skupu podataka. Ostvareni rezultati klasifikacije usporedivi su s rezultatima iz literature, uz očekivano blago smanjenje točnosti zbog ograničenja implementacije i treniranja.

Analiza rezultata segmentacije pokazala je da model uspješno prepoznaje osnovne strukturne dijelove objekata, ali ima poteškoće u preciznom razgraničenju manjih i geometrijski složenijih segmenata, što je u skladu s poznatim ograničenjima osnovne PointNet arhitekture. Dobiveni rezultati potvrđuju da je PointNet prikladna polazna metoda za obradu 3D točkastih skupova, dok se daljnja poboljšanja mogu postići korištenjem naprednijih arhitektura poput PointNet++ te dodatnih tehnika za učenje lokalnih značajki.

Literatura

[1] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation," 2017, arXiv:1612.00593. [Online]. Available: https://arxiv.org/abs/1612.00593

[2] C. R. Qi, L. Yi, H. Su, and L. J. Guibas, "PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space," in Proc. Adv. Neural Inf. Process. Syst. (NeurIPS), 2017, pp. 5099–5108

[3] Y. Guo, H. Wang, Q. Hu, H. Liu, L. Liu, and M. Bennamoun,, "Deep Learning for 3D Point Clouds: A Survey," IEEE Trans. Pattern Anal. Mach. Intell., vol. 43, no. 12, pp. 4338–4364, Dec. 2021.

[4] A. X. Chang et al., "ShapeNet: An Information-Rich 3D Model Repository," arXiv:1512.03012, 2015. [Online]. Available: https://arxiv.org/abs/1512.03012

[5] Z. Wu, S. Song, A. Khosla, F. Yu, L. Zhang, X. Tang, and J. Xiao, "3D ShapeNets: A Deep Representation for Volumetric Shapes," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2015, pp. 1912–1920.