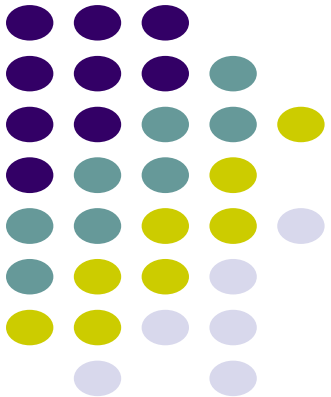
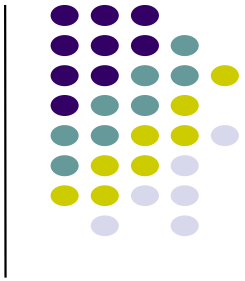
Neuronske mreže

akademik prof. dr. sc. Sven Lončarić
prof. dr. sc. Marko Subašić
izv. prof. dr. sc. Tomislav Petković
doc. dr. sc. Donik Vršnak

Fakultet elektrotehnike i računarstva
https://www.fer.unizg.hr/predmet/neumre



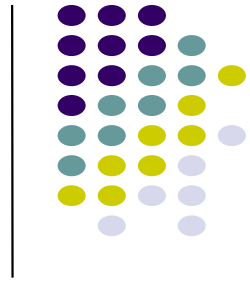
Nastavnici



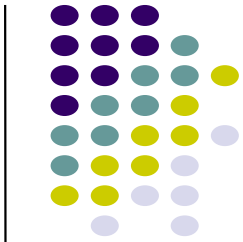
- Akademik prof. dr. sc. Sven Lončarić
  - Ured: D-119, E-mail: sven.loncaric@fer.hr
- Prof. dr. sc. Marko Subašić
  - Ured: D-105, E-mail: marko.subasic@fer.hr
- Izv. prof. dr. sc. Tomislav Petković
  - Ured: D-145, E-mail: tomislav.petkovic.ml@fer.hr
- Doc. dr. sc. Donik Vršnak
  - Ured: D-159, E-mail: donik.vrsnak@fer.hr

Asistenti

- Stella Balić
- Marin Matjanec
- Mario Tropčić

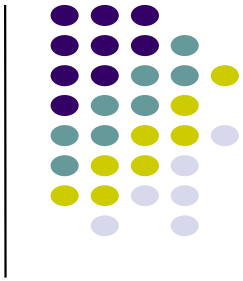


Svrha predmeta



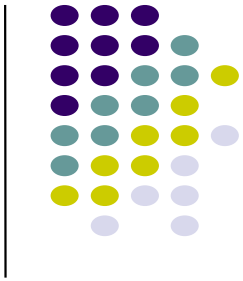
- Dati temeljna znanja iz teorije i primjene umjetnih neuronskih mreža u praktičnim inženjerskim problemima kao što su raspoznavanje uzoraka, analiza signala, slika i videa, te računalni vid

Struktura nastave



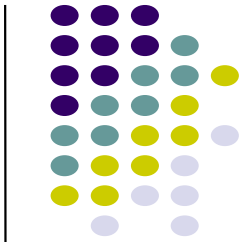
- Nastava:
  - Predavanja
  - Laboratorijske vježbe (projekt)
  - Kratke provjere znanja
  - Međuispit
  - Završni ispit

Pregled predavanja



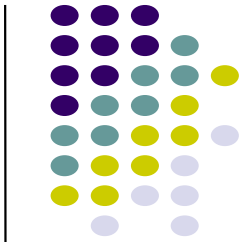
- Uvod
- Proces učenja
- Asocijativna memorija
- Jednoslojni perceptron
- LMS algoritam
- Višeslojni perceptron
- Radijalne mreže
- Stroj s potpornim vektorima
- Mreže s povratnom vezom
- Samoorganizirajuće mreže
- Duboke neuronske mreže

Laboratorijske vježbe



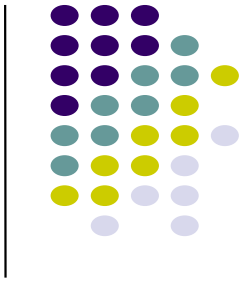
- Laboratorijske vježbe provode se u obliku timskog projekta s ciljem da se kroz praktične projekte stekne iskustvo u radu s neuronskim mrežama i primjenama za rješavanje raznih problema
- U satnici su rezervirani termini za laboratorijske vježbe na kojima će timovi prezentirati napredak na projektu
- Svrha projekta je da omoguće studentima:
  - primjenu stečenih teoretskih znanja za rješenje raznovrsnih realnih problema
  - usavršavanje vještine pisanja tehničkih izvještaja
  - usavršavanje vještine usmene prezentacije rezultata

Laboratorijske vježbe



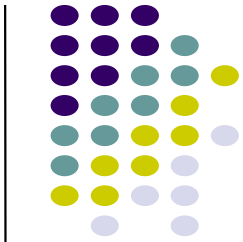
- Projekt je zadatak na kojem grupe od po pet studenata rade tijekom semestra
- Na početku semestra tim predaje nastavnicima prijedlog projekta duljine jedne stranice s naslovom, opisom problema i ciljevima projekta
- Na kraju semestra timovi predaju pisani izvještaj i prezentaciju
- Upute i rokovi na web stranicama predmeta

Kratke provjere znanja



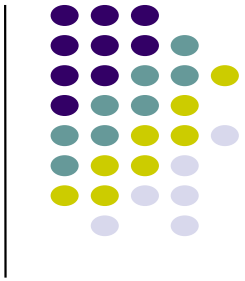
- Pet kratkih provjera znanja na predavanjima
- Ispituje se gradivo prethodnog predavanja

Auditorne vježbe



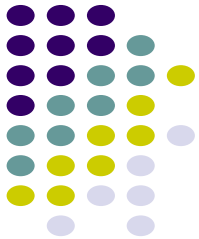
- Na kraju svakog ciklusa bit će održane auditorne vježbe za pomoć studentima za pripremu ispita
  - primjeri zadataka kakvi se pojavljuju na međuispitima i završnom ispitu (na web stranici predmeta, stranica Ispiti)
- Zadaci pomažu studentima bolje savladati gradivo, te ih pripremaju za međuispite, odnosno završni ispit

Međuispit i završni ispit



- Međuispit:
  - provjera znanja nakon prvog ciklusa predavanja
- Završni ispit:
  - provjera znanja na kraju semestra

Način bodovanja:
Kontinuirana provjera znanja



- Laboratorijske vježbe (projekt): 30 bodova (prag: 50% = 15 bodova)
- Kratke provjere znanja: 10 bodova (prag: 50% = 5 bodova)
- Međuispit: 30 bodova (prag: 20% = 6 boda)
- Završni ispit: 30 bodova (prag: 20% = 6 boda)

- Prag za zbroj rezultata međuispita i završnog ispita je 30 bodova.

Način bodovanja:
Ispitni rok



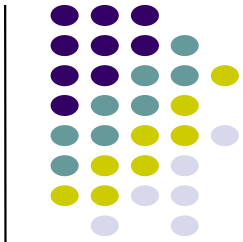
- Laboratorijske vježbe: 20 bodova (prag: 50% = 10 bodova)
- Timski projekt: 20 bodova (prag: 20% = 4 boda)
- Pismeni ispit: 60 bodova (prag: 50% = 30 bodova)

Ocjenjivanje

- Skala za ocjenjivanje (podložna korekcijama pragova):
- Izvrstan (5) – min. 87 bodova
- Vrlo dobar (4) – min. 75 bodova
- Dobar (3) – min. 63 bodova
- Dovoljan (2) – min. 51 bodova

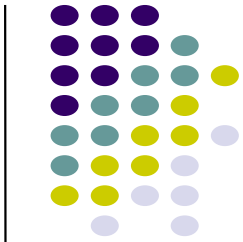
- Napomena: max. broj bodova je 100

Korištenje alata umjetne inteligencije



- Alati umjetne inteligencije mogu se koristiti za brainstorming, jezične ispravke i pomoć pri organizaciji rada, ali ne i za generiranje konačnih rješenja za projekt, programskog koda ili cjelovitih odgovora koji se predaju kao vlastiti rad.

Literatura



- S. Lončarić, M. Subašić, Predavanja iz neuronskih mreža, http://www.fer.hr/predmet/neumre_c
- H. Kalinić, S. Lončarić, Zbirka zadataka iz neuronskih mreža, http://www.fer.hr/predmet/neumre_c
- S. Haykin, Neural Networks, A Comprehensive Foundation, Prentice Hall, 1994
- J. A. Anderson, An Introduction to Neural Networks, MIT Press, 1995