Neuronske mreže:
Duboke neuronske mreže i duboko učenje

Prof. dr. sc. Sven Lončarić
Prof. dr. sc. Marko Subašić
dr. sc. Donik Vršnak

Fakultet elektrotehnike i računarstva
Sveučilište u Zagrebu

http://www.fer.hr/predmet/neumre_b

Zašto VEĆE mreže?

- Veći kapacitet mreže može se postići povećanjem broja neurona
  - Tako je i u živom svijetu
    - Jednostavni organizmi nekoliko stotina neurona u mozgu
    - Čovjek 86.000.000.000 neurona
    - Slon 257.000.000.000 neurona – nije sve u broju neurona
- Bitna je i arhitektura mreže
  - Istraživanje arhitektura NM je i dalje vrlo aktualno (uz algoritme učenja)

Zašto “duboke” mreže?

- Može se pokazati da je efikasnije ako se povećanje ostvari korištenjem više slojeva sa manje neurona nasuprot manje slojeva sa više neurona
- Ljudski mozak ima sličnu strukturu
  - Ne može se govoriti o feed forward slojevima jer postoje i povratne veze
- Ljudski kognitivni procesi često su hijerarhijski organizirani i "duboki"

Je li to nova ideja?

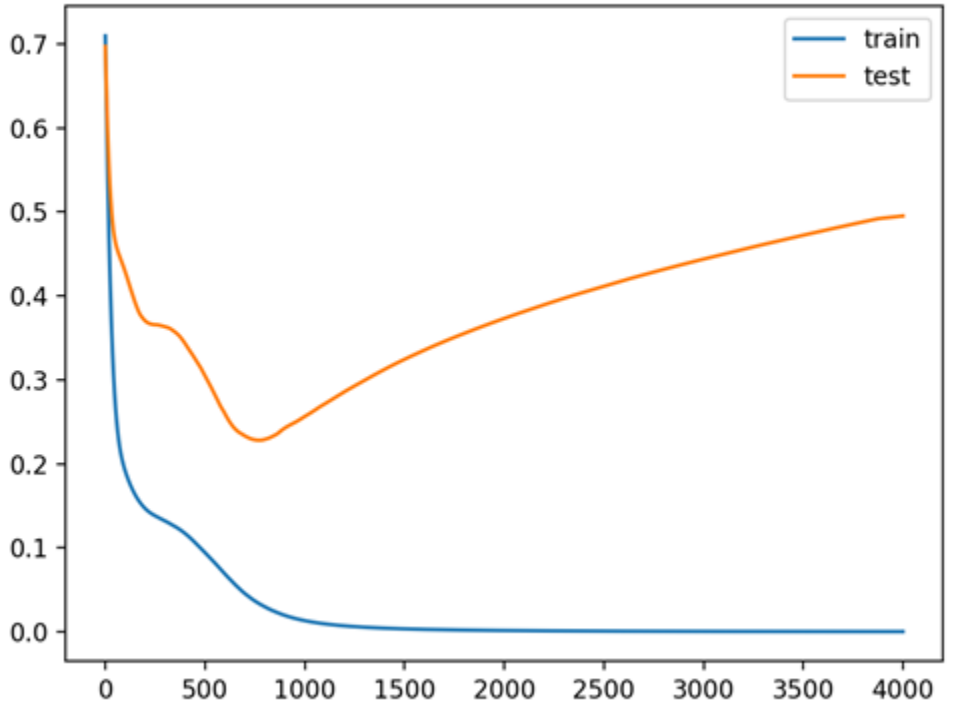
- Višeslojne mreže postojale su i ranije
  - MLP
- Ideja dubokih mreža seže u 1980-te godine
  - Treniranje je bilo presporo
    - U međuvremenu su identificirani razlozi
    - Dio razloga otklonio je napredak hardvera
    - Dio razloga otklonili su novi algoritmi

Je li to nova ideja?

- Koristilo se uglavnom učenje pod nadzorom i povratna propagacija pogreške
  - Kao i danas*
- Pokazalo se da su mreže sa većim brojem skrivenih slojeva imale lošije performanse i kod treniranja i kod testiranja
  - Suprotno od očekivanog
  - Koji je razlog?

Stari problemi I

- Pretreniranje – mreža opisuje slučajnu pogrešku ili šum umjesto bitnih odnosa ulaznih podataka



Stari problemi I

- Slaba generalizacija
  - Neće dobro raditi na novim podacima
- Mreža je prekompleksna za dani skup za treniranje
  - Veća kompleksnost mreže potencijalno vodi do veće točnosti
  - Traži se kompromis između kompleksnosti mreže (točnosti) i pretreniranja

Stari problemi I

- Osmišljeni su i neki trikovi za izbjegavanje pretreniranja
  1) Early stopping
     - Nije poželjno
  2) Smanjenje kompleksnosti mreže
     - Nije poželjno
  3) Povećanje količine ulaznih podataka
     - Nije uvijek moguće

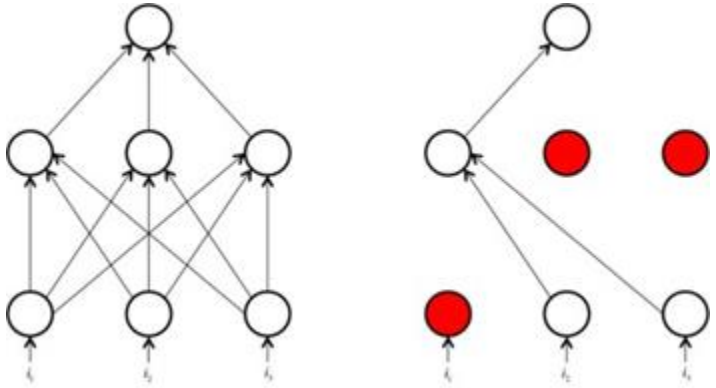
Stari problemi I

4) Augmentacija skupa za treniranje
   - Umjetno povećanje varijabilnosti u ulaznom skupu
   - Dodavanje šuma
5) Regularizacija
   - Dodatni član u funkciji cilja
   - Efektivno smanjuje kompleksnost mreže – nadamo se na dobar način
   - Npr. L2 regularizacija – kažnjava velike težine
     - Intuitivno – potiče se mreža da podjednako koriti sve ulaze
     - Težine teže prema nuli

Stari problemi I

6) Dropout

- Gašenje pojedinih neurona
- Dodavanje šuma



7)Odabir druge arhitekture

- Koristiti tuđa iskustva i intuiciju

- Pretjerivanje s trikovima obično vodi do loših performansi mreže
  - Koliko je dovoljno?

Stari problemi II

- Backpropagation se temelji na gradijentima
  - oni su ključni za treniranje
  - Propagiranje gradijenata u početne slojeve

$$\frac{dE(n)}{\mathrm{d}w_{ji}(n)} = \frac{\partial E(n)}{\partial e_j(n)} \frac{\partial e_j(n)}{\partial y_j(n)} \frac{\partial y_j(n)}{\partial v_j(n)} \frac{\partial v_j(n)}{\partial w_{ji}(n)}$$

$$\Delta w_{ji}(n) = \eta \delta_j(n) y_i(n)$$

$$\delta_j(n) = \varphi_j{}'\left(v_j(n)\right) e_j(n)$$

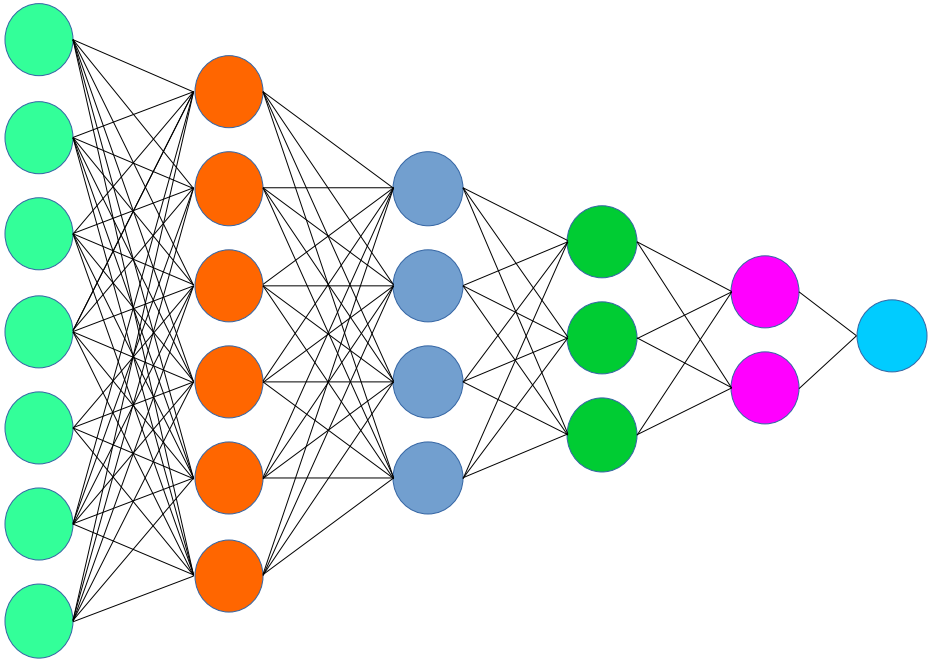
$$\delta_j(n) = \varphi_j{}'\left(v_j(n)\right) \sum_k \delta_k(n) w_{kj}(n)$$

Stari problemi II

- Što želimo na kraju treniranja?
  - Da gradijenti za svaki parametar mreže padnu na 0
    - Tada je mreža kovergirala i daljnja mijenjanja parametara mreže ne minimiziraju funkciju cijene
    - Želimo stati kada je mreža naučila što je trebala – kraj treniranja
- Što ne želimo na početku (ili sredini) treniranja?
  - Da gradijenti za svaki parametar mreže padnu na 0
    - Efektivno zaustavlja treniranje
  - Da gradijenti za svaki parametar mreže bude jako velik
    - Nestabilnost

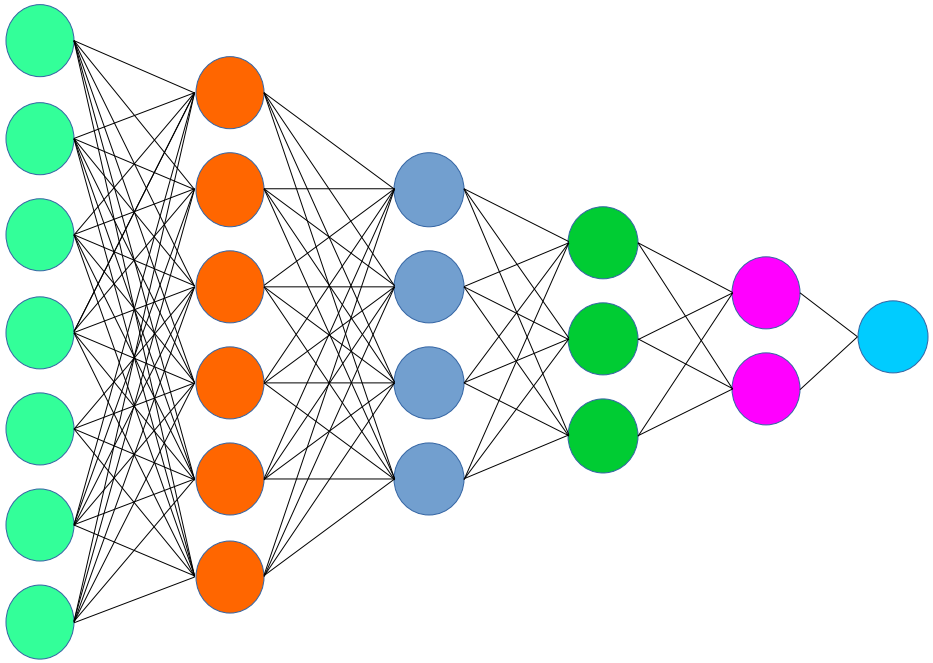
Stari problemi II

- Iščezavajući gradijenti – s povećanjem broja slojeva, povratna propagacija pogreške postaje sve lošija u prosljeđivanju informacija nižim slojevima
- Dublji slojevi blizu ulaznog teško uče
  - Ne propagiraju se gradijenti u početne slojeve
- Problem je značajan kada se koristi slučajna inicijalizacija
- Ne mora nužno značiti kraj treniranja nego se treniranje jako produžuje



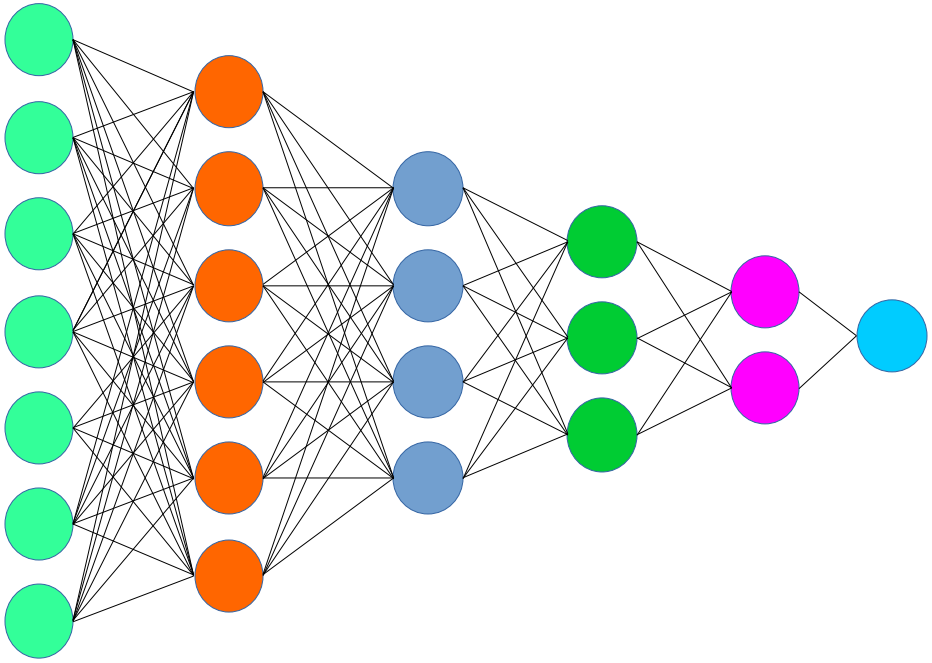
Stari problemi II

- Eksplodirajući gradijenti – korekcija je prevelika pa ne dovodi do smanjenja greške
- Sličan efekt kao i kod iščezavajućih gradijenta
- Bitno nam je da početni slojevi dobro rade



Stari problemi II

- Moguće je da neki od zadnjih skrivenih slojeva duboke mreže ima dovoljno kapaciteta za modeliranje zadanog problema
- Prethodni slojevi tada nisu potrebni i dodaju šum ulaznim podacima
  - Duboka mreža funkcionira slično kao plitka mreža



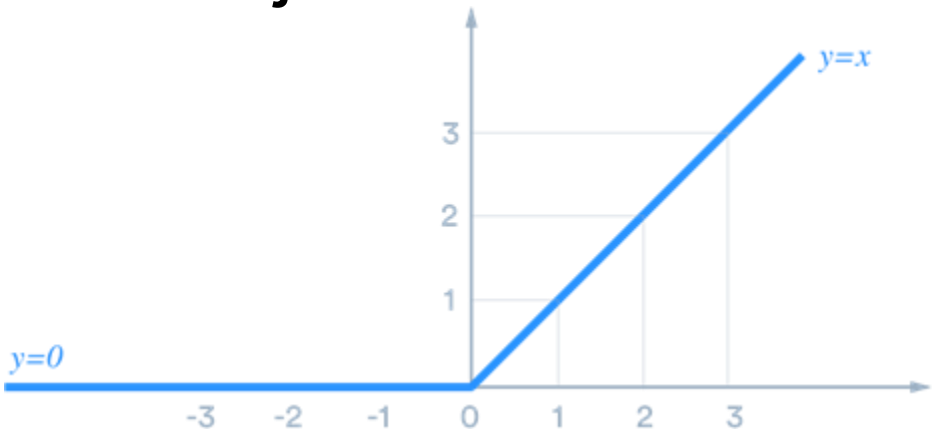
Stari problemi II

Trikovi osmišljeni za izbjegavanje iščezavajućih gradijenata:

- Bolja random inicijalizacija parametara mreže
  - Ciljano izbjegavanje malih gradijenata
- Korištenje predtreniranih slojeva
  - Predtreniranje na drugom problemu
    - Npr. učenjem bez nadzora (autoenkoderi)
- **Preskočna veza** (skip connection)

Stari problemi II

- Treniranje sloj po sloj
- Drugačije aktivacijske funkcije
  - ReLU



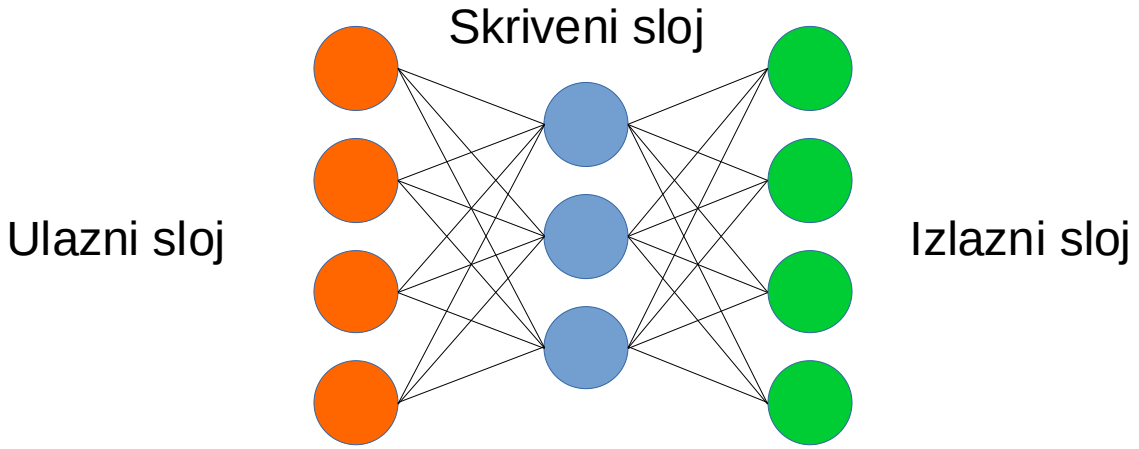
- "Izvor" gradijenata za treniranje bliže ulaznom sloju
  - Npr. kod autoenkodera

Što je još pomoglo

- Jeftina i dostupna računalna snaga iz GPU
- Sve češće situacije u kojima je potrebno efikasno analizirati velike količine sirovih podataka

Autoenkoder

- Feedforward mreža kojom se želi naučiti komprimirati (enkodirati) ulazne vektore



- Informaciju prisutnu u ulaznom vektoru predstaviti pomoću manjeg broja elemenata (čvorova skrivenog sloja) iz kojih je moguća savršena rekonstrukcija svih elemenata ulaznog vektora
- Potrebno ju naučiti kodirati vektore iz skupa za treniranje

Autoenkoder

- Mreža treba naučiti unutarnju strukturu podataka i bitne značajke – bit podataka na ulazu
- Skriveni sloj se naziva detektor značajki
- Broj neurona u skrivenom sloju je manji od broja neurona u ulaznom sloju
- Mreža je prisiljena pronaći samo bitne značajke kako bi postigla redukciju dimenzionalnosti
- Dobar pristup za postizanje generalizacije

Autoenkoder

- Treniranje pod nadzorom – npr. Backpropagation
- Ne radi se o "pravom" nadzoru
  - Ne uči se nepoznata funkcija
  - Provjerava se da li je na izlazu isto što i na ulazu
- U literaturi se takvo treniranje smatra nenadziranim
- Postoje brojne varijacije osnovnog autoenkodera

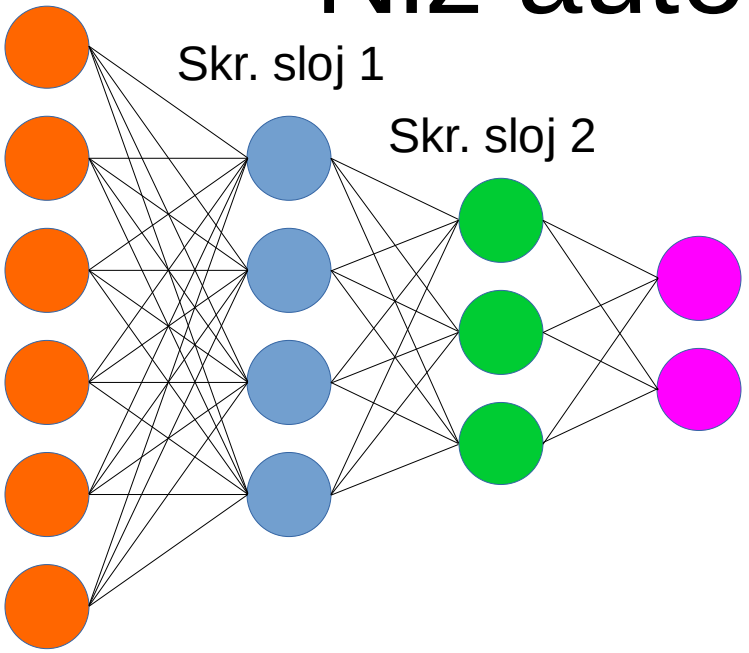
Autoenkoder

- Varijante:
  - Denoising autoenkoder
    - Dodaje se umjetni šum u ulazne podatke
    - Autoenkoder mora naučiti uklanjati šum
  - Contractive autoenkoder
    - Izbjegavanje promjena u skrivenom sloju za male promjene ulaza (mala promjena = šum ?)
    - Dodatni član funkcije cijene temeljen na derivaciji
    - Odnosi se na centralni skriveni sloj
      - Dobro za iščezavajući gradijent

Duboke mreže

- Autoenkoderi mogu funkcionirati kao detektori značajki
- Detektirane značajke su "skrivene" u skrivenom sloju – nisu direktno upotrebljive
- Spomenute mreže se mogu nastavljati jedna na drugu
  - Pohlepno treniranje sloj po sloj
  - Izostaje problem isčezavajućih gradijenata i pretreniranja

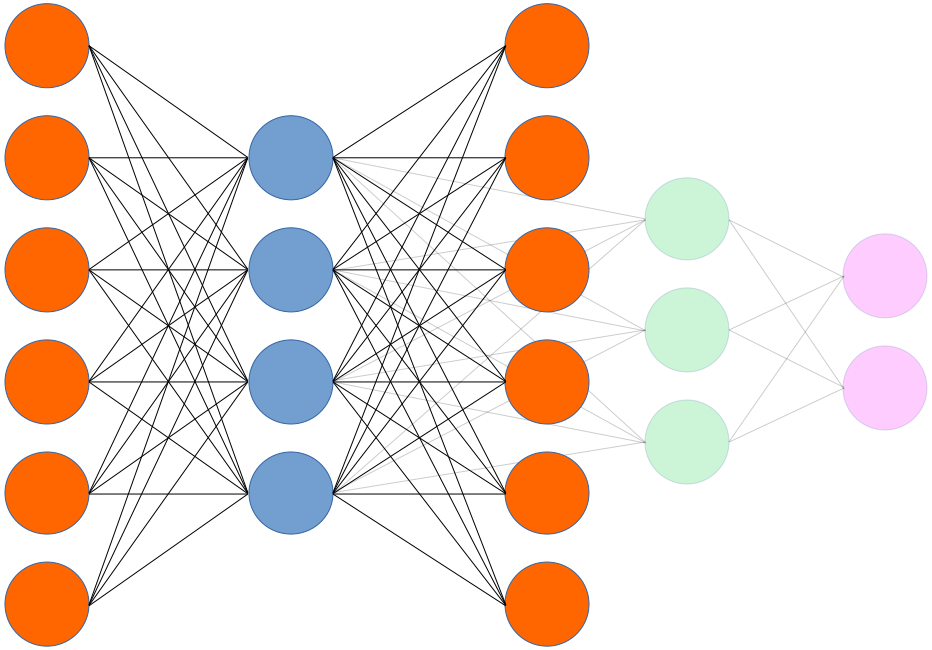
Niz autoenkodera

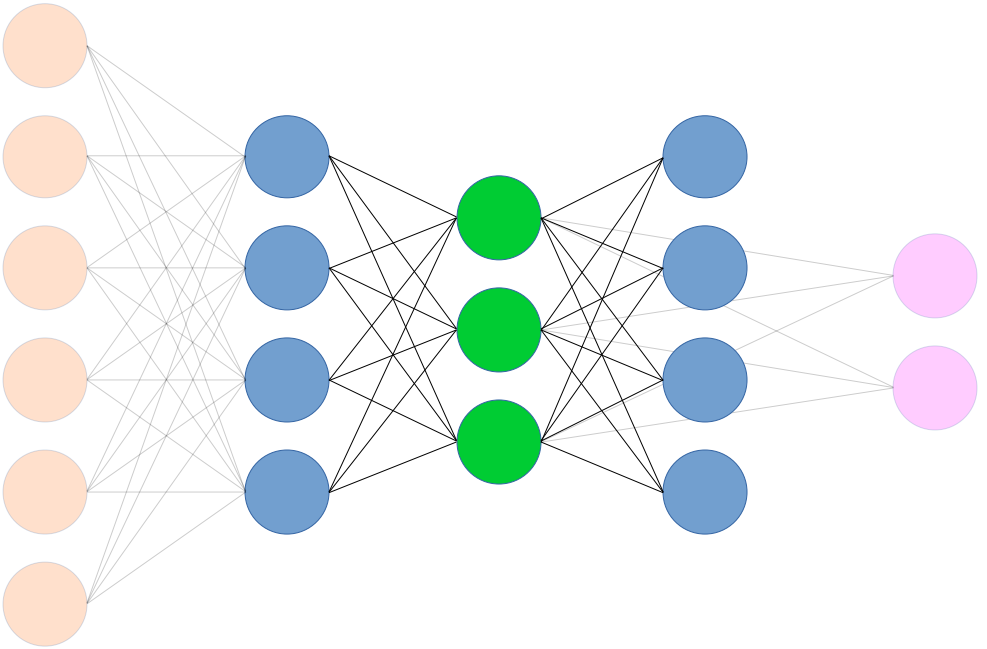


Ulazni sloj

Izlazni sloj

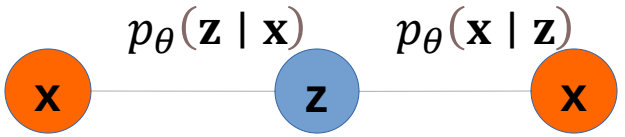
- Ulaz u slijedeći autoenkoder je izlaz iz prethodnog





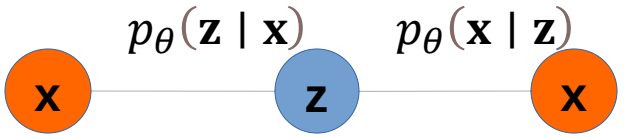
Varijacijski autoenkoder

- Kompleksnija ideja
- Cilj je naučiti distribuciju podataka iz skupa za treniranje p(**x**)
- Nakon toga se mogu generirati uzorci prema toj distribuciji
- Može biti dubok
- Iako je mreža stohastička, za treniranje se koristi back-prop



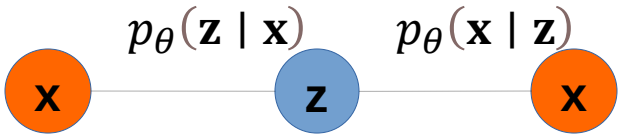
Varijacijski autoenkoder

- Skriveni sloj čini slučajni vektor zadane distribucije u koje se mapiraju uzorci za treniranje
- Iz skrivenog sloja se određuju distribucije izlaznih elemenata na temelju kojih se generiraju izlazni uzorci
- Formalno, cilj je maksimizirati vjerojatnosti uzoraka za treniranje



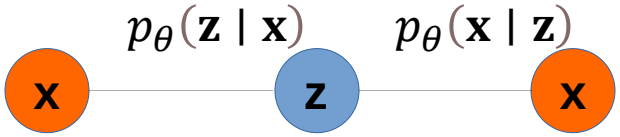
Varijacijski autoenkoder

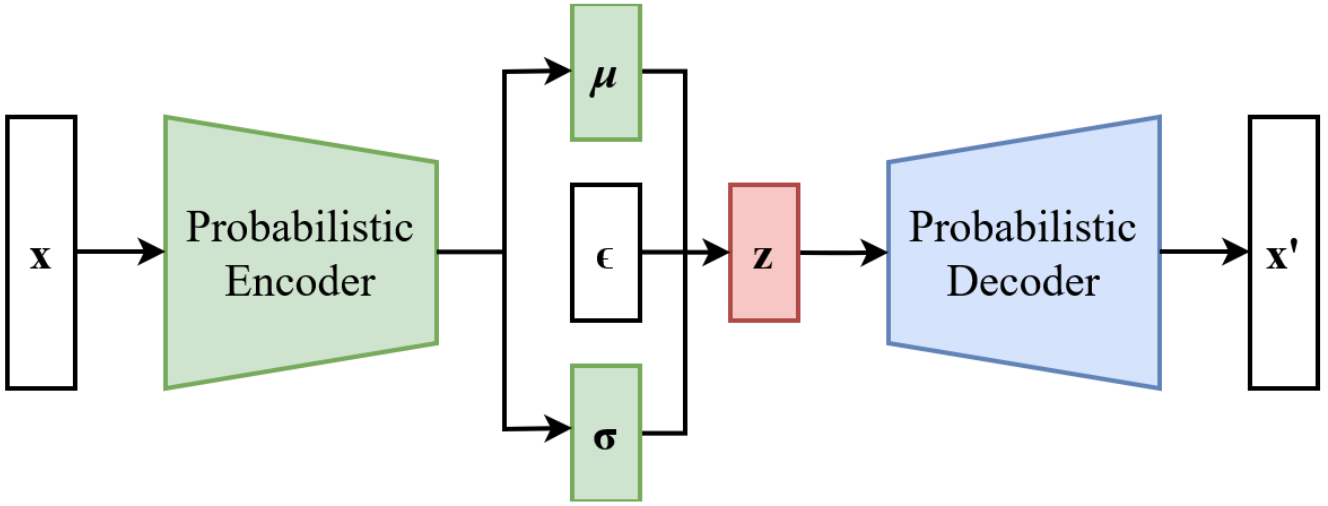
- Funkcija cilja ima regularizacijski član koji se odnosi na skriveni sloj
  - Slično kao i contractive autoenkoder
  - Omogućava efikasnije treniranje i izbjegavanje iščezavajućeg gradijenta
  - Minimizacija KL divergencije
- Skriveni sloj je stohastički
  - Dodavanje šuma u mrežu
  - Slično kao i denoising autoenkoder



Varijacijski autoenkoder

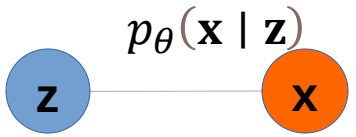
- Algoritam nema hiperparametara
- Iako je mreža stohastička, uspješno se koristi back-prop





Varijacijski autoenkoder

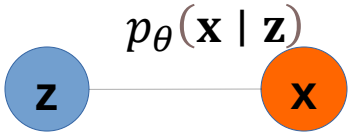
- Takav sustav omogućuje generiranje novih, nikad viđenih uzoraka
  - Generativni model
  - Dekoderski dio kojem se na ulaz dovede slučajni uzorak iz zadane distribucije



Varijacijski autoenkoder

- Primjeri

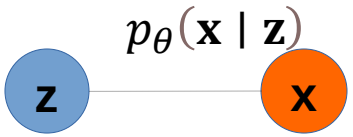




Varijacijski autoenkoder

- Primjeri

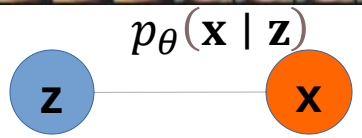




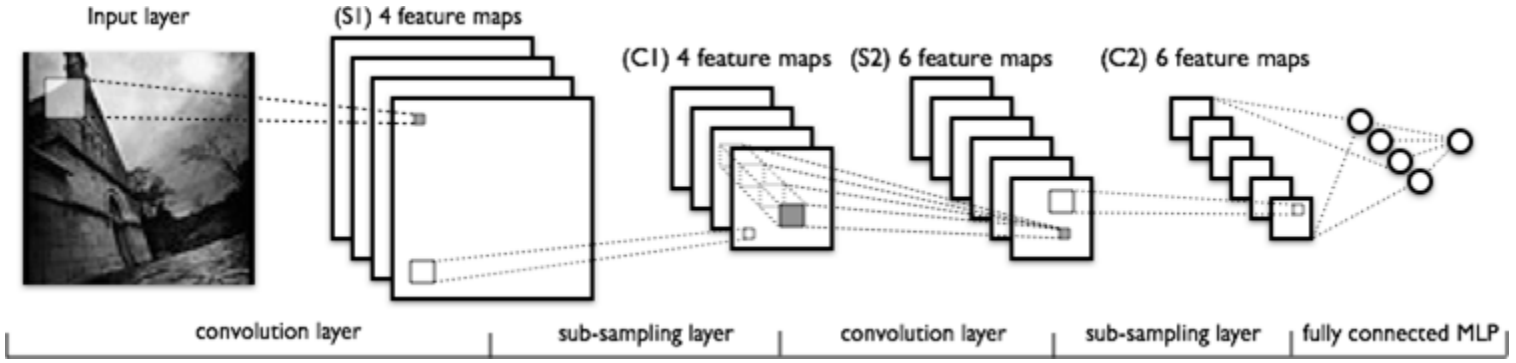
Varijacijski autoenkoder

- Pojedini elementi iz skrivenog sloja mogu predstavljati pojedinu karakteristiku izlaza
- Varijacijom tog parametra modulira se prisutnost te karakteristike



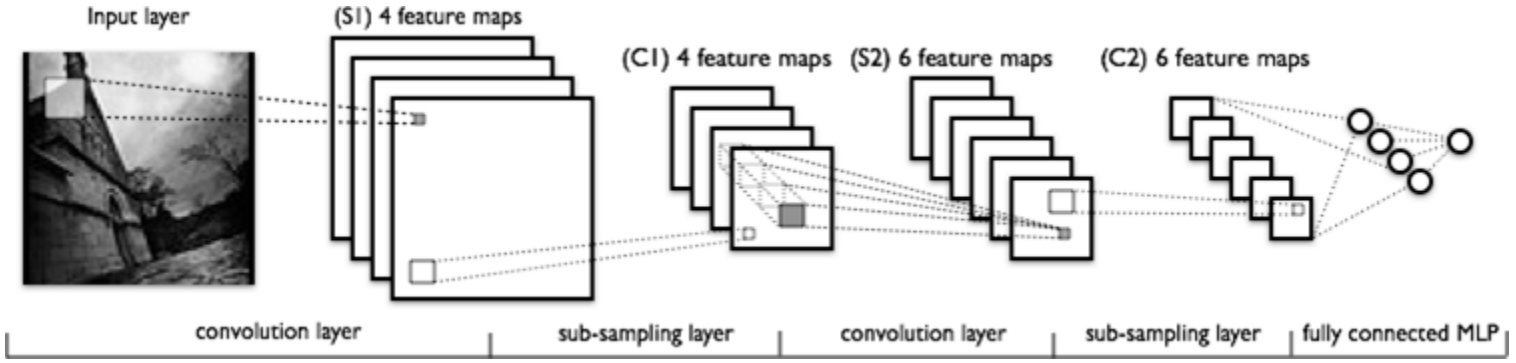


Konvolucijske mreže



- Varijanata MLP-a
- Temelji se na filtriranju slike - konvoluciji
- Sve težine treniraju se prilagođenim bakpropagation algoritmom

Konvolucijske mreže



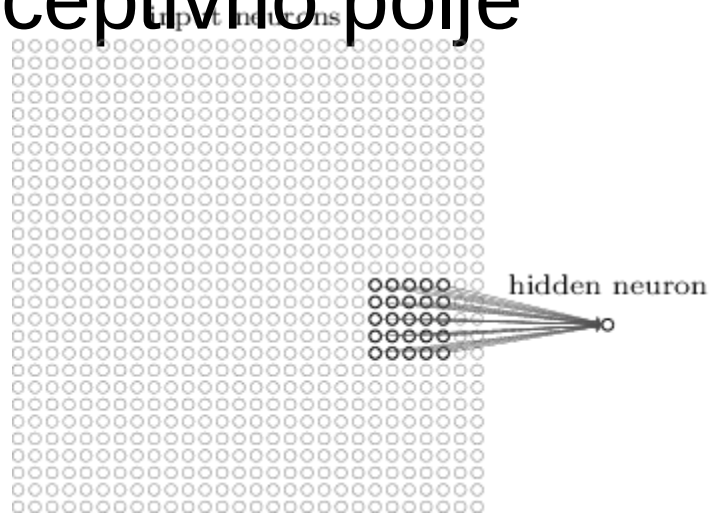
- Mreža je deterministička
- Zadnji dio mreže može biti klasični MLP (bez konvolucije)
  - Uspostavlja vezu između naučenih mapi značajki i željenih izlaza

Konvolucijske mreže

- Pogodna za analizu slika – detekciju objekata
  - Slike su stacionarne
  - Značajka koja se pojavi na jednoj lokaciji u slici, jednako je vjerojatna i na drugim lokacijama
  - Neosjetljivost na translaciju u slici
  - Logično je agregirati informacije o takvim značajkama

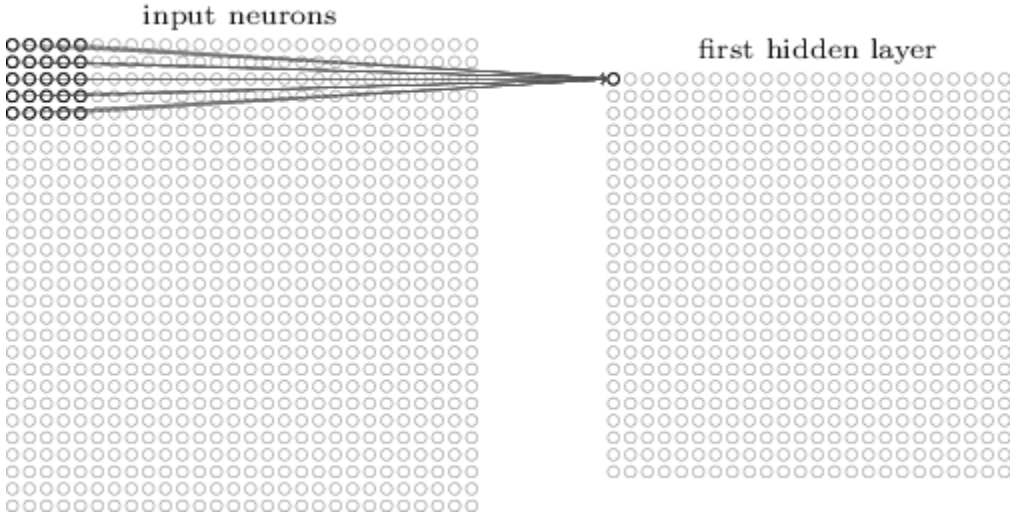
Konvolucijske mreže

- Konvolucijski slojevi
  - Primjenjuje se određeni broj filtera - neurona
- Omogućuje traženje različitih značajki
  - Svaki filter je zadužen za jednu "značajku"
- Lokalno receptivno polje



Konvolucijske mreže

- Konvolucijski slojevi
  - Rezultat filtriranja svakim filtrom se naziva mapa značajki *(feature map*)



Konvolucijske mreže

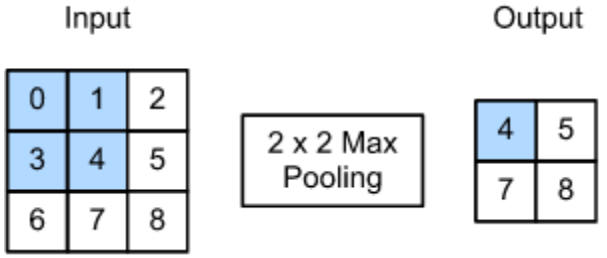
- Konvolucijski slojevi
  - Svaki se filter primjenjuje na svim mapama značajki prethodnog sloja ali uz iste/slične težine
- Omogućuje pronalazak značajki bez obzira u kojoj mapi značajki se nalaze

Konvolucijske mreže

- Konvolucijski slojevi
  - Pozicija značajke nije bitna – bitan je međusobni prostorni raspored značajki
- Neovisnost o translaciji
- Ograničena robusnost na rotaciju

Konvolucijske mreže

- Podotipkavajući sloj
  - Smanjuje veličinu ulaza
  - Umanjuje utjecaj pomaka značajki u prostoru i drugih distorzija
  - Različite procedure
    - Max pooling
    - Usrednjavanje
    - Stohastičko uzorkovanje
    - Trenirani neuron



Konvolucijske mreže - backprop

- Moguće su i razne druge varijacije i dodatci
- Nužno je samo da funkcionira povratna propagacija pogreške
  - Računanje parcijalnih derivacija izlaza s obzirom na svaki ulaz u sloju
- Kod konvolucijskih slojeva možemo govoriti o dijeljenim težinama koje se onda korigiraju odjednom
  - Prosječna korekcija

$$\Delta w_i^{uk} = \frac{1}{N} \sum_n \Delta w_i^n$$

Konvolucijske mreže - backprop

- Obično se treniranje provodi u mini grupama (mini batch)
  - Provodi se radi što veće paralelizacije i ubrzavanja treniranja
  - Glavno ograničenje je količina GPU memorije

$$\Delta w_i^b = \frac{1}{N} \sum_m \Delta w_i^{uk}(m)$$

Konvolucijske mreže - problem

- Puno konvolucijskih slojeva – duboka mreža
  - Problem iščezavajućeg gradijnta i dalje postoji
  - Problem pretreniranja i dalje postoji

Konvolucijske mreže - trikovi

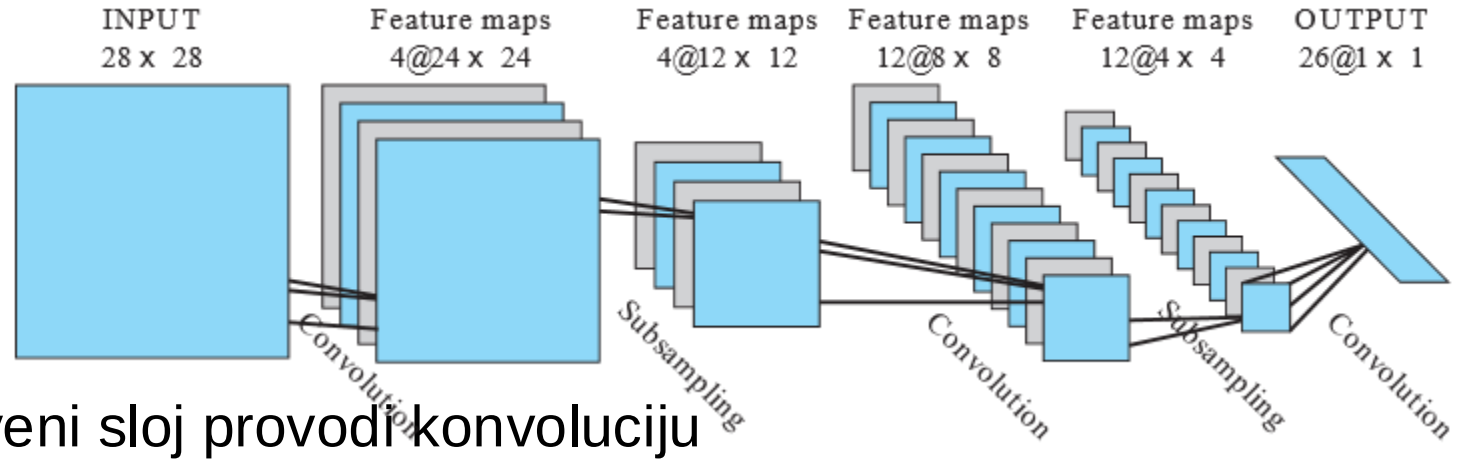
- Jedno rješenje je korištenje predtreniranih slojeva
  - Transfer learning
  - Postoje popularni predtrenirani konvolucijski slojevi
    - Trenirani na velikoj količini slika za neki problem analize slike – najčešće klasifikacija slika
  - I oni se po želji mogu trenirati za konkretan problem, ali će zbog iščezavajućeg gradijenta promjena biti mala
    - Fine-tuning

Konvolucijske mreže - trikovi

- Još jedno rješenje je dropout
  - Slučajno isključivanje pojedinih neurona
  - Koristi se samo kod treniranja
  - Tjera mrežu da bude redundantna
  - Uvodi se stohastika u deterministički proces treniranja

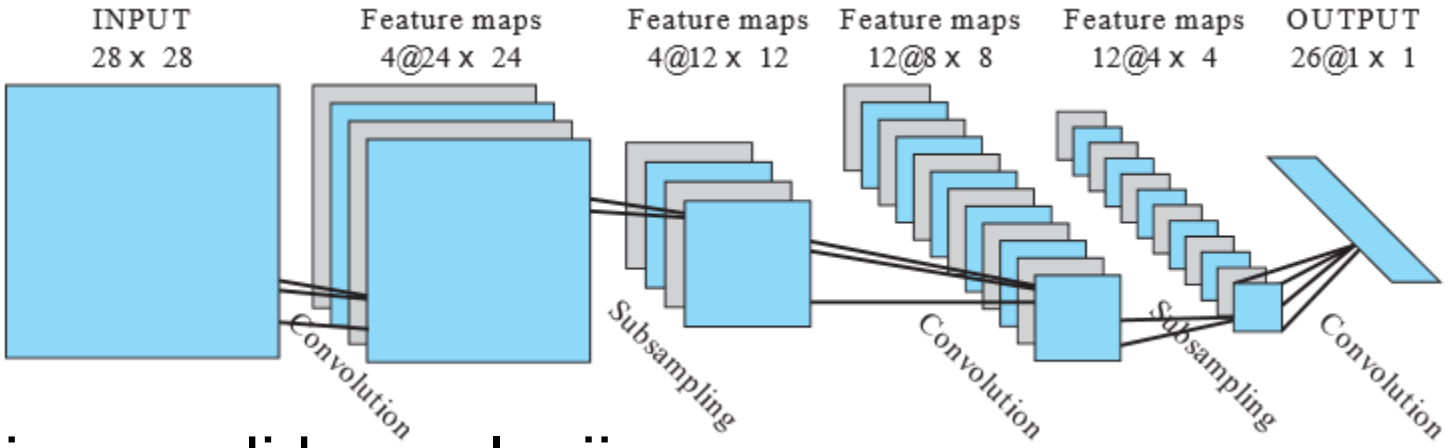
Primjer konvolucijske mreže

- Primjena - raspoznavanje slova



1. skriveni sloj provodi konvoluciju
   - Rezultat su četiri mape značajki sa 24x24 neurona
   - Svaki neuron ima receptivno polje 5x5
2. skriveni sloj provodi podotipkavanje i lokalno usrednjavanje
   - Mape značajki 12x12
   - Receptivana polja neurona 2x2
   - Svaki neuron ima težinu/e, posmak i nelinearnu aktivacijsku funkciju

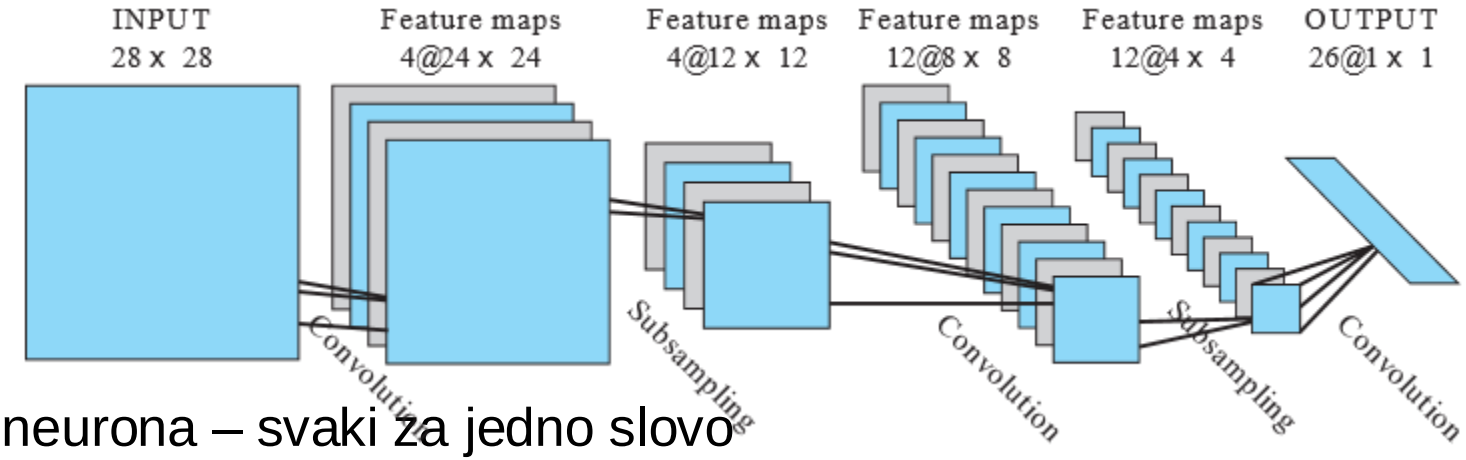
Primjer konvolucijske mreže



3. skriveni sloj provodi konvoluciju
   - Rezultat su četiri mape značajki sa 8x8 neurona
   - Svaki neuron težinski je povezan sa svim mapama značajki iz prethodnog sloja

1. skriveni sloj provodi podotipkavanje i lokalno usrednjavanje
   - Mape značajki 4x4
   - Receptivana polja neurona 2x2

Primjer konvolucijske mreže



5. Izlazni sloj
   - ima 26 neurona – svaki za jedno slovo
   - Receptivno polje svakog neurona je 4x4 po svim mapama značajki iz prethodnog sloja
- Prostorna rezolucija se smanjuje dok se broj mapa značajki povećava
  - Inspirirano vizualnim korteksom mačke
- Svaki element mape značajki je jedan neuron no svi neuroni u jednom sloju dijele isti skup težina koje se treniraju
  - Redukcija broja parametara koji se treniraju
    - Ograničavanje kapaciteta mreže
    - Bolja generalizacija
  - Paralelizacija!

Konvolucijske mreže – trikovi

- Korištenje isključivo konvolucijksih slojeva
  - Zadnja mapa značajki postaje mapa rješenja
  - Konačno rješenje dobijemo usrednjavanjem
    - Average pooling
  - Prednosti
    - Veća robusnost na pomak
    - Ne ovisi o veličini slike

Konvolucijske mreže

- Znatno manji broj parametara u odnosu na MLP
- Broj filtara u konvolucijskom sloju
  - Znatno utječe na vrijeme izvođenja i treniranja
  - Manje filtara u slojevima bližim ulaznom sloju
    - Mape značajki su veće
  - Recept: ujednačit broj računskih operacija među slojevima – umnožak broja piksela/neurona i filtara u sloju konstantan

Konvolucijske mreže - izbori

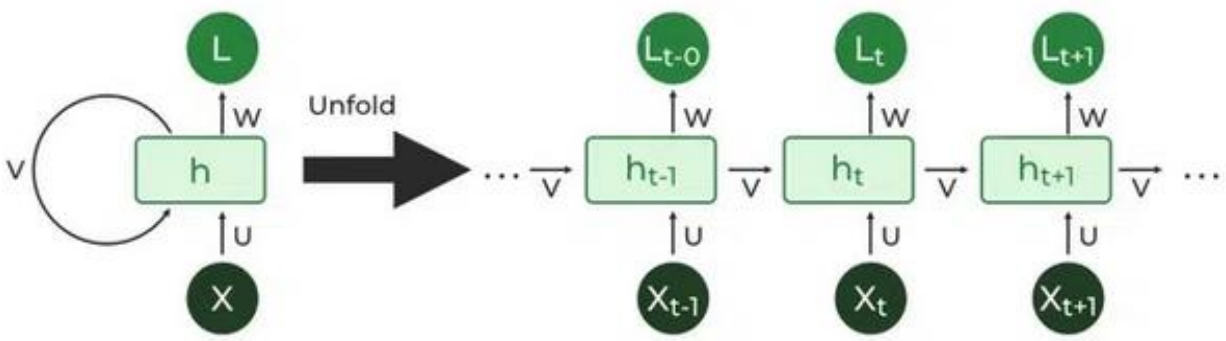
- Veličina filtara
  - Ovisno o skupu podataka
- Podotipkavanje
  - Skala
  - Procedura (ako se ne trenira)
- Faktori učenja
  - Smanjivati ih sa svakom epohom?
- Predprocesiranje
  - PCA?

Konvolucijske mreže

- Konačni rezultat je MLP čija veličina nije pretjerana
- Lokalna povezanost neurona
  - Izbjegnuta je puna povezanost mreže
- Dizajn mreže je prilagođen problemu koji se nastoji riješiti

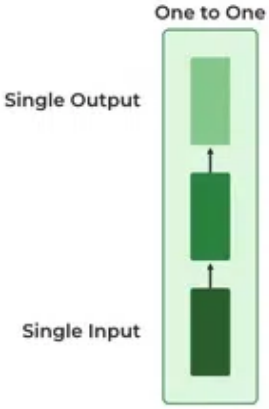
RNN

- Obrada slijednih nizova podataka (npr. rečenice, signali)
- Predviđanje sljedeće riječi u rečenici ovisi o svim prethodnim riječima
- Bazirane na skrivenom stanju koje drži informacije o prošlosti

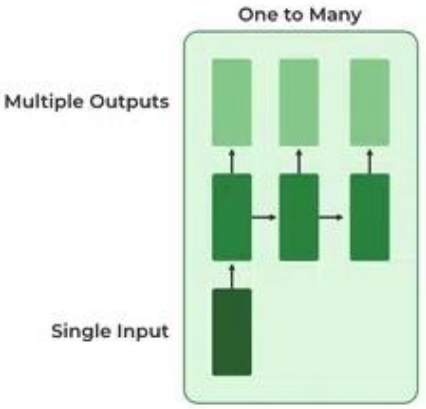


RNN

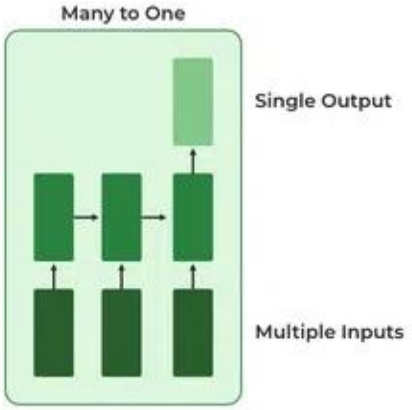
- Nekoliko vrsta problema:



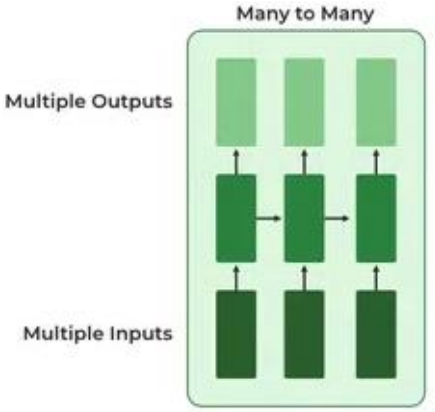
Klasični MLP



Generiranje teksta



Klasifikacija teksta



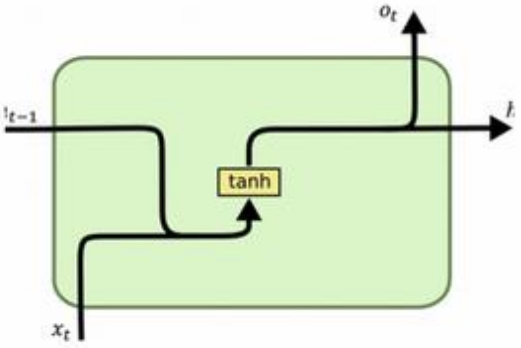
seq2seq Prevođenje

RNN

- Obični RNN imaju probleme sa zaboravljanjem konteksta
- Postoje varijacije tipa **LSTM** ili **GRU**
- LSTM i GRU imaju mehanizme odbacivanja nevažnog konteksta i zadržavanje samo najbitnijeg

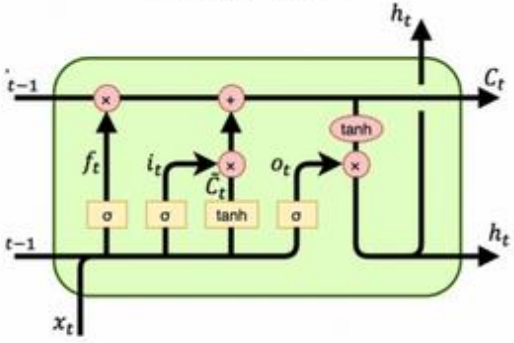
$$h_t = \sigma_h(W_h x_t + U_h h_{t-1} + b_h)$$
$$y_t = \sigma_y(W_y h_t + b_y)$$

RNN



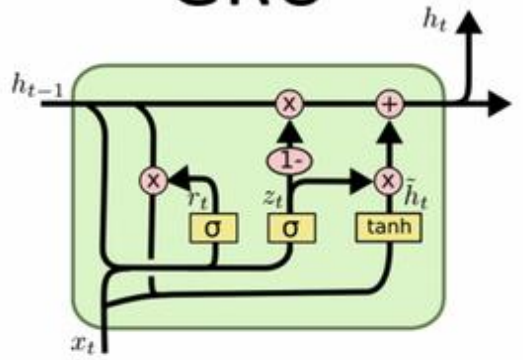
$$f_t = \sigma_g(W_f x_t + U_f h_{t-1} + b_f)$$
$$i_t = \sigma_g(W_i x_t + U_i h_{t-1} + b_i)$$
$$o_t = \sigma_g(W_o x_t + U_o h_{t-1} + b_o)$$
$$\tilde{c}_t = \sigma_c(W_c x_t + U_c h_{t-1} + b_c)$$
$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$
$$h_t = o_t \odot \sigma_h(c_t)$$

LSTM



$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$$
$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$
$$\hat{h}_t = \phi(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h)$$
$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \hat{h}_t$$

GRU

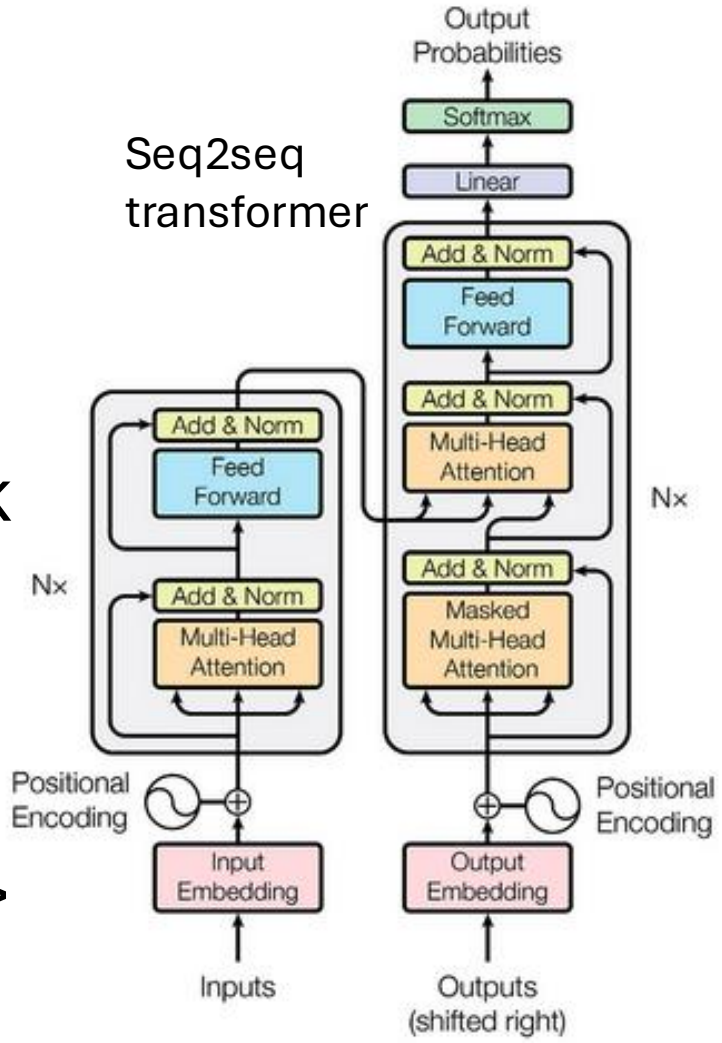


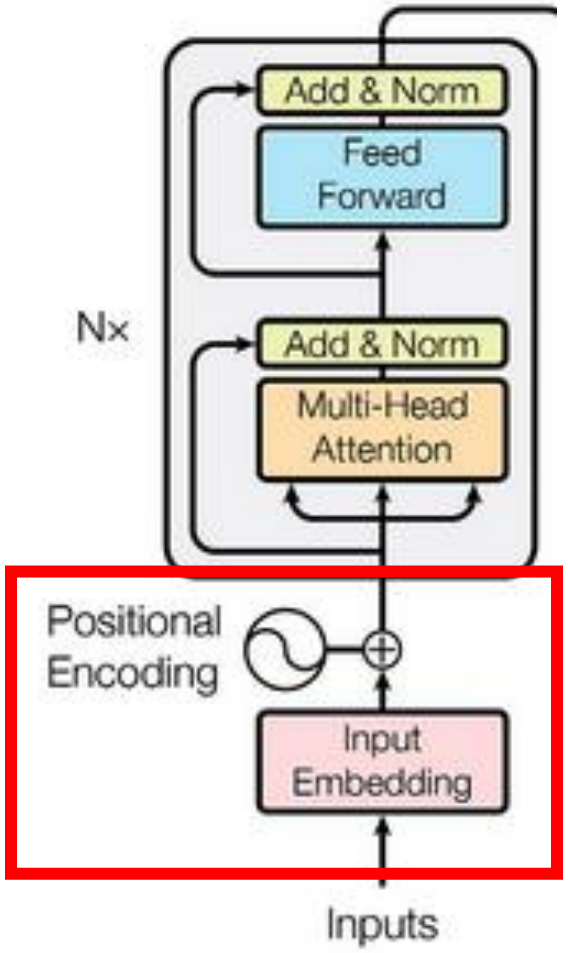
RNN

- Sve RNN mreže imaju još neke probleme
  - Linearna vremenska ovisnost gradijenata o duljini niza
  - Nije moguće paralelizirati računanje
  - Išćezavanje ili eksplozija gradijenata
  - Kontekst je uvijek lokalan i konstantne veličine - uvodi se i **mehanizam pažnje** koji maskira određene dijelove konteksta i ulaza
- Konstatna memorija (neovisna o duljini niza)

Transformeri

- Moderni GPU-ovi -> Puno memorije
- Što ako kontekst ne bi bio konstantan nego bi mogli gledati svaki dio niza sa svakim drugim (kvadratna memorijska složenost, ali konstatna vremenska složenost)
- MHSA – Multi-head self-attention blok
- Preskočne veze -> gradijenti su očuvani
- Nema induktivne pristranosti, očekujemo da mreža to sama nauči -> puno podataka



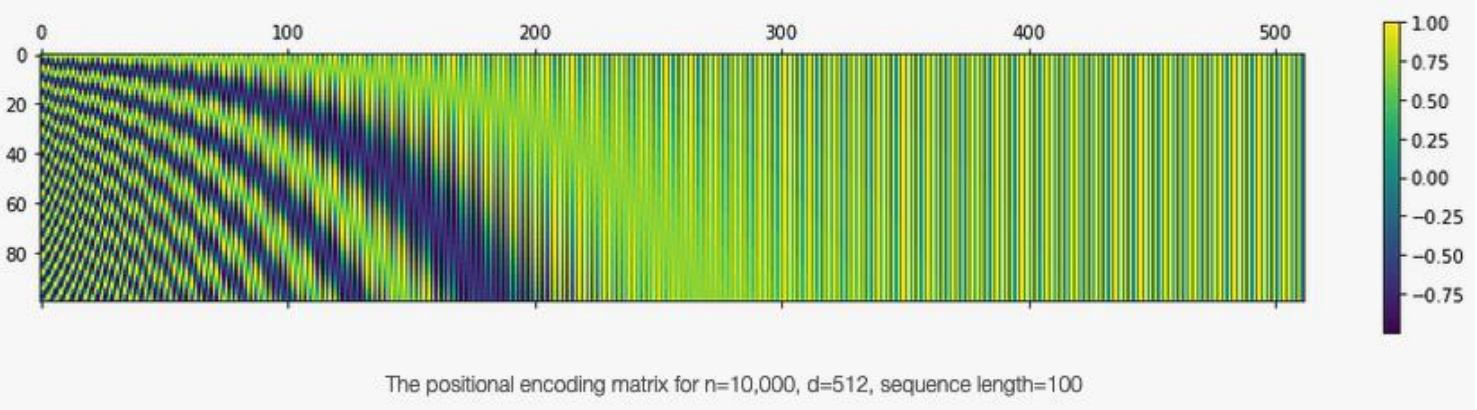


Transformeri

- Ulaz je niz ”tokena”
- Linearna projekcija
- Za razliku od RNNova, transformer nemaju sekvancijalnu prirodu
- Pozicijsko kodiranje, bližim elementima u nizu dodajemo sličnije stvari

$$P(k, 2i) = \sin\left(\frac{k}{n^{2i/d}}\right)$$

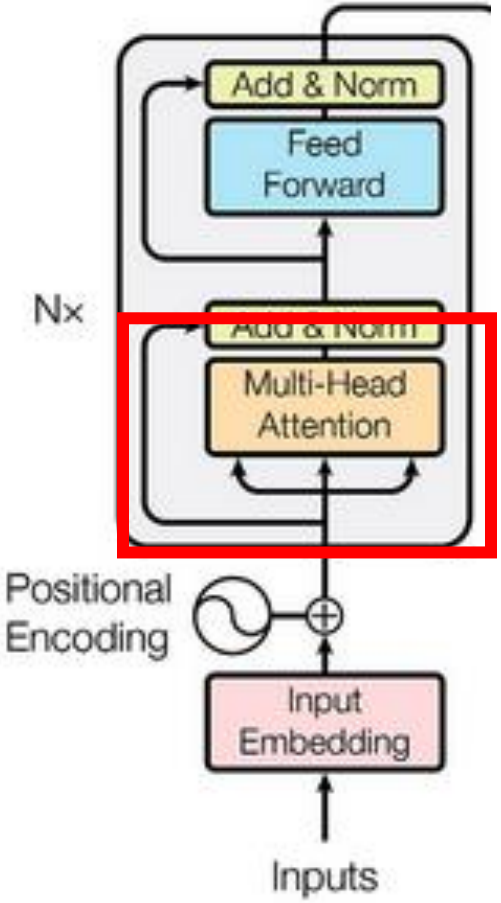
$$P(k, 2i+1) = \cos\left(\frac{k}{n^{2i/d}}\right)$$



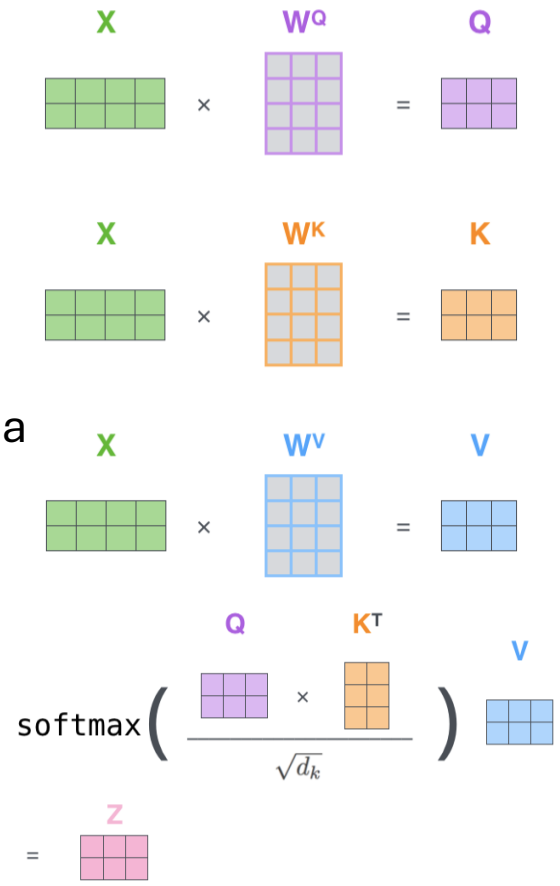
The positional encoding matrix for n=10,000, d=512, sequence length=100

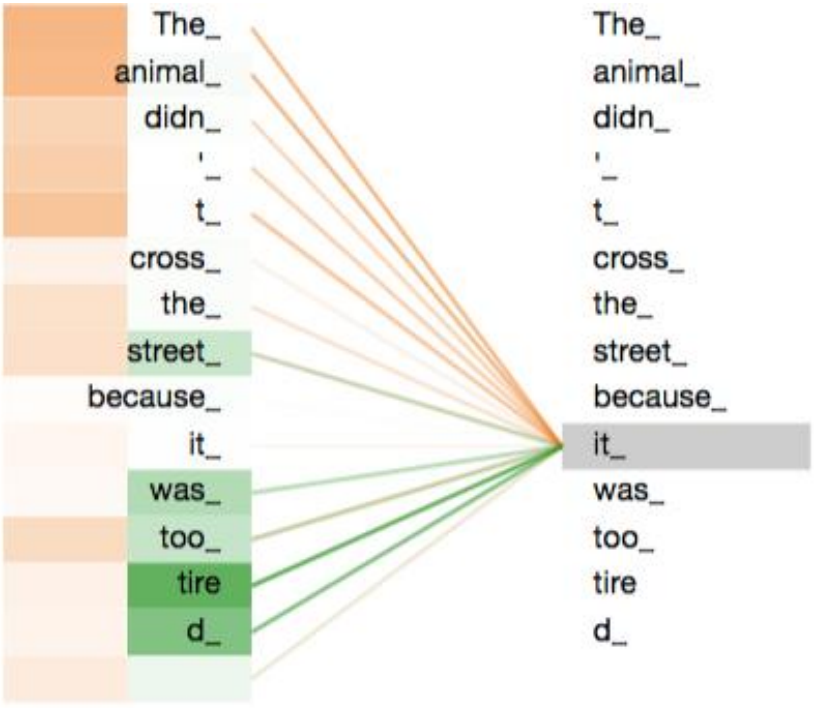
Transformeri

- Mehanizam pažnje je glavni dio transformer arhitekture
- Ideja svaki sa svakim

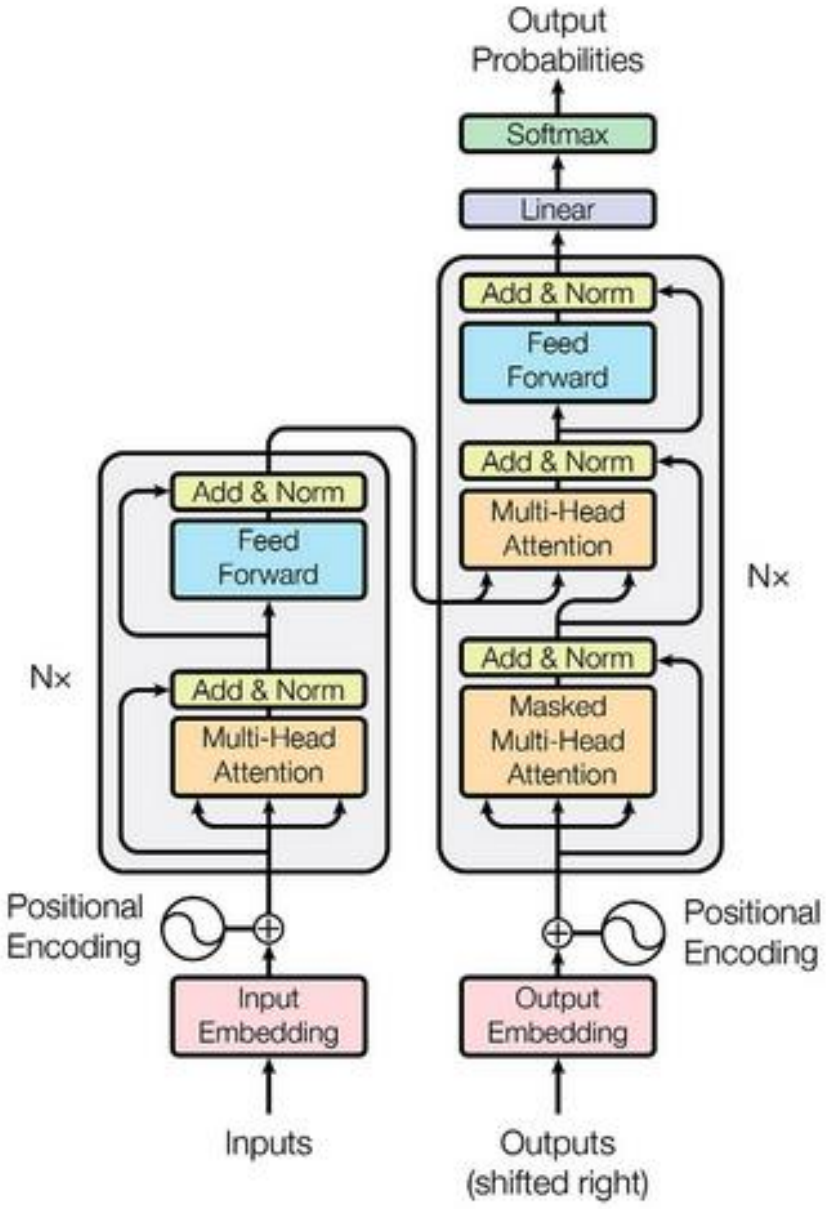


Primjer mehanizma pažnje s 2 tokena i jednom glavom





Transformeri

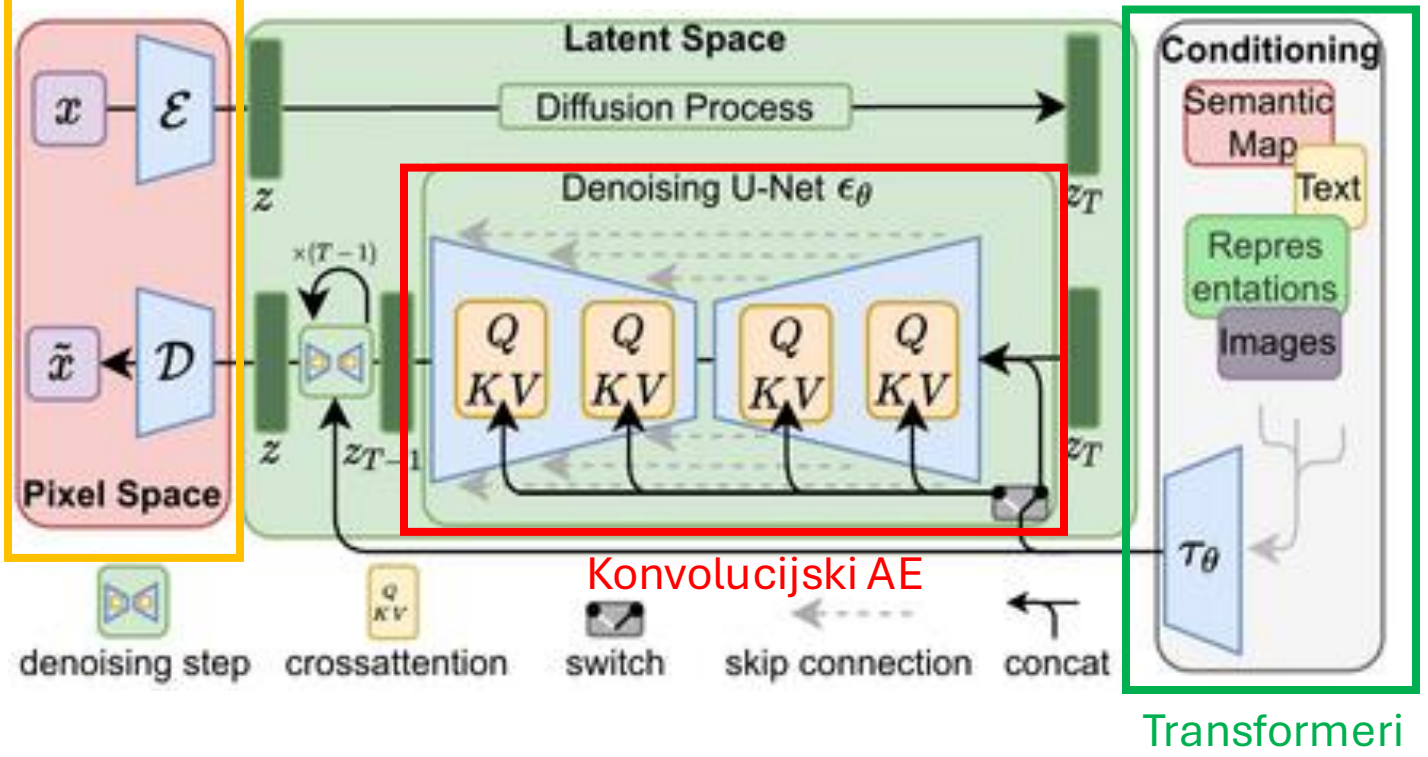


- Primjena: Slično kao RNN kod nizova i teksta (većina NLP modela danas su transformeri)
- U obradi slike (ViT) nemamo induktivnu pristranost kao kod CNN-ova
- Ogromne mreže koje zahtjevaju jako jako puno GPU-ova, ali postižu najbolje rezultate

Kombinacija – Stable Diffusion

Konvolucijski VAE

Difuzija -> Dodavanje šuma u koracima (*Duboko učenje 2*)



Konvolucijski AE

Transformeri

Sažetak

- Duboke mreže - Veći broj slojeva sa nelinearnim neuronima (npr. veći od 10)
- Učenje sa ili bez nadzora
- Hijerarhijska struktura: od jednostavnijih ka složenijim značajkama
- Više slojeva – veća razina apstrakcije
- U nekim zadacima dosegle točnost ljudskih eksperata
- Učestala kritika – koristi se kao crna kutija