# Operacijska istraživanja

3. predavanje: Primjene simpleksne metode

# Rezime simpleksne metode

- efikasna za rješavanje linearnih programa (s milijunima varijabli)
- jedan od rijetkih slučajeva optimizacije u kojem se može pronaći globalni optimum iterativnim lokalnim poboljšanjima
- može biti polazišna točka za rješavanje nelinearnih problema
- moguće je da ne može naći optimum, no to se rijetko događa
- **Fundamentalni teorem**: Svaki LP je izvediv (engl. feasible), neograničen (engl. unbounded) ili neizvediv (engl. infeasible).
  - Ako je LP izvediv, onda ima bazično izvedivo rješenje.
  - Ako LP ima optimlano rješenje, ono je bazično izvedivo.

Operacijska istraživanja
3. predavanje: Primjene simpleksne metode

# Minimizacija

18. listopada 2017.

# Metoda 1: primjer minimizacije

$$\begin{aligned} \textbf{min.} \quad & z = 2x_1 - 3x_2 \\ \text{ako je:} \quad & x_1 + x_2 \leq 4 \\ & x_1 - x_2 \leq 6 \\ & x_1, x_2 \geq 0 \end{aligned}$$

- Rješenje problema je točka $(x_1, x_2)$ u području izvedivosti u kojoj je funkcija **z** minimalna.
- Ekvivalentno, optimalno rješenje problema je točka za koju je funkcija **–z** maksimalna, tj. rješavamo početni problem rješavajući sljedeće:

$$\begin{aligned} \textbf{max.} \quad & -z = -2x_1 + 3x_2 \\ \text{ako je:} \quad & x_1 + x_2 \leq 4 \\ & x_1 - x_2 \leq 6 \\ & x_1, x_2 \geq 0 \end{aligned}$$

# Metoda 1: inicijalna i završna tablica

| -z | $x_1$ | $x_2$ | $s_1$ | $s_2$ | rhs | basic | ratio |
|---|---|---|---|---|---|---|---|
| 1 | 2 | **-3** | 0 | 0 | 0 | -z = 0 | |
| **0** | **1** | **1** | **1** | **0** | **4** | **$s_1$ = 4** | **4/1** |
| 0 | 1 | **-1** | 0 | 1 | 6 | $s_2$ = 6 | neg. |

| -z | $x_1$ | $x_2$ | $s_1$ | $s_2$ | rhs | basic | ratio |
|---|---|---|---|---|---|---|---|
| 1 | 5 | 0 | 3 | 0 | 12 | **-z = 12** | |
| 0 | 1 | 1 | 1 | 0 | 4 | **$x_2$ = 4** | |
| 0 | 2 | 0 | 1 | 1 | 10 | **$s_2$ = 10** | |

- rješenje je točka z = -12, $x_2$= 4, $s_2$= 10

# Metoda 2: primjer minimizacije

**min.** $z = 2x_1 - 3x_2$

ako je: $x_1 + x_2 \leq 4$

$x_1 - x_2 \leq 6$

$x_1, x_2 \geq 0$

- Modifikacija simpleksne metode:

Ako sve nebazične varijable u z-retku imaju nepozitivan koeficijent, onda je trenutno rješenje optimalno.

Ako bilo koja nebazična varijabla u z-retku ima pozitivan koeficijent, odabrati varijablu s 'najpozitivnim' koeficijentom u z-retku za ulazak u bazu.

# Metoda 2: inicijalna i završna tablica

| z | $x_1$ | $x_2$ | $s_1$ | $s_2$ | rhs | basic | ratio |
|---|---|---|---|---|---|---|---|
| 1 | -2 | **3** | 0 | 0 | 0 | z = 0 | |
| **0** | **1** | **1** | **1** | **0** | **4** | **$s_1$ = 4** | **4/1** |
| 0 | 1 | **-1** | 0 | 1 | 6 | $s_2$ = 6 | |

| z | $x_1$ | $x_2$ | $s_1$ | $s_2$ | rhs | basic | ratio |
|---|---|---|---|---|---|---|---|
| 1 | -5 | 0 | -3 | 0 | -12 | **z = -12** | |
| 0 | 1 | 1 | 1 | 0 | 4 | **$x_2$ = 4** | |
| 0 | 2 | 0 | 1 | 1 | 10 | **$s_2$ = 10** | |

- rješenje je točka z = -12, $x_2$= 4, $s_2$= 10

Operacijska istraživanja
3. predavanje: Primjene simpleksne metode

# Metoda velikog M

18. listopada 2017.

# Problem početne baze

- Ako LP ima $\geq$ ili = ograničenja, početno bazično izvedivo rješenje (engl. basic feasible solution, bfs) ne mora biti očito.
- Ako LP ima $\leq$ ograničenja, dodaju se dopunske varijable koje se automatski kvalificiraju za bazične.
- Za $\geq$ ili = ograničenja, dodaju se negativne dopunske varijable koje ne mogu biti u inicijalnoj bazi.
- Uvodi se minimalan broj umjetnih varijabli (engl. artificial variable) da se dobije početno bazično izvedivo rješenje (bfs).

# Postupak rješavanja

- **1. korak:** modificirati ograničenja tako da su sve desne strane nenegativne, te su oblika jednakosti (=) ili nejednakosti (≥)
- **2. korak:** pretvoriti svaku nejdnakost u standardni oblik
- **3. korak:** dodati umjetne varijable (engl. artificial variable) $a_i$ , te ograničenja $a_i \geq 0$
- **4. korak:** Neka je M veliki pozitivni broj, te za problem minimizacije dodati za svaku umjetnu varijablu $Ma_i$ u funkciju cilja odnosno $-Ma_i$ za problem maksimizacije.
- **5. korak:** sve umjetne varijable su u inicijalnoj bazi, te ih treba eliminirati iz z-retka prije početka simpleksne metode.

# Rješenje

- Ako su sve umjetne varijable jednake nuli u optimalnom rješenju, postoji optimalno rješenje originalnog problema.
- Ako je bilo koja umjetna varijabla pozitivna u optimalom rješenju, onda je originalni problem nerješiv (engl. infeasible).

# Primjer metode velikog M

**min.** $z = 2x_1 + 3x_2$

ako je: $1/2x_1 + 1/4x_2 \leq 4$

$x_1 + 3x_2 \geq 20$

$x_1 + x_2 = 10$

$x_1, x_2 \geq 0$

- zahtjev nenegativnosti:

**min.** $z - 2x_1 - 3x_2 = 0$

ako je: $1/2x_1 + 1/4x_2 + s_1 = 4$

$x_1 + 3x_2 - e_1 = 20$

$x_1 + x_2 = 10$

$x_1, x_2, s_1, e_1 \geq 0$

# Uvođenje umjetnih varijabli

**min.** $z - 2x_1 - 3x_2 = 0$

ako je: $1/2x_1 + 1/4x_2 + s_1 = 4$

$x_1 + 3x_2 - e_2 + a_2 = 20$

$x_1 + x_2 + a_3 = 10$

$x_1, x_2, s_1, e_2 \geq 0$

- ovime je postignuto inicijalno bfs: $s_1 = 4$, $a_2 = 20$, $a_3 = 10$.
- uvesti umjetne varijable u funkciju cilja: $z - 2x_1 - 3x_2 - Ma_2 - Ma_3 = 0$
- pomnožiti ograničenja s M:

  $Mx_1 + 3Mx_2 - Me_2 + Ma_2 = 20M$,

  $Mx_1 + Mx_2 + Ma_3 = 10M$, te pribrojiti funkciji cilja

- $z + (2M - 2)x_1 + (4M - 3)x_2 - Me_2 = 30M$

# Inicijalna tablica

| z | $x_1$ | $x_2$ | $s_1$ | $e_2$ | $a_2$ | $a_3$ | rhs | basic | ratio |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 2M – 2 | **4M – 3** | 0 | -M | 0 | 0 | 30M | z = 30M | |
| 0 | 1/2 | **1/4** | 1 | 0 | 0 | 0 | 4 | $s_1$ = 4 | 16 |
| **0** | **1** | **3** | **0** | **-1** | **1** | **0** | **20** | **$a_2$ = 20** | **20/3** |
| 0 | 1 | **1** | 0 | 0 | 0 | 1 | 10 | $a_3$ = 10 | 10 |

- ulazna varijabla: $x_2$
- izlazna varijabla: $a_2$

# Nakon 1. iteracije

| z | $x_1$ | $x_2$ | $s_1$ | $e_2$ | $a_2$ | $a_3$ | rhs | basic | ratio |
|---|---|---|---|---|---|---|---|---|---|
| 1 | **(2M–3)/3** | 0 | 0 | (M-3)/3 | (3-4M)/3 | 0 | (60+10M)/3 | z = (60+ 10M)/3 | |
| 0 | **5/12** | 0 | 1 | 1/12 | -1/12 | 0 | 7/3 | $s_1$ = 7/3 | 28/5 |
| 0 | **1/3** | 1 | 0 | -1/3 | 1/3 | 0 | 20/3 | $x_2$ = 20/3 | 20 |
| **0** | **2/3** | **0** | **0** | **1/3** | **-1/3** | **1** | **10/3** | **$a_3$ = 10/3** | **5** |

- ulazna varijabla: $x_1$
- izlazna varijabla: $a_3$

# Nakon 2. iteracije

| z | $x_1$ | $x_2$ | $s_1$ | $e_2$ | $a_2$ | $a_3$ | rhs | basic |
|---|---|---|---|---|---|---|---|---|
| 1 | 0 | 0 | 0 | -1/2 | (1-2M)/2 | (3-2M)/2 | 25 | **z = 25** |
| 0 | 0 | 0 | 1 | -1/8 | 1/8 | -5/8 | 1/4 | **$s_1$ = 1/4** |
| 0 | 0 | 1 | 0 | -1/2 | 1/2 | -1/2 | 5 | **$x_2$ = 5** |
| 0 | 1 | 0 | 0 | 1/2 | -1/2 | 3/2 | 5 | **$x_1$ = 5** |

- optimalno rješenje: $z = 25$, $x_1 = x_2 = 5$, $s_1 = 1/4$
- umjetne varijable napustile su bazu