PPKS 01: Generiranje i operacije nad signalima u Pythonu

Signali

Signali opisuju promjenu neke fizičke vrijednosti u vremenu i/ili prostoru.

Na primjer, promjena visine tla u nekoj točki je signal u vremenu, a promjena intenziteta piksela nekog retka u slici je signal u prostoru. Primjer signala koji se mijenja u vremenu i prostoru je redak jednog okvira (eng. frame) u videu. Električni signali predstavljaju promjene električnih veličina (npr. struje i napona). Za njih kažemo da su temeljni nosioci informacija jer se informacija, koja je izvorno bila u nekom drugom, neelektričnom obliku (npr. temperatura i zvuk) pretvara u električni kako bi se uspješno prenijela kroz komunikacijski sustav.

Signal se matematički definira kao funkcija koja ovisi o jednoj ili više varijabli, najčešće vremenu. Razlikujemo periodične i aperiodične signale. Kod periodičnih se određeni uzorak ponavlja u pravilnim intervalima, a neki od primjera su sinusni, kosinusni i pilasti signal te pulsni niz. Odnosno, za signal kažemo da je periodičan ako vrijedi $x(t) = x(t \pm T)$ gdje je T vremenski period u kojem se signal ponavlja.

Sinusni signal koji se kreće u vremenu t definiramo pomoću:

- amplitude A (najveći otklon od ravnotežnog položaja),
- frekvencije f (broj oscilacija signala u jednoj sekundi) i
- početne faze ϕ (fazni pomak signala u trenutku $t = 0$):

$$sinusni\_signal = A \sin(2\pi f t + \phi)$$

Sinusni signal može se interpretirati kao projekcija točke koja se jednoliko giba po kružnici na jednu os. Zbog toga se takvi signali često opisuju pomoću kutne frekvencije ω. **Kutna frekvenija** predstavlja brzinu promjene faznog kuta signala, odnosno koliko se faza signala promijeni u jednoj sekundi. Mjeri se u radijanima po sekundi (rad/s) i povezana je s frekvencijom izrazom: $\omega = 2\pi f$ što znači da jedan period signala odgovara promjeni faze od 2π radijana.

U programskom jeziku sinusni signal možemo generirati i prikazati u četiri koraka:

1. definiranje nezavisne varijable (vrijeme t)
2. definiranje parametara signala (amplituda, frekvencija, početna faza)
3. generiranje sinusoidalnog signala korištenjem biblioteke Numpy
4. prikaz generiranog signala pomoću biblioteke Matplotlib.

In [4]:

```
import numpy as np  # Učitaj biblioteku za numeričke operacije
import matplotlib.pyplot as plt  # Učitaj biblioteku za iscrtavanje

# 1. definiranje nezavisne varijable (Generiranje vremenske osi)
trajanje = 1.0  # Trajanje signala u sekundama
frekvencija_uzorkovanja = 1000  # Frekvencija uzorkovanja u Hz
vrijeme = np.linspace(0, trajanje, int(frekvencija_uzorkovanja * trajanje), endpoint=

# 2. definiranje parametara signala
amplituda = 1.0  # Amplituda signala
frekvencija = 5  # Frekvencija sinusnog signala u Hz
pocetna_faza = 0 # Početna faza signala

# 3. generiranje sinusnog signala
sinusni_signal = amplituda * np.sin(2 * np.pi * frekvencija * vrijeme + pocetna_faza)


# 4. prikaz generiranog signala
plt.figure()
plt.plot(vrijeme, sinusni_signal, label=f'Sinusni signal {frekvencija} Hz')  # Crtanj
plt.xlabel('Vrijeme [s]')  # Oznaka x-osi
plt.ylabel('Amplituda [V]')  # Oznaka y-osi
plt.title('Generirani sinusni signal')
plt.legend()
plt.grid(True)
plt.show()
```

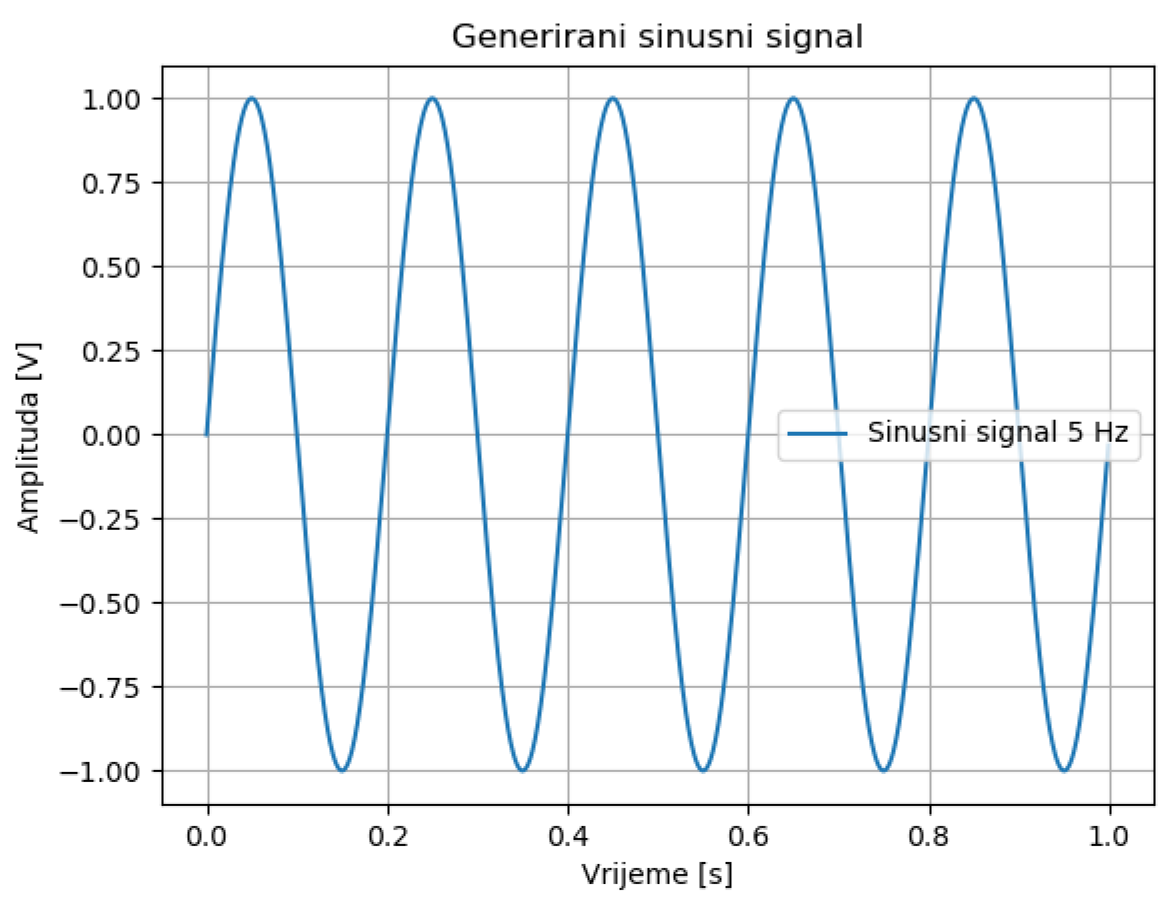

Eulerova formula

U obradi signala sinusni i kosinusni signali imaju vrlo važnu ulogu jer se mnogi signali mogu predstaviti kao zbroj sinusnih komponenti različitih frekvencija. Takav prikaz omogućuje analizu složenih signala u frekvencijskoj domeni.

Zbog toga je korisno imati matematički zapis koji pojednostavljuje rad s takvim signalima. Upravo to omogućuje Eulerova formula, koja povezuje trigonometrijske funkcije (sinus i kosinus) i kompleksnu eksponencijalnu funkciju:

$$e^{j\phi} = \cos(\phi) + j\sin(\phi)$$

gdje je ϕ fazni kut izražen u radijanima.

Ako uzmemo i kompleksno konjugirani izraz $e^{-j\phi} = \cos(\phi) - j\sin(\phi)$ možemo dobiti izraze za kosinus i sinus pomoću eksponencijalnih funkcija: $\cos(\phi) = \frac{e^{j\phi}+e^{-j\phi}}{2}$

$$\sin(\phi) = \frac{e^{j\phi}-e^{-j\phi}}{2j}$$

To znači da kosinus možemo promatrati kao srednju vrijednost dviju kompleksnih eksponencijalnih funkcija suprotnih faza, a da je sinus proporcionalan razlici dviju kompleksnih eksponencijalnih funkcija suprotnih faza.

Zašto je to važno?

Kompleksne eksponencijalne funkcije imaju jednostavna matematička svojstva. Deriviranje, integriranje i množenje svodi se na jednostavne algebarske operacije nad eksponentima pa su zbog toga te funkcije temelj mnogih metoda u obradi signala. Jedna od njih je **Fourierova transformacija** kojom ćemo se baviti kasnije.

Diskretizacija i kvantizacija signala

Kontinuirani signali definirani su za svaki trenutak u vremenu i mogu poprimiti bilo koju vrijednost unutar određenog raspona. Primjer takvog signala je analogni audio signal koji predstavlja zvučne valove kao neprekidnu funkciju vremena. U zapisu kontinuiranog signala koristimo oble zagrade: $x(t)$.

Diskretni signali, s druge strane, definirani su samo u određenim, diskretnim trenucima vremena. Vrijednosti između tih trenutaka nisu definirane. Primjer diskretnog signala je digitalni audio zapis gdje se uzimaju uzorci analognog signala u pravilnim intervalima, a svaki uzorak predstavlja vrijednost signala u tom trenutku. U zapisu diskretnog signala koristimo indeksni zapis s uglatim zagradama: $x[n]$ (n predstavlja indeks uzorka, a ne vrijeme).

Prilikom pretvaranja analognog signala u digitalni oblik prolazimo kroz dva ključna procesa: diskretizaciju i kvantizaciju. Ova dva procesa omogućuju obradu signala na računalima i drugim digitalnim sustavima.

Diskretizacija je proces uzorkovanja kontinuiranog signala u diskretnim vremenskim točkama. To znači da uzimamo uzorke signala u pravilnim vremenskim intervalima.

Ako imamo kontinuirani signal $x(t)$, diskretizirani signal dobivamo uzorkovanjem s periodom uzorkovanja T_s:

$$x[n] = x(nT_s), n \in \mathbb{Z}$$

gdje je T_s period uzorkovanja (obrnuto proporcionalno od frekvencije uzorkovanja, odnosno $f_s = 1/T_s$).

Prema **Nyquist-Shannonovom teoremu uzorkovanja**, frekvencija uzorkovanja mora biti barem dvostruko veća od najveće frekvencije u signalu kako bi se izbjegao aliasing (gubitak informacija zbog nedovoljno čestog uzorkovanja). Dakle, ako signal $x(t)$ sadrži samo frekvencije do f_{max}, tada frekvencija uzorkovanja mora biti:

$$f_s \geq 2f_{max}$$

Kvantizacija je proces zaokruživanja amplitudnih vrijednosti u diskretiziranim uzorcima signala na najbližu vrijednost iz ograničenog skupa mogućih vrijednosti (na najbližu kvantizacijsku razinu).

Kvantizacija može biti:

- Uniformna – jednaki razmaci između razina kvantizacije,
- Neuniformna – različiti razmaci (češće se koristi u obradi govora).

Mjerilo kvalitete kvantizacije je kvantizacijska pogreška: $e_q[n] = x[n] - x_q[n]$. Kvantizacijska pogreška ponaša se poput dodatnog kvantizacijskog šuma, koji može uzrokovati izobličenja signala.

Kombinacija diskretizacije i kvantizacije naziva se **analogno-digitalna pretvorba** (A/D pretvorba).

In [101…

```
import numpy as np
import matplotlib.pyplot as plt

# Parametri za diskretizaciju i uzorkovanje
fs_disc = 100    # Frekvencija uzorkovanja (diskretizacija)
num_levels = 16 # Broj razina kvantizacije

# Generiranje kontinuiranog signala
fs_cont = 1000  # Signal izgleda kao kontinuirani (i dalje je samo niz točaka)
t_cont = np.linspace(0, 1, fs_cont)  # nezavisna varijabla
signal_cont = np.sin(2 * np.pi * 5 * t_cont)  # Sinusni signal od 5 Hz

# Diskretizacija signala
t_disc = np.arange(0, 1, 1/fs_disc)  # Diskretne vremenske točke
signal_disc = np.sin(2 * np.pi * 5 * t_disc)

# Kvantizacija signala
q_step = 2 / num_levels  # Veličina kvantizacijskog koraka (raspon -1 do 1)
signal_quant = np.round(signal_disc / q_step) * q_step  # Kvantizacija

# Grafički prikaz rezultata
plt.figure(figsize=(10,8))

# Prikaz kontinuiranog signala
plt.plot(t_cont, signal_cont, label="Kontinuirani signal", linestyle="dashed", alpha=

# Prikaz diskretiziranog signala
plt.scatter(t_disc, signal_disc, color="red", label="Diskretizirani uzorci")

# Prikaz kvantiziranog signala
plt.step(t_disc, signal_quant, where="mid", color="green", label="Kvantizirani signal"

plt.xlabel("Vrijeme (s)")
plt.ylabel("Amplituda")
plt.title("Diskretizacija i kvantizacija sinusnog signala")
plt.legend()
plt.grid()
plt.show()
```

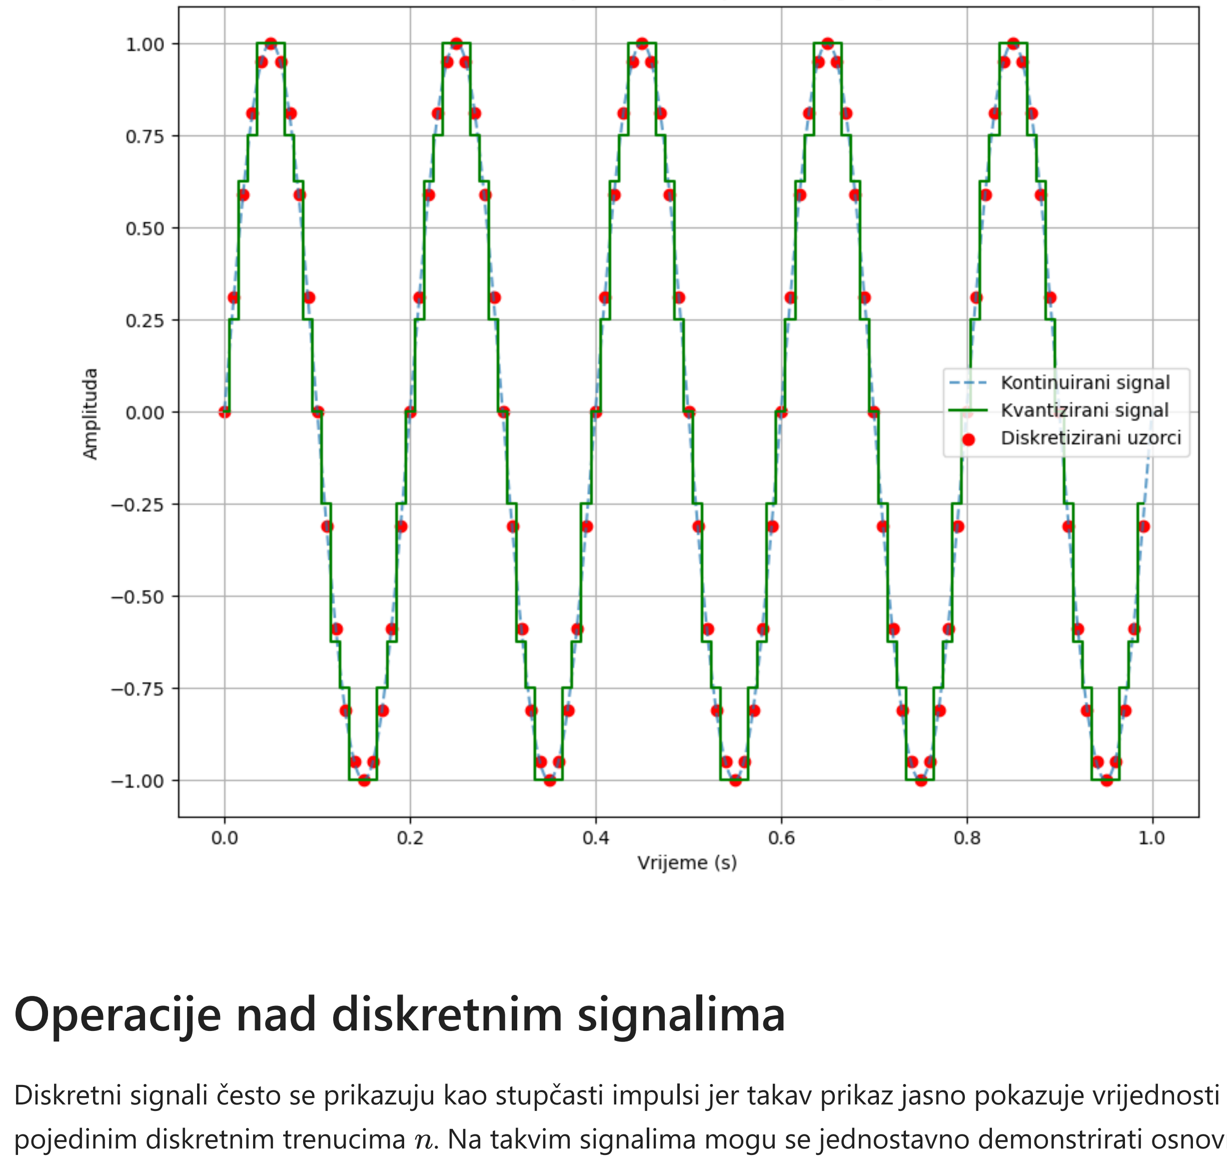

Operacije nad diskretnim signalima

Diskretni signali često se prikazuju kao stupčasti impulsi jer takav prikaz jasno pokazuje vrijednosti signala u pojedinim diskretnim trenucima n. Na takvim signalima mogu se jednostavno demonstrirati osnovne operacije koje se često koriste u obradi signala.

1. **Zrcaljenje** (engl. Flipping)

Zrcaljenje signala obrće redoslijed uzoraka oko ishodišta $n = 0$. Drugim riječima, uzorci koji su bili desno od nule premještaju se lijevo, i obrnuto: $x[n] \rightarrow x[-n]$

Ako je signal imao vrijednost $x[3]$, nakon zrcaljenja ta vrijednost se pojavljuje u trenutku $n = -3$. Ova operacija je posebno važna kod izračuna konvolucije diskretnih signala, gdje se jedan od signala najprije zrcali, a zatim pomiče kroz drugi signal.

1. **Skaliranje** (engl. Scaling)

Skaliranje mijenja vremensku skalu signala, odnosno razmak između uzoraka:

$$x[n] \rightarrow x[kn]$$

gdje je k faktor skaliranja.

- Ako je $k > 1$ signal se komprimira (sažima) u vremenu jer se uzorci efektivno približavaju. Dolazi do gubitka dijela informacija.
- Ako je $0 < k < 1$ signal se rasteže u vremenu jer se razmak između uzoraka povećava.

1. **Pomak** (engl. Shifting)

Pomak signala znači pomicanje signala lijevo ili desno po osi indeksa n. Ova operacija se često koristi za modeliranje kašnjenja ili ubrzavanja signala: $x[n] \rightarrow x[n-k]$

gdje je k broj uzoraka za koji se signal pomiče.

- Ako je $k > 0$ signal se pomiče udesno, što predstavlja kašnjenje signala.
- Ako je $k < 0$ signal se pomiče ulijevo, što znači da se signal pojavljuje ranije.

Na primjer, ako je $x[n] \rightarrow x[n-2]$ signal se pomiče za dva uzorka udesno, odnosno svaki uzorak pojavljuje se dva koraka kasnije.